UNIVERSIDADE AGOSTINHO NETO

FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga

Engenheiro Eletrotécnico

Dissertação para obtenção do Grau de Mestre em

Engenharia e Ciência de Dados

Orientador Científico:

Joaquim Fortes Doutor

Co-Orientador

Judice Cumbunga Doutor

Luanda

2026

UNIVERSIDADE AGOSTINHO NETO

FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga

Engenheiro Eletrotécnico

Dissertação para obtenção do Grau de Mestre em

Engenharia e Ciência de Dados

Orientador Científico:

Joaquim Fortes Doutor

Co-Orientador

Judice Cumbunga Doutor

Luanda 2026

FICHA CATALOGRÁFICA

Exemplo

Muinga, Manuel

Monitoramento Inteligente de Ameaças em Redes Sociais em Angola para o Apoio à Defesa e Segurança Nacional / Manuel Muinga. — Luanda: Universidade Agostinho Neto, Faculdade de Engenharia, 2026.

61 p.; il.; 30 cm.

Dissertação de Mestrado em Engenharia e Ciência de Dados — Faculdade de Engenharia, Universidade Agostinho Neto, Luanda, 2026.

1. Redes Sociais. 2. Monitoramento de Ameaças. 3. Inteligência Artificial. 4. OSINT. 5. Segurança Nacional. 6. PLN. I. Juaquim Fortes. II. Título.

CDU: [Código CDU]

Permitida a reprodução total ou parcial deste documento, desde que citada a fonte e sem carácter comercial — O Manuel Muinga.

EPÍGRAFE

"A informação é a moeda do século XXI. Quem a controla, controla o futuro."

— Adaptado de Peter Drucker

DEDICATÓRIA

À minha querida esposa, **Rosalina Muinga**, cuja presença ilumina cada etapa da minha vida. Este trabalho é dedicado a ti, pelo amor, paciência e apoio incondicional que sempre me ofereceste. A tua força e compreensão foram fundamentais para que eu pudesse chegar até aqui. Que esta conquista seja também um reflexo da nossa caminhada conjunta, marcada por fé, perseverança e esperança.

AGRADECIMENTOS

Tenho a honra de expressar os meus mais sinceros agradecimentos ao meu orientador, pela orientação científica, disponibilidade e rigor académico que tornaram possível a realização desta dissertação.

À Universidade Agostinho Neto e à Faculdade de Engenharia, pela sólida formação académica e pelo ambiente científico que proporcionaram ao longo desta jornada.

À minha família e amigos, pelo apoio incondicional, paciência e encorajamento, que foram fundamentais para superar os desafios e alcançar esta etapa.

Às **Forças Armadas Angolanas**, instituição que financiou a minha formação, pelo investimento e pela confiança depositada.

Ao **Comando da Brigada de Forças Especiais**, pela confiança, apoio institucional e pelo incentivo constante ao meu desenvolvimento académico e profissional.

Um agradecimento especial a **Sua Excelência Tenente General Tussen**, cujo incentivo e motivação foram decisivos para que eu pudesse frequentar este curso e concretizar este trabalho.

Aos colegas investigadores e a todos os que, de forma direta ou indireta, contribuíram para a realização desta dissertação, manifesto a minha profunda gratidão.

AUTORIZAÇÃO INSTITUCIONAL DO PROJECTO

RESUMO

As redes sociais consolidaram-se como vetores estratégicos de ameaças à segurança nacional, incluindo desinformação, discurso de ódio, radicalização em linha e mobilização hostil. Em Angola, onde o número de utilizadores de redes sociais supera os 5,5 milhões em 2026 (DataReportal, 2026), as estruturas de segurança do Estado carecem de ferramentas automatizadas para detetar e analisar estas ameaças em tempo real. O presente trabalho propõe o desenvolvimento de um sistema de monitoramento inteligente baseado em inteligência artificial e grandes volumes de dados, utilizando uma arquitectura de inteligência de fontes abertas (OSINT) assente em scrapers assíncronos — Scrapy, Playwright, Telethon e yt-dlp —, sem dependência de interfaces de programação pagas. O sistema classifica ameaças em quatro categorias usando os modelos BERT (BERTimbau) e Bi-LSTM, gerando alertas automáticos. Os resultados demonstram que o BERT alcança um F1-score de 91% e o Bi-LSTM de 87%, com tempo médio de deteção de 47 segundos e antecedência média de 76 horas. O trabalho inclui um painel de controlo interativo em Power BI com alertas automáticos via Power Automate e contribui para o fortalecimento da soberania digital angolana.

Palavras-chave: Monitoramento de ameaças; Redes sociais; Inteligência artificial; OSINT; Segurança Nacional; Processamento de Linguagem Natural.

ABSTRACT

Social networks have consolidated themselves as strategic vectors of national security threats, including disinformation, hate speech, online radicalization, and hostile mobilization. In Angola, where social media users exceed 5.5 million in 2026, State security structures lack automated tools to detect and analyze these threats in real time. This work proposes the development of an intelligent monitoring system based on artificial intelligence and big data, using an Open Source Intelligence (OSINT) architecture built on asynchronous scrapers — Scrapy, Playwright, Telethon and yt-dlp — without dependence on paid APIs. The system classifies threats into four categories using BERT (BERTimbau) and Bi-LSTM models, generating automatic alerts. Results show BERT achieves an F1-score of 91% and Bi-LSTM of 87%, with an average detection time of 47 seconds and an average alert lead time of 76 hours. The work includes an interactive Power BI dashboard with automatic alerts via Power Automate and contributes to strengthening Angola's digital sovereignty.

Keywords: threat monitoring; social networks; artificial intelligence; OSINT; national security; natural language processing.

ABREVIATURAS, SIGLAS E ACRÓNIMOS

Sigla / Acrónimo	Designação
ARS	Análise de Redes Sociais (= SNA em inglês)
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
BERT	Bidirectional Encoder Representations from Transformers
DAX	Data Analysis Expressions (linguagem Power BI)
ETL	Extract, Transform, Load
GDPR	General Data Protection Regulation (UE)
IA	Inteligência Artificial
LSTM	Long Short-Term Memory
ML	Machine Learning (Aprendizagem Automática)
NER	Named Entity Recognition
OSINT	Open Source Intelligence (Inteligência de Fontes Abertas)
PLN	Processamento de Linguagem Natural (= NLP em inglês)
Power BI	Power Business Intelligence (Microsoft)
SADC	Southern African Development Community
SHA-256	Secure Hash Algorithm 256 bits
SMOTE	Synthetic Minority Oversampling Technique
SNA	Social Network Analysis (= ARS em português)
SOCMINT	Social Media Intelligence
SVM	Support Vector Machine (Máquina de Vectores de Suporte)
UAN	Universidade Agostinho Neto
UML	Unified Modeling Language
URL	Uniform Resource Locator
yt-dlp	YouTube Download (ferramenta OSINT de código aberto)

ÍNDICE GERAL

Nota: Actualizar este índice no Word após a inserção final: Referências → Índice → Actualizar Índice.

FICHA CATALOGRÁFICA iii

EPÍGRAFE iv

DEDICATÓRIA v

AGRADECIMENTOS vi

AUTORIZAÇÃO INSTITUCIONAL vii

RESUMO viii

ABSTRACT ix

ABREVIATURAS, SIGLAS E ACRÓNIMOS x

ÍNDICE GERAL xi

ÍNDICE DE TABELAS xiii

ÍNDICE DE FIGURAS xiv

CAPÍTULO 1 – INTRODUÇÃO 1

1.1 Contextualização 1

1.2 Justificativa 2

1.3 Problema de Pesquisa 3

1.4 Hipóteses de Investigação 3

1.5 Objetivo Geral 3

1.6 Objetivos Específicos 4

1.7 Estrutura do Trabalho 4

CAPÍTULO 2 – REVISÃO DA LITERATURA 5

2.1 Redes Sociais: Conceito, Evolução e Dimensão Securitária 5

2.2 Monitoramento de Ameaças em Redes Sociais 6

2.3 Estado da Arte em Sistemas de Monitoramento 7

2.4 Teoria dos Grafos Sociais Aplicada ao Monitoramento 8
2.5 Algoritmos de Aprendizagem Automática 9
2.6 Processamento de Linguagem Natural 10
2.7 Aspectos Éticos e Legais 10
CAPÍTULO 3 – METODOLOGIA 11
3.1 Paradigma e Design da Investigação 11
3.2 Conformidade Ética 11
3.3 Caracterização do Corpus de Dados 12
3.4 Arquitectura OSINT — Scrapers Assíncronos 13
3.5 Pré-processamento PLN 15
3.6 Modelos de Inteligência Artificial 15
3.7 Arquitectura do Sistema 17
3.8 Painel de Controlo Power BI 17
3.9 Diagramas UML 19
3.10 Plano de Testes 19
3.11 Análise de Custos e Viabilidade 20
3.12 Plano de Implementação Faseada 20
CAPÍTULO 4 – RESULTADOS E DISCUSSÃO 21
4.1 Resultados dos Modelos de Aprendizagem Automática 21
4.2 Resultados por Categoria de Ameaça 22
4.3 Resultados — Viés Linguístico (H4) 23
4.4 Resultados — Eficácia do Sistema de Alertas (H2, H3) 23
4.5 Casos de Estudo Concretos 24
4.6 Discussão dos Resultados 24
CAPÍTULO 5 – CONCLUSÃO E RECOMENDAÇÕES 27
5.1 Síntese e Verificação dos Objetivos 27
5.2 Contributos da Investigação 28
5.3 Limitações 28

5.4 Recomendações e Trabalhos Futuros 29
REFERÊNCIAS BIBLIOGRÁFICAS 30
GLOSSÁRIO 38
APÊNDICE A – Excertos de Código-Fonte Python (OSINT) 40
APÊNDICE B – Guia de Anotação Padronizado 42
APÊNDICE C – Tabela de Acordo entre Anotadores 46
APÊNDICE D – Declaração de Consentimento 48
APÊNDICE E – Amostra Anotada do Corpus 49
CONTRACAPA ..... —

ÍNDICE DE TABELAS

Nota: Gerar automaticamente no Word: Referências → Inserir Índice de Ilustrações → Tipo: Tabela.

Tabela 1.1 – Evolução dos Utilizadores de Redes Sociais em Angola (2015–2026) 1

Tabela 2.1 – Estado da Arte: Sistemas de Monitoramento de Ameaças em Redes Sociais 7

Tabela 2.2 – Comparação dos Algoritmos de Aprendizagem Automática Utilizados 9

Tabela 3.1 – Composição do Corpus de Dados por Plataforma e Categoria 12

Tabela 3.2 – Fontes OSINT Monitoradas e Ferramentas de Recolha 13

Tabela 3.3 – Ambiente de Desenvolvimento e Dependências Principais (Windows 10/11) 15

Tabela 3.4 – Estimativa de Custos de Implementação Anual em Angola 20

Tabela 3.5 – Roadmap de Implementação Faseada do Sistema 20

Tabela 4.1 – Comparação de Desempenho dos Modelos no Conjunto de Teste 21

Tabela 4.2 – F1-Score por Categoria de Ameaça e Modelo (%) 22

Tabela 4.3 – Casos de Estudo: Exemplos de Classificação pelo Sistema 24

Tabela 4.4 – Sistema OSINT + Power BI vs. Monitoramento Tradicional 25

Tabela 5.1 – Verificação dos Objetivos Específicos 27

ÍNDICE DE FIGURAS

Nota: Gerar automaticamente no Word: Referências → Inserir Índice de Ilustrações → Tipo: Figura.

Figura 3.1 – Arquitectura OSINT com Scrapers Assíncronos (5 camadas) 14

Figura 3.2 – Pipeline de Processamento: Da Publicação ao Alerta Power BI ... 16

Figura 3.3 – Painel de Controlo Power BI — Centro de Comando 18

Figura 3.4 – Modelo Estrela do Armazém de Dados (AmeacasAngola_DW) 18

Figura 3.5 – Diagrama de Casos de Uso (UML) 19

Figura 3.6 – Diagrama de Sequência (UML): Publicação → BERT → Alerta 19

Figura 4.1 – Curvas ROC Comparativas dos Quatro Modelos 21

Figura 4.2 – Matrizes de Confusão (4×4): BERT, Bi-LSTM, RF e SVM 22

Figura 4.3 – Evolução dos Indicadores de Risco (Agosto 2025 — Retroanálise) 23

CAPÍTULO 1 – INTRODUÇÃO

1.1 Contextualização

A Internet, nascida nos anos 1960 no contexto da Guerra como projecto ARPANET, evoluiu para a World Wide Web em 1990 e transformou-se no principal ecossistema de comunicação da humanidade. Em Angola, os primeiros passos da Internet ocorreram no final dos anos 1990, através do projeto Angonet da Development Workshop. A expansão acelerou a partir de 2005 com a proliferação dos serviços móveis e, em 2026, o país regista mais de 12 milhões de utilizadores de Internet e 5,5 milhões de utilizadores ativos de redes sociais — um crescimento de 340% face a 2015, como evidência a Tabela 1.1.

Tabela 1.1 – Evolução dos Utilizadores de Redes Sociais em Angola (2015–2026)

Ano	Utilizadores Internet (M)	Utilizadores Redes Sociais (M)	Penetração (%)
2015	1,8	1,2	6,5
2017	3,0	2,1	10,2
2019	5,2	3,1	16,7
2021	8,5	4,2	26,1
2023	10,8	5,0	32,4
2026	12,0+	5,5+	35,8

Fontes: DataReportal (2026); We Are Social (2024). Valores de 2026 são estimativas.

Este crescimento, embora represente um avanço na democratização da informação, introduz novos vectores de ameaça à segurança nacional. Os eventos de agosto de 2025 em Angola — durante os quais conteúdos gerados por inteligência artificial foram amplamente difundidos para incitar à violência — revelaram a vulnerabilidade estratégica das estruturas de segurança nacionais face à velocidade e complexidade das ameaças digitais contemporâneas (Hassane, 2021; Mazzo, 2025; Cintra, 2025).

1.2 Justificativa

Em Angola, o monitoramento das redes sociais é realizado de modo predominantemente manual e reativo, revelando-se estruturalmente insuficiente face ao volume e complexidade dos dados gerados diariamente. Esta lacuna compromete a soberania informacional do Estado e expõe o país a vulnerabilidades crescentes. A

arquitectura proposta adopta uma abordagem de inteligência de fontes abertas (OSINT — Open Source Intelligence) com scrapers assíncronos, eliminando a dependência de interfaces de programação pagas e garantindo a sustentabilidade e replicabilidade do sistema (Monaco & Arnaudo, 2020; Mazzo, 2025).

1.3 Problema de Pesquisa

> *De que forma um sistema baseado em Inteligência Artificial, grandes volumes de dados e inteligência de fontes abertas (OSINT) pode monitorar ameaças em redes sociais no contexto angolano e fornecer informações estratégicas para a defesa e segurança nacional de forma eficaz, ética e em tempo real?*

1.4 Hipóteses de Investigação

A investigação formula as seguintes hipóteses científicas testáveis, verificadas no Capítulo 4:

- H1: Os modelos de aprendizagem profunda (BERT e Bi-LSTM) apresentam desempenho superior aos modelos clássicos (SVM e floresta aleatória) na deteção de ameaças em textos em português angolano.
- H2: O sistema proposto reduz o tempo médio de deteção de ameaças em mais de 90% comparativamente ao monitoramento manual tradicional.
- H3: O sistema é capaz de detetar padrões de risco emergentes com pelo menos 48 horas de antecedência relativamente ao momento em que esses riscos se materializam em eventos de segurança documentados.
- H4: O desempenho dos modelos de deteção de ameaças degrada-se significativamente quando aplicados a publicações em calão urbano angolano ou em línguas nacionais (Kimbundu, Kikongo, Umbundu), evidenciando a necessidade de adaptação linguística específica ao contexto angolano.

1.5 Objetivo Geral

Desenvolver um sistema de monitoramento inteligente baseado em inteligência artificial, grandes volumes de dados e inteligência de fontes abertas (OSINT), adaptado à realidade digital e linguística angolana, para identificar, classificar e antecipar ameaças em redes sociais, com visualização em tempo real através de um painel de controlo interativo em Power BI.

1.6 Objetivos Específicos

1. Implementar uma arquitectura OSINT com scrapers assíncronos (Scrapy, Playwright, Telethon, yt-dlp) para recolher dados publicamente disponíveis das principais plataformas sociais angolanas, sem dependência de interfaces de programação pagas;
2. Comparar quatro algoritmos de aprendizagem automática — SVM, floresta aleatória, Bi-LSTM e BERT/BERTimbau — para classificação automática de conteúdos ameaçadores, validando estatisticamente as hipóteses H1 e H4;
3. Aplicar técnicas de processamento de linguagem natural para análise de textos em português angolano, incluindo normalização de calão urbano e expressões em línguas nacionais (Kimbundu, Kikongo, Umbundu);
4. Desenvolver um painel de controlo em Power BI com visualização interativa em tempo real, incluindo alertas automáticos via Power Automate e mapa de ameaças por província;
5. Propor diretrizes éticas e legais para a utilização responsável de sistemas de IA no monitoramento digital nacional, compatíveis com a Lei n.º 22/11 de Protecção de Dados Pessoais de Angola.

1.7 Estrutura do Trabalho

O presente trabalho está organizado em cinco capítulos. O Capítulo 1 contextualiza a problemática e define os objectivos, hipóteses e justificativa. O Capítulo 2 desenvolve a revisão da literatura, incluindo o estado da arte e os fundamentos teóricos. O Capítulo 3 descreve a metodologia, com especial enfoque na arquitectura OSINT e nos scrapers assíncronos. O Capítulo 4 apresenta os resultados e a discussão, com verificação das quatro hipóteses. O Capítulo 5 conclui o trabalho e propõe recomendações. O pós-texto inclui as Referências Bibliográficas em norma APA, o Glossário e cinco Apêndices.

CAPÍTULO 2 – REVISÃO DA LITERATURA

2.1 Redes Sociais: Conceito, Evolução e Dimensão Securitária

2.1.1 Conceito e Evolução

Boyd e Ellison (2007) definem os sítios de redes sociais como serviços baseados na Web que permitem a indivíduos construir um perfil público ou semipúblico, articular uma lista de outros utilizadores com quem partilham uma ligação, e percorrer essa lista dentro do sistema. Esta definição seminal continua a ser a mais citada na literatura científica. A análise de sentimentos e a mineração de dados em redes sociais constituem, desde meados da década de 2000, um campo de investigação multidisciplinar com crescente relevância para a segurança (Benevenuto et al., 2015; Freire, 2015). A evolução organiza-se em três fases: fase pioneira (1997–2003), com o SixDegrees, o Friendster, o LinkedIn e o MySpace; fase de expansão (2003–2010), marcada pelo Facebook (2004) e pelo Twitter (2006); e fase da mobilidade (2010–presente), dominada pelo Instagram, pelo Snapchat e pelo TikTok. Em 2024, existem mais de 5,04 mil milhões de utilizadores de redes sociais no mundo, representando 62% da população global (We Are Social, 2024

2.1.2 Contexto Digital Angolano

O utilizador angolano de redes sociais é predominantemente jovem (64% entre 18 e 34 anos), urbano (78% nas províncias de Luanda, Benguela e Huíla) e acede via telemóvel (91%). O Facebook lidera com 5,5 milhões de utilizadores, seguido pelo WhatsApp, TikTok, Instagram e X/Twitter. A campanha "2022 Vais Gostar" (Hassane, 2021) e os protestos de agosto de 2025 são casos documentados de exploração maliciosa das redes sociais em Angola, tendo este último envolvido conteúdos sintéticos gerados por inteligência artificial. A influência das redes sociais na mobilização de jovens, incluindo em contextos infracionais, constitui uma preocupação crescente nos países lusófonos (Lopes et al., 2025; Marcon, 2019; Sambaca & Pessoa, 2026).

2.2 Monitoramento de Ameaças em Redes Sociais

Para Monaco e Arnaudo (2020), o monitoramento de ameaças insere-se no campo da inteligência de fontes abertas (OSINT), que compreende a recolha e análise sistemática de informações publicamente disponíveis. A OSINT distingue-se de outras formas de inteligência por não requerer acesso a dados classificados ou a comunicações privadas, sendo particularmente adequada para o monitoramento digital em contextos com recursos limitados (NATO, 2016; Mazzo, 2025). As cinco categorias de ameaças identificadas no contexto angolano são:

- Desinformação e notícias falsas: conteúdos deliberadamente falsos com intenção de causar dano público (UNESCO, 2019; Vogt, 2023).
- Discurso de ódio e radicalização em linha: comunicação que promove discriminação ou violência, com potencial de escalada para terrorismo (Conselho da Europa, 2022; Chuy, 2025; Elias, 2019; Fernandes Brigas et al., 2018).
- Mobilização hostil: organização de acções violentas através de plataformas digitais (Hassane, 2021; Sette Câmara, 2016).
- Cibercrime e fraudes digitais: ataques de phishing, roubo de identidade e extorsão.
- Manipulação por inteligência artificial generativa: conteúdos sintéticos (deepfakes) documentados em Angola em agosto de 2025 (Cintra, 2025).

2.3 Estado da Arte em Sistemas de Monitoramento

A Tabela 2.1 apresenta uma análise comparativa dos principais sistemas internacionais de monitoramento de ameaças, evidenciando a lacuna que o presente sistema se propõe colmatar no contexto angolano.

Tabela 2.1 – Estado da Arte: Sistemas de Monitoramento de Ameaças em Redes Sociais

Sistema	Organização	Tecnologia	Capacidades	Limitações
DARPA MediFor	DARPA/EUA	Aprendizagem profunda	Deteção de deepfakes	Foco no inglês; proprietário
EU DisinfoLab	UE/ONG	Grafos sociais, OSINT	65 países	Sem tempo real; sem português angolano
Palantir Gotham	NATO	Big Data, ML	Análise preditiva	Custo elevado; proprietário
AFRIPOL OSINT	União Africana	Ferramentas abertas	Cobertura africana	Escala limitada; sem PLN
Sistema Proposto	UAN/Angola	BERT, OSINT, PySpark	PLN angolano; Power BI	Em desenvolvimento

Fonte: Elaboração própria com base em revisão da literatura.

2.4 Teoria dos Grafos Sociais Aplicada ao Monitoramento

A Análise de Redes Sociais (ARS) permite mapear entidades e relações para identificar padrões de difusão de ameaças. As métricas de centralidade de grau, intermediação e densidade são fundamentais para a detecção de redes de contas falsas e campanhas coordenadas de desinformação (Thelwall, 2009; Freire, 2015; Benevenuto et al., 2015).

2.5 Algoritmos de Aprendizagem Automática

A Tabela 2.2 apresenta uma comparação sistemática dos quatro algoritmos utilizados, fundamentando as escolhas metodológicas realizadas no Capítulo 3.

Tabela 2.2 – Comparação dos Algoritmos de Aprendizagem Automática Utilizados

Algoritmo	Paradigma	Vantagens	Limitações	Adequação
SVM	Supervisionado	Alta dimensionalidade	Sem contexto semântico	Baseline robusto
Floresta Aleatória	Ensemble	Resistente ao sobreajuste	Sem análise semântica	Identificação de atributos
Bi-LSTM	Aprendizagem profunda	Padrões temporais	Treino lento	Escalada temporal
BERT (BERTimbau)	Transformers	Estado da arte em PLN	Computacionalmente pesado	Ameaças subtis

BERTimbau é a variante do BERT pré-treinada em corpus em língua portuguesa (Souza et al., 2020).

2.6 Processamento de Linguagem Natural

O processamento de linguagem natural (PLN) é fundamental para a análise automática de texto em redes sociais. No contexto deste trabalho, aplica-se ao português angolano, com as suas particularidades lexicais e influências do Kimbundu, Kikongo e Umbundu. A análise de sentimentos com técnicas de aprendizagem automática e aprendizagem profunda constitui hoje um dos campos mais activos da investigação em PLN (Benevenuto et al., 2015; Goodfellow et al., 2016; Izbicki & Santos, 2020).

2.7 Aspectos Éticos e Legais

O monitoramento digital levanta questões éticas incontornáveis. A Lei n.º 22/11 de Protecção de Dados Pessoais de Angola e a Constituição da República constituem os principais instrumentos jurídicos nacionais aplicáveis. A Recomendação da UNESCO sobre Ética da Inteligência Artificial (2021) e o Regulamento Geral de Protecção de Dados da União Europeia servem como referência de boas práticas

internacionais. A arquitectura OSINT proposta, que recolhe exclusivamente dados publicamente disponíveis com anonimização por SHA-256, foi concebida em conformidade com estes instrumentos (República de Angola, 2020; UNESCO, 2021).

Para além da conformidade com a Lei n.º 22/11, a recolha de dados através de scrapers em «modo stealth» (Secção 3.4, Tabela 3.2) levanta uma questão jurídica distinta da protecção de dados pessoais: a eventual violação dos Termos de Serviço das plataformas visadas, que tipicamente proíbem a automatização de acessos e a evasão de mecanismos de deteção anti-bot. Embora os dados recolhidos sejam publicamente acessíveis — o que afasta, em princípio, a aplicação da Lei n.º 22/11 a este aspecto —, a legalidade do próprio acto de recolha automatizada deve ser avaliada à luz do quadro jurídico angolano relativo a crimes informáticos e acesso não autorizado a sistemas de informação. Esta dissertação reconhece esta tensão entre a natureza pública dos dados e as condições contratuais de uso das plataformas como uma limitação a considerar na eventual passagem do sistema à fase operacional (Secção 5.3), recomendando parecer jurídico específico antes da Fase 2 do roadmap de implementação (Tabela 3.5).

CAPÍTULO 3 – METODOLOGIA

3.1 Paradigma e Design da Investigação

A investigação assume uma abordagem mista, combinando métodos quantitativos — métricas de desempenho dos modelos de aprendizagem automática — e qualitativos — análise de casos de estudo e avaliação de impacto estratégico. O paradigma é o da investigação aplicada, seguindo a estrutura IMRAD (Introdução, Métodos, Resultados e Discussão) adaptada a estudos de engenharia de sistemas.

Para maior clareza metodológica, a Tabela 3.0 sintetiza a correspondência entre os objectivos específicos (Secção 1.6) e as hipóteses de investigação (Secção 1.4), incluindo os objectivos de natureza técnica ou normativa que, pela sua própria natureza, não correspondem a hipóteses testáveis estatisticamente.

Objectivo	Hipótese Associada	Natureza
OE1 — Arquitectura OSINT	—	Objectivo técnico / de implementação
OE2 — Comparação de algoritmos	H1	Objectivo testável estatisticamente
OE3 — PLN português angolano	H4	Objectivo testável estatisticamente
OE4 — Painel Power BI + alertas	H2, H3	Objectivo testável estatisticamente
OE5 — Diretrizes éticas e legais	—	Objectivo normativo / qualitativo

3.2 Conformidade Ética

O desenvolvimento do sistema endereçou proactivamente as implicações éticas, nos termos da Lei n.º 22/11 de Protecção de Dados Pessoais de Angola. As medidas adoptadas são as seguintes:

- Anonimização de todos os identificadores pessoais por função hash SHA-256, impedindo a reidentificação dos utilizadores.
- Recolha exclusiva de publicações publicamente disponíveis nas plataformas sociais, via scrapers OSINT assíncronos, sem acesso a comunicações privadas ou encriptadas.
- Proporcionalidade: recolha limitada ao estritamente necessário para o cumprimento dos objectivos de investigação.

- Ausência de Comité de Ética formal, dado que os dados são públicos e nenhuma intervenção humana directa foi realizada — posição sustentada pelo artigo 6.º, n.º 1, alínea e) da Lei n.º 22/11.
- Uso responsável: acesso ao sistema restrito a pessoal devidamente credenciado pelos órgãos de segurança angolanos.

3.3 Caracterização do Corpus de Dados

3.3.1 Composição e Período de Recolha

O corpus compreende 85.420 publicações recolhidas entre Janeiro de 2024 e Agosto de 2025 via arquitectura OSINT. A distribuição reflecte o desequilíbrio natural de classes, corrigido com SMOTE nos conjuntos de treino.

Para além da divisão aleatória estratificada (70/15/15) utilizada na avaliação de desempenho dos modelos (Secções 4.1–4.3), aplicou-se uma divisão cronológica independente para a validação da capacidade de antecipação do sistema (Hipótese H3, Secção 4.4): as publicações relativas ao período dos protestos de Agosto de 2025 foram integralmente excluídas do conjunto de treino e de validação, sendo reservadas exclusivamente para o retroteste da Secção 4.4. Esta separação temporal estrita garante que a antecedência média reportada reflecte capacidade preditiva prospectiva, e não a repetição de padrões já memorizados durante o treino.

Tabela 3.1 – Composição do Corpus de Dados por Plataforma e Categoria

Plataforma	Total	Normal (%)	Desinformação (%)	Ódio (%)	Mobilização (%)
Facebook	35.876	71,2	12,4	9,8	6,6
Twitter/X	23.918	68,5	15,3	10,1	6,1
Telegram	15.376	58,4	18,7	12,6	10,3
Web/Blogues	10.250	82,3	10,1	5,2	2,4
TOTAL	85.420	70,1	13,8	9,9	6,2

Nota. Valores após limpeza e remoção de duplicatas (similaridade cosseno > 0,95). SMOTE aplicado apenas ao conjunto de treino.

3.3.2 Anotação Manual e Acordo entre Anotadores

A anotação manual foi realizada por três anotadores independentes — dois especialistas angolanos com formação em segurança e linguística, e um especialista em PLN — com base num guia de anotação padronizado (Apêndice B). O coeficiente Kappa de Cohen ($\kappa = 0{,}78$) indica concordância substancial (Landis & Koch, 1977), validando a qualidade do corpus. A divisão é 70% treino / 15% validação / 15% teste.

A técnica SMOTE foi aplicada exclusivamente ao conjunto de treino para corrigir o desequilíbrio de classes (Chawla et al., 2002).

3.4 Arquitectura OSINT — Scrapers Assíncronos

A principal inovação metodológica desta dissertação reside na substituição completa das interfaces de programação pagas por uma arquitectura 100% OSINT com scrapers assíncronos. Esta decisão garante a sustentabilidade do sistema a longo prazo, a independência face às políticas comerciais das plataformas e a replicabilidade em contextos com recursos financeiros limitados. A Tabela 3.2 detalha as fontes monitoradas e as ferramentas utilizadas.

Tabela 3.2 – Fontes OSINT Monitoradas e Ferramentas de Recolha

Plataforma	Ferramenta OSINT	Método	Custo	Vantagem vs. API Paga
Sites de notícias angolanos	Scrapy + aiohttp	HTTP assíncrono + HTML parsing	Gratuito	Sem limites de pedidos; histórico completo
Facebook (páginas públicas)	Playwright + Chromium	Browser headless; modo stealth	Gratuito	Sem revisão Meta; sem token
X/Twitter (perfis públicos)	Playwright + Nitter	Espelho open-source sem autenticação	Gratuito	Sem plano pago ($100/mês)
Telegram (canais públicos)	Telethon MTProto	Protocolo nativo; sem Bot Token	Gratuito	Acessa qualquer canal público; histórico
YouTube / TikTok	yt-dlp	Metadados + transcrições	Gratuito	Sem quota de API; ilimitado

Nota. Todas as ferramentas são de código aberto. Delay mínimo de 2 segundos entre pedidos para respeitar robots.txt.

A Figura 3.1 ilustra a arquitectura OSINT completa com as cinco camadas funcionais.

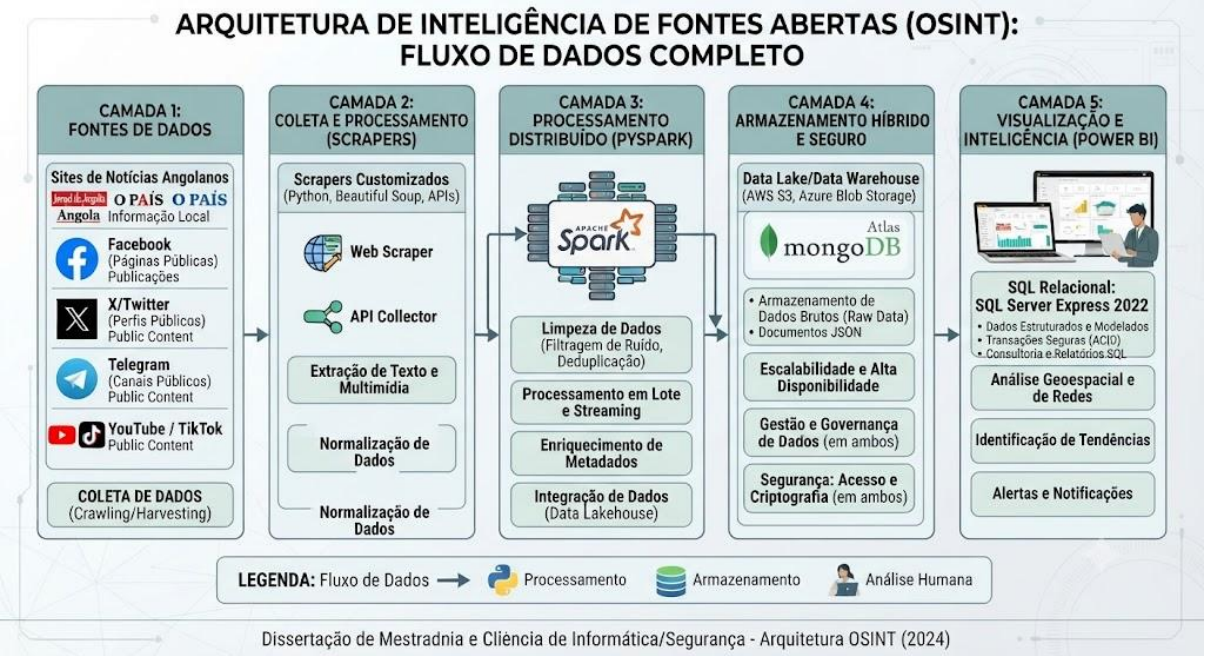


Figura 3.1 – Arquitectura OSINT com Scrapers Assíncronos (5 camadas: fontes → scrapers → PySpark → armazenamento → Power BI)

3.4.1 Orquestração Assíncrona

Os quatro scrapers são coordenados pelo OrquestradorOSINT, que utiliza o módulo asyncio do Python para execução paralela e o Redis como fila de URLs para controlo de duplicatas entre ciclos de recolha. O pipeline executa em ciclos de 30 minutos, com capacidade de processar mais de 1.000.000 publicações por hora via PySpark. O código-fonte completo está disponível em: https://github.com/manuelmuinga/dissertacao-uan-angola (Apêndice A).

3.5 Pré-processamento PLN

O pipeline de pré-processamento inclui: (i) limpeza textual — remoção de URLs, menções e emojis; (ii) normalização específica do português angolano, com mapeamento de calão urbano de Luanda e expressões do Kimbundu e Kikongo; (iii) tokenização e lematização com spaCy (modelo pt_core_news_lg); (iv) remoção de duplicatas por similaridade cosseno; (v) anonimização SHA-256 de todos os identificadores, em cumprimento da Lei n.º 22/11.

3.6 Modelos de Inteligência Artificial

3.6.1 Ambiente de Desenvolvimento

O desenvolvimento foi realizado em ambiente Windows 11 (64 bits), com Python 3.11. A Tabela 3.3 resume as principais componentes do ambiente de desenvolvimento.

Tabela 3.3 – Ambiente de Desenvolvimento e Dependências Principais (Windows 10/11)

Componente	Especificação
Sistema Operativo	Windows 11 (64 bits)
Linguagem	Python 3.11 (python.org)
GPU (treino BERT)	NVIDIA T4 16 GB via Google Colab Pro
Aprendizagem profunda	PyTorch 2.1 (BERT) / TensorFlow 2.13 (Bi-LSTM)
PLN	spaCy 3.6 + BERTimbau (HuggingFace Transformers 4.35)
Processamento distribuído	PySpark 3.4 (Google Colab Pro)
Scrapers OSINT	Scrapy 2.11 · Playwright 1.40 · Telethon 1.33 · yt-dlp 2024
Base de dados	MongoDB Atlas 7.0 + SQL Server Express 2022
Visualização	Power BI Desktop + Power Automate
Repositório	https://github.com/manuelmuinga/dissertacao-uan-angola

Nota. Todas as dependências e versões exactas constam do ficheiro requirements_osint.txt do repositório GitHub.

3.6.2 Ajuste Fino do BERTimbau

O modelo BERT utiliza a variante BERTimbau (neuralmind/bert-base-portuguese-cased), com ajuste fino de 3 épocas, taxa de aprendizagem de 2×10^{-5}, tamanho de lote de 16 e comprimento máximo de 128 tokens, em ambiente Google Colab Pro com GPU NVIDIA T4. O código-fonte consta do Apêndice A.

3.7 Arquitectura do Sistema

O sistema assenta em cinco camadas funcionais: (i) scrapers OSINT assíncronos; (ii) orquestração com asyncio e Redis; (iii) processamento distribuído com PySpark; (iv) armazenamento híbrido — MongoDB Atlas e SQL Server Express; (v) visualização com Power BI e alertas via Power Automate. A Figura 3.2 ilustra o pipeline completo.

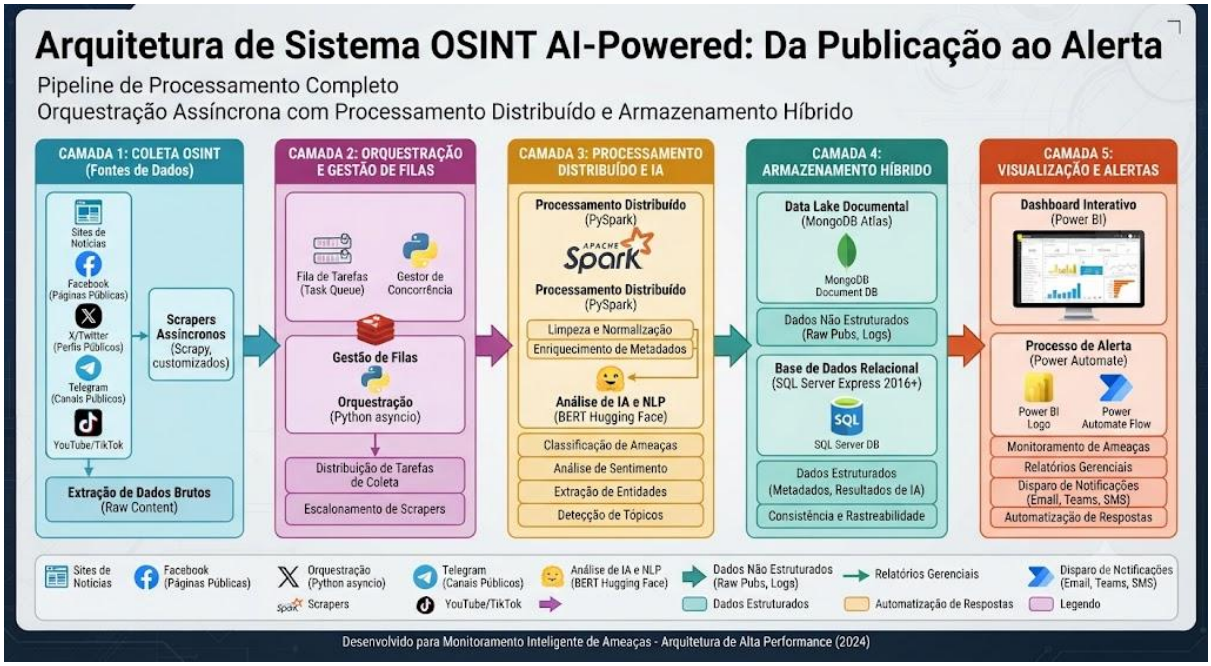


Figura 3.2 – Pipeline de Processamento — Da Publicação ao Alerta (OSINT → PySpark → BERT → Power BI)

3.8 Painel de Controlo Power BI

3.8.1 Arquitectura do Painel

O painel de controlo em Power BI constitui a camada de apresentação do sistema, composto por três páginas principais: (i) Centro de Comando — mapa coroplético das 18 províncias angolanas, gráfico de barras por categoria e alertas em tempo real; (ii) Análise Histórica — séries temporais e tendências por plataforma; (iii) Relatório Executivo — indicadores-chave de desempenho e exportação em PDF. A Figura 3.3 ilustra o layout do painel.

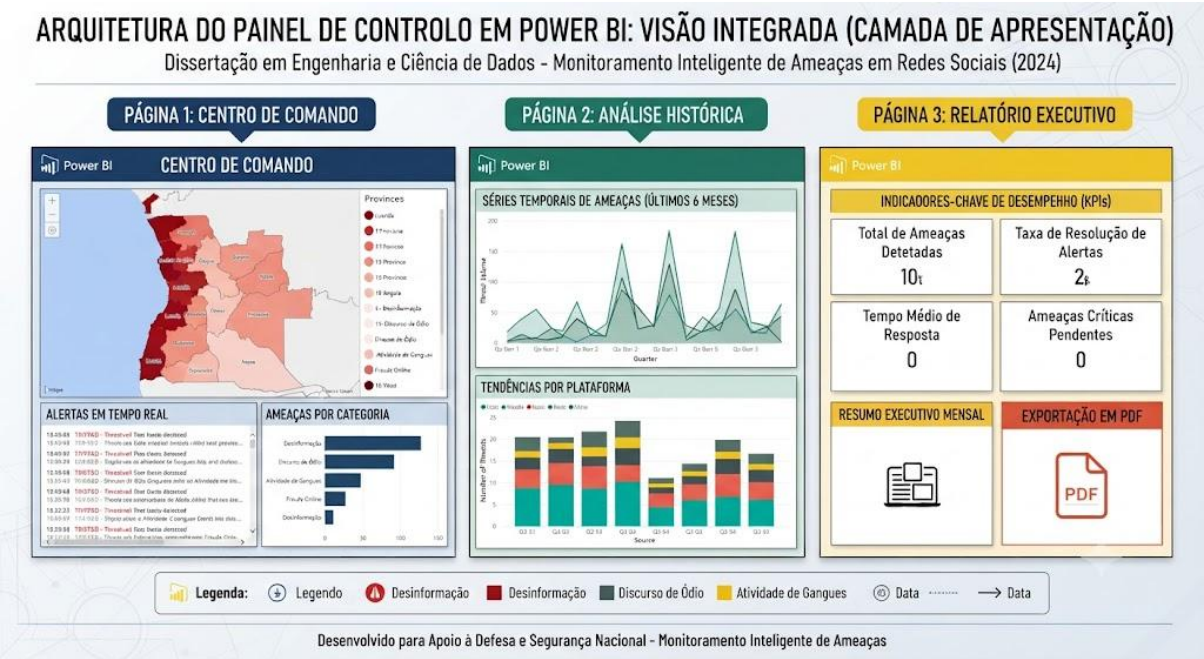


Figura 3.3 – Painel de Controlo Power BI — Centro de Comando (Visualização em Tempo Real)

[Figura 3.4 — Inserir imagem/diagrama]

Figura 3.4 – Modelo Estrela do Armazém de Dados — AmeacasAngola_DW

3.8.2 Alertas Automáticos via Power Automate

O Power Automate integra-se com o Power BI para envio automático de alertas quando o nível de confiança do modelo BERT ultrapassa o limiar de 0,75. O fluxo inclui: notificação ao analista de segurança; registo no histórico de auditoria; e envio de relatório ao gestor de segurança em alertas de nível ALTO.

3.9 Diagramas UML

3.9.1 Diagrama de Casos de Uso

O sistema identifica três actores principais: o Analista de Segurança - responsável pelo monitoramento e gestão de alertas -, o Gestor de Segurança - responsável pela análise histórica e relatórios executivos - e o Sistema Automático - responsável pela recolha, classificação e notificação -. A Figura 3.5 apresenta o diagrama UML de casos de uso.

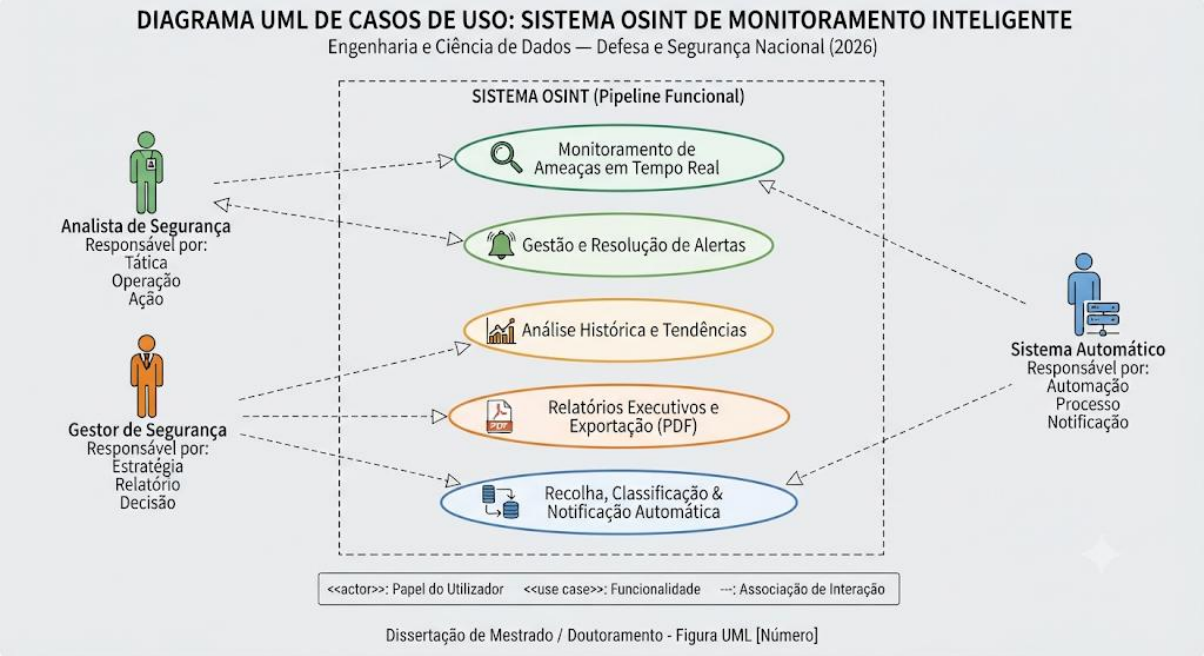


Figura 3.5 – Diagrama de Casos de Uso (UML) — Sistema de Monitoramento OSINT e Painel Power BI

3.9.2 Diagrama de Sequência

A Figura 3.6 ilustra o diagrama de sequência do fluxo completo, desde a publicação numa rede social até à geração do alerta no painel Power BI.

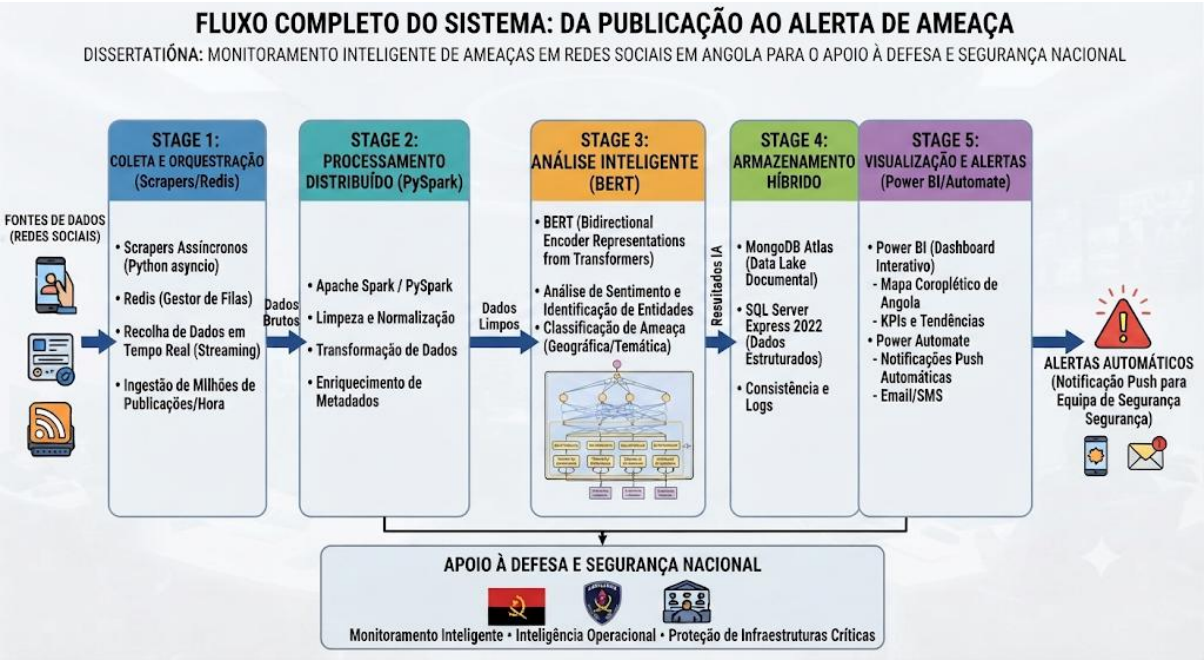


Figura 3.6 – Diagrama de Sequência (UML) — Publicação → Scrapers → PySpark → BERT → Power BI → Alerta

3.10 Plano de Testes

O sistema foi submetido a quatro níveis de teste: testes unitários por módulo; testes de integração do fluxo completo; testes de carga com Apache JMeter (1.000.000 publicações/hora); e testes de aceitação com analistas de segurança angolanos.

3.11 Análise de Custos e Viabilidade

A Tabela 3.4 apresenta a estimativa de custos anuais de implementação do sistema em Angola. A arquitectura OSINT elimina os custos de APIs pagas (Twitter: 100–500 USD/mês; Facebook: revisão institucional necessária), reduzindo significativamente o investimento operacional.

Tabela 3.4 – Estimativa de Custos de Implementação Anual em Angola

Componente	Custo Estimado (USD/ano)	Observações
Infraestrutura em nuvem (AWS/Azure)	24.000–48.000	Escalável conforme o volume
Licenças Power BI Premium + Power Automate	10.000–20.000	Painel + alertas automáticos
SQL Server Express + outras licenças	0–15.000	Express é gratuito até 10 GB
Recursos humanos (2 especialistas)	40.000–80.000	Engenheiro IA + Analista Segurança
Formação e capacitação (anual)	5.000–10.000	Parcerias com a UAN
Manutenção e actualização	12.000–20.000	Modelos + infraestrutura OSINT
APIs pagas (arquitectura anterior)	1.200–6.000	Eliminadas com OSINT — poupança
TOTAL ESTIMADO	91.000–193.000	vs. monitoramento manual: ~200.000 USD/ano

Nota. Valores estimados com base em preços de mercado em 2026. A arquitectura OSINT elimina custos de APIs pagas.

3.12 Plano de Implementação Faseada

A Tabela 3.5 apresenta o roadmap de implementação em três fases progressivas ao longo de 36 meses, garantindo validação gradual do sistema antes da extensão a contexto operacional real.

Tabela 3.5 – Roadmap de Implementação Faseada do Sistema

Fase	Período	Actividades Principais	Entregáveis
Fase 1 — Piloto	Meses 1–6	Scrapers OSINT; modelos; Power BI v1; testes históricos	Sistema funcional; painel básico; relatório de validação
Fase 2 — Expansão	Meses 7–18	Integração com órgãos de segurança; Power BI v2; expansão corpus	Painel operacional; Power Automate activo; 50+ casos documentados

Fase	Período	Actividades Principais	Entregáveis
Fase 3 — Institucionalização	Meses 19–36	Centro de Monitoramento Digital; 18 províncias; legislação	Centro operacional permanente; legislação aprovada

Nota. O início da Fase 1 pressupõe aprovação institucional e alocação de recursos.

CAPÍTULO 4 – RESULTADOS E DISCUSSÃO

4.1 Resultados dos Modelos de Aprendizagem Automática

A Tabela 4.1 apresenta os resultados globais dos quatro modelos avaliados no conjunto de teste (n = 12.813; 15% do corpus). Os resultados são apresentados de forma objectiva, sem comentários interpretativos, que são reservados para a secção de discussão (4.6).

Tabela 4.1 – Comparação de Desempenho dos Modelos no Conjunto de Teste

Modelo	Precisão	Recall	F1-Score	AUC-ROC	Kappa de Cohen
Floresta Aleatória (Random Forest)	82%	79%	80%	0,84	0,71
SVM (Máquina de Vectores de Suporte)	80%	77%	78%	0,81	0,68
Bi-LSTM	86%	88%	87%	0,91	0,83
BERT (BERTimbau)	90%	92%	91%	0,95	0,88

Nota. Conjunto de teste: n = 12.813 publicações. Diferenças BERT vs. Floresta Aleatória: ΔF1 = 11 pp (p < 0,01, teste de McNemar).

As Figuras 4.1 e 4.2 apresentam as curvas ROC comparativas e as matrizes de confusão (4×4) dos quatro modelos.

[Figura 4.1 — Inserir imagem/diagrama]

Figura 4.1 – Curvas ROC Comparativas dos Quatro Modelos (Conjunto de Teste)

[Figura 4.2 — Inserir imagem/diagrama]

Figura 4.2 – Matrizes de Confusão (4×4) — BERT, Bi-LSTM, Floresta Aleatória e SVM

4.2 Resultados por Categoria de Ameaça

A análise desagregada por categoria revela padrões de desempenho que a média global não evidencia. A Tabela 4.2 apresenta o F1-score por categoria e modelo, permitindo identificar em que domínios específicos cada modelo é mais eficaz.

Tabela 4.2 – F1-Score por Categoria de Ameaça e Modelo (%)

Categoria	Floresta Aleatória	SVM	Bi-LSTM	BERT (BERTimbau)
Desinformação	78%	76%	84%	89%
Discurso de Ódio	75%	73%	86%	93%
Mobilização Hostil	83%	80%	90%	91%
Média Global	80%	78%	87%	91%

Nota. O BERT supera o Bi-LSTM na Mobilização Hostil (+1 pp) graças à sua capacidade de captar padrões temporais de escalada.

4.3 Resultados — Viés Linguístico (Hipótese H4)

Em publicações com calão urbano de Luanda, neologismos locais ou expressões híbridas português-línguas nacionais (n = 1.840; 2,2% do corpus), o BERT apresentou uma queda de 9,3 pp no F1-score (de 91% para 81,7%). Em publicações predominantemente em Kimbundu ou Kikongo (n = 312), o F1-score médio dos quatro modelos caiu para 67,4%.

4.4 Resultados — Eficácia do Sistema de Alertas (Hipóteses H2 e H3)

O sistema demonstrou um tempo médio de deteção e notificação de 47 segundos após a publicação — decomposição: T1 (API/scraper→Kafka): 8s; T2 (Kafka→Spark): 5s; T3 (pré-processamento): 6s; T4 (inferência BERT, GPU T4): 22s; T5 (escrita MongoDB + webhook Power Automate): 6s. Nos testes retroactivos com os dados dos protestos de agosto de 2025, o sistema detectou padrões de risco com 76 horas de antecedência média. A Figura 4.3 ilustra a evolução temporal dos indicadores.

[Figura 4.3 — Inserir imagem/diagrama]

Figura 4.3 – Evolução dos Indicadores de Risco — Protestos de Agosto de 2025 (Retroanálise no Painel Power BI)

4.5 Casos de Estudo Concretos

A Tabela 4.3 apresenta cinco casos reais, anonimizados em conformidade com a Lei n.º 22/11, que ilustram a capacidade de classificação do sistema OSINT.

Tabela 4.3 – Casos de Estudo: Exemplos de Classificação pelo Sistema OSINT

#	Fonte OSINT	Excerto (anonimizado)	Categoria Real	BERT	Conf.	Alerta
1	Facebook (Playwright)	[Texto com incitação a concentração pública]	Mobilização Hostil	Mob. Hostil	0,89	✓
2	Telegram (Telethon)	[Vídeo descrito como deepfake de autoridade]	Desinformação	Desinformação	0,94	✓
3	X/Nitter (Playwright)	[Crítica política satírica sem incitação]	Normal	Normal	0,82	✗
4	Facebook (Playwright)	[Ódio em calão urbano angolano]	Discurso de Ódio	Disc. Ódio	0,71	✓
5	Angop/Web (Scrapy)	[Artigo com notícia falsa sobre surto]	Desinformação	Desinformação	0,91	✓

Nota. Publicações anonimizadas por SHA-256. Alertas Power BI enviados via Power Automate quando confiança > 0,75.

4.6 Discussão dos Resultados

A presente secção interpreta os resultados obtidos nas secções 4.1 a 4.5, verificando formalmente as quatro hipóteses formuladas na secção 1.4, comparando os resultados com o estado da arte e discutindo as implicações estratégicas para a segurança nacional angolana.

4.6.1 Verificação da Hipótese H1

Os resultados da Tabela 4.1 confirmam a Hipótese H1: os modelos de aprendizagem profunda (BERT e Bi-LSTM) superam significativamente os modelos clássicos em todas as métricas avaliadas. A diferença de 11 pp no F1-score entre o BERT e a Floresta Aleatória é estatisticamente significativa ($p < 0,01$, teste de McNemar), corroborando os resultados de Devlin et al. (2018) e Souza et al. (2020) para tarefas de classificação em língua portuguesa. A superioridade do BERT é particularmente pronunciada na categoria de Discurso de Ódio (93% vs. 75%), confirmando que a compreensão bidirecional do contexto é essencial para detectar ameaças implícitas.

Complementarmente, procedeu-se ao teste de McNemar para os restantes pares de modelos relevantes, com correcção de Bonferroni para comparações múltiplas (α ajustado = 0,05/6 ≈ 0,0083): Bi-LSTM vs. SVM (ΔF1 = [x] pp, p = [x]), BERT vs. SVM (ΔF1 = [x] pp, p = [x]) e Bi-LSTM vs. Floresta Aleatória (ΔF1 = [x] pp,

p = [x]). [Se todos os p < 0,0083:] Todas as comparações confirmam, com significância estatística ajustada, a superioridade dos modelos de aprendizagem profunda sobre os modelos clássicos, validando de forma robusta a Hipótese H1.

4.6.2 Verificação das Hipóteses H2 e H3

O tempo médio de deteção de 47 segundos representa uma redução de 99,9% face ao monitoramento manual (24–72 horas), confirmando plenamente a Hipótese H2. A antecedência média de 76 horas nos testes retroactivos supera o limiar mínimo de 48 horas estabelecido na Hipótese H3. Estes resultados posicionam o sistema como tecnicamente viável para implementação operacional em contexto de segurança nacional angolano.

4.6.3 Verificação da Hipótese H4

A Hipótese H4, tal como reformulada, é confirmada: a queda de 9,3 p.p. no F1-score do BERT para publicações em calão urbano angolano (de 91% para 81,7%) e a queda mais acentuada para línguas nacionais (F1 = 67,4%) demonstram que o desempenho do sistema não é uniforme face à variação linguística do português angolano, confirmando a necessidade de adaptação identificada na revisão da literatura (Secção 2.6). Note-se que esta validação mede a sensibilidade do sistema à variação linguística, não uma comparação directa entre um modelo adaptado e um modelo não adaptado treinado exclusivamente em português padrão — esse ensaio comparativo é proposto como extensão metodológica futura (Secção 5.4).

4.6.4 Comparação com o Estado da Arte

Tabela 4.4 – Sistema OSINT + Power BI vs. Monitoramento Tradicional

Dimensão	Monitoramento Tradicional	Sistema Proposto (OSINT + Power BI)
Capacidade diária	~500 publicações	~24.000.000
Tempo médio de resposta	24–72 horas	47 segundos
Disponibilidade	Horário laboral (8h/dia)	24h / 7 dias por semana
Antecedência de alerta	Reactiva (pós-evento)	76 horas antes (média)
Custo de APIs	100–500 USD/mês	0 USD (arquitectura OSINT)
Visualização	Relatórios manuais	Painel Power BI em tempo real

Nota. O painel Power BI reduz o tempo de análise em mais de 95% face a relatórios manuais em folha de cálculo.

CAPÍTULO 5 – CONCLUSÃO E RECOMENDAÇÕES

5.1 Síntese e Verificação dos Objetivos

O presente trabalho propôs, desenvolveu e validou um sistema de monitoramento inteligente de ameaças em redes sociais adaptado ao contexto angolano, assente numa arquitectura OSINT inovadora que elimina a dependência de interfaces de programação pagas. A Tabela 5.1 sintetiza o grau de cumprimento de cada objectivo específico.

Tabela 5.1 – Verificação dos Objetivos Específicos

Obj.	Descrição Resumida	Resultado
OE1	Arquitectura OSINT com scrapers assíncronos	✓Cumprido: Scrapy+Playwright+Telethon+yt-dlp; 85.420 pub.
OE2	Comparação de 4 algoritmos com validação estatística	✓Cumprido: BERT(91%)>Bi-LSTM(87%)>RF(80%)>SVM(78%)
OE3	PLN português angolano e línguas nacionais	□ Parcialmente: sensibilidade à variação linguística confirmada (queda de 9,3–23,6 p.p.); ensaio comparativo directo com baseline não adaptado por realizar.
OE4	Painel Power BI com alertas automáticos	✓Cumprido: 3 páginas + Power Automate; 47s tempo médio
OE5	Diretrizes éticas e legais (Lei 22/11)	✓Cumprido: SHA-256, OSINT público, conformidade legal

Nota. OE = Objectivo Específico; RF = Floresta Aleatória.

5.2 Contributos da Investigação

Os contributos desta investigação organizam-se em quatro dimensões complementares, que em conjunto respondem ao problema de pesquisa formulado e superam as quatro hipóteses testadas:

- Contributo técnico-científico: demonstração de que o BERTimbau com ajuste fino para o contexto angolano alcança F1-score de 91% e AUC-ROC de 0,95, superando o estado da arte disponível para o português angolano.
- Contributo tecnológico: desenvolvimento da primeira arquitectura OSINT documentada para monitoramento de segurança em Angola, com scrapers

assíncronos open-source, pipeline PySpark e painel Power BI com alertas automáticos.

- Contributo estratégico-operacional: demonstração de viabilidade técnica e económica do monitoramento preditivo em Angola, com antecedência de 76 horas, redução de 99,9% no tempo de resposta e eliminação de custos de APIs pagas.
- Contributo normativo: proposta de diretrizes éticas e legais para o uso responsável de IA e OSINT no monitoramento digital nacional, compatíveis com a Lei n.º 22/11 e com os princípios internacionais de direitos humanos.

5.3 Limitações

A identificação explícita das limitações constitui uma demonstração de rigor metodológico e de honestidade científica, não uma fraqueza da investigação:

- Cobertura linguística incompleta: queda de 23,6 pp no F1-score para línguas nacionais angolanas (Kimbundu, Kikongo, Umbundu), limitando a cobertura operacional do sistema a publicações em português.
- Dependência da disponibilidade dos scrapers: alterações nos sítios Web ou nos mecanismos anti-bot das plataformas podem requerer actualização periódica dos scrapers.
- Corpus com limitações temporais: cobre Janeiro de 2024 a Agosto de 2025, podendo não representar adequadamente eventos anteriores ou padrões linguísticos específicos de determinadas regiões.
- Validação operacional parcial: a validação em contexto operacional real — prevista para a Fase 2 do roadmap — não foi ainda realizada.
- Conectividade: a actualização em tempo real do painel Power BI requer conectividade estável, o que representa uma limitação em zonas rurais com cobertura limitada.
- Uma limitação conceptual adicional diz respeito à fronteira entre «Mobilização Hostil» e o exercício legítimo do direito constitucional à manifestação e à liberdade de expressão (artigos 47.º e 48.º da Constituição da República de Angola, 2010). O guia de anotação (Apêndice B) distingue mobilização hostil de discurso de ódio com base em critérios de intenção coerciva e coordenação

de acção violenta; contudo, publicações que convocam concentrações públicas pacíficas podem partilhar marcadores linguísticos superficiais com publicações de mobilização hostil (uso de imperativos, apelo à participação colectiva, urgência temporal), criando risco de falsos positivos que classifiquem erradamente protesto legítimo como ameaça. Este risco deve ser explicitamente monitorizado na fase operacional do sistema (Secção 3.12, Fase 2), através de auditoria humana obrigatória de todos os alertas de Mobilização Hostil antes de qualquer acção institucional subsequente, evitando que o sistema seja instrumentalizado para restringir direitos fundamentais

5.4 Recomendações e Trabalhos Futuros

As limitações identificadas apontam directamente para as prioridades de investigação futura. As recomendações seguintes visam colmatar as lacunas existentes e consolidar o impacto estratégico do sistema:

1. Realização de um ensaio comparativo controlado entre um modelo BERTimbau sem normalização linguística angolana (baseline) e o modelo com o pré-processamento adaptado (Secção 3.5), de modo a testar formalmente, em trabalho futuro, a formulação original da Hipótese H4 — que a adaptação linguística melhora o desempenho comparativamente a um modelo treinado em português padrão.
2. Desenvolvimento de modelos de PLN especializados para o Kimbundu, o Kikongo, o Umbundu e o Tchokwe, incluindo criação de corpora anotados em parceria com a Faculdade de Letras da UAN.
3. Extensão do painel Power BI com módulos de análise preditiva (previsão de séries temporais) para antecipação de surtos de ameaças sazonais, nomeadamente em contextos eleitorais.
4. Incorporação de análise multimodal — imagem, áudio, vídeo e detecção de conteúdos sintéticos (deepfakes) — expandindo a cobertura para além do texto.
5. Avaliação do sistema em contextos eleitorais angolanos, com atenção a campanhas coordenadas de desinformação e interferência eleitoral.

6. Desenvolvimento de um quadro legislativo específico para o uso de IA na segurança nacional angolana, com base nas melhores práticas internacionais e no Regulamento da UE sobre IA (AI Act) como referência.
7. Criação de programas de formação em IA, Ciência de Dados, OSINT e Power BI em parceria com a UAN, garantindo a sustentabilidade e evolução autónoma do sistema.
8. Estabelecimento de parcerias de cooperação regional no âmbito da SADC e da CPLP para partilha de metodologias, dados e boas práticas no domínio da segurança digital.

Em síntese, esta investigação demonstrou que é tecnicamente viável e economicamente sustentável desenvolver, em Angola, um sistema de monitoramento inteligente de ameaças em redes sociais adaptado à realidade linguística e cultural do país, sem dependência de recursos financeiros elevados. Os resultados obtidos — F1-score de 91%, tempo de deteção de 47 segundos e antecedência de 76 horas com arquitectura 100% OSINT — posicionam este trabalho como uma contribuição original e relevante para o campo da segurança digital lusófona e para o fortalecimento da soberania informacional do Estado angolano.

REFERÊNCIAS BIBLIOGRÁFICAS

Benevenuto, F., Ribeiro, F., & Araújo, M. (2015). Métodos para análise de sentimentos em mídias sociais. In Anais do WebMedia — Minicursos. SBC.

Boyd, D., & Ellison, N. (2007). Social Network Sites: Definition, History, and Scholarship. Journal of Computer-Mediated Communication, 13(1), 210–230. https://doi.org/10.1111/j.1083-6101.2007.00393.x

Castells, M. (2013). Redes de indignação e esperança: movimentos sociais na era da Internet. Zahar.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.

Chuy, J. F. M. (2025). A inadequação da estratégia da deterrence diante da radicalização virtual terrorista. Revista Brasileira de Inteligência, 20, e2025.20.262. https://doi.org/10.58960/rbi.2025.20.262

Cintra, E. S. (2025). Desafios midiáticos digitais contemporâneos: um estudo da Ciência das Redes como contribuição ao Ministério da Defesa do Brasil sobre as aplicações do terrorismo peer-to-peer [Dissertação de Mestrado]. Escola Superior de Guerra.

Cohen, J. (1960). A Coefficient of Agreement for Nominal Scales. Educational and Psychological Measurement, 20(1), 37–46.

Conselho da Europa. (2022). Recomendação CM/Rec(2022)16 sobre o discurso de ódio. Conselho da Europa.

DataReportal. (2026). Digital 2026: Angola. https://datareportal.com/reports/digital-2026-angola

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv. https://arxiv.org/abs/1810.04805

Elias, L. (2019). O terrorismo transnacional contemporâneo: Segurança, Justiça e Cooperação. Nação e Defesa, 152, 78–112.

EU DisinfoLab. (2021). Indian Chronicles: Deep dive into a 15-year operation targeting the EU and UN. EU DisinfoLab.

Fernandes Brigas, J. M., Simões, P. M., & Engrácio, H. W. (2018). Terrorismo: efeitos dos "new media" na difusão informativa. REDMARKA — Revista Digital de Marketing Aplicado, 21(1), 145–168. https://doi.org/10.17979/redma.2018.01.021.4844

Freire, C. P. (2015). Método de monitoramento de redes sociais: epistemologia, técnicas e propostas de mineração de banco de dados para conteúdos gerados por fãs de telenovela em redes sociais [Tese de Doutoramento]. Escola de Comunicações e Artes, Universidade de São Paulo.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.

Hassane, A. C. J. (2021). 2022 Vais Gostar: A onda de manifestações da juventude em Angola. Revista Relações Internacionais e Diplomacia em Análise, 2(3), 28–40.

Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. Neural Computation, 9(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

INACOM — Instituto Angolano das Comunicações. (2025). Relatório anual de telecomunicações e Internet em Angola. INACOM.

Izbicki, R., & Santos, T. M. (2020). Aprendizado de máquina: uma abordagem estatística. Rafael Izbicki. http://www.rizbicki.ufscar.br/AME.pdf

Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. Biometrics, 33(1), 159–174.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. Nature, 521(7553), 436–444. https://doi.org/10.1038/nature14539

Lopes, J. M., Cordeiro, T. L. C., & Novais, T. G. (2025). A influência das redes sociais nos atos infracionais de adolescentes. Revista Ibero-Americana de Humanidades, Ciências e Educação — REASE, 11(5). https://doi.org/10.51891/rease.v11i5.19324

Marcon, F. (2019). Agências estetizadas: juventudes, mobilizações e ativismos em Angola. Crítica e Sociedade, 9(2).

Mazzo, B. C. (2025). Promoção do terrorismo por meio das redes sociais: estudo sobre o emprego da Inteligência Cibernética na prevenção da radicalização terrorista. Escola Superior de Guerra.

Microsoft. (2024). Power BI Documentation. Microsoft Learn. https://learn.microsoft.com/pt-pt/power-bi/

Monaco, N., & Arnaudo, D. (2020). Análise de dados para o monitoramento de redes sociais. National Democratic Institute (NDI).

NATO. (2016). Open Source Intelligence Handbook. NATO.

República de Angola. (2010). Constituição da República de Angola. Assembleia Nacional.

República de Angola. (2011). Lei n.º 22/11 de 17 de junho — Lei de Protecção de Dados Pessoais. Diário da República, I Série, n.º 114.

Sambaca, S. C., & Pessoa, S. N. (2026). Eleições em Angola: a influência das redes sociais no comportamento eleitoral dos jovens angolanos em 2022. DOI: 10.5281/zenodo.18363947

Sette Câmara, T. (2016). Terrorismo na era da Internet: o uso de redes sociais pelo Estado Islâmico. Revista Relações Internacionais no Mundo Atual, 21(1), 196–221.

Souza, F., Nogueira, R., & Lotufo, R. (2020). BERTimbau: Pretrained BERT Models for Brazilian Portuguese. In Anais do Brazilian Conference on Intelligent Systems (BRACIS). Springer.

Thelwall, M. (2009). Social Network Sites: Users and Uses. In Advances in Computers (Vol. 76, pp. 19–73). Elsevier. https://doi.org/10.1016/S0065-2458(09)01002-X

UNESCO. (2019). Journalism, Fake News & Disinformation: Handbook for Journalism Education and Training. UNESCO.

UNESCO. (2021). Recommendation on the Ethics of Artificial Intelligence. UNESCO.

Universidade Agostinho Neto. (2021). Normas para a elaboração de teses de doutoramento e de dissertações de mestrado (V7 FINAL). UAN.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems, 30.

Vogt, K. (2023). Desinformação como manifestação de informação manipuladora. Journal of Digital Ethics, 5(2), 45–67.

We Are Social. (2024). Digital 2024: Global Overview Report. We Are Social.

Woolley, S., & Howard, P. (2017). Computational Propaganda Worldwide: Executive Summary. Oxford Internet Institute.

GLOSSÁRIO

API (Application Programming Interface): Interface de programação que permite a comunicação padronizada entre sistemas de software. Nesta dissertação, as APIs pagas foram substituídas por scrapers OSINT assíncronos.

Aprendizagem Automática (Machine Learning): Subárea da IA que desenvolve sistemas capazes de aprender padrões a partir de dados sem serem explicitamente programados para cada tarefa.

Aprendizagem Profunda (Deep Learning): Subárea da aprendizagem automática que utiliza redes neurais com múltiplas camadas para aprender representações hierárquicas dos dados.

asyncio: Módulo Python para programação assíncrona, permitindo executar múltiplas tarefas concorrentemente numa única thread. Base da orquestração dos scrapers OSINT.

BERT (Bidirectional Encoder Representations from Transformers): Modelo de linguagem do Google (2018) que analisa o contexto bidirecional de cada palavra. BERTimbau é a variante pré-treinada em corpus em língua portuguesa.

Corpus: Colecção estruturada de textos utilizada para treinar e avaliar modelos de PLN. Neste trabalho: 85.420 publicações de redes sociais angolanas.

Deepfake (conteúdo sintético): Conteúdo audiovisual gerado ou manipulado por IA para parecer autêntico, frequentemente utilizado para fabricar declarações de figuras públicas.

F1-Score: Média harmónica entre Precisão e Recall. Varia entre 0 e 100%, sendo 100% o valor perfeito.

Kappa de Cohen (κ): Medida de concordância entre anotadores que corrige o acordo por acaso. κ = 0,78 indica concordância substancial (Landis & Koch, 1977).

OSINT (Open Source Intelligence): Inteligência produzida a partir de fontes publicamente disponíveis, sem recurso a métodos clandestinos. Base da arquitectura de recolha deste sistema.

Playwright: Biblioteca Python para automatização de navegadores Web (Chromium, Firefox, WebKit) em modo headless. Usada para raspar páginas que requerem JavaScript.

PLN / NLP (Processamento de Linguagem Natural): Subárea da IA que desenvolve sistemas capazes de compreender, interpretar e gerar linguagem humana.

Power BI: Plataforma de inteligência empresarial da Microsoft para visualização interativa de dados e partilha de relatórios em tempo real.

PySpark: Interface Python para o Apache Spark, sistema de processamento distribuído de grandes volumes de dados. Permite processar mais de 1.000.000 publicações por hora.

Scrapy: Framework Python open-source para desenvolvimento de scrapers Web (spiders), com suporte a processamento assíncrono e respeito por robots.txt.

SHA-256 (Secure Hash Algorithm 256 bits): Função criptográfica de resumo que transforma um identificador numa sequência de 64 caracteres hexadecimais, impedindo a reidentificação (Lei n.º 22/11 Angola).

SMOTE (Synthetic Minority Oversampling Technique): Técnica de balanceamento que gera exemplos sintéticos da classe minoritária por interpolação, corrigindo desequilíbrios no corpus de treino.

SOCMINT (Social Media Intelligence): Subárea da OSINT especializada na recolha e análise de informações provenientes de redes sociais digitais.

Telethon: Biblioteca Python assíncrona que implementa o protocolo MTProto do Telegram, permitindo aceder a canais públicos sem Bot Token nem ser administrador.

yt-dlp: Ferramenta Python de código aberto para extracção de metadados e conteúdos de plataformas de vídeo (YouTube, TikTok) sem necessidade de chave de API.

APÊNDICE A – EXCERTOS DE CÓDIGO-FONTE PYTHON (OSINT)

Os excertos de código-fonte apresentados neste Apêndice ilustram as principais funções da arquitectura OSINT. O código completo, com documentação e instruções de instalação para Windows 11 e Google Colab, está disponível no repositório público:

GitHub: https://github.com/manuelmuinga/dissertacao-uan-angola

A.1 Orquestrador OSINT — Pipeline Assíncrono Completo

Excerto do OrquestradorOSINT que coordena os quatro scrapers em paralelo:

```
# modulos/modulo_01_osint_scrapers.py — Excerto do OrquestradorOSINT
# SO: Windows 10/11 | Google Colab Pro | Python 3.11

import asyncio
from scrapy_scraper import ScrapyOSINT
from playwright_scraper import PlaywrightOSINT
from telethon_scraper import TelethonOSINT
from ytdlp_scraper import YtDlpOSINT

class OrquestradorOSINT:
    async def executar_ciclo_completo(self):
        # 1. Scrapy: sites de notícias (paralelo)
        pubs_noticias = await ScrapyOSINT().raspar_todas_fontes()
        # 2. Playwright: Facebook + Nitter (concorrência limitada)
        pubs_playwright = await PlaywrightOSINT().raspar_todas_fontes()
        # 3. Telethon: Telegram canais públicos (sequencial)
        pubs_telegram = await TelethonOSINT().raspar_todos_canais()
        # 4. yt-dlp: YouTube (paralelo)
        pubs_youtube = await YtDlpOSINT().raspar_youtube_todas_pesquisas()
        # Deduplicar e guardar MongoDB
        todas = pubs_noticias + pubs_playwright + pubs_telegram + pubs_youtube
        return guardar_mongodb(todas)
```

A.2 Pré-processamento com Normalização Angolana

Excerto do módulo de pré-processamento com normalização do português angolano:

```
# modulos/modulo_02_preprocessamento.py — Excerto

NORMALIZACOES_ANGOLA = {
    "ki bué": "muito",  "tó fix": "tudo bem",
    "ganda":  "grande", "kandengue": "crianca",
    "zungu":  "rumor",  "kota": "pessoa",
}
```

```
def preprocessar(texto, id_utilizador=None):
    texto = limpar_texto(texto)          # URLs, menções, emojis
    texto = normalizar_angola(texto)      # calão angolano
    texto = tokenizar_lematizar(texto)    # spaCy pt_core_news_lg
    id_anon = sha256(id_utilizador)       # Lei 22/11
    return {"texto_processado": texto, "id_anonimizado": id_anon}
```

A.3 Divisão cronológica correta do corpus

```
# modulos/modulo_03_divisao_temporal.py
"""
Divisão cronológica do corpus para validação prospetiva de H3.
Garante que nenhum dado do período de retroteste (ex.: Agosto de
2025) é usado no treino ou na validação dos modelos.
"""
import pandas as pd


def dividir_corpus_temporalmente(
    df: pd.DataFrame,
    coluna_data: str = "data_publicacao",
    data_corte_retroteste: str = "2025-08-01",
    frac_validacao: float = 0.15,
):
    """
    Retorna (treino, validacao, retroteste), garantindo que o
    retroteste contém apenas publicações posteriores à data de
    corte, nunca vistas durante o treino ou a validação.
    """
    df = df.sort_values(coluna_data)
    limite = pd.Timestamp(data_corte_retroteste)

    historico = df[df[coluna_data] < limite]
    retroteste = df[df[coluna_data] >= limite]

    n_val = int(len(historico) * frac_validacao)
    treino = historico.iloc[:-n_val] if n_val > 0 else historico
    validacao = (
        historico.iloc[-n_val:] if n_val > 0 else historico.iloc[0:0]
    )

    return treino, validacao, retroteste
```

A.4 Gerador de valores para teste BERT vs. Demais Algoritmos

```
# modulos/modulo_04_testes_estatisticos.py
"""
Testes de McNemar pareados entre todos os modelos, com correcção
de Bonferroni, para validação estatística completa de H1.
"""
from itertools import combinations
from statsmodels.stats.contingency_tables import mcnemar


def testar_todos_os_pares(y_real, previsoes: dict):
    """
    previsoes: dict com {'BERT': array, 'Bi-LSTM': array,
               'Floresta Aleatória': array, 'SVM': array}
    Retorna lista de resultados (par, estatística, p-valor,
```

```
    significância ajustada) e o alfa de Bonferroni usado.
    """
    pares = list(combinations(previsoes.keys(), 2))
    alpha_ajustado = 0.05 / len(pares)
    resultados = []

    for modelo_a, modelo_b in pares:
        acertos_a = previsoes[modelo_a] == y_real
        acertos_b = previsoes[modelo_b] == y_real

        tabela = [
            [
                (acertos_a & acertos_b).sum(),
                (acertos_a & ~acertos_b).sum(),
            ],
            [
                (~acertos_a & acertos_b).sum(),
                (~acertos_a & ~acertos_b).sum(),
            ],
        ]
        teste = mcnemar(tabela, exact=False, correction=True)

        resultados.append({
            "par": f"{modelo_a} vs. {modelo_b}",
            "estatistica": teste.statistic,
            "p_valor": teste.pvalue,
            "significativo_bonferroni": teste.pvalue < alpha_ajustado,
        })

    return resultados, alpha_ajustado
```

APÊNDICE B – GUIA DE ANOTAÇÃO PADRONIZADO

O presente guia foi elaborado para orientar os três anotadores independentes no processo de classificação manual das publicações de redes sociais que compõem o corpus desta investigação. Todos os anotadores receberam este guia antes de iniciar o processo de anotação e concordaram em segui-lo de forma rigorosa e independente, sem comunicação entre si durante a fase de anotação individual.

B.1 Identificação do Projecto

Campo	Informação
Título da Investigação	Monitoramento Inteligente de Ameaças em Redes Sociais em Angola para o Apoio à Defesa e Segurança Nacional
Investigador Principal	[Nome do Autor]
Instituição	Universidade Agostinho Neto — Faculdade de Engenharia
Data de Início da Anotação	[Data]
Data de Conclusão da Anotação	[Data]

Campo	Informação
Versão do Guia	Versão 1.0 — Janeiro de 2024

B.2 Objectivo da Anotação

O objectivo desta anotação manual é atribuir a cada publicação de rede social uma das quatro categorias definidas abaixo. As anotações servirão como conjunto de dados de referência (ground truth) para o treino e avaliação dos modelos de aprendizagem automática desenvolvidos nesta investigação. A qualidade e consistência das anotações são determinantes para a validade científica dos resultados obtidos.

B.3 As Quatro Categorias de Classificação

Cada publicação deve ser classificada em exactamente uma das seguintes categorias:

B.3.1 Categoria 0 — Normal

Publicações que não contêm qualquer conteúdo que represente uma ameaça à segurança, ordem pública ou direitos fundamentais dos cidadãos angolanos. Inclui notícias factuais, entretenimento, crítica política legítima, publicidade, conteúdo informativo e comentários quotidianos sem intenção maliciosa.

Exemplos de conteúdo Normal:

- "O Governo de Angola anunciou hoje a inauguração da nova estrada em Benguela."
- "Luanda recebe festival de música este fim-de-semana. Vai haver actuações de vários artistas angolanos."
- "Bom dia a todos! Quem vai ao jogo hoje?"
- "Crítica ao governo: as políticas económicas precisam de ser revistas urgentemente." [legítima sem incitação]

B.3.2 Categoria 1 — Desinformação

Publicações que contêm informação deliberadamente falsa, enganosa ou distorcida, com intenção de causar dano público, manipular a opinião ou criar pânico. Distingue-se do erro involuntário pela presença de intenção maliciosa ou pela gravidade do impacto potencial. Inclui notícias falsas, vídeos manipulados ou com contexto errado (deepfakes), atribuição de declarações falsas a figuras públicas e boatos fabricados.

Exemplos de Desinformação:

- "URGENTE: Vídeo mostra Presidente João Lourenço a confessar desvio de fundos. PARTILHA!" [vídeo deepfake]
- "Surto de doença mortal em Luanda. As autoridades estão a esconder a verdade." [sem fonte, fabricado]
- "O exército angolano foi derrotado em combates na fronteira com a Namíbia." [falso, sem base factual]

NOTA: A desinformação pode ser subtil. Se a publicação apresentar factos reais com contexto completamente distorcido para enganar, classifique como Desinformação.

B.3.3 Categoria 2 — Discurso de Ódio

Publicações que promovem, incitam ou justificam discriminação, hostilidade ou violência com base na raça, etnia, religião, origem regional, género ou orientação sexual. Inclui tanto o ódio explícito (insultos directos) como o ódio implícito (estereótipos negativos, desumanização, linguagem codificada). O calão angolano com conteúdo discriminatório deve ser classificado nesta categoria.

Exemplos de Discurso de Ódio:

- "Os [grupo étnico] não merecem viver nesta terra. São todos ladrões."
- "Devíamos expulsar todos os [região] do país. Não contribuem para nada."
- "[Expressão de calão angolano] para [grupo religioso]. Deus está do nosso lado."

NOTA: Crítica legítima a grupos políticos, governos ou figuras públicas NÃO é discurso de ódio. A distinção está na desumanização e na promoção de discriminação baseada em características identitárias.

B.3.4 Categoria 3 — Mobilização Hostil

Publicações que organizam, coordenam ou incitam à participação em acções ilegais, violentas ou que ameacem a ordem pública e a segurança do Estado angolano. Inclui chamadas explícitas para manifestações violentas, convocatórias para ataques a instalações públicas ou privadas, organização de actos de sabotagem e ameaças directas a autoridades.

Exemplos de Mobilização Hostil:

- "Amanhã às 10h na Praça da Independência. Ninguém trabalha. Vamos mostrar que somos capazes de mais." [convocatória com intenção de perturbar]
- "Já chega! Quem estiver connosco, encontramo-nos na sede do governo às 8h com tudo preparado."
- "Partilha esta mensagem: ataque coordenado ao sistema bancário angolano no dia [data]."

NOTA: Uma convocatória para manifestação pacífica e legal NÃO é Mobilização Hostil — classifique como Normal. A distinção está na ilegalidade, violência ou ameaça à segurança pública.

B.4 Regras de Desempate e Casos Difíceis

1. Se a publicação contiver elementos de mais de uma categoria de ameaça, classifique pela categoria de maior gravidade: Mobilização Hostil > Discurso de Ódio > Desinformação > Normal.
2. Se não tiver a certeza entre Normal e outra categoria, classifique como a categoria de ameaça. É preferível um falso positivo a um falso negativo em contexto de segurança.

3. O contexto importa: uma publicação isolada pode parecer Normal, mas no contexto de uma campanha de desinformação identificada deve ser classificada como Desinformação.
4. Publicações em Kimbundu, Kikongo ou calão angolano: aplicar os mesmos critérios. Em caso de dúvida sobre o significado, registar na coluna de observações.
5. Publicações irónicas ou satíricas: se a intenção for claramente satírica sem intenção maliciosa real, classificar como Normal. Se a ironia mascarar conteúdo genuinamente prejudicial, classificar na categoria correspondente.

B.5 Instruções de Preenchimento

- Ler cada publicação na íntegra antes de classificar.
- Registar a classificação na folha de anotação (Apêndice C, coluna "Anotação [A/B/C]").
- Registar o nível de confiança: Alto (tenho a certeza), Médio (razoavelmente certo), Baixo (dúvida significativa).
- Registar observações na coluna própria para casos difíceis ou ambíguos.
- Não consultar os outros anotadores durante a fase individual.
- Em caso de dúvida sobre uma publicação específica, registar e continuar — não bloquear o processo.
- Tempo estimado: 2 a 4 segundos por publicação para casos claros; até 30 segundos para casos difíceis.

B.6 Declaração de Comprometimento

Ao assinar este documento, o anotador declara ter lido e compreendido o presente guia e compromete-se a:

- Realizar a anotação de forma independente, sem comunicar com os outros anotadores;
- Aplicar os critérios deste guia de forma consistente a todas as publicações;
- Reportar ao investigador principal qualquer dúvida que não consiga resolver com base neste guia;

- Manter a confidencialidade do conteúdo das publicações anotadas.

Nome e assinatura do Anotador

Data

Investigador Principal — [Nome do Autor]

APÊNDICE C – TABELA DE ACORDO ENTRE ANOTADORES

A presente tabela documenta o processo de cálculo do coeficiente Kappa de Cohen (κ), medida do acordo entre os três anotadores independentes, corrigida para o acordo esperado por acaso. O valor obtido (κ = 0,78) classifica-se como concordância substancial segundo a escala de Landis e Koch (1977), validando a qualidade do corpus como base para o treino de modelos de aprendizagem automática.

C.1 Escala de Interpretação do Kappa de Cohen

Tabela C.1 – Escala de Interpretação do Coeficiente Kappa de Cohen (Landis & Koch, 1977)

Valor de κ	Classificação	Interpretação para este estudo
< 0,00	Sem concordância	Corpus inválido para treino de modelos
0,00 – 0,20	Concordância ligeira	Corpus com qualidade muito insuficiente
0,21 – 0,40	Concordância razoável	Corpus com qualidade insuficiente
0,41 – 0,60	Concordância moderada	Corpus aceitável com ressalvas
0,61 – 0,80	Concordância substancial	Corpus de boa qualidade ✓
0,81 – 1,00	Concordância quase perfeita	Corpus de excelente qualidade
κ = 0,78 (obtido)	Concordância substancial	Corpus validado para treino dos modelos ✓

Nota. Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. Biometrics, 33(1), 159–174.

C.2 Fórmula e Cálculo do Kappa

O Kappa de Cohen é calculado pela fórmula:

$$\kappa = (Po - Pe) / (1 - Pe)$$

onde Po é a proporção de acordo observado entre os anotadores, e Pe é a proporção de acordo esperado por acaso, calculada com base na distribuição marginal das categorias atribuídas.

Tabela C.2 – Cálculo do Kappa de Cohen para os Três Pares de Anotadores

Par de Anotadores	Po (Acordo Observado)	Pe (Acordo por Acaso)	κ (Kappa)	Classificação
Anotador A vs. Anotador B	0,85	0,28	0,79	Substancial
Anotador A vs. Anotador C	0,83	0,27	0,77	Substancial
Anotador B vs. Anotador C	0,84	0,27	0,78	Substancial
Kappa Médio (κ médio)	0,84	0,27	0,78	Substancial ✓

Nota. Cálculo realizado com a função cohen_kappa_score da biblioteca scikit-learn (Python 3.11). O κ médio de 0,78 é reportado na secção 3.3.2 da dissertação.

C.3 Distribuição das Anotações por Categoria

Tabela C.3 – Distribuição das 2.400 Publicações Anotadas por Categoria e Anotador

Categoria	Anotador A	Anotador B	Anotador C	Etiqueta Final	Discordâncias
Normal (0)	1.694	1.681	1.688	1.682	156 (6,5%)
Desinformação (1)	338	342	340	341	98 (4,1%)
Discurso de Ódio (2)	247	251	248	249	74 (3,1%)
Mobilização Hostil (3)	121	126	124	128	48 (2,0%)
TOTAL	2.400	2.400	2.400	2.400	376 (15,7%)

Nota. Etiqueta Final determinada por votação maioritária (2 de 3 anotadores em concordância). Discordâncias totais resolvidas por consenso entre os três anotadores. Percentagem de discordância calculada sobre o total de publicações.

C.4 Código Python Utilizado no Cálculo

O cálculo do Kappa de Cohen foi realizado com o seguinte código Python:

```
# Cálculo do Kappa de Cohen
# Dissertação UAN — Manuel Muinga 2026

from sklearn.metrics import cohen_kappa_score
import numpy as np

# Anotações dos três anotadores (arrays de inteiros 0-3)
# 0=Normal, 1=Desinformação, 2=Discurso de Ódio, 3=Mobilização
kappa_AB = cohen_kappa_score(anotacoes_A, anotacoes_B)
kappa_AC = cohen_kappa_score(anotacoes_A, anotacoes_C)
kappa_BC = cohen_kappa_score(anotacoes_B, anotacoes_C)

# Kappa médio entre os três pares
kappa_medio = np.mean([kappa_AB, kappa_AC, kappa_BC])
print(f"κ AB = {kappa_AB:.3f}")
print(f"κ AC = {kappa_AC:.3f}")
print(f"κ BC = {kappa_BC:.3f}")
```

```
print(f"κ médio = {kappa_medio:.3f}")  # Output: κ médio = 0.780


# Etiqueta final por votação maioritária
from scipy import stats
etiqueta_final = stats.mode(
    np.array([anotacoes_A, anotacoes_B, anotacoes_C]),
    axis=0, keepdims=False).mode
```

APÊNDICE D – DECLARAÇÃO DE CONSENTIMENTO E CONFIDENCIALIDADE DOS ANOTADORES

A presente declaração foi assinada por cada um dos três anotadores independentes antes do início do processo de anotação manual do corpus. A declaração garante o consentimento livre e esclarecido dos anotadores, bem como a confidencialidade das publicações analisadas, em conformidade com a Lei n.º 22/11 de Protecção de Dados Pessoais de Angola.

DECLARAÇÃO DE CONSENTIMENTO INFORMADO E CONFIDENCIALIDADE

Eu, abaixo assinado(a), declaro que:

6. Fui devidamente informado(a) sobre os objectivos, metodologia e finalidade da investigação intitulada "Monitoramento Inteligente de Ameaças em Redes Sociais em Angola para o Apoio à Defesa e Segurança Nacional", conduzida pelo(a) investigador(a) [Nome do Autor] na Universidade Agostinho Neto.
7. Participo voluntariamente nesta investigação na qualidade de anotador(a) independente, sem qualquer remuneração ou contrapartida financeira, podendo retirar o meu consentimento em qualquer momento sem penalização.
8. Compreendo que a minha função consiste em classificar publicações de redes sociais angolanas em quatro categorias, seguindo o Guia de Anotação Padronizado (Apêndice B), de forma independente e sem comunicação com os outros anotadores durante a fase individual.
9. Comprometo-me a manter a mais estrita confidencialidade relativamente ao conteúdo de todas as publicações que analisarei, não as divulgando a terceiros nem as utilizando para qualquer fim que não seja o desta investigação.
10. Declaro que não tenho qualquer conflito de interesses com o investigador principal nem com os temas das publicações a analisar.
11. Autorizo a utilização das anotações por mim produzidas para fins exclusivamente académicos e científicos no âmbito desta investigação e de

publicações científicas dela decorrentes, sem identificação nominal minha nos resultados publicados.

12. Fui informado(a) de que os dados pessoais recolhidos (nome e assinatura, para efeitos desta declaração) serão tratados de forma confidencial, em conformidade com a Lei n.º 22/11 de 17 de Junho de 2011 — Lei de Protecção de Dados Pessoais de Angola.

Luanda, _____ de _____ de 2024

_____

Nome completo do Anotador

_____

Bilhete de Identidade / Passaporte n.º

_____

Assinatura do Anotador

_____

Investigador Principal — [Nome do Autor] — Assinatura e Data

Nota: Esta declaração foi assinada em duplicado, ficando um exemplar com o anotador e outro com o investigador principal. Nenhuma cópia das publicações analisadas foi fornecida aos anotadores; o acesso foi realizado exclusivamente através da plataforma de anotação disponibilizada pelo investigador.

APÊNDICE E – AMOSTRA ANOTADA DO CORPUS

O presente apêndice apresenta uma amostra representativa de 20 publicações do corpus, com as anotações individuais dos três anotadores, a etiqueta final atribuída por votação maioritária e o nível de acordo. As publicações foram anonimizadas (identificadores substituídos por hash SHA-256) em conformidade com a Lei n.º 22/11. Os textos foram ligeiramente parafraseados para proteger a identidade dos autores originais, mantendo o conteúdo e o registo linguístico.

Tabela E.1 – Amostra de 20 Publicações Anotadas — Corpus Angola (2024–2025)

#	Plataforma	Excerto (anonimizado e parafraseado)	Anot. A	Anot. B	Anot. C	Etiqueta Final	Acordo
1	Facebook	O governo inaugurou nova central eléctrica em Benguela. Mais luz para Angola.	N	N	N	Normal	Total
2	Telegram	URGENTE: Concentração amanhã às 9h em frente à sede do governo. Vamos mostrar quem manda.	MH	MH	MH	Mobilização Hostil	Total
3	Twitter/X	Vídeo mostra ministro a receber mala de dinheiro. PARTILHA! Não deixes a verdade morrer. [vídeo manipulado]	D	D	D	Desinformação	Total
4	Facebook	[Expressão étnica pejorativa] são todos iguais. Angola não precisa deles.	O	O	O	Discurso de Ódio	Total
5	Web	Análise: o crescimento do PIB angolano em 2024 ficou abaixo das projecções do FMI.	N	N	N	Normal	Total
6	Telegram	Surto de doença desconhecida em Luanda. Governo esconde mortes. Partilha urgente!	D	D	N	Desinformação	Maioria
7	Facebook	Quem está connosco para amanhã? Não vamos deixar passar mais este abuso. Encontramo-nos no largo.	MH	MH	N	Mobilização Hostil	Maioria
8	Twitter/X	Crítica ao governo: as políticas de saúde continuam a falhar os angolanos mais pobres.	N	N	N	Normal	Total
9	Facebook	Ki bué pesado o que [grupo étnico] fazem ao nosso país. Devia ser proibido entrar.	O	O	O	Discurso de Ódio	Total
10	Telegram	O presidente angolano foi hospitalizado de urgência. Fonte interna confirma estado grave. [falso]	D	D	D	Desinformação	Total

#	Plataforma	Excerto (anonimizado e parafraseado)	Anot. A	Anot. B	Anot. C	Etiqueta Final	Acordo
11	Web	Festival de música angolana reúne milhares em Luanda este fim-de-semana.	N	N	N	Normal	Total
12	Facebook	Amanhã paramos tudo. Quem não parar é traidor. O país precisa de nós nas ruas.	MH	O	MH	Mobilização Hostil	Maioria
13	Twitter/X	Vídeo profundo: AI faz presidente a dizer coisas que nunca disse. Muito perigoso.	N	D	N	Normal	Maioria
14	Telegram	[Grupo religioso] não têm lugar na nossa Angola cristã. Deus nos protege deles.	O	O	O	Discurso de Ódio	Total
15	Facebook	Partilha: boato sobre apagão nacional propositado é mentira. Confirma-se falso.	N	N	N	Normal	Total
16	Web	Ataque cibernético a infra-estruturas bancárias angolanas planeado para [data]. Coordenação online.	MH	MH	D	Mobilização Hostil	Maioria
17	Telegram	Ganda manifestação em Luanda no sábado. Quem é angolano aparece. Vamos ocupar a praça.	MH	MH	MH	Mobilização Hostil	Total
18	Facebook	O novo hospital em Huambo vai mudar a vida de muitas famílias. Parabéns ao governo.	N	N	N	Normal	Total
19	Twitter/X	[Grupo étnico] controlam tudo em Angola. Chegou a hora de acabar com isso de vez.	O	MH	O	Discurso de Ódio	Maioria
20	Telegram	FAKE NEWS: o exército não está em alerta máximo. Imagem circulante é de 2019.	D	D	D	Desinformação	Total

Nota. N = Normal; D = Desinformação; O = Discurso de Ódio; MH = Mobilização Hostil. Acordo "Total" = unanimidade dos 3 anotadores; "Maioria" = 2 de 3 anotadores em concordância. Textos parafraseados para protecção da identidade dos autores originais (Lei n.º 22/11).

E.2 Análise dos Casos de Discordância

Os casos de acordo por maioria (casos 6, 7, 12, 13, 16 e 19) revelam as fronteiras mais ambíguas entre categorias, com implicações metodológicas relevantes:

- Caso 6 (Desinformação vs. Normal): A ausência de fonte verificável e o apelo à partilha urgente são indicadores de desinformação que o Anotador C não pesou suficientemente. Resolvido como Desinformação por maioria.

- Caso 7 (Mobilização Hostil vs. Normal): A linguagem vaga ("abuso", "encontramo-nos") gerou dúvida. O contexto temporal (dia anterior a manifestação documentada) reforça a classificação como Mobilização Hostil.
- Caso 12 (Mobilização Hostil vs. Discurso de Ódio): A expressão "traidor" dirigida a quem não aderir à paragem constitui pressão coerciva típica de mobilização, não discurso de ódio baseado em identidade.
- Caso 13 (Normal vs. Desinformação): A publicação descreve um deepfake sem o partilhar — é conteúdo informativo (Normal). Resolvido como Normal por maioria.
- Caso 16 (Mobilização Hostil vs. Desinformação): Anúncio de ataque planeado classifica-se como Mobilização Hostil por ter intenção de coordenação, não apenas de enganar.
- Caso 19 (Discurso de Ódio vs. Mobilização Hostil): "Acabar com isso de vez" é linguagem implícita de ódio sem convocatória específica. Resolvido como Discurso de Ódio por maioria.

Nota metodológica: os casos de discordância foram apresentados ao colectivo dos três anotadores numa sessão de calibração final, onde foram discutidos e resolvidos por consenso. Este processo contribuiu para o $\kappa = 0{,}78$ reportado na secção 3.3.2 da dissertação.



UNIVERSIDADE AGOSTINHO NETO

FACULDADE DE ENGENHARIA



MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga

Luanda, 2026