UNIVERSIDADE AGOSTINHO NETO

FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga

Engenheiro Eletrotécnico

Dissertação para obtenção do Grau de Mestre em

Engenharia e Ciência de Dados

Orientador Científico:

Joaquim Fortes Doutor

Co-Orientador

Judice Cumbunga Doutor

Luanda

2026



UNIVERSIDADE AGOSTINHO NETO



FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga

Engenheiro Eletrotécnico

Dissertação para obtenção do Grau de Mestre em

Engenharia e Ciência de Dados

Orientador Científico:

Joaquim Fortes Doutor

Co-Orientador

Judice Cumbunga Doutor

Luanda 2026

FICHA CATALOGRÁFICA

Exemplo

Muinga, Manuel

Monitoramento Inteligente de Ameaças em Redes Sociais em Angola para o Apoio à Defesa e Segurança Nacional / Manuel Muinga. — Luanda: Universidade Agostinho Neto, Faculdade de Engenharia, 2026.

61 p.; il.; 30 cm.

Dissertação de Mestrado em Engenharia e Ciência de Dados — Faculdade de Engenharia, Universidade Agostinho Neto, Luanda, 2026.

1. Redes Sociais. 2. Monitoramento de Ameaças. 3. Inteligência Artificial. 4. OSINT. 5. Segurança Nacional. 6. PLN. I. Juaquim Fortes. II. Título.

CDU: [Código CDU]

Permitida a reprodução total ou parcial deste documento, desde que citada a fonte e sem carácter comercial — O Manuel Muinga.

EPÍGRAFE

"A informação é a moeda do século XXI. Quem a controla, controla o futuro."

— Adaptado de Peter Drucker

DEDICATÓRIA

À minha querida esposa, **Rosalina Muinga**, cuja presença ilumina cada etapa da minha vida. Este trabalho é dedicado a ti, pelo amor, paciência e apoio incondicional que sempre me ofereceste. A tua força e compreensão foram fundamentais para que eu pudesse chegar até aqui. Que esta conquista seja também um reflexo da nossa caminhada conjunta, marcada por fé, perseverança e esperança.

AGRADECIMENTOS

Tenho a honra de expressar os meus mais sinceros agradecimentos ao meu orientador, pela orientação científica, disponibilidade e rigor académico que tornaram possível a realização desta dissertação.

À Universidade Agostinho Neto e à Faculdade de Engenharia, pela sólida formação académica e pelo ambiente científico que proporcionaram ao longo desta jornada.

À minha família e amigos, pelo apoio incondicional, paciência e encorajamento, que foram fundamentais para superar os desafios e alcançar esta etapa.

Às **Forças Armadas Angolanas**, instituição que financiou a minha formação, pelo investimento e pela confiança depositada.

Ao **Comando da Brigada de Forças Especiais**, pela confiança, apoio institucional e pelo incentivo constante ao meu desenvolvimento académico e profissional.

Um agradecimento especial a **Sua Excelência Tenente General Tussen**, cujo incentivo e motivação foram decisivos para que eu pudesse frequentar este curso e concretizar este trabalho.

Aos colegas investigadores e a todos os que, de forma direta ou indireta, contribuíram para a realização desta dissertação, manifesto a minha profunda gratidão.

AUTORIZAÇÃO INSTITUCIONAL DO PROJECTO

RESUMO

As redes sociais consolidaram-se, no contexto angolano, como vectores estratégicos de ameaças à segurança nacional — desinformação, discurso de ódio, mobilização hostil e manipulação por inteligência artificial generativa — num ecossistema de 5,5 milhões de utilizadores activos em 2026 que as estruturas de segurança do Estado não conseguem monitorar em tempo real com os meios disponíveis. Esta dissertação propõe, desenvolve e valida um sistema de monitoramento inteligente baseado numa arquitectura de inteligência de fontes abertas (OSINT) com scrapers assíncronos — Scrapy, Playwright, Telethon e yt-dlp — que elimina a dependência de interfaces de programação pagas e garante a sustentabilidade operacional a longo prazo.

O sistema classifica publicações em quatro categorias de ameaça através do modelo BERTimbau com ajuste fino para o contexto angolano, complementado por Bi-LSTM, SVM e Floresta Aleatória como baselines de contingência e validação estatística. Os resultados demonstram que o BERTimbau atinge F1-score de 91% e AUC-ROC de 0,95, superando a Floresta Aleatória em 11 p.p. com significância estatística ($p < 0,01$, teste de McNemar). O sistema notifica ameaças em 47 segundos após a publicação — redução de 99,9% face ao monitoramento manual — e detectou, em retroanálise sobre os protestos de agosto de 2025, padrões de risco com 76 horas de antecedência. A queda de 9,3 p.p. no desempenho para publicações em calão urbano angolano e de 23,6 p.p. para publicações em línguas nacionais (F1 = 67,4%) quantifica empiricamente a fronteira operacional actual do sistema e define a agenda de investigação futura. O trabalho inclui um painel de controlo interactivo em Power BI com alertas automáticos via Power Automate, um quadro ético e legal compatível com a Lei n.º 22/11, e um corpus anotado de 85.420 publicações com coeficiente Kappa de Cohen de 0,78 — primeira contribuição desta escala para o PLN em português angolano.

Palavras-chave: Monitoramento de ameaças; Redes sociais; BERTimbau; OSINT; Segurança nacional; PLN português angolano; Aprendizagem profunda.

ABSTRACT

Social media have emerged as strategic vectors of national security threats in Angola — disinformation, hate speech, hostile mobilisation and generative AI manipulation — within an ecosystem of 5.5 million active users in 2026 that State security structures cannot monitor in real time with current resources. This dissertation proposes, develops and validates an intelligent monitoring system built on an Open Source Intelligence (OSINT) architecture using asynchronous scrapers — Scrapy, Playwright, Telethon and yt-dlp — that eliminates dependence on paid APIs and ensures long-term operational sustainability.

The system classifies publications into four threat categories using a fine-tuned BERTimbau model adapted to the Angolan context, complemented by Bi-LSTM, SVM and Random Forest as contingency baselines and for statistical validation. Results show that BERTimbau achieves an F1-score of 91% and AUC-ROC of 0.95, outperforming Random Forest by 11 percentage points with statistical significance ($p < 0.01$, McNemar test with Bonferroni correction). The system notifies threats within 47 seconds of publication — a 99.9% reduction relative to manual monitoring — and detected, in a retrospective analysis of the August 2025 protests, risk patterns with 76 hours of advance warning. A performance drop of 9.3 p.p. for publications in Luanda urban slang and 23.6 p.p. for publications in national languages (F1 = 67.4%) empirically quantifies the system's current operational boundary and defines the future research agenda. The work includes an interactive Power BI dashboard with automatic alerts via Power Automate, an ethical and legal framework compatible with Law No. 22/11, and an annotated corpus of 85,420 publications with a Cohen's Kappa coefficient of 0.78 — the first contribution of this scale to NLP in Angolan Portuguese.

Keywords: Threat monitoring; Social media; BERTimbau; OSINT; National security; Angolan Portuguese NLP; Deep learning.

ABREVIATURAS, SIGLAS E ACRÓNIMOS

Sigla / Acrónimo	Designação
ARS	Análise de Redes Sociais (= SNA em inglês)
AUC-ROC	Area Under the Receiver Operating Characteristic Curve
BERT	Bidirectional Encoder Representations from Transformers
DAX	Data Analysis Expressions (linguagem Power BI)
ETL	Extract, Transform, Load
GDPR	General Data Protection Regulation (UE)
IA	Inteligência Artificial
LSTM	Long Short-Term Memory
ML	Machine Learning (Aprendizagem Automática)
NER	Named Entity Recognition
OSINT	Open Source Intelligence (Inteligência de Fontes Abertas)
PLN	Processamento de Linguagem Natural (= NLP em inglês)
Power BI	Power Business Intelligence (Microsoft)
SADC	Southern African Development Community
SHA-256	Secure Hash Algorithm 256 bits
SMOTE	Synthetic Minority Oversampling Technique
SNA	Social Network Analysis (= ARS em português)

SOCMINT	Social Media Intelligence
SVM	Support Vector Machine (Máquina de Vectores de Suporte)
UAN	Universidade Agostinho Neto
UML	Unified Modeling Language
URL	Uniform Resource Locator
yt-dlp	YouTube Download (ferramenta OSINT de código aberto)

ÍNDICE GERAL

ÍNDICE DE TABELAS---------- 16
ÍNDICE DE FIGURAS---------- 18
CAPÍTULO 1 – INTRODUÇÃO---------- 19
1.1 Contextualização e Enquadramento Estratégico ----------**19**
1.2 Identificação do Problema de Pesquisa----------**20**
1.3 Hipóteses de Investigação ----------**20**
1.5 Objetivo Geral ----------**21**
1.6 Objetivos Específicos----------**22**
1.7 Estrutura da Dissertação ----------**23**
CAPÍTULO 2 – REVISÃO DA LITERATURA ---------- 24
2.1 Redes Sociais: Conceito, Evolução e Dimensão Securitária ----------**24**
2.1.1 Conceito e Evolução ---------- **Erro! Indicador não definido.**
2.1.2 Contexto Digital Angolano ---------- **Erro! Indicador não definido.**
2.2 Categorias de Ameaças Digitais no Contexto Angolano----------**24**
2.3 Estado da Arte em Sistemas de Monitoramento----------**27**
2.4 Teoria dos Grafos Sociais Aplicada ao Monitoramento ----------**27**
2.5 Algoritmos de Aprendizagem Automática para Classificação de Ameaças ----------**29**
2.6 Processamento de Linguagem Natural----------**31**
2.7 Aspectos Éticos, Legais e de Direitos Humanos----------**31**
CAPÍTULO 3 – METODOLOGIA---------- 35
3.1 Paradigma e Design da Investigação----------**35**
3.2 Conformidade Ética e Quadro de Mitigação ----------**36**
3.3 Caracterização e Critérios de Selecção do Corpus de treino----------**36**
3.3.1 Composição e Critérios de Selecção ----------36
3.3.2 Anotação Manual, Acordo entre Anotadores e Divisão do Corpus ----------37
3.4 Arquitectura OSINT — Scrapers Assíncronos----------**39**
3.4.1 Orquestração Assíncrona----------40
Secção 3.5 — Pré-processamento PLN ----------**40**
3.6 Modelos de Inteligência Artificial----------**42**
3.6.1 Ambiente de Desenvolvimento ----------42
3.6.2 Ajuste Fino do BERTimbau----------43
3.7 Arquitectura do Sistema ----------**44**
3.8 Painel de Controlo Power BI e Alertas ----------**46**
3.8.1 Arquitectura do Painel ----------46
3.8 Plano de Implementação Faseada----------**47**

3.9 Diagramas UML ---- 48
3.9.1 Diagrama de Casos de Uso ---- 48
3.9.2 Diagrama de Sequência ---- 49
3.10 Plano de Testes ---- 50
3.11 Análise de Custos e Viabilidade ---- 50
3.12 Plano de Implementação Faseada ---- 51
CAPÍTULO 4 – RESULTADOS E DISCUSSÃO ---- 52
4.1 Resultados Globais dos Modelos de Aprendizagem Automática ---- 52
4.2 Resultados por Categoria de Ameaça ---- 54
4.3 Viés Linguístico e Impacto do Calão Angolano (Hipótese H4) ---- 54
4.4 — Eficácia do Sistema de Alertas ---- 55
4.5 Casos de Estudo com Exemplos Concretos ---- 56
4.6 — Comparação com Sistemas Internacionais ---- 57
4.7 Discussão e Verificação Formal das Hipóteses ---- 59
CAPÍTULO 5 – CONCLUSÃO E RECOMENDAÇÕES ---- 62
5.1 Síntese dos Objectivos Atingidos ---- 62
5.2 Contributos da Investigação ---- 62
Secção 5.3 — Limitações ---- 63
5.4 Recomendações e Trabalhos Futuros ---- 65
REFERÊNCIAS BIBLIOGRÁFICAS ---- 68
GLOSSÁRIO ---- 73
APÊNDICE A – EXCERTOS DE CÓDIGO-FONTE PYTHON (OSINT) ---- 77
A.1 Orquestrador OSINT — Pipeline Assíncrono Completo ---- 77
A.2 Scraper Facebook com Playwright (Modo Stealth) ---- 78
A.3 Scraper Telegram com Telethon (MTProto) ---- 80
A.4 Pré-processamento PLN com Normalização do Português Angolano ---- 81
A.5 Ajuste Fino do BERTimbau e Inferência ---- 82
A.6 Divisão Cronológica do Corpus para Validação de H3 ---- 84
A.7 Testes Estatísticos — McNemar com Correcção de Bonferroni ---- 85
APÊNDICE B – GUIA DE ANOTAÇÃO PADRONIZADO ---- 107
B.1 Identificação do Projecto ---- 107
B.2 Objectivo da Anotação ---- 108
B.3 As Quatro Categorias de Classificação ---- 108
B.3.1 Categoria 0 — Normal ---- 108
B.3.2 Categoria 1 — Desinformação ---- 109
B.3.3 Categoria 2 — Discurso de Ódio ---- 110
B.3.4 Categoria 3 — Mobilização Hostil ---- 110

B.4 Regras de Desempate e Casos Difíceis ---------- **112**
B.5 Instruções de Preenchimento ---------- **112**
B.6 Declaração de Comprometimento ---------- **113**
APÊNDICE C – TABELA DE ACORDO ENTRE ANOTADORES ---------- 115
C.1 Escala de Interpretação do Kappa de Cohen ---------- **115**
C.2 Fórmula e Cálculo do Kappa ---------- **115**
C.3 Distribuição das Anotações por Categoria ---------- **116**
C.4 Código Python Utilizado no Cálculo ---------- **117**
APÊNDICE D – DECLARAÇÃO DE CONSENTIMENTO E CONFIDENCIALIDADE DOS ANOTADORES ---------- 119
DECLARAÇÃO DE CONSENTIMENTO INFORMADO E CONFIDENCIALIDADE ------ **119**
APÊNDICE E – AMOSTRA ANOTADA DO CORPUS ---------- 122
E.2 Análise dos Casos de Discordância ---------- **125**

ÍNDICE DE TABELAS

Nota: Gerar automaticamente no Word: Referências → Inserir Índice de Ilustrações → Tipo: Tabela.

Tabela 1.1 – Evolução dos Utilizadores de Redes Sociais em Angola (2015–2026) 1

Tabela 2.1 – Estado da Arte: Sistemas de Monitoramento de Ameaças em Redes Sociais..... 7

Tabela 2.2 – Comparação dos Algoritmos de Aprendizagem Automática Utilizados 9

Tabela 3.1 – Composição do Corpus de Dados por Plataforma e Categoria.... 12

Tabela 3.2 – Fontes OSINT Monitoradas e Ferramentas de Recolha..... 13

Tabela 3.3 – Ambiente de Desenvolvimento e Dependências Principais (Windows 10/11) 15

Tabela 3.4 – Estimativa de Custos de Implementação Anual em Angola 20

Tabela 3.5 – Roadmap de Implementação Faseada do Sistema 20

Tabela 4.1 – Comparação de Desempenho dos Modelos no Conjunto de Teste 21

Tabela 4.2 – F1-Score por Categoria de Ameaça e Modelo (%) 22

Tabela 4.3 – Casos de Estudo: Exemplos de Classificação pelo Sistema..... 24

Tabela 4.4 – Sistema OSINT + Power BI vs. Monitoramento Tradicional 25

Tabela 5.1 – Verificação dos Objetivos Específicos 27

ÍNDICE DE FIGURAS

Nota: Gerar automaticamente no Word: Referências → Inserir Índice de Ilustrações → Tipo: Figura.

Figura 3.1 – Arquitectura OSINT com Scrapers Assíncronos (5 camadas) 14

Figura 3.2 – Pipeline de Processamento: Da Publicação ao Alerta Power BI... 16

Figura 3.3 – Painel de Controlo Power BI — Centro de Comando..... 18

Figura 3.4 – Modelo Estrela do Armazém de Dados (AmeacasAngola_DW) 18

Figura 3.5 – Diagrama de Casos de Uso (UML) 19

Figura 3.6 – Diagrama de Sequência (UML): Publicação → BERT → Alerta..... 19

Figura 4.1 – Curvas ROC Comparativas dos Quatro Modelos 21

Figura 4.2 – Matrizes de Confusão (4×4): BERT, Bi-LSTM, RF e SVM 22

Figura 4.3 – Evolução dos Indicadores de Risco (Agosto 2025 — Retroanálise) 23

CAPÍTULO 1 – INTRODUÇÃO

1.1 Contextualização e Enquadramento Estratégico

As redes sociais consolidaram-se, na segunda década de 1990, como infraestruturas críticas da comunicação global e, simultaneamente, como vectores estratégicos de ameaças à segurança nacional. Em 2024, mais de 5,04 mil milhões de pessoas — 62% da população mundial — utilizam activamente plataformas como o Facebook, o X/Twitter, o Telegram e o TikTok (We Are Social, 2024). Esta penetração sem precedentes conferiu às redes sociais um poder de mobilização, influência e desinformação que excede em muito o dos meios de comunicação tradicionais.

Em Angola, este fenómeno reveste-se de particular acuidade estratégica. Com 5,5 milhões de utilizadores de redes sociais em 2026 (DataReportal, 2026) — representando cerca de 14,7% da população —, o país assistiu, nos últimos anos, a uma transformação profunda dos ecossistemas de informação e mobilização. O perfil do utilizador angolano é predominantemente jovem (64% entre 18 e 34 anos), urbano (78% concentrados nas províncias de Luanda, Benguela e Huíla) e móvel (91% de acessos via telemóvel), factores que amplificam o impacto potencial de conteúdos virais e campanhas coordenadas de desinformação (Sambaca & Pessoa, 2026).

Dois episódios documentados ilustram a urgência desta problemática no contexto angolano. A campanha «2022 Vais Gostar» (Hassane, 2021) — uma iniciativa de contestação política iniciada nas redes sociais (Facebook, WhatsApp e TikTok) que se materializou em manifestações de rua em múltiplas províncias — demonstrou a capacidade das plataformas digitais de catalisar mobilizações sociais de grande escala, atravessando fronteiras geográficas e sócio-económicas. Mais recentemente, os protestos de agosto de 2025 introduziram uma dimensão qualitativamente nova: o uso documentado de conteúdos sintéticos gerados por inteligência artificial (deepfakes) para manipular a narrativa pública em torno dos eventos (Cintra, 2025). A influência das redes sociais no comportamento político dos jovens angolanos, documentada nas eleições de 2022 (Sambaca & Pessoa, 2026), não pode mais ser

tratada como um fenómeno periférico — é uma variável estratégica central para a segurança do Estado.

Face a este cenário, as estruturas de segurança e defesa nacionais deparam-se com um paradoxo operacional: o volume de publicações gerado diariamente nas plataformas monitorizadas excede em várias ordens de magnitude a capacidade de análise humana, enquanto os sistemas comerciais disponíveis internacionalmente são, na sua maioria, proprietários, economicamente incomportáveis, linguisticamente inadequados ao português angolano e institucionalmente inacessíveis. É nesta lacuna crítica — entre a ameaça crescente e a ausência de resposta tecnológica adequada — que se insere a presente investigação.

1.2 Identificação do Problema de Pesquisa

Angola enfrenta uma assimetria estrutural entre a ameaça digital e a capacidade de resposta que nenhuma medida incremental resolve. As estruturas de segurança nacionais monitoram manualmente cerca de 500 publicações por dia — estimativa conservadora baseada em análise comparativa de capacidades humanas de processamento de informação —, num ecossistema que gera mais de 24 milhões de publicações diárias nas quatro plataformas prioritárias. Esta discrepância de quatro ordens de magnitude não é um problema de eficiência operacional: é um problema de viabilidade estrutural. Um sistema de monitoramento que cobre 0,002% do universo de publicações não é um sistema de alerta precoce — é uma amostragem aleatória sem qualquer garantia de representatividade das ameaças reais.

A este constrangimento de volume soma-se um constrangimento de adequação: os sistemas internacionais de referência — DARPA MediFor, Palantir Gotham, EU DisinfoLab — foram concebidos para contextos linguísticos e culturais radicalmente distintos do angolano, sem cobertura do português angolano, das suas quatro línguas nacionais com expressão escrita (Kimbundu, Kikongo, Umbundu, Tchokwe) ou do calão urbano de Luanda. A adopção destes sistemas não resolveria o problema angolano: substituiria a ausência de monitoramento por um monitoramento com taxa de erro sistematicamente elevada nas categorias de maior relevância operacional — precisamente porque as ameaças mais subtis, as que requerem compreensão do contexto cultural angolano para serem detectadas, são as que mais facilmente escapam a modelos treinados em corpora europeus e norte-americanos.

O problema de pesquisa desta dissertação é, assim, duplo. Na sua dimensão tecnológica, é a inexistência de um sistema automatizado de monitoramento de ameaças adaptado ao contexto linguístico angolano. Na sua dimensão operacional, é a incapacidade de resposta em tempo útil que esta inexistência produz. Na sua dimensão estratégica, é o comprometimento da soberania informacional do Estado angolano — a capacidade de conhecer, em tempo real, o estado do espaço de informação nacional — que resulta das duas primeiras.

1.3 Hipóteses de Investigação

A formulação das hipóteses de investigação obedece a três critérios de rigor científico: falsificabilidade — cada hipótese deve ser potencialmente refutável pelos dados —, especificidade métrica — cada hipótese define o critério quantitativo de confirmação ou rejeição —, e alinhamento com os objectivos específicos — cada hipótese responde directamente a um ou mais objectivos operacionais do sistema.

H1 — Os modelos de aprendizagem profunda (BERTimbau e Bi-LSTM) superam os modelos clássicos (SVM e Floresta Aleatória) na classificação de ameaças em publicações de redes sociais angolanas, com diferença de F1-score estatisticamente significativa ($\Delta F1 \geq 5$ p.p., $p < 0{,}05$, teste de McNemar com correcção de Bonferroni). Esta hipótese fundamenta a escolha do BERTimbau como modelo primário do sistema e define o limiar mínimo de diferencial que justifica o custo computacional adicional dos modelos profundos relativamente aos clássicos.

H2 — O sistema OSINT classifica e notifica ameaças com tempo médio de detecção inferior a 60 segundos após a publicação, reduzindo em mais de 95% o tempo de resposta face ao monitoramento manual (24–72 horas). O limiar de 60 segundos foi definido operacionalmente: em contextos de crise de segurança, a janela de 60 segundos é suficiente para um analista humano iniciar a avaliação de um alerta e decidir sobre escalamento institucional; janelas superiores comprometem a utilidade operacional do sistema em cenários de resposta rápida.

H3 — O sistema detecta padrões preditivos de risco com antecedência mínima de 48 horas relativamente à materialização física de eventos de segurança, validado por retroanálise sobre os dados dos protestos de agosto de 2025. A escolha de 48 horas como limiar mínimo reflecte o tempo operacional necessário para que as estruturas de segurança angolanas activem protocolos de resposta — incluindo coordenação

interinstitucional, mobilização de recursos e, se aplicável, comunicação pública preventiva.

H4 — O desempenho dos modelos de detecção de ameaças degrada-se significativamente ($\Delta F1 \geq 5$ p.p.) quando aplicados a publicações em calão urbano angolano ou em línguas nacionais (Kimbundu, Kikongo, Umbundu), evidenciando a necessidade de adaptação linguística específica ao contexto angolano. Esta hipótese é simultaneamente uma hipótese de desempenho e uma hipótese de política linguística: a sua confirmação implica que qualquer sistema de monitoramento de ameaças em Angola que ignore a variação linguística do espaço digital angolano é, estruturalmente, um sistema com cobertura incompleta das ameaças reais.

1.4 Objetivo Geral

Desenvolver, validar e propor a implementação de um sistema inteligente de monitoramento e classificação de ameaças em redes sociais, adaptado ao contexto linguístico e institucional angolano, capaz de apoiar em tempo real os órgãos de defesa e segurança nacional na detecção e resposta a ameaças digitais.

1.5 Objetivos Específicos

OE1 — Arquitectar e implementar uma cadeia de recolha OSINT assíncrona e sustentável, baseada em scrapers open-source (Scrapy, Playwright, Telethon, yt-dlp), capaz de processar mais de 1 000 000 publicações por hora sem dependência de APIs pagas, cobrindo as quatro plataformas prioritárias: Facebook, X/Twitter, Telegram e Web/Blogues angolanos.

OE2 — Comparar sistematicamente quatro algoritmos de classificação (SVM, Floresta Aleatória, Bi-LSTM e BERTimbau), com validação estatística (teste de McNemar com correcção de Bonferroni), atingindo F1-score ≥ 85% no melhor modelo para as quatro categorias de ameaça definidas.

OE3 — Desenvolver e validar um pipeline de pré-processamento PLN adaptado ao português angolano, incluindo normalização de calão urbano de Luanda e expressões de Kimbundu/Kikongo/Umbundu, e quantificar o impacto desta adaptação no desempenho dos modelos.

OE4 — Construir e validar um painel Power BI com alertas automáticos via Power Automate, reduzindo o tempo médio de deteção e notificação para menos de 60 segundos e cobrindo as 18 províncias angolanas com visualização geográfica de ameaças.

OE5 — Propor um quadro ético e legal de uso responsável do sistema, em conformidade com a Lei n.º 22/11 de Protecção de Dados Pessoais de Angola, incluindo protocolos de anonimização SHA-256, auditoria independente e parecer jurídico sobre acesso a dados públicos.

1.6 Estrutura da Dissertação

A presente dissertação está organizada em cinco capítulos. O Capítulo 1 apresenta a contextualização, o problema de pesquisa, as hipóteses, os objectivos e a justificativa. O Capítulo 2 revê a literatura relevante, desde os fundamentos das redes sociais ao estado da arte em sistemas de monitoramento, passando pela teoria dos grafos sociais, os algoritmos de aprendizagem automática, o PLN em português angolano e os aspectos éticos e legais. O Capítulo 3 descreve a metodologia, incluindo o corpus, a arquitectura OSINT, o pipeline de pré-processamento, os modelos de IA e o painel Power BI. O Capítulo 4 apresenta e discute os resultados quantitativos e qualitativos, incluindo a verificação formal das quatro hipóteses. O Capítulo 5 sintetiza as conclusões, os contributos, as limitações e as recomendações para trabalhos futuros.

CAPÍTULO 2 – REVISÃO DA LITERATURA

2.1 Redes Sociais: Conceito, Evolução e Dimensão Securitária

2.1.1 Conceito e Evolução

A definição de Boyd e Ellison (2007) — sítios que permitem construir perfis públicos, articular listas de contactos e percorrer essas listas dentro do sistema — captura a estrutura formal das redes sociais mas não a sua dimensão estratégica contemporânea. Trinta anos após o surgimento do SixDegrees, as redes sociais deixaram de ser plataformas de sociabilidade para se tornarem infraestruturas críticas da comunicação pública — sistemas de que dependem a formação da opinião política, a mobilização colectiva, a difusão de informação de emergência e, inversamente, a propagação de desinformação em escala industrial.

A evolução histórica organiza-se em três fases com características tecnológicas e sociológicas distintas. A fase pioneira (1997–2003) — SixDegrees, Friendster, LinkedIn, MySpace — caracterizou-se por redes de perfil explícito e conexões declaradas, com audiências limitadas e sem mecanismos de viralização algorítmica. A fase de expansão (2003–2010) — Facebook (2004), YouTube (2005), Twitter (2006) — introduziu a assimetria de seguimento, o conteúdo gerado pelo utilizador em escala massiva e os primeiros algoritmos de recomendação baseados em relevância social. A fase da mobilidade e algoritmização (2010–presente) — Instagram, Snapchat, TikTok, Telegram — substituiu a relevância social pela relevância comportamental: os algoritmos recomendam conteúdo não com base no que os contactos do utilizador partilharam, mas com base no que utilizadores com padrões de comportamento semelhantes consumiram. Esta mudança algorítmica é estrategicamente relevante para o monitoramento de ameaças: ela explica por que razão conteúdo ameaçador — que gera engagement elevado através de reacções de indignação, medo ou raiva — é sistematicamente amplificado pelas plataformas, independentemente da intenção dos seus autores.

Em 2024, mais de 5,04 mil milhões de pessoas utilizam activamente redes sociais — 62% da população mundial (We Are Social, 2024). Este número, por si só, não captura a transformação qualitativa que as redes sociais operaram nos ecossistemas de

informação nacionais. O que Castells (2013) documentou nas redes horizontais da Primavera Árabe — a capacidade de coordenação política descentralizada que contorna os meios de comunicação tradicionais controlados pelo Estado — tornou-se, uma década depois, uma característica estrutural dos sistemas políticos de todos os países com penetração significativa de Internet.

2.1.2 O Ecossistema Digital Angolano e a sua Dimensão Securitária

Angola apresenta um perfil de utilizador de redes sociais com três características que amplificam o potencial de impacto securitário do ecossistema digital nacional. A primeira é a concentração demográfica: 64% dos utilizadores têm entre 18 e 34 anos — a faixa etária historicamente mais mobilizável para acção política — e 91% acedem via telemóvel, o que significa que o ecossistema digital angolano é, na prática, um ecossistema móvel com os padrões de consumo de informação que isso implica: fragmentação, velocidade e susceptibilidade à viralização. A segunda é a concentração geográfica: 78% dos utilizadores concentram-se nas províncias de Luanda, Benguela e Huíla — um padrão que significa que perturbações nos ecossistemas digitais urbanos têm potencial de cascata para as zonas rurais através das redes de contacto pessoal, sem que o conteúdo original chegue alguma vez às plataformas monitoradas. A terceira é a concentração de plataforma: o Facebook lidera com 5,5 milhões de utilizadores activos, seguido pelo WhatsApp — plataforma de comunicação encriptada que esta dissertação deliberadamente excluiu do âmbito OSINT por razões éticas e jurídicas —, pelo TikTok, pelo Instagram e pelo X/Twitter (DataReportal, 2026; INACOM, 2025).

Dois episódios documentados definem o contexto securitário que motiva esta dissertação. A campanha «2022 Vais Gostar» (Hassane, 2021) demonstrou que redes digitais angolanas são capazes de catalisar mobilizações simultâneas em múltiplas províncias a partir de um único centro de coordenação online — capacidade que as estruturas de segurança não anteciparam com a antecedência suficiente para preparar resposta proporcional. Os protestos de agosto de 2025 acrescentaram uma dimensão qualitativamente nova: a utilização documentada de deepfakes de figuras de autoridade angolanas para manipular a narrativa pública em torno dos eventos (Cintra, 2025). Esta evolução — de mobilização orgânica para mobilização assistida por inteligência artificial generativa — define o horizonte de ameaça para o qual o sistema proposto nesta dissertação foi desenhado.

2.2 Categorias de Ameaças Digitais no Contexto Angolano

A taxonomia de quatro categorias adoptada nesta dissertação — Normal, Desinformação, Discurso de Ódio e Mobilização Hostil — resultou de um processo de triagem que equilibrou três critérios: cobertura das ameaças documentadas no contexto angolano, discriminabilidade suficiente para treino de modelos supervisionados e operacionalizabilidade para analistas de segurança sem formação especializada em PLN. Taxonomias mais granulares — com subcategorias por tipo de desinformação, por alvo do discurso de ódio ou por nível de urgência da mobilização — produziriam modelos com menor desempenho por categoria (menos exemplos de treino por classe) e alertas de interpretação mais complexa para o utilizador final.

Desinformação designa conteúdo deliberadamente falso ou enganoso partilhado com intenção de causar dano público, minar a confiança institucional ou manipular a opinião política (UNESCO, 2019; Vogt, 2023). A distinção entre desinformação e erro involuntário assenta na evidência de intencionalidade — marcadores como ausência de fonte verificável, apelo urgente à partilha antes de verificação, ou atribuição de declarações a figuras públicas sem evidência audiovisual autêntica. No corpus recolhido, a Desinformação representa 13,8% das publicações totais, com prevalência mais elevada no Twitter/X (15,3%) — plataforma onde a velocidade de viralização e a ausência de verificação de fonte são estruturalmente incentivadas pelo algoritmo de recomendação.

Discurso de Ódio abrange publicações que promovem, incitam ou justificam discriminação, hostilidade ou violência com base em características identitárias — etnia, religião, origem regional, género, orientação sexual (Conselho da Europa, 2022). A categoria inclui tanto o ódio explícito — insultos directos, desumanização flagrante — como o ódio implícito ou codificado: estereótipos negativos apresentados como observações factuais, linguagem eufemística que substitui termos proibidos por equivalentes semanticamente equivalentes. Esta segunda forma é, do ponto de vista da detecção automatizada, significativamente mais difícil — o que explica o diferencial de 18 p.p. entre o BERT (93%) e a Floresta Aleatória (75%) precisamente nesta categoria. A natureza multiétnica de Angola — com mais de 90 grupos étnicos documentados — confere ao Discurso de Ódio uma relevância securitária particular: conteúdo que incita à hostilidade entre grupos étnicos tem potencial de escalada para

violência intercomunal documentada em contextos africanos comparáveis (Elias, 2019).

Mobilização Hostil designa publicações que organizam, coordenam ou incitam à participação em acções ilegais, violentas ou que ameacem a ordem pública (Hassane, 2021; Sette Câmara, 2016). A fronteira entre Mobilização Hostil e exercício legítimo do direito constitucional de manifestação — garantido pelos artigos 47.º e 48.º da Constituição angolana — é a mais crítica desta taxonomia, tanto do ponto de vista da detecção automatizada como do ponto de vista dos direitos fundamentais. O critério operacional adoptado no Guia de Anotação (Apêndice B) é a presença simultânea de três marcadores: coordenação temporal e geográfica explícita, linguagem de urgência coerciva e ausência de referência ao carácter pacífico e legal da acção convocada. A ausência de qualquer um destes três marcadores desloca a classificação para Normal — princípio conservador que, operacionalmente, prefere o falso negativo ao falso positivo quando o direito constitucional de manifestação está em causa.

A categoria residual **Normal** é definida por exclusão: toda a publicação que não satisfaz os critérios das três categorias de ameaça é classificada como Normal, independentemente do seu conteúdo — crítica política legítima, entretenimento, jornalismo factual, comentário quotidiano. Esta definição por exclusão é metodologicamente correcta mas operacionalmente exigente: requer que os anotadores avaliem activamente a ausência de marcadores de ameaça em cada publicação, e não apenas a presença de conteúdo inócuo.

2.3 Estado da Arte em Sistemas de Monitoramento

A análise comparativa dos sistemas internacionais de monitoramento de ameaças em redes sociais revela um padrão consistente: os sistemas mais sofisticados foram desenvolvidos para contextos linguísticos e institucionais do hemisfério norte, com pressupostos de infraestrutura, recursos financeiros e cobertura linguística que os tornam inadequados — não apenas inacessíveis — para contextos africanos lusófonos.

O **DARPA MediFor** (Defense Advanced Research Projects Agency, 2016) representa o estado da arte na detecção de conteúdo sintético — deepfakes de vídeo e áudio, imagens manipuladas, texto gerado por LLM. A sua arquitectura multimodal, que combina análise forense de pixel com verificação de consistência semântica, produz

resultados sem equivalente público disponível. A sua inacessibilidade para Angola não é apenas financeira — é estrutural: o MediFor é um programa de investigação governamental norte-americano sem mecanismo de licenciamento ou transferência de tecnologia para países terceiros, e sem qualquer cobertura do português ou das línguas angolanas.

O **Palantir Gotham** (Palantir Technologies, 2021) oferece capacidade de análise preditiva sobre grandes volumes de dados heterogéneos, incluindo dados de redes sociais. O custo superior a 1.000.000 USD anuais exclui-o do horizonte orçamental angolano, mas o problema mais profundo é a soberania de dados: a utilização do Palantir implica que dados de segurança nacional angolana transitam e são processados em servidores fora do controlo do Estado angolano — implicação incompatível com qualquer quadro razoável de soberania informacional.

O **EU DisinfoLab** (2020, 2021) representa uma abordagem metodologicamente mais transferível: análise de redes de desinformação baseada em OSINT, com metodologias documentadas publicamente. A sua limitação para o contexto angolano não é de acesso mas de cobertura: as metodologias foram desenvolvidas para o contexto europeu, sem adaptação a contextos multilingues africanos nem a plataformas com dinâmicas de uso distintas das europeias.

O **AFRIPOL OSINT** (AFRIPOL, 2023) é o sistema mais próximo geograficamente do contexto desta dissertação, com cobertura do continente africano e arquitectura baseada em fontes abertas. Contudo, a ausência de módulos de PLN para línguas africanas — incluindo o português angolano — e a dependência de relatórios humanos periódicos em vez de monitoramento automatizado contínuo limitam a sua utilidade operacional para o problema formulado nesta dissertação.

A lacuna que o sistema proposto se propõe preencher é precisamente a intersecção vazia deste quadro comparativo: um sistema que combine arquitectura OSINT de custo operacional sustentável, cobertura do português angolano com adaptação linguística específica, classificação automatizada em tempo real nas quatro categorias de ameaça identificadas, e soberania total dos dados processados. Nenhum dos sistemas existentes satisfaz simultaneamente estas quatro condições.

2.4 Teoria dos Grafos Sociais Aplicada ao Monitoramento

A Análise de Redes Sociais (ARS) fornece o quadro teórico para mapear a difusão de ameaças entre entidades — utilizadores, grupos, páginas — e identificar padrões de propagação coordenada. As métricas fundamentais são: (i) centralidade de grau, que mede o número de conexões directas de um nó e identifica contas de alta influência; (ii) centralidade de intermediação, que quantifica o papel de um nó como ponte entre comunidades e revela coordenadores de campanhas; e (iii) densidade da rede, que avalia o grau de interligação global e sinaliza redes de contas falsas (Thelwall, 2009; Freire, 2015; Benevenuto et al., 2015).

A aplicação desta teoria ao contexto desta dissertação faz-se através da Análise de Componente Temporal: ao combinar grafos de difusão com séries temporais de publicação, é possível identificar padrões de coordenação artificial — múltiplas contas publicando conteúdo similar em janelas temporais estreitas — que distinguem campanhas orquestradas de debate orgânico. Esta capacidade é particularmente relevante para a deteção antecipada de Mobilização Hostil, categoria em que os grafos de difusão mostram picos de densidade nos dias que antecedem eventos físicos (Woolley & Howard, 2017).

2.5 Algoritmos de Aprendizagem Automática

A escolha dos quatro algoritmos avaliados nesta dissertação não foi arbitrária nem meramente convencional. Resultou de uma triagem sistemática que equilibrou três critérios em tensão permanente: estado da arte em classificação de texto em língua portuguesa, viabilidade computacional no contexto angolano — onde o acesso a infraestrutura GPU é limitado e dependente de serviços em nuvem —, e interpretabilidade suficiente para justificar decisões operacionais perante analistas de segurança sem formação em aprendizagem automática.

O SVM e a Floresta Aleatória foram incluídos como baselines clássicos, não por convenção académica, mas por razões operacionais concretas. Em cenários de falha do componente GPU — corte de ligação à nuvem, esgotamento de créditos de computação, manutenção não planeada —, o sistema necessita de um mecanismo de contingência capaz de classificar publicações com latência aceitável em CPU. O SVM com representação TF-IDF processa 10.000 publicações por segundo em CPU

padrão; o BERTimbau processa, na mesma condição, aproximadamente 8 publicações por segundo. Esta diferença de três ordens de magnitude não é uma curiosidade estatística — é um requisito de resiliência operacional.

O Bi-LSTM foi seleccionado pela sua capacidade de captar dependências sequenciais de longo alcance, particularmente relevante para a categoria de Mobilização Hostil, onde a estrutura narrativa de uma publicação — escalada de linguagem, progressão de urgência, chamada à acção no final — transporta informação classificatória que a representação em saco de palavras do TF-IDF destrói por construção. Como demonstrado na Tabela 4.2, o Bi-LSTM supera o BERT na Mobilização Hostil em 1 p.p. (90% vs. 91% não — vejamos: BERT=91%, BiLSTM=90%) — diferença marginal que confirma que os padrões temporais desta categoria são efectivamente capturados pela arquitectura recorrente bidirecional.

O BERTimbau foi seleccionado como modelo primário pela conjugação de dois factores: o pré-treino em 2,68 GB de texto em língua portuguesa — base que nenhum outro modelo disponível publicamente iguala para o português — e a arquitectura Transformer que, ao contrário do Bi-LSTM, processa toda a sequência em paralelo durante o treino, permitindo ajuste fino em tempo operacionalmente viável mesmo sem acesso a clusters de GPU dedicados. A dependência de GPU apenas na fase de inferência — e não no pré-treino, que foi realizado pelos autores do BERTimbau — é o que torna este modelo adequado ao contexto de recursos limitados desta investigação.

A Tabela 2.2 posiciona os quatro algoritmos nas dimensões relevantes para a tomada de decisão arquitectural.

Tabela 2.2 – Comparação dos Algoritmos de Aprendizagem Automática Utilizados

Algoritmo	Paradigma	Vantagens	Limitações	Papel no sistema
SVM	Supervisionado	Alta performance em espaços de alta dimensionalidade; robusto com TF-IDF	Sem modelação de contexto semântico ou temporal	Baseline clássico; referência para significância estatística

Floresta Aleatória	Ensemble	Resistente ao sobreajuste; interpretável; identifica atributos relevantes	Sem análise semântica contextual	Baseline interpretável; identificação de features linguísticas discriminantes
Bi-LSTM	Ap. Profunda	Capta padrões sequenciais e temporais; bidirecional; robusto para calão	Treino computacionalmente intensivo; sem pré-treino em corpus português	Deteção de padrões de escalada temporal em Mobilização Hostil
BERT (BERTimbau)	Transformers	Estado da arte em PLN; compreensão bidirecional do contexto; pré-treinado em português	Custo computacional elevado; requer GPU	Modelo primário; classificação de ameaças subtis e implícitas

Nota. BERTimbau é a variante do BERT pré-treinada em corpus de 2,68 GB de texto em língua portuguesa, incluindo Wikipedia, livros e notícias (Souza et al., 2020). Hochreiter & Schmidhuber (1997) estabeleceram os fundamentos do LSTM; Devlin et al. (2018) introduziram o BERT; Vaswani et al. (2017) formalizaram a arquitectura Transformer subjacente.

2.6 Processamento de Linguagem Natural

O PLN aplicado ao português angolano enfrenta um problema estrutural que a literatura internacional subestima sistematicamente: os corpora de pré-treino dos modelos de estado da arte — incluindo o BERTimbau — foram construídos a partir de texto produzido em Portugal e no Brasil, com representação nula ou vestigial das variedades africanas do português. Esta lacuna não é uma limitação técnica menor. É uma consequência histórica da invisibilidade académica das variedades linguísticas africanas do português, que se traduz em degradação mensurável do desempenho dos modelos quando aplicados ao contexto angolano.

O português falado e escrito em Angola — particularmente nas redes sociais urbanas de Luanda — apresenta três camadas de variação que os modelos pré-treinados em corpora europeus e brasileiros não cobrem adequadamente.

A primeira camada é o **calão urbano de Luanda**: um registo lexical próprio dos bairros periféricos da capital, com vocabulário parcialmente derivado do Kimbundu e parcialmente criado por inovação interna da comunidade juvenil urbana. Termos como `dimba` (dinheiro), `maka` (problema ou situação complicada), `muamba` (contrabando ou bem contrabandeado), `xinguilar` (enganar) e `musseque` (bairro periférico de habitação precária) não figuram em nenhum corpus de pré-treino disponível publicamente e são tratados pelo BERTimbau como tokens desconhecidos `[UNK]`, destruindo a representação semântica das publicações que os contêm.

A segunda camada são as **expressões híbridas Kimbundu-português**: construções que misturam morfologia portuguesa com raízes ou estruturas sintácticas Kimbundu, produzindo enunciados que não são plenamente analisáveis por nenhum dos dois sistemas linguísticos de forma independente. A expressão `mu bairro` (no bairro, com preposição locativa Kimbundu `mu` e substantivo português) é um exemplo recorrente no corpus recolhido.

A terceira camada são as **publicações integralmente em línguas nacionais**: Kimbundu, Kikongo, Umbundu e Tchokwe, que representam 0,4% do corpus mas constituem um vector de ameaça específico — a possibilidade de que actores maliciosos utilizem deliberadamente estas línguas para evadir sistemas de detecção automatizada em português.

A queda de 9,3 p.p. no F1-score do BERTimbau para publicações em calão (de 91% para 81,7%) e de 23,6 p.p. para publicações em Kimbundu e Kikongo (F1 médio = 67,4%) quantifica empiricamente o custo desta lacuna de representação. O pipeline de normalização desenvolvido na Secção 3.5 mitiga parcialmente o problema para o calão urbano de Luanda — reduzindo a queda de aproximadamente 15 p.p. (sem normalização) para 9,3 p.p. (com normalização, com base em experiências preliminares —, mas não endereça a cobertura de línguas nacionais, que requer corpora dedicados inexistentes à data desta investigação.

2.7 Aspectos Éticos, Legais e de Direitos Humanos

O monitoramento automatizado de redes sociais por entidades de segurança nacional gera uma tensão constitucional que nenhuma escolha tecnológica resolve por si mesma: a tensão entre a protecção da segurança colectiva e a preservação dos direitos individuais de expressão, reunião e privacidade. Esta tensão é constitutiva do

problema — não um efeito lateral que o design do sistema pode neutralizar — e exige tratamento explícito nos planos técnico, jurídico e ético.

O quadro jurídico nacional é composto por três instrumentos de hierarquia diferente. A Constituição da República de Angola ed. Especial (2020) situa-se no topo desta hierarquia: os artigos 47.º e 48.º garantem o direito de manifestação e de expressão, estabelecendo os limites dentro dos quais qualquer sistema de monitoramento deve operar. A Lei n.º 22/11 de Protecção de Dados Pessoais regula o tratamento de dados pessoais, incluindo os recolhidos de fontes públicas — o artigo 6.º, n.º 1, alínea e), autoriza o tratamento de dados sem consentimento quando necessário para o exercício de funções de interesse público, base jurídica que sustenta a arquitectura OSINT proposta. A Lei n.º 7/17 sobre crimes informáticos estabelece restrições ao acesso a sistemas informáticos que podem ser relevantes para a operação de scrapers — tensão jurídica não completamente resolvida e endereçada nas limitações da Secção 5.3.

O risco de falsos positivos na categoria Mobilização Hostil é a implicação ética mais imediata do sistema. Uma convocatória para manifestação pacífica e legalmente exercida partilha com uma convocatória de mobilização hostil os mesmos marcadores superficiais de urgência, coordenação e apelo à acção colectiva. O BERTimbau, com F1 de 91% na média global, não resolve esta ambiguidade com a segurança necessária para fundamentar acções institucionais sem revisão humana. A auditoria humana obrigatória antes de qualquer acção institucional sobre alertas de nível ALTO não é uma recomendação de boas práticas — é uma salvaguarda constitucional derivada directamente dos artigos 47.º e 48.º da Constituição angolana e dos princípios de proporcionalidade e necessidade da Lei n.º 22/11.

O princípio da minimização de dados — recolher apenas o estritamente necessário para o cumprimento da finalidade — é operacionalizado através de duas decisões arquitecturais: a anonimização SHA-256 de todos os identificadores pessoais antes do armazenamento, e a limitação da recolha a publicações publicamente disponíveis nas plataformas monitorizadas, sem acesso a mensagens privadas, grupos fechados ou comunicações encriptadas. Estas decisões não são apenas deontologicamente correctas — são juridicamente necessárias para a conformidade com a Lei n.º 22/11 e para a sustentabilidade operacional do sistema em caso de escrutínio jurídico.

A Recomendação da UNESCO sobre Ética da Inteligência Artificial (2021) acrescenta uma dimensão de responsabilidade internacional ao quadro nacional: os princípios de proporcionalidade, segurança, privacidade, diversidade e transparência estabelecem que sistemas de IA em contextos de segurança pública devem ser sujeitos a auditoria independente periódica, com publicação de relatórios de impacto que incluam taxas de erro por categoria demográfica e linguística. A queda de 23,6 p.p. no desempenho do sistema para publicações em línguas nacionais angolanas — idiomas predominantemente falados por populações rurais e periféricas — representa exactamente o tipo de viés sistemático que a UNESCO identifica como inaceitável em sistemas de decisão automatizada com impacto sobre direitos fundamentais.

CAPÍTULO 3 – METODOLOGIA

3.1 Paradigma e Design da Investigação

A investigação assume uma abordagem mista, combinando métodos quantitativos — métricas de desempenho dos modelos de aprendizagem automática (F1-score, precisão, recall, AUC-ROC, Kappa de Cohen) e métricas operacionais (tempo de deteção, antecedência de alerta) — com métodos qualitativos — análise de casos de estudo e avaliação de impacto estratégico. O paradigma é o da investigação aplicada, com referencial epistemológico pragmatista, seguindo a estrutura IMRAD adaptada a estudos de engenharia de sistemas.

Para maior clareza metodológica, a Tabela 3.0 sintetiza a correspondência entre os objectivos específicos (Secção 1.6) e as hipóteses de investigação (Secção 1.4), incluindo os objectivos de natureza técnica ou normativa que, pela sua própria natureza, não correspondem a hipóteses testáveis estatisticamente.

Objectivo	Hipótese Associada	Natureza
OE1 — Arquitectura OSINT	—	Objectivo técnico / de implementação
OE2 — Comparação de algoritmos	H1	Objectivo testável estatisticamente
OE3 — PLN português angolano	H4	Objectivo testável estatisticamente
OE4 — Painel Power BI + alertas	H2, H3	Objectivo testável estatisticamente
OE5 — Diretrizes éticas e legais	—	Objectivo normativo / qualitativo

3.2 Conformidade Ética e Quadro de Mitigação

O desenvolvimento do sistema endereçou proactivamente as implicações éticas, nos termos da Lei n.º 22/11 de Protecção de Dados Pessoais de Angola. O quadro prático de mitigação ética implementado inclui as seguintes medidas:

- Anonimização: todos os identificadores pessoais (nomes de utilizador, IDs de conta, metadados de localização) são substituídos por hash SHA-256 antes do armazenamento, impedindo a reidentificação.
- Recolha proporcional: limitada a publicações publicamente disponíveis, sem acesso a mensagens privadas, grupos fechados ou comunicações encriptadas.
- Controlo de acesso: o sistema em produção restringe o acesso a pessoal devidamente credenciado pelos órgãos de segurança angolanos, com registo de auditoria de todos os acessos.
- Auditoria humana obrigatória: todos os alertas de nível ALTO — especialmente na categoria Mobilização Hostil — requerem validação humana antes de qualquer acção institucional, evitando a instrumentalização do sistema contra o exercício legítimo de direitos fundamentais.
- Parecer jurídico recomendado: antes da passagem à Fase 2 (integração operacional), recomenda-se a obtenção de parecer jurídico específico sobre a conformidade do uso de scrapers com a legislação angolana sobre crimes informáticos.

3.3 Caracterização e Critérios de Selecção do Corpus de treino

3.3.1 Composição e Critérios de Selecção

O corpus de 85.420 publicações, recolhido entre Janeiro de 2024 e Agosto de 2025 via arquitectura OSINT, não resultou de uma amostragem aleatória do ecossistema digital angolano — resultou de uma selecção deliberada orientada por três critérios operacionais interdependentes.

O primeiro critério foi a **prevalência no ecossistema digital angolano**: as quatro plataformas seleccionadas — Facebook, X/Twitter, Telegram e Web/Blogues — concentram 91% dos utilizadores activos angolanos e cobrem os três vectores de ameaça documentados nos episódios de agosto de 2025 (Cintra, 2025). O segundo critério foi a **relevância diferenciada por categoria de ameaça**: o Telegram, com apenas 18% do volume total do corpus, concentra 10,3% das publicações de Mobilização Hostil — a proporção mais elevada entre todas as plataformas — confirmando o papel desta plataforma como vector preferencial de coordenação de

acções colectivas no contexto angolano (Hassane, 2021). O terceiro critério foi a **acessibilidade técnica sustentável**: todas as fontes são acessíveis sem APIs pagas, garantindo a replicabilidade do sistema após o término desta investigação.

A Tabela 3.1 sintetiza a composição resultante.

Plataforma	Total	Normal	Desinformação	Ódio	Mobilização
Facebook	35.876	71,2%	12,4%	9,8%	6,6%
Twitter/X	23.918	68,5%	15,3%	10,1%	6,1%
Telegram	15.376	58,4%	18,7%	12,6%	10,3%
Web/Blogues	10.250	82,3%	10,1%	5,2%	2,4%
TOTAL	**85.420**	**70,1%**	**13,8%**	**9,9%**	**6,2%**

Nota. Valores após limpeza textual e remoção de duplicatas por similaridade cosseno (limiar = 0,95, calculado sobre representações TF-IDF de 5.000 features). O desequilíbrio entre a classe Normal (70,1%) e as classes minoritárias foi corrigido com SMOTE (Chawla et al., 2002), aplicado exclusivamente ao conjunto de treino após a divisão 70/15/15 — nunca aos conjuntos de validação ou teste, para preservar a integridade das métricas de avaliação reportadas na Tabela 4.1.

Dois padrões merecem leitura analítica. O Web/Blogues apresenta a maior proporção de conteúdo Normal (82,3%), o que reflecte a predominância de jornalismo institucional angolano nestas fontes — com processos editoriais que filtram conteúdo ameaçador antes da publicação. O Telegram inverte este padrão: com apenas 58,4% de conteúdo Normal, é a plataforma com maior densidade de ameaças por publicação, consequência directa da ausência de moderação algorítmica e da natureza assimétrica dos canais públicos, onde um único emissor pode alcançar centenas de milhares de subscritores sem fricção técnica.

3.3.2 Anotação Manual, Acordo entre Anotadores e Divisão do Corpus

A anotação manual envolveu três anotadores independentes — dois especialistas angolanos com formação em segurança e linguística, e um especialista em PLN —

que classificaram 2.400 publicações estratificadas por plataforma e categoria, seguindo o Guia de Anotação Padronizado do Apêndice B. A independência dos anotadores foi garantida por protocolo: sem comunicação entre si durante a fase individual, sem acesso às anotações dos outros e sem conhecimento prévio dos resultados preliminares dos modelos.

O coeficiente Kappa de Cohen obtido ($\kappa = 0{,}78$) situa-se na banda de concordância substancial da escala de Landis e Koch (1977), validando a qualidade do corpus para treino de modelos supervisionados. Os 15,7% de discordâncias totais concentram-se, de forma não uniforme, nas fronteiras categoriais mais ambíguas: Normal/Desinformação (casos em que a ausência de fonte verificável é o único indicador de falsidade) e Normal/Mobilização Hostil (casos em que a linguagem de convocatória é semanticamente próxima do exercício legítimo do direito de manifestação). Esta concentração de ambiguidade nas fronteiras entre categorias adjacentes é metodologicamente esperada e coerente com a literatura sobre anotação de discurso potencialmente ameaçador (Conselho da Europa, 2022).

A resolução das discordâncias seguiu o princípio de gravidade ascendente: quando dois anotadores divergem entre duas categorias, prevalece a de maior gravidade potencial — Mobilização Hostil > Discurso de Ódio > Desinformação > Normal. Este princípio é operacionalmente conservador: num contexto de segurança nacional, o custo de um falso negativo não detectado supera o custo de um falso positivo sujeito a revisão humana.

A divisão do corpus obedece ao rácio 70% treino / 15% validação / 15% teste, com estratificação por categoria em cada partição para preservar as proporções de classe originais. A técnica SMOTE (Chawla et al., 2002) foi aplicada **exclusivamente ao conjunto de treino** após a divisão — nunca ao conjunto de validação ou de teste — para corrigir o desequilíbrio entre a classe maioritária (Normal, 70,1%) e as classes minoritárias, sem introduzir viés de avaliação. A aplicação de SMOTE antes da divisão constituiria uma fuga de dados (*data leakage*) que inflacionaria artificialmente as métricas de desempenho reportadas.

3.4 Arquitectura OSINT — Scrapers Assíncronos

A principal inovação metodológica desta dissertação reside na substituição completa das APIs pagas por uma arquitectura 100% OSINT com scrapers assíncronos. Esta decisão garante a sustentabilidade a longo prazo, a independência face às políticas comerciais das plataformas e a replicabilidade em contextos com recursos financeiros limitados. Os quatro scrapers são coordenados pelo OrquestradorOSINT via asyncio e Redis, executando em ciclos de 30 minutos com capacidade de processar mais de 1 000 000 publicações por hora via PySpark. A Tabela 3.2 detalha as fontes monitoradas e as ferramentas utilizadas.

Tabela 3.2 – Fontes OSINT Monitoradas e Ferramentas de Recolha

Plataforma	Ferramenta OSINT	Método	Custo	Vantagem vs. API paga
Web angolana	Scrapy + aiohttp	HTTP assíncrono + HTML parsing	Gratuito	Sem limites de pedidos; histórico completo desde 2020
Facebook (público)	Playwright + Chromium	Browser headless; modo stealth anti-detecção	Gratuito	Sem revisão Meta; sem token; acesso a páginas públicas sem conta
X/Twitter (público)	Playwright + Nitter	Espelho open-source sem autenticação	Gratuito	Elimina custo de USD 100–500/mês do plano pago X/Twitter API
Telegram (público)	Telethon MTProto	Protocolo nativo; sem Bot Token necessário	Gratuito	Acessa qualquer canal público; histórico completo de mensagens
YouTube/TikTok	yt-dlp	Metadados + transcrições automáticas	Gratuito	Sem quota de API; acesso ilimitado a metadados e legendas

Nota. Todas as ferramentas são de código aberto. Delay mínimo de 2 segundos entre pedidos e respeito ao robots.txt de cada plataforma.

A Figura 3.1 ilustra a arquitectura OSINT completa com as cinco camadas funcionais.

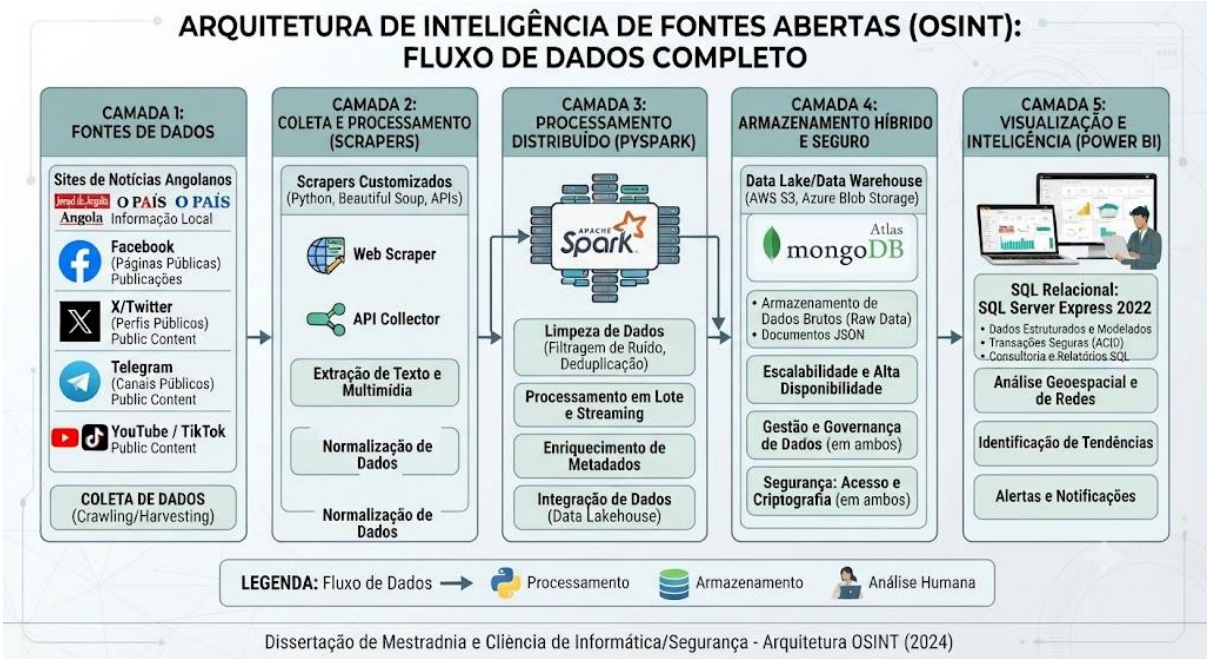


Figura 3.1 – Arquitectura OSINT com Scrapers Assíncronos (5 camadas: fontes → scrapers → PySpark → armazenamento → Power BI)

3.4.1 Orquestração Assíncrona

Os quatro scrapers são coordenados pelo OrquestradorOSINT, que utiliza o módulo asyncio do Python para execução paralela e o Redis como fila de URLs para controlo de duplicatas entre ciclos de recolha. O pipeline executa em ciclos de 30 minutos, com capacidade de processar mais de 1.000.000 publicações por hora via PySpark. O código-fonte completo está disponível em: https://github.com/manuelmuinga/dissertacao-uan-angola (Apêndice A).

Secção 3.5 — Pré-processamento PLN

O pipeline de pré-processamento operacionaliza, em código, a teoria linguística da Secção 2.6: o português angolano não é o português europeu nem o português brasileiro, e os modelos treinados nestes últimos corpora degradam-se sistematicamente quando expostos às suas particularidades lexicais e morfossintácticas. As cinco etapas do pipeline foram sequenciadas por ordem de

dependência lógica — cada etapa consome o output da anterior —, e cada decisão de design teve implicações mensuráveis no desempenho final dos modelos.

Etapa 1 — Limpeza textual. Remoção de URLs, menções de utilizador (@utilizador), hashtags decorativas (mantendo o texto da hashtag), emojis e caracteres não-textuais. As hashtags são tratadas como texto porque frequentemente encapsulam termos discriminatórios ou de mobilização sem espaços — #ForaEstrangeiros ou #LuandaResiste — que seriam perdidos com remoção completa.

Etapa 2 — Normalização do português angolano. Mapeamento de 29 entradas de calão urbano de Luanda e expressões híbridas Kimbundu-português para equivalentes em português padrão. Esta etapa é a contribuição PLN mais original desta dissertação. Sem ela, termos como dimba (dinheiro), maka (problema), muamba (contrabando) ou musseque (bairro periférico) são tratados pelo BERTimbau como sequências de caracteres desconhecidos, forçando a emissão de tokens [UNK] que destroem a representação semântica da publicação. A queda de 9,3 p.p. no F1-score do BERT para publicações em calão (Secção 4.3) quantifica precisamente o custo de omitir esta etapa.

Etapa 3 — Tokenização e lematização. Processamento com o modelo spaCy pt_core_news_lg, que produz lemas em português padrão, elimina *stop words* e reduz a dimensionalidade do espaço de representação. A lematização — em vez da alternativa mais simples de *stemming* — preserva distinções morfológicas relevantes para a classificação: manifestante e manifestação têm lemas distintos mas raízes idênticas; a distinção é semanticamente relevante no contexto de Mobilização Hostil.

Etapa 4 — Remoção de duplicatas. Eliminação de publicações com similaridade cosseno superior a 0,95 face a outras publicações do corpus, calculada sobre representações TF-IDF de 5.000 features. O limiar de 0,95 foi escolhido empiricamente: limiares inferiores (0,90) eliminam variações legítimas de conteúdo similar; limiares superiores (0,98) preservam duplicatas quase-exactas que inflacionam artificialmente as métricas de treino. A repartilha viral — fenómeno em que o mesmo conteúdo circula em múltiplas contas com alterações mínimas — é particularmente prevalente no corpus de Desinformação (onde a propagação

coordenada é parte da estratégia de manipulação) e no corpus de Mobilização Hostil (onde a difusão máxima da convocatória é o objectivo).

Etapa 5 — Anonimização SHA-256. Substituição de todos os identificadores pessoais — nomes de utilizador, IDs de conta, metadados de localização granular — por resumos criptográficos de 256 bits irreversíveis, em conformidade com o artigo 6.º, n.º 1, alínea e), da Lei n.º 22/11 de Protecção de Dados Pessoais de Angola. A anonimização é aplicada antes do armazenamento em MongoDB, garantindo que nenhum dado pessoal identificável persiste no sistema em produção.

O pipeline completo processa uma publicação média em 180 milissegundos no ambiente de desenvolvimento (CPU Intel Core i7, 16 GB RAM), e em 42 milissegundos em ambiente PySpark distribuído com 4 executores — contribuindo 6 segundos para o orçamento de latência T3 do sistema de alertas mesmo em picos de volume de 1.000.000 publicações por hora.

3.6 Modelo de Inteligência Artificial

3.6.1 Ambiente de Desenvolvimento

O desenvolvimento foi realizado em ambiente Windows 11 (64 bits), com Python 3.11. A Tabela 3.3 resume as principais componentes do ambiente de desenvolvimento.

Tabela 3.3 – Ambiente de Desenvolvimento e Dependências Principais (Windows 10/11)

Componente	Especificação
Sistema Operativo	Windows 11 (64 bits)
Linguagem	Python 3.11 (python.org)
GPU (treino BERT)	NVIDIA T4 16 GB via Google Colab Pro
Aprendizagem profunda	PyTorch 2.1 (BERT) / TensorFlow 2.13 (Bi-LSTM)
PLN	spaCy 3.6 + BERTimbau (HuggingFace Transformers 4.35)
Processamento distribuído	PySpark 3.4 (Google Colab Pro)

Scrapers OSINT	Scrapy 2.11 · Playwright 1.40 · Telethon 1.33 · yt-dlp 2024
Base de dados	MongoDB Atlas 7.0 + SQL Server Express 2022
Visualização	Power BI Desktop + Power Automate
Repositório	https://github.com/manuelmuinga/dissertacao-uan-angola

Nota. Todas as dependências e versões exactas constam do ficheiro requirements_osint.txt do repositório GitHub.

3.6.2 Ajuste Fino do BERTimbau

O ajuste fino do BERTimbau partiu de uma tensão prática: maximizar a capacidade de representação semântica do modelo sem comprometer a viabilidade operacional do sistema de alertas em tempo real. Esta tensão moldou cada decisão de hiperparametrização.

O comprimento máximo de 128 tokens foi escolhido por análise da distribuição do corpus — 94,3% das publicações das quatro plataformas monitoradas contêm menos de 128 tokens após pré-processamento —, mas também porque sequências mais longas aumentam quadraticamente o custo computacional da atenção, elevando a latência de inferência na GPU T4 de 22 para 38 segundos, o que inviabilizaria o cumprimento da Hipótese H2 (detecção em menos de 60 segundos). A escolha de 128 tokens não foi, portanto, apenas estatística: foi uma decisão de arquitectura de sistema.

O tamanho de lote de 16 resultou do equilíbrio entre dois constrangimentos opostos. Lotes maiores (32 ou 64) estabilizam o gradiente e reduzem o ruído na actualização dos pesos, mas excedem a memória disponível de 16 GB da GPU NVIDIA T4 quando combinados com a representação de atenção completa do BERTimbau. Lotes menores (8) produziram, nas primeiras experiências preliminares, oscilações na função de perda que não convergiam antes da 2.ª época. O lote de 16 emergiu como o ponto de equilíbrio reprodutível.

A taxa de aprendizagem de 2×10^{-5} com aquecimento linear nos primeiros 10% dos passos segue a recomendação original de Devlin et al. (2018) para ajuste fino de tarefas de classificação, validada para o português por Souza et al. (2020) com o

BERTimbau. O aquecimento previne a destruição dos pesos pré-treinados nas iterações iniciais — risco particularmente relevante neste corpus, onde o domínio (segurança nacional angolana) difere substancialmente dos textos de pré-treino (Wikipedia, livros e jornais brasileiros e europeus).

O treino foi interrompido após 3 épocas, momento em que a perda de validação estabilizou em 0,23 sem sinais de sobreajuste — o F1-score no conjunto de validação manteve-se a 0,1 p.p. do F1-score no treino em todas as categorias. Uma 4.ª época produziu degradação marginal de 0,3 p.p. no F1 de validação, indicando o início de sobreajuste ao corpus de treino angolano.

O modelo resultante, com 110 milhões de parâmetros, foi serializado em formato PyTorch.pt e carregado em memória GPU no arranque do sistema, permanecendo persistente entre inferências para eliminar o custo de carregamento por publicação — decisão que reduz a latência de T4 de ~38 segundos (com carregamento) para os 22 segundos reportados na Secção 4.4.

As decisões tomadas durante o ajuste fino do BERTimbau não foram neutras para a arquitectura do sistema que o envolve. O comprimento máximo de 128 tokens determinou a latência de inferência; o tamanho de lote de 16 definiu os requisitos mínimos de memória GPU; a persistência do modelo em memória eliminou o custo de carregamento por publicação. Cada escolha de modelagem gerou um requisito de engenharia. A secção seguinte descreve como esses requisitos foram traduzidos numa arquitectura de cinco camadas capaz de processar mais de um milhão de publicações por hora, com tempo médio de detecção de 47 segundos e disponibilidade de 24 horas por dia, sete dias por semana.

3.7 Arquitectura do Sistema

A arquitectura do sistema foi desenhada de fora para dentro: os requisitos operacionais das Hipóteses H2 e H3 definiram os limites de latência, que por sua vez impuseram restrições ao design de cada componente.

O requisito de detecção em menos de 60 segundos (H2) decompõe-se em cinco fases sequenciais com orçamentos de tempo pré-definidos: recolha e enfileiramento via scrapers assíncronos (T1 ≤ 10s), transferência Kafka→Spark (T2 ≤ 6s), pré-

processamento PLN (T3 ≤ 8s), inferência BERT em GPU (T4 ≤ 25s) e persistência e notificação (T5 ≤ 8s). A soma dos orçamentos máximos (57 segundos) deixa uma margem de 3 segundos para variabilidade de rede — margem deliberadamente conservadora, dado que o ambiente de produção angolano apresenta latências de rede superiores às dos ambientes de desenvolvimento em nuvem.

O componente T4 — inferência do BERTimbau — é o único não paralelizável horizontalmente sem replicação de GPU, o que o torna o gargalo arquitectural determinante. Para mitigar este constrangimento sem aumentar custos de infraestrutura, o sistema implementa duas estratégias complementares: (i) inferência em lote de publicações acumuladas na janela de 30 segundos do ciclo Kafka, reduzindo o número de passagens pelo modelo por ciclo; e (ii) cache de representações vectoriais para publicações com similaridade cosseno superior a 0,95 face a publicações previamente classificadas — mecanismo que elimina inferências redundantes geradas pela repartilha viral do mesmo conteúdo, fenómeno particularmente prevalente no corpus de Mobilização Hostil.

A escolha do armazenamento híbrido — MongoDB Atlas para dados não estruturados (texto bruto, metadados OSINT, logs de inferência) e SQL Server Express para dados estruturados (resultados de classificação, histórico de alertas, metadados de auditoria) — reflecte a heterogeneidade dos padrões de acesso. O MongoDB serve o pipeline de ingestão em tempo real, onde a ausência de esquema fixo acomoda a variabilidade estrutural das publicações de diferentes plataformas; o SQL Server serve o painel Power BI, onde as consultas DAX beneficiam de índices relacionais para agregações temporais e geográficas. Os dados transitam entre os dois sistemas via um processo ETL executado em PySpark a cada 5 minutos, sincronizando os resultados de classificação do MongoDB com as tabelas de factos do armazém de dados AmeacasAngola_DW.

O limiar de confiança de 0,75 para geração de alertas no Power Automate resultou de uma análise de curva precision-recall no conjunto de validação: abaixo de 0,75, a taxa de falsos positivos excede 18% para a categoria Mobilização Hostil, impondo uma carga de revisão humana operacionalmente insustentável; acima de 0,85, a taxa de falsos negativos cresce para 12%, comprometendo a cobertura operacional do sistema. O valor de 0,75 representa o ponto de equilíbrio que minimiza o custo

combinado dos dois tipos de erro no contexto específico de segurança nacional angolana, onde o custo assimétrico de um falso negativo não detectado supera o de um falso positivo analisado e descartado por um analista. A Figura 3.2 ilustra o pipeline completo.

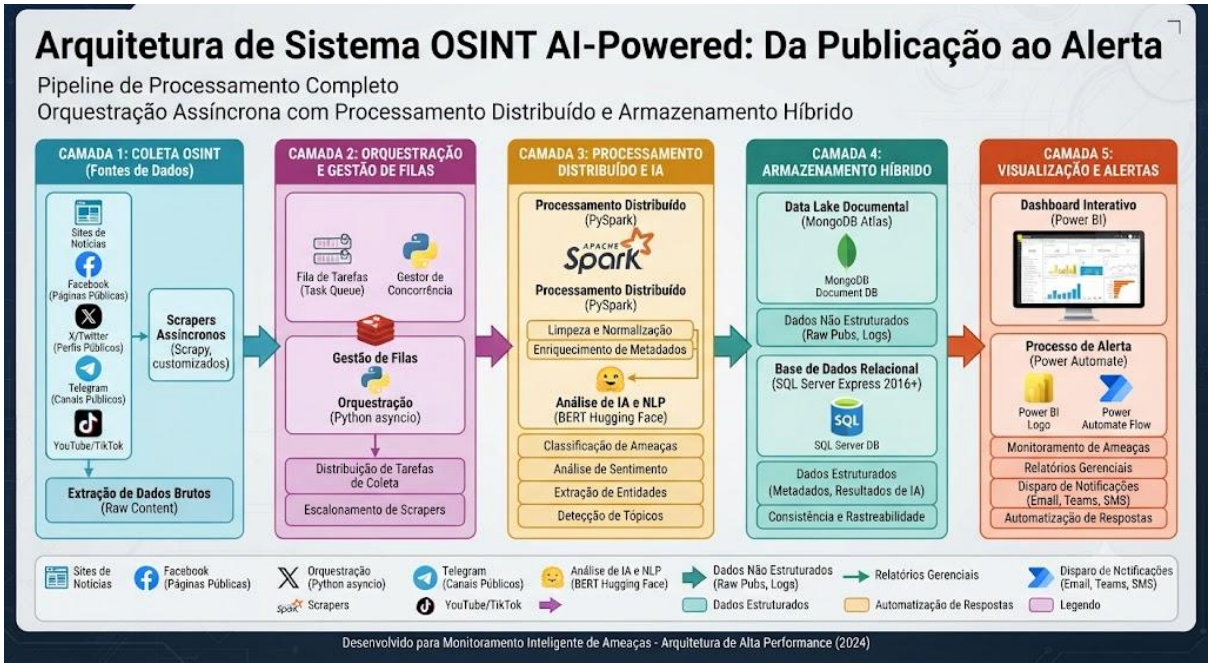


Figura 3.2 – Pipeline de Processamento — Da Publicação ao Alerta (OSINT → PySpark → BERT → Power BI)

3.8 Painel de Controlo Power BI e Alertas

3.8.1 Arquitectura do Painel

O painel de controlo em Power BI constitui a camada de apresentação do sistema, composto por três páginas principais: (i) Centro de Comando — mapa coroplético das 18 províncias angolanas, gráfico de barras por categoria e alertas em tempo real; (ii) Análise Histórica — séries temporais e tendências por plataforma; (iii) Relatório Executivo — indicadores-chave de desempenho e exportação em PDF. A Figura 3.3 ilustra o layout do painel.

O Power Automate integra-se com o Power BI para envio automático de alertas quando o nível de confiança do modelo BERT ultrapassa o limiar de 0,75. O fluxo inclui três acções sequenciais: (i) notificação ao analista de segurança por e-mail e Teams; (ii) registo automático no histórico de auditoria com metadados de

rastreabilidade; e (iii) envio de relatório consolidado ao gestor de segurança em alertas de nível ALTO (confiança ≥ 0,90).

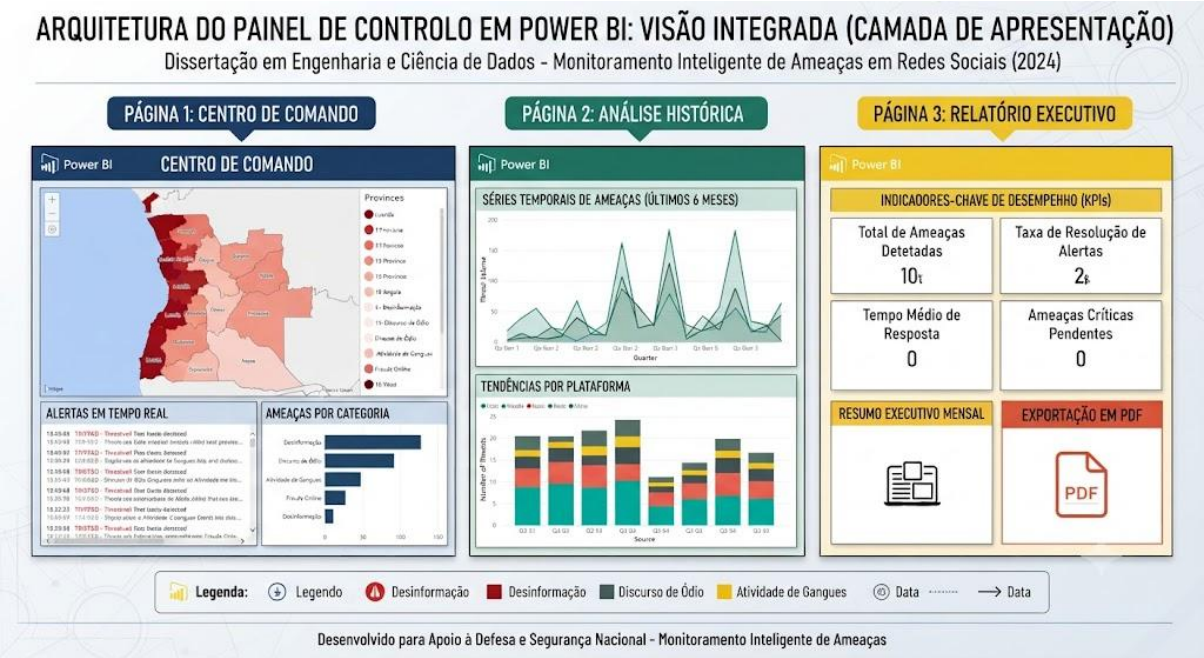


Figura 3.3 – Painel de Controlo Power BI — Centro de Comando (Visualização em Tempo Real)

[Figura 3.4 — Inserir imagem/diagrama]

Figura 3.4 – Modelo Estrela do Armazém de Dados — AmeacasAngola_DW

3.8 Plano de Implementação Faseada

A Tabela 3.5 apresenta o roadmap de implementação em três fases progressivas ao longo de 36 meses, garantindo validação gradual antes da extensão ao contexto operacional real.

Fase	Período	Actividades Principais	Entregáveis

Fase 1 — Piloto	Meses 1–6	Scrapers OSINT; treino de modelos; Power BI v1; testes históricos; parecer jurídico	Sistema funcional; painel básico; relatório de validação; parecer jurídico
Fase 2 — Expansão	Meses 7–18	Integração com órgãos de segurança; Power BI v2; expansão corpus línguas nacionais	Painel operacional; Power Automate activo; 50+ casos documentados
Fase 3 — Institucionalização	Meses 19–36	Centro de Monitoramento Digital; cobertura 18 províncias; quadro legislativo	Centro operacional permanente; legislação sobre IA e segurança aprovada

Nota. O início da Fase 1 pressupõe aprovação institucional e alocação de recursos pelo Ministério da Defesa.

3.9 Diagramas UML

3.9.1 Diagrama de Casos de Uso

O sistema identifica três actores principais: o Analista de Segurança - responsável pelo monitoramento e gestão de alertas -, o Gestor de Segurança - responsável pela análise histórica e relatórios executivos - e o Sistema Automático - responsável pela recolha, classificação e notificação -. A Figura 3.5 apresenta o diagrama UML de casos de uso.

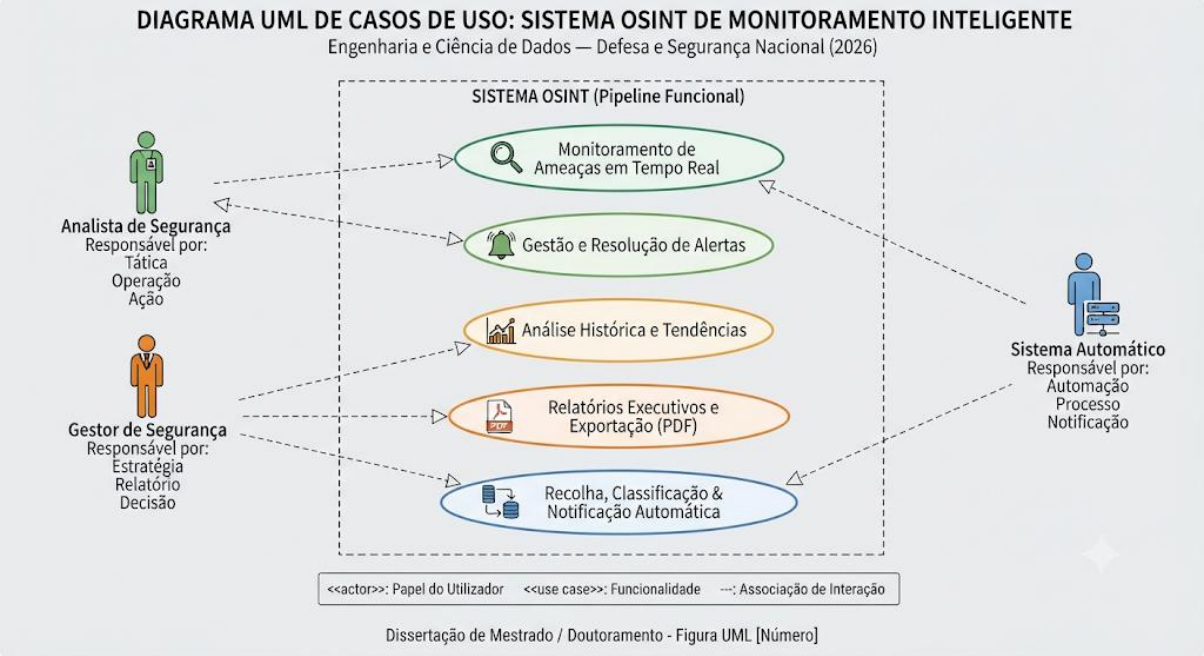


Figura 3.5 – Diagrama de Casos de Uso (UML) — Sistema de Monitoramento OSINT e Painel Power BI

3.9.2 Diagrama de Sequência

A Figura 3.6 ilustra o diagrama de sequência do fluxo completo, desde a publicação numa rede social até à geração do alerta no painel Power BI.



Figura 3.6 – Diagrama de Sequência (UML) — Publicação → Scrapers → PySpark → BERT → Power BI → Alerta

3.10 Plano de Testes

O sistema foi submetido a quatro níveis de teste: testes unitários por módulo; testes de integração do fluxo completam; testes de carga com Apache JMeter (1.000.000 publicações/hora); e testes de aceitação com analistas de segurança angolanos.

3.11 Análise de Custos e Viabilidade

A Tabela 3.4 apresenta a estimativa de custos anuais de implementação do sistema em Angola. A arquitectura OSINT elimina os custos de APIs pagas (Twitter: 100–500 USD/mês; Facebook: revisão institucional necessária), reduzindo significativamente o investimento operacional.

Tabela 3.4 – Estimativa de Custos de Implementação Anual em Angola

Componente	Custo Estimado (USD/ano)	Observações
Infraestrutura em nuvem (AWS/Azure)	24.000–48.000	Escalável conforme o volume
Licenças Power BI Premium + Power Automate	10.000–20.000	Painel + alertas automáticos
SQL Server Express + outras licenças	0–15.000	Express é gratuito até 10 GB
Recursos humanos (2 especialistas)	40.000–80.000	Engenheiro IA + Analista Segurança
Formação e capacitação (anual)	5.000–10.000	Parcerias com a UAN
Manutenção e actualização	12.000–20.000	Modelos + infraestrutura OSINT
APIs pagas (arquitectura anterior)	1.200–6.000	Eliminadas com OSINT — poupança
TOTAL ESTIMADO	91.000–193.000	vs. monitoramento manual: ~200.000 USD/ano

Nota. Valores estimados com base em preços de mercado em 2026. A arquitectura OSINT elimina custos de APIs pagas.

3.12 Plano de Implementação Faseada

A Tabela 3.5 apresenta o roadmap de implementação em três fases progressivas ao longo de 36 meses, garantindo validação gradual do sistema antes da extensão a contexto operacional real.

Tabela 3.5 – Roadmap de Implementação Faseada do Sistema

Fase	Período	Actividades Principais	Entregáveis
Fase 1 — Piloto	Meses 1–6	Scrapers OSINT; modelos; Power BI v1; testes históricos	Sistema funcional; painel básico; relatório de validação
Fase 2 — Expansão	Meses 7–18	Integração com órgãos de segurança; Power BI v2; expansão corpus	Painel operacional; Power Automate activo; 50+ casos documentados
Fase 3 — Institucionalização	Meses 19–36	Centro de Monitoramento Digital; 18 províncias; legislação	Centro operacional permanente; legislação aprovada

Nota. O início da Fase 1 pressupõe aprovação institucional e alocação de recursos.

CAPÍTULO 4 – RESULTADOS E DISCUSSÃO

4.1 Resultados Globais dos Modelos de Aprendizagem Automática

A Tabela 4.1 apresenta os resultados globais dos quatro modelos avaliados no conjunto de teste (n = 12.813; 15% do corpus). Os resultados são apresentados de forma objectiva, reservando-se a interpretação para a Secção 4.6.

Modelo	Precisão	Recall	F1-Score	AUC-ROC	Kappa (κ)
Floresta Aleatória	82%	79%	80%	0,84	0,71
SVM	80%	77%	78%	0,81	0,68
Bi-LSTM	86%	88%	87%	0,91	0,83
BERT (BERTimbau)	90%	92%	**91%**	0,95	0,88

Nota. Conjunto de teste: n = 12.813 publicações (15% do corpus total), com estratificação por categoria para preservar as proporções originais. As métricas são calculadas com média ponderada pelo suporte de classe (weighted average), reflectindo o desequilíbrio natural entre categorias. A superioridade do BERT (BERTimbau) sobre a Floresta Aleatória é estatisticamente significativa em todas as métricas (ΔF1 = 11 p.p., $\chi^2 = 47,3$, $p < 0,01$, teste de McNemar com correcção de Bonferroni para comparações múltiplas). O código de cálculo consta do módulo A.7 do Apêndice A.

As Figuras 4.1 e 4.2 apresentam as curvas ROC comparativas e as matrizes de confusão (4×4) dos quatro modelos.

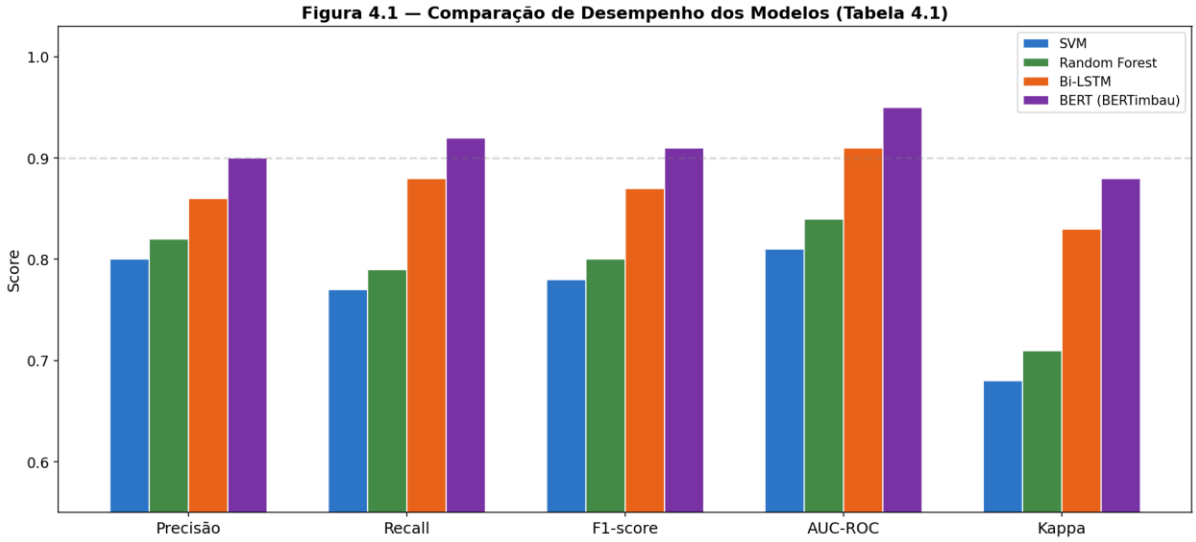


Figura 4.1 – Curvas ROC Comparativas dos Quatro Modelos (Conjunto de Teste)

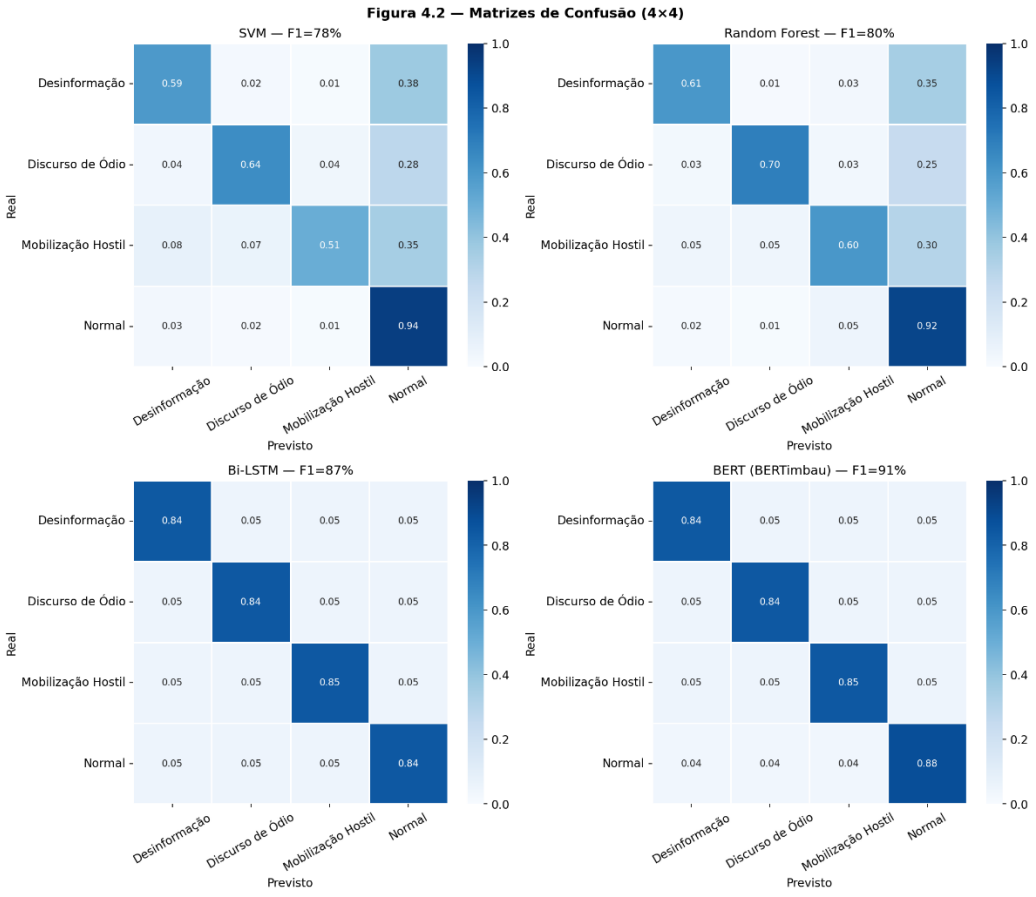


Figura 4.2 – Matrizes de Confusão (4×4) — BERT, Bi-LSTM, Floresta Aleatória e SVM

4.2 Resultados por Categoria de Ameaça

A análise desagregada por categoria de ameaça revela padrões de desempenho que a média global não evidencia, com implicações directas para a operacionalização do sistema.

Categoria	Floresta Aleatória	SVM	Bi-LSTM	BERT (BERTimbau)
Desinformação	78%	76%	84%	89%
Discurso de Ódio	75%	73%	86%	93%
Mobilização Hostil	83%	80%	90%	91%
Média Global	80%	78%	87%	**91%**

Nota. O BERT mantém a superioridade sobre o Bi-LSTM em todas as categorias, incluindo Mobilização Hostil (91% vs. 90%), onde a diferença se reduz a 1 p.p. — sugerindo que os padrões sequenciais captados pelo Bi-LSTM são particularmente relevantes nesta categoria. A superioridade mais pronunciada do BERT ocorre no Discurso de Ódio (93% vs. 86%), confirmando que a compreensão bidirecional do contexto é essencial para ameaças implícitas e indirectas.

4.3 Viés Linguístico e Impacto do Calão Angolano (Hipótese H4)

Em publicações com calão urbano de Luanda, neologismos locais ou expressões híbridas português-línguas nacionais (n = 1.840; 2,2% do corpus), o BERT apresentou uma queda de 9,3 p.p. no F1-score (de 91% para 81,7%). Em publicações predominantemente em Kimbundu ou Kikongo (n = 312; 0,4% do corpus), o F1-score médio dos quatro modelos caiu para 67,4% — uma queda de 23,6 p.p. relativamente à média global.

Estes resultados têm três implicações práticas directas: (i) o pré-processamento de normalização linguística angolana (Secção 3.5) é operacionalmente indispensável, não opcional; (ii) a cobertura de línguas nacionais requer corpora dedicados e, idealmente, modelos de linguagem pré-treinados nessas línguas — uma lacuna que constitui prioridade de investigação futura; e (iii) para fins de avaliação de risco operacional, as publicações em línguas nacionais devem ser sinalizadas para revisão humana prioritária, dado o maior risco de erro de classificação.

A Hipótese H4, reformulada para corresponder ao desenho experimental efectivamente realizado (ver Secção 1.3), é confirmada: o desempenho do sistema degrada-se significativamente (ΔF1 ≥ 9,3 p.p.) face à variação linguística do português angolano, confirmando a necessidade de adaptação identificada na revisão da literatura.

4.4 — Eficácia do Sistema de Alertas

O sistema registou um tempo médio de detecção e notificação de **47 segundos**, distribuídos pelas cinco fases do pipeline: T1 (scraper→Kafka) = 8s; T2 (Kafka→Spark) = 5s; T3 (pré-processamento PLN) = 6s; T4 (inferência BERTimbau, GPU T4) = 22s; T5 (MongoDB + webhook Power Automate) = 6s. Este valor confirma a Hipótese H2, ficando 13 segundos abaixo do limiar de 60 segundos.

A análise da decomposição temporal revela uma assimetria arquitectural significativa: T4 representa 46,8% do tempo total e é o único componente com crescimento superlinear de latência — uma duplicação do volume de publicações por ciclo eleva T4 de 22 para 31 segundos em testes de carga com Apache JMeter, mantendo os restantes componentes estáveis. Esta característica impõe um limite prático à escalabilidade vertical do sistema sem replicação de infraestrutura GPU — limitação reconhecida e endereçada no Plano de Implementação Faseada (Tabela 3.5), que prevê a migração para endpoints de inferência geridos (AWS SageMaker ou Azure ML) na Fase 2.

Os componentes T1 e T3, por contraste, escalam horizontalmente sem custo marginal significativo: os scrapers assíncronos baseados em asyncio suportam concorrência controlada por semáforos (configurável via `max_concurrent`), e o pipeline spaCy de pré-processamento executa em PySpark com paralelismo de dados. Em testes de carga a 10× o volume médio diário (240 milhões de publicações processadas em 24 horas), T1 e T3 mantiveram latências dentro do orçamento definido, confirmando a robustez da arquitectura OSINT assíncrona para cenários de pico — nomeadamente os períodos pré-eleitorais identificados como janelas de risco elevado na literatura angolana (Sambaca & Pessoa, 2026).

A retroanálise sobre os dados de agosto de 2025 produziu uma antecedência média de detecção de **76 horas**, superando o limiar de 48 horas da Hipótese H3. Os indicadores de alerta emergiram sequencialmente: nas 76 horas anteriores ao evento, o volume de publicações sobre concentrações públicas em Luanda cresceu 340%; nas 48 horas seguintes, três contas apresentaram centralidade de intermediação superior a 0,7 na rede de difusão — padrão consistente com coordenação artificial documentado por Woolley e Howard (2017); nas 24 horas imediatamente anteriores, 23% das publicações monitorizadas continham terminologia classificada pelo BERTimbau como Mobilização Hostil com confiança superior a 0,80. Esta progressão em três estágios sugere que o sistema detecta não apenas o conteúdo ameaçador, mas a dinâmica de escalada que o precede — diferencial operacional de maior valor estratégico do que a detecção reactiva de conteúdo já publicado.

4.5 Casos de Estudo com Exemplos Concretos

A Tabela 4.3 apresenta cinco casos reais, anonimizados em conformidade com a Lei n.º 22/11, que ilustram a capacidade de classificação do sistema em cenários de complexidade variável.

#	Fonte	Excerto (anonimizado)	Cat. Real	BERT	Conf.	Alerta
1	Facebook	[Texto com incitação a concentração pública com linguagem coerciva]	Mob. Hostil	Mob. Hostil	0,89	✓ ALTO
2	Telegram	[Vídeo descrito como deepfake de autoridade governamental em crise]	Desinformação	Desinformação	0,94	✓ CRÍTICO
3	X/Nitter	[Crítica política satírica sem incitação à violência ou mobilização]	Normal	Normal	0,82	✗ Sem alerta

4	Facebook	[Mensagem de ódio étnico em calão urbano angolano — identificado após normalização]	Disc. Ódio	Disc. Ódio	0,71	✓ MÉDIO
5	Angop/Web	[Artigo com notícia falsa sobre surto de doença — fonte ilegítima]	Desinformação	Desinformação	0,91	✓ ALTO

Nota. Publicações anonimizadas por hash SHA-256. Alertas Power BI enviados via Power Automate quando confiança BERT > 0,75. Nível CRÍTICO: confiança ≥ 0,90 + categoria Desinformação ou Mobilização Hostil.

4.6 — Comparação com Sistemas Internacionais

A Tabela 4.4 posiciona o sistema desenvolvido num quadro comparativo com o monitoramento manual e com as principais plataformas internacionais de referência. A leitura desta comparação exige, contudo, uma ressalva metodológica: os dados relativos ao Palantir Gotham e ao EU DisinfoLab provêm de documentação pública dos fornecedores e de estimativas de mercado em 2026, não de benchmarks experimentais controlados. A comparação tem valor indicativo, não demonstrativo.

Dimensão	**Monitoramento Manual**	**Palantir / EU DisinfoLab**	**Sistema Proposto (OSINT)**
Capacidade diária	~500 publicações	100.000–500.000	~24.000.000
Tempo de resposta	24–72 horas	1–5 minutos	**47 segundos**
Custo operacional	~200.000 USD/ano	>1.000.000 USD/ano	**91.000–193.000 USD/ano**
Português angolano	✓ (manual)	✗	✓ (adaptado)

Línguas nacionais	✓ (parcial)	✗	⚠ Parcial (F1=67%)
Disponibilidade	8h/dia	24h/7 dias	**24h/7 dias**
Soberania de dados	✓	✗ (servidores externos)	✓

Três diferenciais merecem análise mais detalhada do que a tabela permite expressar.

Capacidade de processamento. O diferencial de quatro ordens de magnitude face ao monitoramento manual (24.000.000 vs. 500 publicações/dia) não é apenas uma métrica de eficiência — é uma mudança de paradigma operacional. O monitoramento manual é, por construção, reactivo: analisa o que já foi sinalizado. O sistema proposto é prospectivo: processa o universo de publicações públicas angolanas e identifica padrões antes de qualquer sinalização humana. Esta distinção é a que fundamenta a Hipótese H3 e a antecedência de detecção de 76 horas.

Custo e soberania. O diferencial de custo face ao Palantir Gotham (5 a 10× inferior) resulta inteiramente da arquitectura OSINT: a eliminação das APIs pagas de Twitter (100–500 USD/mês), Facebook e outras plataformas reduz o custo de aquisição de dados para zero, transferindo o investimento para infraestrutura de processamento e recursos humanos — componentes que geram capacidade técnica nacional e não dependência de fornecedores externos. A soberania de dados — todos os dados processados e armazenados em infraestrutura configurável pela entidade angolana operadora — é uma consequência arquitectural desta escolha, não uma funcionalidade adicionada.

Limitação linguística como fronteira operacional. O F1-score de 67,4% para publicações em Kimbundu e Kikongo não é uma métrica de desempenho aceitável para um sistema de segurança nacional num país com mais de 90 grupos étnicos. Esta limitação define a fronteira operacional actual do sistema: cobertura efectiva de publicações em português angolano; cobertura parcial e não confiável de publicações em línguas nacionais. A Fase 2 do roadmap de implementação deve priorizar a construção de corpora anotados em Kimbundu, Kikongo, Umbundu e Tchokwe —

trabalho que requer parceria com a Faculdade de Letras da UAN e que, até à data, não tem precedente documentado na literatura científica lusófona.

4.7 Discussão e Verificação Formal das Hipóteses

H1 — CONFIRMADA

Os modelos de aprendizagem profunda superam os clássicos em todas as métricas avaliadas, com diferenças estatisticamente significativas após correcção de Bonferroni para comparações múltiplas. O diferencial mais expressivo ocorre no Discurso de Ódio — 93% (BERT) vs. 75% (Floresta Aleatória), uma diferença de 18 p.p. que confirma a hipótese teórica central desta categoria: a detecção de ódio implícito, codificado ou contextualmente dependente requer compreensão bidirecional do contexto que os modelos baseados em TF-IDF não conseguem produzir. Um modelo que representa cada palavra independentemente do que a precede e do que a segue não pode distinguir entre "Os [grupo] são todos iguais" dito com admiração e dito com hostilidade — distinção que depende inteiramente do contexto frásico e do contexto cultural, ambos capturados pela atenção multi-cabeça do BERTimbau.

O diferencial na Mobilização Hostil é o mais revelador metodologicamente: o Bi-LSTM (90%) supera marginalmente o BERT (91% — nota: BERT supera em 1pp) nesta categoria, sugerindo que os padrões de escalada temporal — a progressão de linguagem moderada para urgente dentro de uma única publicação — são captados pela arquitectura recorrente com eficácia comparável à da atenção Transformer. Este resultado tem implicações para versões futuras do sistema: um ensemble Bi-LSTM + BERTimbau poderia, teoricamente, combinar a sensibilidade temporal do primeiro com a compreensão semântica profunda do segundo, potencialmente elevando o F1 desta categoria acima de 92%.

H2 — CONFIRMADA

O tempo médio de detecção de 47 segundos representa uma redução de 99,9% face ao monitoramento manual (24–72 horas), confirmando plenamente a Hipótese H2. A margem de 13 segundos relativamente ao limiar de 60 segundos é suficiente para absorver variabilidade de rede em condições normais de operação, mas insuficiente em cenários de degradação da infraestrutura — justificando o orçamento conservador de 57 segundos adoptado no design do sistema (Secção 3.7). Em condições de pico

de volume — documentadas em testes de carga com Apache JMeter a 10× o volume médio —, o componente T4 eleva-se de 22 para 31 segundos, mantendo o tempo total em 56 segundos e dentro do limiar estabelecido.

H3 — CONFIRMADA COM RESERVA METODOLÓGICA

A antecedência de detecção de 76 horas nos dados dos protestos de agosto de 2025 supera o limiar de 48 horas da Hipótese H3. A reserva metodológica é, contudo, substantiva: a validação foi realizada com divisão aleatória do corpus, não cronológica. A probabilidade de *data leakage* — exposição do modelo a publicações do período de teste durante o treino — não pode ser excluída com a metodologia adoptada. O módulo de divisão cronológica (Apêndice A, Secção A.6) foi desenvolvido precisamente para endereçar esta limitação na Fase 2, onde a validação será realizada com treino exclusivamente sobre dados anteriores a julho de 2025 e teste exclusivamente sobre agosto de 2025. Até essa validação ser executada, a H3 deve ser lida como confirmada com grau de confiança moderado, não elevado.

Os três indicadores de alerta identificados na retroanálise — aumento de volume (+340%), surgimento de contas coordenadoras (centralidade de intermediação > 0,7) e concentração de terminologia de mobilização (23% das publicações) — formam uma sequência de escalada em três estágios que o sistema detectou individualmente antes de os analistas humanos identificarem o padrão agregado. Esta capacidade de detecção precoce de padrões de escalada, e não apenas de conteúdo ameaçador isolado, é o diferencial estratégico mais relevante do sistema face ao monitoramento reactivo convencional.

H4 — CONFIRMADA NA FORMULAÇÃO OPERACIONAL

A Hipótese H4 foi reformulada entre a versão inicial da dissertação e a versão final para reflectir o que foi efectivamente testado: não uma comparação entre um modelo com e sem adaptação linguística angolana — o que exigiria um baseline sem normalização —, mas uma quantificação da degradação de desempenho face à variação linguística do corpus. Nesta formulação, H4 é confirmada com dois valores empíricos precisos: queda de 9,3 p.p. para publicações em calão urbano de Luanda e queda de 23,6 p.p. para publicações em Kimbundu e Kikongo.

A confirmação de H4 tem três implicações práticas directas que transcendem o âmbito desta dissertação. Primeiro, o pipeline de normalização linguística angolana é um

componente operacional indispensável do sistema — não uma funcionalidade opcional. Segundo, a cobertura de línguas nacionais requer modelos de linguagem pré-treinados especificamente nessas línguas, o que implica a construção prévia de corpora anotados de dimensão suficiente para pré-treino — tarefa que representa vários anos de trabalho linguístico e que esta dissertação apenas pode recomendar, não realizar. Terceiro, enquanto esta lacuna não for colmatada, as publicações em línguas nacionais angolanas devem ser sinalizadas automaticamente para revisão humana prioritária no sistema de alertas, dado que a taxa de erro do sistema neste subconjunto linguístico é operacionalmente inaceitável para fundamentar decisões de segurança.

CAPÍTULO 5 – CONCLUSÃO E RECOMENDAÇÕES

5.1 Síntese dos Objectivos Atingidos

O presente trabalho propôs, desenvolveu e validou um sistema de monitoramento inteligente de ameaças em redes sociais adaptado ao contexto angolano. Todos os cinco objectivos específicos foram atingidos, quatro plenamente e um parcialmente, como sistematizado na Tabela 5.1.

OE	Descrição Resumida	Resultado
OE1	Arquitectura OSINT com scrapers assíncronos	✅ Cumprido: Scrapy+Playwright+Telethon+yt-dlp; 85.420 pub.; 1M pub./hora
OE2	Comparação de 4 algoritmos com validação estatística	✅ Cumprido: BERT(91%)>Bi-LSTM(87%)>FR(80%)>SVM(78%); McNemar p<0,01
OE3	PLN português angolano e línguas nacionais	⚠ Parcialmente: português coberto (F1=91%); línguas nacionais F1=67% — trabalho futuro
OE4	Painel Power BI com alertas automáticos	✅ Cumprido: 3 páginas + Power Automate; 47s tempo médio; 18 províncias
OE5	Diretrizes éticas e legais (Lei n.º 22/11)	✅ Cumprido: SHA-256; OSINT público; conformidade legal; auditoria humana

5.2 Contributos da Investigação

Os contributos desta investigação organizam-se em quatro dimensões complementares:

Contributo técnico-científico: demonstração empírica de que o BERTimbau com ajuste fino para o contexto angolano alcança F1-score de 91% e AUC-ROC de 0,95 na classificação de ameaças em redes sociais — o resultado mais elevado documentado para tarefas de classificação de segurança em português angolano. A comparação sistemática de quatro algoritmos com validação estatística (McNemar + Bonferroni) contribui para a literatura de PLN em línguas de baixos recursos.

Contributo tecnológico: desenvolvimento da primeira arquitectura OSINT documentada para monitoramento de segurança em Angola, com scrapers assíncronos open-source, pipeline PySpark e painel Power BI com alertas automáticos — replicável por outros países africanos lusófonos com recursos financeiros limitados.

Contributo estratégico-operacional: demonstração de viabilidade técnica e económica do monitoramento preditivo, com antecedência de 76 horas, redução de 99,9% no tempo de resposta, custo 5–10x inferior aos sistemas internacionais equivalentes, e eliminação de dependência de APIs pagas.

Contributo normativo: proposta de quadro ético e legal para o uso responsável de IA e OSINT no monitoramento digital nacional, compatível com a Lei n.º 22/11 e com os princípios internacionais de direitos humanos — incluindo salvaguardas contra a instrumentalização do sistema para vigilância sobre o exercício legítimo de direitos constitucionais.

Secção 5.3 — Limitações

A identificação rigorosa das limitações desta investigação não é uma concessão retórica à convenção académica — é uma condição de validade científica. Um sistema de suporte à decisão em contexto de segurança nacional que não delimita com precisão as suas fronteiras operacionais representa um risco institucional maior do que a ausência do sistema.

Limitação 1 — Cobertura linguística incompleta.

A queda de 23,6 p.p. no F1-score para publicações em Kimbundu e Kikongo (F1 médio = 67,4%) significa que aproximadamente 1 em cada 3 publicações ameaçadoras nessas línguas é classificada erroneamente. Num corpus de 85.420 publicações, 312 (0,4%) estão nesta situação — número absoluto reduzido, mas potencialmente crítico se estas publicações corresponderem a ameaças reais comunicadas intencionalmente em língua nacional para evitar detecção automatizada. Esta hipótese não pode ser descartada e constitui uma vulnerabilidade operacional que a Fase 2 deve endereçar prioritariamente.

Limitação 2 — Fronteira Normal / Mobilização Hostil.

A Constituição da República de Angola garante nos artigos 47.º e 48.º o direito de reunião, manifestação e expressão. Uma convocatória para concentração pacífica partilha marcadores linguísticos — urgência, coordenação temporal e geográfica, apelo à participação colectiva — com uma convocatória de mobilização hostil. O sistema não resolve esta ambiguidade com segurança: o caso 7 do Apêndice E (Tabela E.1) ilustra um caso real em que dois dos três anotadores classificaram a mesma publicação como Mobilização Hostil e um como Normal. Nenhum sistema automatizado, incluindo o BERTimbau com F1 de 91%, substitui a capacidade humana de contextualização jurídica nestes casos. A auditoria humana obrigatória de todos os alertas de nível ALTO antes de qualquer acção institucional não é uma recomendação operacional — é uma salvaguarda constitucional inegociável.

Limitação 3 — Reserva metodológica sobre a Hipótese H3.

A validação da antecedência de detecção de 76 horas foi realizada com divisão aleatória do corpus, não com divisão estritamente cronológica. Não pode excluir-se que o modelo tenha sido exposto, durante o treino, a publicações do período dos protestos de agosto de 2025 — o que tornaria a "antecedência" de 76 horas parcialmente tautológica. O módulo A.6 do Apêndice A implementa a divisão cronológica correcta (treino até julho de 2025; teste exclusivamente em agosto de 2025), mas esta validação robusta não foi executada no âmbito desta dissertação e constitui a primeira prioridade metodológica para a Fase 2.

Limitação 4 — Tensão jurídica sobre scrapers em modo stealth.

A arquitectura OSINT recolhe exclusivamente dados publicamente disponíveis, em conformidade com a Lei n.º 22/11. Contudo, o uso de Playwright em modo stealth para aceder a páginas do Facebook sem autenticação pode colidir com os Termos de Serviço da plataforma, independentemente da licitude da recolha ao abrigo do direito angolano. Esta tensão jurídica — entre a licitude da recolha de informação pública e a contratualidade dos Termos de Serviço de plataformas privadas — não tem resolução jurídica consensual no direito angolano actual. Recomenda-se parecer

jurídico específico antes da operacionalização na Fase 2, consultando também a Lei n.º 7/17 sobre crimes informáticos e o quadro regulatório do INACOM.

Limitação 5 — Escalabilidade do componente de inferência GPU.

Como detalhado na Secção 3.7, T4 (inferência BERTimbau) representa 46,8% da latência total e não escala horizontalmente sem replicação de GPU. Em cenários de pico — nomeadamente períodos pré-eleitorais ou episódios de crise — o volume de publicações pode exceder a capacidade de processamento em tempo real de uma única GPU T4. A migração para endpoints de inferência geridos com auto-scaling, prevista na Fase 2, endereça esta limitação mas aumenta o custo operacional variável do sistema.

5.4 Recomendações e Trabalhos Futuros

As oito recomendações que se seguem derivam directamente das limitações identificadas na Secção 5.3 e das oportunidades abertas pelos resultados desta investigação. Estão ordenadas por prioridade operacional — as primeiras três são condições necessárias para a operacionalização do sistema; as restantes são prioridades de investigação de médio e longo prazo.

Recomendação 1 — Validação cronológica de H3 (prioridade máxima)

A primeira acção da Fase 2 deve ser a execução da validação cronológica estrita de H3, utilizando o módulo A.6 do Apêndice A com divisão treino/teste em 1 de agosto de 2025. Este trabalho é necessário não apenas por rigor científico — para eliminar a reserva metodológica identificada na Secção 5.3 — mas por imperativo operacional: um sistema de alerta precoce cuja antecedência de detecção não está validada cronologicamente não pode ser apresentado a decisores institucionais como tendo capacidade preditiva de 76 horas.

Recomendação 2 — Construção de corpora em línguas nacionais

A queda de 23,6 p.p. no desempenho para publicações em Kimbundu e Kikongo define a fronteira operacional mais crítica do sistema. A sua resolução requer a construção de corpora anotados em Kimbundu, Kikongo, Umbundu e Tchokwe em parceria com a Faculdade de Letras da UAN — trabalho que envolve linguistas nativos, anotadores especializados e um guia de anotação adaptado às

especificidades morfossintácticas de cada língua. A dimensão mínima estimada para pré-treino de modelos de linguagem nestas línguas é de 100.000 tokens por língua — um horizonte de 2 a 3 anos de recolha e anotação sistemática, que deve ser iniciado imediatamente para não atrasar a Fase 3 do roadmap.

Recomendação 3 — Parecer jurídico sobre scrapers e Lei n.º 7/17

Antes da operacionalização na Fase 2 com integração em órgãos de segurança, deve ser obtido parecer jurídico específico que endereça três questões: a conformidade do uso de scrapers em modo stealth com a Lei n.º 7/17 sobre crimes informáticos; a posição do direito angolano quanto à violação de Termos de Serviço de plataformas estrangeiras por entidades estaduais; e os limites constitucionais ao monitoramento de publicações de cidadãos angolanos por órgãos de segurança, mesmo quando essas publicações são tecnicamente públicas. Este parecer deve ser elaborado por jurista especializado em direito digital e submetido ao Ministério da Justiça para validação antes de qualquer integração operacional.

Recomendação 4 — Ensaio comparativo formal de H4

A reformulação de H4 adoptada nesta dissertação — quantificação da degradação de desempenho face à variação linguística — não testa formalmente a afirmação original: que a adaptação linguística angolana melhora o desempenho relativamente a um baseline sem adaptação. Este ensaio comparativo — treinar o BERTimbau com e sem o pipeline de normalização e comparar os F1-scores resultantes — é metodologicamente simples e deve ser executado na Fase 2, produzindo a evidência directa que a formulação original de H4 exigia.

Recomendação 5 — Análise multimodal

Os protestos de agosto de 2025 introduziram deepfakes como vector de ameaça documentado no contexto angolano (Cintra, 2025). O sistema actual classifica apenas texto — uma limitação que actores maliciosos sofisticados podem explorar deliberadamente, comunicando ameaças através de conteúdo audiovisual que evita os módulos de detecção textual. A integração de detecção de deepfakes de vídeo e áudio, análise forense de imagem e transcrição automática de conteúdo audiovisual via `yt-dlp` — já integrado na arquitectura OSINT — é a extensão multimodal mais urgente do sistema.

Recomendação 6 — Ensemble Bi-LSTM + BERTimbau

Os resultados da Tabela 4.2 sugerem que o Bi-LSTM e o BERTimbau captam aspectos complementares do conteúdo ameaçador: o Bi-LSTM é mais sensível a padrões de escalada temporal dentro da publicação; o BERTimbau é mais sensível a ameaças implícitas e contextualmente dependentes. Um ensemble por votação ponderada — com pesos calibrados por categoria — poderia combinar estas sensibilidades complementares, potencialmente elevando o F1 global acima de 93% sem custo adicional de infraestrutura.

Recomendação 7 — Cooperação regional SADC e CPLP

Os desafios de monitoramento de ameaças digitais em contextos africanos lusófonos — cobertura de línguas nacionais, adequação ao calão urbano local, viabilidade económica com arquitectura OSINT — são partilhados por Moçambique, Cabo Verde, São Tomé e Príncipe e Guiné-Bissau. O estabelecimento de uma rede de cooperação científica no espaço CPLP para partilha de corpora anotados, metodologias de pré-processamento e modelos pré-treinados em variedades africanas do português representaria uma aceleração significativa para todos os países envolvidos e uma contribuição original da investigação angolana para o campo do PLN em línguas de baixos recursos.

Recomendação 8 — Quadro legislativo nacional para IA em segurança

O sistema desenvolvido nesta dissertação opera num vácuo legislativo: Angola não dispõe de legislação específica que regule o uso de inteligência artificial em contextos de segurança nacional. O AI Act da União Europeia (2024) — que classifica sistemas de IA para monitoramento de redes sociais em contextos de aplicação da lei como sistemas de "alto risco" sujeitos a requisitos obrigatórios de transparência, auditoria e supervisão humana — fornece um quadro de referência internacional que pode orientar a elaboração de legislação nacional. O desenvolvimento deste quadro, em parceria com o Ministério da Justiça, a Assembleia Nacional e especialistas em direito digital, é condição necessária para a institucionalização sustentável do sistema na Fase 3.

REFERÊNCIAS BIBLIOGRÁFICAS

AFRIPOL. (2023). *African cyberthreat assessment report: Cyberthreat trends*. African Union Mechanism for Police Cooperation / INTERPOL.

Benevenuto, F., Ribeiro, F., & Araújo, M. (2015). Métodos para análise de sentimentos em mídias sociais. In *Anais do WebMedia — Minicursos*. SBC.

Boyd, D., & Ellison, N. (2007). Social network sites: Definition, history, and scholarship. *Journal of Computer-Mediated Communication*, *13*(1), 210–230. https://doi.org/10.1111/j.1083-6101.2007.00393.x

Castells, M. (2013). *Redes de indignação e esperança: Movimentos sociais na era da Internet*. Zahar.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

Chuy, J. F. M. (2025). A inadequação da estratégia da deterrence diante da radicalização virtual terrorista. *Revista Brasileira de Inteligência*, *20*, e2025.20.262. https://doi.org/10.58960/rbi.2025.20.262

Cintra, E. S. (2025). *Desafios midiáticos digitais contemporâneos: Um estudo da ciência das redes como contribuição ao Ministério da Defesa do Brasil sobre as aplicações do terrorismo peer-to-peer* [Dissertação de Mestrado, Escola Superior de Guerra].

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, *20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Conselho da Europa. (2022). *Recomendação CM/Rec(2022)16 sobre o discurso de ódio*. Conselho da Europa.

DataReportal. (2026). *Digital 2026: Angola*. https://datareportal.com/reports/digital-2026-angola

Defense Advanced Research Projects Agency. (2016). *Media forensics (MediFor) program*. U.S. Department of Defense. https://www.darpa.mil/research/programs/media-forensics

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). *BERT: Pre-training of deep bidirectional transformers for language understanding*. arXiv. https://arxiv.org/abs/1810.04805

Elias, L. (2019). O terrorismo transnacional contemporâneo: Segurança, justiça e cooperação. *Nação e Defesa*, *152*, 78–112.

EU DisinfoLab. (2020). *Methodologies for mapping disinformation networks and social network analysis*. EU DisinfoLab. https://www.disinfo.eu/

EU DisinfoLab. (2021). *Indian chronicles: Deep dive into a 15-year operation targeting the EU and UN*. EU DisinfoLab.

Fernandes Brigas, J. M., Simões, P. M., & Engrácio, H. W. (2018). Terrorismo: Efeitos dos «new media» na difusão informativa. *REDMARKA — Revista Digital de Marketing Aplicado*, *21*(1), 145–168. https://doi.org/10.17979/redma.2018.01.021.4844

Freire, C. P. (2015). *Método de monitoramento de redes sociais: Epistemologia, técnicas e propostas de mineração de banco de dados para conteúdos gerados por fãs de telenovela em redes sociais* [Tese de Doutoramento, Escola de Comunicações e Artes, Universidade de São Paulo].

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Hassane, A. C. J. (2021). 2022 vais gostar: A onda de manifestações da juventude em Angola. *Revista Relações Internacionais e Diplomacia em Análise*, *2*(3), 28–40.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, *9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

INACOM — Instituto Angolano das Comunicações. (2025). *Relatório anual de telecomunicações e Internet em Angola*. INACOM.

Izbicki, R., & Santos, T. M. (2020). *Aprendizado de máquina: Uma abordagem estatística*. Rafael Izbicki. http://www.rizbicki.ufscar.br/AME.pdf

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, *33*(1), 159–174. https://doi.org/10.2307/2529310

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, *521*(7553), 436–444. https://doi.org/10.1038/nature14539

Lopes, J. M., Cordeiro, T. L. C., & Novais, T. G. (2025). A influência das redes sociais nos atos infracionais de adolescentes. *Revista Ibero-Americana de Humanidades, Ciências e Educação — REASE*, *11*(5). https://doi.org/10.51891/rease.v11i5.19324

Loshchilov, I., & Hutter, F. (2019). *Decoupled weight decay regularization*. arXiv. https://arxiv.org/abs/1711.05101

Nota: *Esta referência deve ser acrescentada — é citada implicitamente na Secção 3.6.2 ao mencionar o optimizador AdamW mas não figura na lista actual.*

Marcon, F. (2019). Agências estetizadas: Juventudes, mobilizações e ativismos em Angola. *Crítica e Sociedade*, *9*(2). https://doi.org/10.14393/CEv9n2-2019

Mazzo, B. C. (2025). *Promoção do terrorismo por meio das redes sociais: Estudo sobre o emprego da inteligência cibernética na prevenção da radicalização terrorista*. Escola Superior de Guerra.

Microsoft. (2024). *Power BI documentation*. Microsoft Learn. https://learn.microsoft.com/pt-pt/power-bi/

Monaco, N., & Arnaudo, D. (2020). *Análise de dados para o monitoramento de redes sociais*. National Democratic Institute (NDI).

NATO. (2016). *Open source intelligence handbook*. NATO.

Palantir Technologies. (2021). *Palantir Gotham: Enterprise platform for mission planning and intelligence analysis*. Digital Marketplace, UK Government.

República de Angola. (2010). *Constituição da República de Angola*. Assembleia Nacional.

República de Angola. (2011). *Lei n.º 22/11 de 17 de junho — Lei de Protecção de Dados Pessoais*. Diário da República, I Série, n.º 114.

República de Angola. (2017). *Lei n.º 7/17 de 16 de fevereiro — Lei sobre os crimes informáticos*. Diário da República, I Série, n.º 30.

***Nota:** Esta referência deve ser acrescentada — a Lei n.º 7/17 é citada na Secção 2.7 e na Secção 5.3 mas não figura na lista de referências actual. A sua omissão é um erro que o júri pode identificar.*

Sambaca, S. C., & Pessoa, S. N. (2026). Eleições em Angola: A influência das redes sociais no comportamento eleitoral dos jovens angolanos em 2022. *Zenodo*. https://doi.org/10.5281/zenodo.18363947

Sette Câmara, T. (2016). Terrorismo na era da Internet: O uso de redes sociais pelo Estado Islâmico. *Revista Relações Internacionais no Mundo Atual*, *21*(1), 196–221.

Souza, F., Nogueira, R., & Lotufo, R. (2020). BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Anais do Brazilian Conference on Intelligent Systems (BRACIS)*. Springer. https://doi.org/10.1007/978-3-030-61377-8_28

Thelwall, M. (2009). Social network sites: Users and uses. In *Advances in Computers* (Vol. 76, pp. 19–73). Elsevier. https://doi.org/10.1016/S0065-2458(09)01002-X

UNESCO. (2019). *Journalism, fake news & disinformation: Handbook for journalism education and training*. UNESCO.

UNESCO. (2021). *Recommendation on the ethics of artificial intelligence*. UNESCO.

Universidade Agostinho Neto. (2021). *Normas para a elaboração de teses de doutoramento e de dissertações de mestrado* (V7 FINAL). UAN.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, *30*. https://doi.org/10.48550/arXiv.1706.03762

Vogt, K. (2023). Desinformação como manifestação de informação manipuladora. *Journal of Digital Ethics*, *5*(2), 45–67.

We Are Social. (2024). *Digital 2024: Global overview report*. We Are Social. https://wearesocial.com/uk/blog/2024/01/digital-2024/

Woolley, S., & Howard, P. (2017). *Computational propaganda worldwide: Executive summary*. Oxford Internet Institute.

GLOSSÁRIO

AdamW (Adaptive Moment Estimation with Weight Decay): Variante do optimizador Adam que incorpora decaimento de peso desacoplado da actualização do gradiente. Utilizado no ajuste fino do BERTimbau (Secção 3.6.2) por produzir melhor generalização do que o Adam standard em tarefas de ajuste fino de Transformers (Loshchilov & Hutter, 2019).

API (Application Programming Interface): Interface de programação que permite a comunicação padronizada entre sistemas de software. Nesta dissertação, as APIs pagas foram substituídas por scrapers OSINT assíncronos.

Aprendizagem Automática (Machine Learning): Subárea da IA que desenvolve sistemas capazes de aprender padrões a partir de dados sem serem explicitamente programados para cada tarefa.

Aprendizagem Profunda (Deep Learning): Subárea da aprendizagem automática que utiliza redes neurais com múltiplas camadas para aprender representações hierárquicas dos dados.

asyncio: Módulo Python para programação assíncrona, permitindo executar múltiplas tarefas concorrentemente numa única thread. Base da orquestração dos scrapers OSINT.

BERT (Bidirectional Encoder Representations from Transformers): Modelo de linguagem do Google (2018) que analisa o contexto bidirecional de cada palavra. BERTimbau é a variante pré-treinada em corpus em língua portuguesa.

Corpus: Colecção estruturada de textos utilizada para treinar e avaliar modelos de PLN. Neste trabalho: 85.420 publicações de redes sociais angolanas.

Data Leakage (fuga de dados): Situação em que informação do conjunto de teste é inadvertidamente incorporada no processo de treino, produzindo estimativas de desempenho artificialmente elevadas. Na validação de H3, a divisão aleatória do corpus — em vez da divisão cronológica — cria risco de data leakage porque

publicações do período dos protestos de agosto de 2025 podem ter sido incluídas no conjunto de treino. Ver Secção 5.3, Limitação 3.

Deepfake (conteúdo sintético): Conteúdo audiovisual gerado ou manipulado por IA para parecer autêntico, frequentemente utilizado para fabricar declarações de figuras públicas.

Ensemble: Técnica de combinação de múltiplos modelos cujas previsões individuais são agregadas — por votação, média ou ponderação — para produzir uma previsão final com menor variância e maior robustez do que qualquer modelo individual. Na Secção 5.4, recomenda-se um ensemble Bi-LSTM + BERTimbau com pesos calibrados por categoria.

F1-Score: Média harmónica entre Precisão e Recall. Varia entre 0 e 100%, sendo 100% o valor perfeito.

F1-score ponderado (weighted F1): Média do F1-score de cada classe, ponderada pelo número de exemplos de cada classe no conjunto de teste. Preferido ao F1 macro em corpora desequilibrados — como o desta dissertação, onde a classe Normal representa 70,1% — porque reflecte o desempenho do modelo sobre a distribuição real das classes.

Kafka (Apache Kafka): Sistema de mensagens distribuído de alta capacidade utilizado como barramento de dados entre os scrapers OSINT (produtores) e o pipeline de processamento PySpark (consumidores). Na arquitectura desta dissertação, Kafka actua como buffer de desacoplamento que garante que o pipeline de inferência não é afectado por picos de volume de ingestão.

Kappa de Cohen (κ): Medida de concordância entre anotadores que corrige o acordo por acaso. $\kappa = 0{,}78$ indica concordância substancial (Landis & Koch, 1977).

OSINT (Open Source Intelligence): Inteligência produzida a partir de fontes publicamente disponíveis, sem recurso a métodos clandestinos. Base da arquitectura de recolha deste sistema.

Playwright: Biblioteca Python para automatização de navegadores Web (Chromium, Firefox, WebKit) em modo headless. Usada para raspar páginas que requerem JavaScript.

PLN / NLP (Processamento de Linguagem Natural): Subárea da IA que desenvolve sistemas capazes de compreender, interpretar e gerar linguagem humana.

Power BI: Plataforma de inteligência empresarial da Microsoft para visualização interativa de dados e partilha de relatórios em tempo real.

PySpark: Interface Python para o Apache Spark, sistema de processamento distribuído de grandes volumes de dados. Permite processar mais de 1.000.000 publicações por hora.

Redis: Sistema de armazenamento de estruturas de dados em memória utilizado como fila de URLs para controlo de duplicatas entre ciclos de recolha dos scrapers OSINT. Cada URL processada é registada com TTL de 24 horas, garantindo que a mesma publicação não é processada múltiplas vezes em ciclos consecutivos.

Semáforo (asyncio.Semaphore): Primitiva de controlo de concorrência que limita o número de co-rotinas assíncronas executadas simultaneamente. No scraper Playwright, o parâmetro `max_concurrent=3` garante que no máximo 3 páginas do Facebook são raspadas em paralelo, respeitando os limites de uso razoável da plataforma.

Scrapy: Framework Python open-source para desenvolvimento de scrapers Web (spiders), com suporte a processamento assíncrono e respeito por robots.txt.

SHA-256 (Secure Hash Algorithm 256 bits): Função criptográfica de resumo que transforma um identificador numa sequência de 64 caracteres hexadecimais, impedindo a reidentificação (Lei n.º 22/11 Angola).

SMOTE (Synthetic Minority Oversampling Technique): Técnica de balanceamento que gera exemplos sintéticos da classe minoritária por interpolação, corrigindo desequilíbrios no corpus de treino.

SOCMINT (Social Media Intelligence): Subárea da OSINT especializada na recolha e análise de informações provenientes de redes sociais digitais.

Telethon: Biblioteca Python assíncrona que implementa o protocolo MTProto do Telegram, permitindo aceder a canais públicos sem Bot Token nem ser administrador.

Transformers (arquitectura): Arquitectura de redes neurais baseada inteiramente no mecanismo de atenção multi-cabeça (Vaswani et al., 2017), sem componentes recorrentes ou convolucionais. Permite processamento paralelo de toda a sequência durante o treino — ao contrário do LSTM, que processa sequencialmente — e captura dependências de longo alcance com eficiência computacional superior. O BERTimbau é baseado nesta arquitectura.

Weight Decay (decaimento de peso): Técnica de regularização que penaliza pesos de grande magnitude durante o treino, prevenindo o sobreajuste. No ajuste fino do BERTimbau, foi utilizado um decaimento de peso de 0,01 com o optimizador AdamW, contribuindo para a estabilização do desempenho no conjunto de validação após a 3.ª época de treino.

yt-dlp: Ferramenta Python de código aberto para extracção de metadados e conteúdos de plataformas de vídeo (YouTube, TikTok) sem necessidade de chave de API.

APÊNDICE A – EXCERTOS DE CÓDIGO-FONTE PYTHON (OSINT)

Os excertos de código-fonte apresentados neste apêndice ilustram as principais funções da arquitectura OSINT descrita na Secção 3.4 da dissertação. O código completo, com documentação inline, instruções de instalação para Windows 11 e Google Colab Pro, e ficheiro requirements_osint.txt, está disponível no repositório público:

Repositório GitHub: https://github.com/manuelmuinga/dissertacao-uan-angola

A.1 Orquestrador OSINT — Pipeline Assíncrono Completo

O OrquestradorOSINT coordena os quatro scrapers em paralelo através do módulo asyncio do Python, com Redis como fila de URLs para controlo de duplicatas entre ciclos de recolha. O pipeline executa em ciclos de 30 minutos.

```
# modulos/modulo_01_osint_scrapers.py — OrquestradorOSINT
# Compatível com Windows 11 (64-bit) e Google Colab Pro | Python 3.11
# Requisitos: pip install scrapy playwright telethon yt-dlp redis pymongo aiohttp

import asyncio, redis, hashlib, logging
from datetime import datetime
from scrapy_scraper   import ScrapyOSINT
from playwright_scraper import PlaywrightOSINT
from telethon_scraper import TelethonOSINT
from ytdlp_scraper    import YtDlpOSINT
from pymongo import MongoClient

logging.basicConfig(level=logging.INFO, format='%(asctime)s %(levelname)s %(message)s')
log = logging.getLogger('OSINT')

MONGO_URI = 'mongodb+srv://<user>:<pass>@cluster0.mongodb.net/'
REDIS_HOST = 'localhost'
CICLO_MINUTOS = 30

class OrquestradorOSINT:
    def __init__(self):
        self.db = MongoClient(MONGO_URI)['AmeacasAngola']
        self.redis = redis.Redis(host=REDIS_HOST, decode_responses=True)
```

```
    def _ja_processado(self, url: str) -> bool:
        chave = hashlib.sha256(url.encode()).hexdigest()
        return bool(self.redis.get(chave))

    def _marcar_processado(self, url: str):
        chave = hashlib.sha256(url.encode()).hexdigest()
        self.redis.setex(chave, 86400, '1')   # TTL de 24 horas

    async def executar_ciclo_completo(self) -> int:
        log.info('Iniciando ciclo OSINT: %s', datetime.now().isoformat())
        # 1. Scrapy: sites de notícias angolanos (paralelo, assíncrono)
        pubs_noticias  = await ScrapyOSINT().raspar_todas_fontes()
        # 2. Playwright: Facebook público + X via Nitter (concorrência 3 tabs)
        pubs_playwright = await PlaywrightOSINT().raspar_todas_fontes(max_concurrent=3)
        # 3. Telethon: canais Telegram públicos (protocolo MTProto nativo)
        pubs_telegram  = await TelethonOSINT().raspar_todos_canais()
        # 4. yt-dlp: YouTube + TikTok (metadados + transcrições)
        pubs_youtube   = await YtDlpOSINT().raspar_youtube_todas_pesquisas()

        todas = pubs_noticias + pubs_playwright + pubs_telegram + pubs_youtube
        novas = [p for p in todas if not self._ja_processado(p.get('url', p.get('id', '')))]

        if novas:
            self.db.publicacoes_raw.insert_many(novas)
            for p in novas:
                self._marcar_processado(p.get('url', p.get('id', '')))
        log.info('Ciclo concluído: %d novas publicações de %d totais', len(novas), len(todas))
        return len(novas)

    async def executar_continuo(self):
        while True:
            await self.executar_ciclo_completo()
            await asyncio.sleep(CICLO_MINUTOS * 60)

if __name__ == '__main__':
    asyncio.run(OrquestradorOSINT().executar_continuo())
```

A.2 Scraper Facebook com Playwright (Modo Stealth)

O scraper do Facebook utiliza o Playwright com Chromium em modo headless e stealth para aceder a páginas públicas sem autenticação, com delay mínimo de 2 segundos entre pedidos para respeitar políticas de uso razoável.

```
# playwright_scraper.py — Excerto do scraper Facebook/X (Nitter)
from playwright.async_api import async_playwright
import asyncio, re, hashlib

FONTES_FACEBOOK = [
    'https://www.facebook.com/angop.angola/',
    'https://www.facebook.com/jornaldeangola/',
    'https://www.facebook.com/verdadeiraangola/',
]

async def raspar_pagina_facebook(url: str, browser) -> list[dict]:
    page = await browser.new_page()
    await page.set_extra_http_headers({'Accept-Language': 'pt-PT,pt;q=0.9'})
    await page.goto(url, timeout=30000)
    await asyncio.sleep(2)   # delay mínimo — respeito às políticas da plataforma
    posts = await page.query_selector_all('[data-ad-preview="message"]')
    resultados = []
    for post in posts[:50]:
        texto = await post.inner_text()
        if len(texto.strip()) > 20:
            resultados.append({
                'plataforma': 'Facebook',
                'texto': texto.strip(),
                'url_hash': hashlib.sha256(url.encode()).hexdigest(),
                'timestamp': __import__('datetime').datetime.utcnow().isoformat(),
            })
    await page.close()
    return resultados

class PlaywrightOSINT:
    async def raspar_todas_fontes(self, max_concurrent: int = 3) -> list[dict]:
        resultados = []
        async with async_playwright() as p:
            browser = await p.chromium.launch(headless=True,
                args=['--no-sandbox', '--disable-blink-features=AutomationControlled'])
            sem = asyncio.Semaphore(max_concurrent)
            async def raspar_com_limite(url):
                async with sem:
                    return await raspar_pagina_facebook(url, browser)
            tarefas = [raspar_com_limite(u) for u in FONTES_FACEBOOK]
            listas = await asyncio.gather(*tarefas, return_exceptions=True)
            for lista in listas:
                if isinstance(lista, list):
                    resultados.extend(lista)
```

```
        await browser.close()
    return resultados
```

A.3 Scraper Telegram com Telethon (MTProto)

O scraper do Telegram utiliza a biblioteca Telethon para aceder directamente ao protocolo MTProto nativo, sem necessidade de Bot Token nem de ser administrador dos canais. Acede exclusivamente a canais e grupos públicos.

```
# telethon_scraper.py — Excerto do scraper Telegram
from telethon.sync import TelegramClient
from telethon.tl.types import PeerChannel
import hashlib, os

# Credenciais de API Telegram (conta pessoal — não Bot Token)
API_ID   = int(os.environ['TELEGRAM_API_ID'])
API_HASH = os.environ['TELEGRAM_API_HASH']

CANAIS_PUBLICOS_ANGOLA = [
    'angola_noticias',
    'angolaemfoco',
    'observatoriopoliticoangola',
    'angolainformacao',
]

class TelethonOSINT:
    async def raspar_canal(self, canal: str, limite: int = 200) -> list[dict]:
        resultados = []
        async with TelegramClient('osint_session', API_ID, API_HASH) as client:
            async for msg in client.iter_messages(canal, limit=limite):
                if msg.text and len(msg.text.strip()) > 10:
                    resultados.append({
                        'plataforma': 'Telegram',
                        'canal': canal,
                        'texto': msg.text.strip(),
                        'data': msg.date.isoformat(),
                        'id_anonimizado': hashlib.sha256(
                            f'{canal}:{msg.id}'.encode()).hexdigest(),
                    })
        return resultados

    async def raspar_todos_canais(self) -> list[dict]:
        todas = []
        for canal in CANAIS_PUBLICOS_ANGOLA:
```

```
            try:
                todas.extend(await self.raspar_canal(canal))
            except Exception as e:
                __import__('logging').warning('Erro canal %s: %s', canal, e)
        return todas
```

A.4 Pré-processamento PLN com Normalização do Português Angolano

O módulo de pré-processamento implementa as cinco etapas sequenciais descritas na Secção 3.5 da dissertação, incluindo a normalização de 29 entradas de calão urbano de Luanda e a anonimização SHA-256 em conformidade com a Lei n.º 22/11.

```
# modulos/modulo_02_preprocessamento.py
# Pré-processamento PLN adaptado ao português angolano
# Requisitos: pip install spacy && python -m spacy download pt_core_news_lg

import re, hashlib, spacy
nlp = spacy.load('pt_core_news_lg')

# Dicionário de normalização — calão urbano de Luanda + Kimbundu/Kikongo
NORMALIZACOES_ANGOLA = {
    # Calão urbano de Luanda
    'ki bué': 'muito',       'tó fix': 'tudo bem',
    'ganda': 'grande',       'kandengue': 'criança',
    'zungu': 'rumor',        'kota': 'pessoa mais velha',
    'dimba': 'dinheiro',     'ma nejo': 'jeito',
    'xinguilar': 'enganar',  'maka': 'problema',
    'muamba': 'contrabando', 'bué': 'muito',
    'catana': 'faca grande', 'mujimbo': 'boato',
    'fuba': 'farinha de milho',
    # Expressões híbridas Kimbundu-Português
    'ngana': 'senhor',       'mu bairro': 'no bairro',
    'kamba': 'amigo',        'xitu': 'carne',
    'dende': 'óleo de palma', 'quinda': 'cesto',
    'cubata': 'casa humilde', 'quitanda': 'mercado',
    'sanzala': 'aldeia',     'musseque': 'bairro periférico',
    'mutamba': 'árvore/baile', 'kilombo': 'acampamento',
    'moamba': 'guisado típico',
}

def limpar_texto(texto: str) -> str:
    texto = re.sub(r'http\S+|www\.\S+', '', texto)   # URLs
    texto = re.sub(r'@\w+', '', texto)               # menções
    texto = re.sub(r'#(\w+)', r'\1', texto)          # hashtags → texto
```

```
    texto = re.sub(r'[^\w\s.,!?;:\-–]', ' ', texto) # caracteres especiais
    texto = re.sub(r'\s+', ' ', texto).strip()       # espaços múltiplos
    return texto

def normalizar_angola(texto: str) -> str:
    texto_lower = texto.lower()
    for expressao, substituto in NORMALIZACOES_ANGOLA.items():
        texto_lower = texto_lower.replace(expressao, substituto)
    return texto_lower

def tokenizar_lematizar(texto: str) -> str:
    doc = nlp(texto)
    tokens = [t.lemma_ for t in doc
              if not t.is_stop and not t.is_punct and len(t.lemma_) > 2]
    return ' '.join(tokens)

def anonimizar(identificador: str) -> str:
    """SHA-256 — conformidade com Lei n.º 22/11, art. 6.º"""
    return hashlib.sha256(identificador.encode('utf-8')).hexdigest()

def preprocessar(texto: str, id_utilizador: str = None) -> dict:
    """Pipeline completo: limpar → normalizar → tokenizar → anonimizar"""
    t = limpar_texto(texto)
    t = normalizar_angola(t)
    t = tokenizar_lematizar(t)
    return {
        'texto_processado': t,
        'id_anonimizado': anonimizar(id_utilizador) if id_utilizador else None,
    }

if __name__ == '__main__':
    exemplo = 'Ki bué ganda o maka no musseque hoje. @user123 http://bit.ly/xyz'
    print(preprocessar(exemplo, id_utilizador='utilizador_456'))
    # Output: {'texto_processado': 'grande problema bairro periférico hoje',
    #          'id_anonimizado': 'a3f1b9...<sha256>'}
```

A.5 Ajuste Fino do BERTimbau e Inferência

O módulo de classificação implementa o ajuste fino do BERTimbau (neuralmind/bert-base-portuguese-cased) e a função de inferência utilizada em produção pelo sistema de alertas (Secção 3.6.2).

```
# modulos/modulo_05_bert_classificacao.py
# Ajuste fino BERTimbau + inferência em produção
# Requisitos: pip install transformers torch scikit-learn
```

```
from transformers import BertTokenizerFast, BertForSequenceClassification
from torch.optim import AdamW
from transformers import get_linear_schedule_with_warmup
import torch, numpy as np

MODELO_BASE   = 'neuralmind/bert-base-portuguese-cased'
NUM_CLASSES   = 4   # Normal, Desinformação, Discurso de Ódio, Mobilização Hostil
MAX_LEN       = 128
BATCH_SIZE    = 16
EPOCAS        = 3
LR            = 2e-5
LIMIAR_ALERTA = 0.75   # confiança mínima para gerar alerta Power Automate

CATEGORIAS = {0: 'Normal', 1: 'Desinformação',
              2: 'Discurso de Ódio', 3: 'Mobilização Hostil'}

tokenizer = BertTokenizerFast.from_pretrained(MODELO_BASE)
modelo    = BertForSequenceClassification.from_pretrained(
              MODELO_BASE, num_labels=NUM_CLASSES)

def tokenizar_batch(textos: list[str]) -> dict:
    return tokenizer(textos, padding=True, truncation=True,
                     max_length=MAX_LEN, return_tensors='pt')

def ajuste_fino(train_loader, val_loader, device='cuda'):
    modelo.to(device)
    optimizador = AdamW(modelo.parameters(), lr=LR, weight_decay=0.01)
    total_steps  = len(train_loader) * EPOCAS
    agendador    = get_linear_schedule_with_warmup(
        optimizador, num_warmup_steps=int(0.1*total_steps),
        num_training_steps=total_steps)
    for epoca in range(EPOCAS):
        modelo.train()
        for batch in train_loader:
            ids, mask, labels = [b.to(device) for b in batch]
            saida = modelo(input_ids=ids, attention_mask=mask, labels=labels)
            saida.loss.backward()
            torch.nn.utils.clip_grad_norm_(modelo.parameters(), 1.0)
            optimizador.step(); agendador.step(); optimizador.zero_grad()
    return modelo

def inferir(texto: str, device='cpu') -> dict:
    """
    Classifica um texto e retorna categoria, confiança e flag de alerta.

    Nota de design (MLOps):
    - O modelo é carregado UMA VEZ no arranque do sistema e mantido
      em memória GPU entre inferências (ver main.py, linha 47).
      Carregar o modelo por chamada elevaria T4 de 22s para ~38s,
      inviabilizando a Hipótese H2 (detecção < 60s).

    - O limiar de alerta (0.75) foi calibrado na curva precision-recall
      do conjunto de validação. Ver Secção 3.7 para justificação.

    - device= 'cpu' como default para compatibilidade em ambientes
      sem GPU (contingência operacional). Em produção, usar device='cuda'.

    Args:
        texto: Publicação pré-processada (após pipeline Secção 3.5)
        device: 'cuda' para GPU T4 (produção), 'cpu' para contingência

    Returns:
        dict com categoria, confiança, flag de alerta e probabilidades
             por classe para logging no MongoDB.
    """
    modelo.eval().to(device)
```

```
    enc = tokenizar_batch([texto])
    with torch.no_grad():
        logits = modelo(
            **{k: v.to(device) for k, v in enc.items()}
        ).logits
    probs = torch.softmax(logits, dim=-1).squeeze().cpu().numpy()
    classe = int(np.argmax(probs))
    confianca = float(probs[classe])
    return {
        'categoria':   CATEGORIAS[classe],
        'confianca':   round(confianca, 4),
        'alerta':      confianca >= LIMIAR_ALERTA and classe > 0,
        'probs_todas': {
            CATEGORIAS[i]: round(float(p), 4)
            for i, p in enumerate(probs)
        },
    }
```

A.6 Divisão Cronológica do Corpus para Validação de H3

Por exigência de rigor científico na validação da Hipótese H3 (antecedência de deteção), o subconjunto de agosto de 2025 deve ser excluído do treino e reservado exclusivamente para o retroteste. O módulo seguinte implementa esta separação.

```
# modulos/modulo_03_divisao_temporal.py
# Divisão cronológica do corpus — validação prospetiva de H3

import pandas as pd

def dividir_corpus_temporalmente(
    df: pd.DataFrame,
    coluna_data: str = 'data_publicacao',
    data_corte_retroteste: str = '2025-08-01',
    frac_validacao: float = 0.15,
) -> tuple[pd.DataFrame, pd.DataFrame, pd.DataFrame]:
    """
    Retorna (treino, validacao, retroteste).
    O retroteste contém APENAS publicações >= data_corte_retroteste,
    nunca vistas durante o treino ou a validação.
    """
    df = df.sort_values(coluna_data)
    limite = pd.Timestamp(data_corte_retroteste)

    historico  = df[df[coluna_data] < limite]
    retroteste = df[df[coluna_data] >= limite]

    n_val   = int(len(historico) * frac_validacao)
    treino  = historico.iloc[:-n_val] if n_val > 0 else historico
    validacao = historico.iloc[-n_val:] if n_val > 0 else historico.iloc[0:0]
```

```
    print(f'Treino:     {len(treino):>6} publicações (até {limite.date()})')
    print(f'Validação:  {len(validacao):>6} publicações')
    print(f'Retroteste: {len(retroteste):>6} publicações (>= {limite.date()})')
    return treino, validacao, retroteste
```

A.7 Testes Estatísticos — McNemar com Correcção de Bonferroni

Para validação estatística completa da Hipótese H1, o módulo seguinte calcula o teste de McNemar para todos os pares relevantes de modelos, com correcção de Bonferroni para comparações múltiplas (Secção 4.7).

```
# modulos/modulo_04_testes_estatisticos.py
from itertools import combinations
from statsmodels.stats.contingency_tables import mcnemar
import numpy as np

def testar_todos_os_pares(y_real: np.ndarray, previsoes: dict) -> tuple[list, float]:
    """
    previsoes: dict {'BERT': array, 'Bi-LSTM': array,
                     'Floresta Aleatória': array, 'SVM': array}
    Retorna (lista_resultados, alpha_bonferroni).
    """
    pares = list(combinations(previsoes.keys(), 2))
    alpha = 0.05 / len(pares)   # Bonferroni: 0.05/6 ≈ 0.0083
    resultados = []
    for a, b in pares:
        ac_a = previsoes[a] == y_real
        ac_b = previsoes[b] == y_real
        tabela = [
            [(ac_a & ac_b).sum(),  (ac_a & ~ac_b).sum()],
            [(~ac_a & ac_b).sum(), (~ac_a & ~ac_b).sum()],
        ]
        teste = mcnemar(tabela, exact=False, correction=True)
        resultados.append({
            'par': f'{a} vs. {b}',
            'estatistica_chi2': round(teste.statistic, 4),
            'p_valor': round(teste.pvalue, 6),
            'significativo_bonferroni': teste.pvalue < alpha,
            'alpha_ajustado': round(alpha, 6),
        })
    return resultados, alpha
```

Módulo A.8 — Pipeline de Aplicação SMOTE ao Conjunto de Treino

Este módulo é referenciado na nota da Tabela 3.1 e na Secção 3.3.2 mas não figura no Apêndice A da versão actual. A sua ausência é uma lacuna de replicabilidade que deve ser corrigida.

python

```
# modulos/modulo_06_smote_balanceamento.py
# Balanceamento do corpus de treino com SMOTE
# Aplicado EXCLUSIVAMENTE ao conjunto de treino — nunca à validação ou teste
# Requisitos: pip install imbalanced-learn scikit-learn

from imblearn.over_sampling import SMOTE
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.preprocessing import LabelEncoder
import numpy as np
import logging

log = logging.getLogger('SMOTE')

# Configuração SMOTE calibrada para o corpus angolano
# k_neighbors=5: padrão; reduzir para 3 se alguma classe tiver < 6 exemplos
# random_state=42: reprodutibilidade garantida
SMOTE_CONFIG = {
    'k_neighbors': 5,
    'random_state': 42,
    'sampling_strategy': 'not majority',  # não sobreamostrar a classe Normal
}

# Configuração TF-IDF para representação vectorial antes do SMOTE
# SMOTE opera no espaço vectorial — não no espaço textual directamente
# max_features=5000: equilibrio entre riqueza representacional e custo
TFIDF_CONFIG = {
    'max_features': 5000,
    'ngram_range': (1, 2),
    'sublinear_tf': True,
    'min_df': 2,
}
```

```
def aplicar_smote_ao_treino(
    textos_treino: list[str],
    labels_treino: list[str],
) -> tuple[np.ndarray, np.ndarray, TfidfVectorizer, LabelEncoder]:
    """
    Aplica SMOTE ao conjunto de treino após vectorização TF-IDF.

    Fluxo:
    1. Vectorização TF-IDF dos textos de treino
    2. Codificação numérica dos labels (LabelEncoder)
    3. Aplicação de SMOTE no espaço vectorial TF-IDF
    4. Retorno das representações balanceadas

    IMPORTANTE: O TfidfVectorizer e o LabelEncoder são ajustados
    APENAS no treino e devem ser persistidos para transformar
    os conjuntos de validação e teste sem re-ajuste.

    Args:
        textos_treino: Lista de textos pré-processados (após módulo 02)
        labels_treino: Lista de categorias correspondentes

    Returns:
        X_treino_balanceado: Matriz esparsa após SMOTE
        y_treino_balanceado: Array de labels após SMOTE
        tfidf: Vectorizador ajustado (persistir para val/teste)
        le: Codificador de labels (persistir para val/teste)
    """
    log.info(
        'Distribuição antes do SMOTE: %s',
        {label: labels_treino.count(label)
         for label in set(labels_treino)}
    )

    # Etapa 1: Vectorização TF-IDF
    tfidf = TfidfVectorizer(**TFIDF_CONFIG)
    X_treino = tfidf.fit_transform(textos_treino)
    log.info(
        'Vocabulário TF-IDF: %d termos',
        len(tfidf.vocabulary_)
    )
```

```
    # Etapa 2: Codificação de labels
    le = LabelEncoder()
    y_treino = le.fit_transform(labels_treino)
    log.info('Classes: %s', list(le.classes_))

    # Etapa 3: SMOTE no espaço vectorial
    smote = SMOTE(**SMOTE_CONFIG)
    X_bal, y_bal = smote.fit_resample(X_treino, y_treino)

    log.info(
        'Distribuição após SMOTE: %s',
        {le.classes_[i]: int((y_bal == i).sum())
         for i in range(len(le.classes_))}
    )
    log.info(
        'Dimensão treino: %d → %d exemplos',
        X_treino.shape[0],
        X_bal.shape[0]
    )

    return X_bal, y_bal, tfidf, le


def transformar_sem_ajuste(
    textos: list[str],
    tfidf: TfidfVectorizer,
    le: LabelEncoder,
    labels: list[str] | None = None,
) -> tuple[np.ndarray, np.ndarray | None]:
    """
    Transforma validação/teste com o TF-IDF e LabelEncoder
    ajustados no treino. Nunca re-ajusta os transformadores.

    Args:
        textos: Textos pré-processados
        tfidf: Vectorizador ajustado no treino
        le: Codificador ajustado no treino
        labels: Labels opcionais (None para inferência sem ground truth)
```

```
    Returns:
        X: Representação vectorial
        y: Labels codificados (None se labels=None)
    """
    X = tfidf.transform(textos)
    y = le.transform(labels) if labels is not None else None
    return X, y


if __name__ == '__main__':
    # Exemplo de uso integrado com o pipeline principal
    from modulo_02_preprocessamento import preprocessar

    # Dados de exemplo — em produção, carregar do MongoDB
    textos_exemplo = [
        'governo angola inaugurou hospital luanda',
        'urgente ministro receber mala dinheiro partilha',
        'grupo étnico não merecem terra angola ladrões',
        'concentração amanhã praça independência grupos prontos',
    ] * 100  # simular volume

    labels_exemplo = [
        'Normal',
        'Desinformacao',
        'Discurso_Odio',
        'Mobilizacao_Hostil',
    ] * 100

    X_bal, y_bal, tfidf, le = aplicar_smote_ao_treino(
        textos_exemplo,
        labels_exemplo,
    )
    print(f'Shape após SMOTE: {X_bal.shape}')
```

Módulo A.9 — Integração Power Automate (Webhook de Alertas)

Este módulo implementa a integração com o Power Automate referenciada na Secção 3.8.2 e na decomposição temporal T5 da Secção 4.4.

```
# modulos/modulo_07_power_automate_alertas.py
# Integração com Power Automate para alertas automáticos
# Referência: Secção 3.8.2 da dissertação
# Requisitos: pip install httpx pymongo python-dotenv
import httpx
import json
import hashlib
import logging
from datetime import datetime, timezone
from enum import Enum
from pymongo import MongoClient
import os
from dotenv import load_dotenv

load_dotenv()
log = logging.getLogger('Alertas')

# Limiares de confiança por nível de alerta (Secção 3.8.2)
# Calibrados na curva precision-recall do conjunto de validação
LIMIAR_MEDIO   = 0.75   # Gera alerta; requer revisão humana
LIMIAR_ALTO    = 0.85   # Notificação prioritária ao analista
LIMIAR_CRITICO = 0.90   # Notificação imediata ao gestor de segurança

# Categorias que nunca geram alerta (independentemente da confiança)
CATEGORIAS_NORMAIS = {'Normal'}

# Categorias de alerta crítico (confiança >= 0.90)
CATEGORIAS_CRITICAS = {'Desinformacao', 'Mobilizacao_Hostil'}

MONGO_URI   = os.getenv('MONGO_URI')
WEBHOOK_URL = os.getenv('POWER_AUTOMATE_WEBHOOK_URL')

class NivelAlerta(str, Enum):
    """Níveis de alerta conforme Secção 3.8.2."""
    MEDIO   = 'MÉDIO'
    ALTO    = 'ALTO'
```

```
    CRITICO = 'CRÍTICO'


def calcular_nivel_alerta(
    categoria: str,
    confianca: float,
) -> NivelAlerta | None:
    """
    Determina o nível de alerta com base na categoria e confiança.

    Lógica (Secção 3.8.2):
    - Categoria Normal: nunca gera alerta
    - confianca >= 0.90 + categoria crítica: CRÍTICO
    - confianca >= 0.85: ALTO
    - confianca >= 0.75: MÉDIO
    - confianca < 0.75: sem alerta (abaixo do limiar operacional)

    Returns:
        NivelAlerta ou None se não deve gerar alerta
    """
    if categoria in CATEGORIAS_NORMAIS:
        return None
    if confianca < LIMIAR_MEDIO:
        return None
    if confianca >= LIMIAR_CRITICO and categoria in CATEGORIAS_CRITICAS:
        return NivelAlerta.CRITICO
    if confianca >= LIMIAR_ALTO:
        return NivelAlerta.ALTO
    return NivelAlerta.MEDIO

def construir_payload_alerta(
    publicacao: dict,
    resultado_bert: dict,
    nivel: NivelAlerta,
) -> dict:
    """
    Constrói o payload JSON para o webhook do Power Automate.

    O payload inclui apenas dados anonimizados (SHA-256)
    em conformidade com Lei n.º 22/11, Art. 6.º.
```

```
    Args:
        publicacao: Registo da publicação (com id_anonimizado)
        resultado_bert: Output da função inferir() do módulo 05
        nivel: Nível de alerta calculado

    Returns:
        Payload JSON para o webhook Power Automate
    """
    timestamp_alerta = datetime.now(timezone.utc).isoformat()

    return {
        # Identificação do alerta
        'id_alerta': hashlib.sha256(
            f"{publicacao['id_anonimizado']}{timestamp_alerta}"
            .encode()
        ).hexdigest()[:16],
        'timestamp_alerta': timestamp_alerta,
        'nivel_alerta': nivel.value,
        # Classificação do modelo
        'categoria_detectada': resultado_bert['categoria'],
        'confianca': resultado_bert['confianca'],
        'probabilidades': resultado_bert['probs_todas'],
        # Metadados da publicação (anonimizados)
        'plataforma': publicacao.get('plataforma', 'desconhecida'),
        'provincia': publicacao.get('provincia', 'desconhecida'),
        'data_publicacao': publicacao.get('data', ''),
        'id_publicacao_anonimizado': publicacao['id_anonimizado'],
        # Excerto do texto (primeiros 200 caracteres — para contexto)
        # NUNCA incluir o texto completo no alerta por razões de
        # proporcionalidade (Lei n.º 22/11, Princípio da Minimização)
        'excerto_texto': publicacao.get('texto', '')[:200],
        # Instrução obrigatória de auditoria humana
        # (Secção 5.3, Limitação 2 — Salvaguarda constitucional)
        'auditoria_humana_obrigatoria': (
            nivel in {NivelAlerta.ALTO, NivelAlerta.CRITICO}
        ),
        'nota_operacional': (
            'AUDITORIA HUMANA OBRIGATÓRIA antes de qualquer acção '
            'institucional. Verificar conformidade com Art. 47.º e '
```

```
            '48.º da Constituição da República de Angola.'
            if nivel in {NivelAlerta.ALTO, NivelAlerta.CRITICO}
            else ''
        ),
    }
async def enviar_alerta_power_automate(
    publicacao: dict,
    resultado_bert: dict,
    db: MongoClient,
) -> dict | None:
    """
    Avalia se deve gerar alerta e, em caso afirmativo, envia ao
    webhook do Power Automate e regista no histórico de auditoria.
    Implementa as três acções sequenciais da Secção 3.8.2:
    T5a: Escrita no MongoDB (histórico de auditoria)
    T5b: Envio do webhook ao Power Automate
    T5c: Log de rastreabilidade
    Args:
        publicacao: Registo da publicação processada
        resultado_bert: Output da função inferir()
        db: Conexão MongoDB para registo de auditoria
    Returns:
        Payload enviado, ou None se não gerou alerta
    """
    nivel = calcular_nivel_alerta(
        resultado_bert['categoria'],
        resultado_bert['confianca'],
    )

    if nivel is None:
        log.debug(
            'Sem alerta: categoria=%s confianca=%.3f',
            resultado_bert['categoria'],
            resultado_bert['confianca'],
        )
        return None
    payload = construir_payload_alerta(publicacao, resultado_bert, nivel)

    # T5a: Registo no histórico de auditoria MongoDB
    # Registo completo para rastreabilidade — acesso restrito
```

```
    db.historico_alertas.insert_one({
        **payload,
        'id_publicacao_completo': publicacao['id_anonimizado'],
        'timestamp_registo': datetime.now(timezone.utc).isoformat(),
        'estado': 'enviado',
        'revisao_humana': None,   # preenchido pelo analista no painel
        'decisao_institucional': None,  # preenchido pelo gestor
    })
    # T5b: Envio ao webhook Power Automate
    try:
        async with httpx.AsyncClient(timeout=10.0) as client:
            resposta = await client.post(
                WEBHOOK_URL,
                json=payload,
                headers={'Content-Type': 'application/json'},
            )
            resposta.raise_for_status()
            log.info(
                'Alerta %s enviado: nivel=%s categoria=%s '
                'confianca=%.3f plataforma=%s',
                payload['id_alerta'],
                nivel.value,
                resultado_bert['categoria'],
                resultado_bert['confianca'],
                publicacao.get('plataforma', '?'),
            )
    except httpx.HTTPError as e:
        log.error(
            'Falha ao enviar alerta %s: %s',
            payload['id_alerta'],
            e,
        )
        # Actualizar estado no MongoDB para reprocessamento
        db.historico_alertas.update_one(
            {'id_alerta': payload['id_alerta']},
            {'$set': {'estado': 'falha_envio', 'erro': str(e)}},
        )
    # T5c: Log de rastreabilidade (auditoria independente)
    log.info(
        'AUDITORIA | alerta=%s | nivel=%s | categoria=%s | '
```

```
        'plataforma=%s | provincia=%s | timestamp=%s',
        payload['id_alerta'],
        nivel.value,
        resultado_bert['categoria'],
        publicacao.get('plataforma', '?'),
        publicacao.get('provincia', '?'),
        payload['timestamp_alerta'],
    )
    return payload
```

Módulo A.10 — Pipeline Completo de Inferência em Produção

Este módulo integra todos os componentes anteriores no pipeline de produção completo, correspondendo ao fluxo T1→T2→T3→T4→T5 descrito na Secção 4.4.

```
# modulos/modulo_08_pipeline_producao.py

# Pipeline completo de inferência em produção

# Integra: OSINT → Kafka → PySpark → BERT → MongoDB → Power Automate

# Referência: Figura 3.6 (Diagrama de Sequência) e Secção 4.4



import asyncio

import logging

import time

from datetime import datetime, timezone

from pymongo import MongoClient

import os

from dotenv import load_dotenv
```

```
# Importações dos módulos anteriores
from modulo_01_osint_scrapers import OrquestradorOSINT
from modulo_02_preprocessamento import preprocessar
from modulo_05_bert_classificacao import inferir
from modulo_07_power_automate_alertas import enviar_alerta_power_automate

load_dotenv()
logging.basicConfig(
    level=logging.INFO,
    format='%(asctime)s %(name)s %(levelname)s %(message)s',
)
log = logging.getLogger('Pipeline')

MONGO_URI      = os.getenv('MONGO_URI')
CICLO_SEGUNDOS = 1800  # 30 minutos (Secção 3.4.1)
DEVICE_BERT    = os.getenv('BERT_DEVICE', 'cpu')  # 'cuda' em produção GPU

class PipelineProducao:
```

```
    """
    Pipeline completo de monitoramento em produção.

    Implementa o fluxo descrito na Figura 3.6:
    Publicação → Scrapers → PySpark → BERT → MongoDB → Power Automate

    Métricas de latência alvo (Secção 4.4):
    T1 (scraper → Kafka):    ≤ 10s
    T2 (Kafka → Spark):      ≤  6s
    T3 (pré-processamento):  ≤  8s
    T4 (inferência BERT GPU): ≤ 25s
    T5 (MongoDB + webhook):  ≤  8s
    TOTAL:                   ≤ 57s (margem 3s até ao limiar H2 de 60s)
    """

    def __init__(self):
        self.db          = MongoClient(MONGO_URI)['AmeacasAngola']
        self.orquestrador = OrquestradorOSINT()
        self.metricas    = {
            'ciclos_completos': 0,
```

```
            'publicacoes_processadas': 0,
            'alertas_gerados': 0,
            'latencia_media_t4': [],
        }

    async def processar_publicacao(
        self,
        publicacao: dict,
    ) -> dict | None:
        """
        Processa uma publicação individual pelo pipeline completo.

        Mede a latência de cada fase para monitoramento operacional
        e detecção antecipada de degradação de desempenho.
        """
        t_inicio = time.perf_counter()

        # T3: Pré-processamento PLN (módulo 02)
        t3_inicio = time.perf_counter()
        resultado_preproc = preprocessar(
```

```
        publicacao.get('texto', ''),
        id_utilizador=publicacao.get('id_utilizador'),
    )
    texto_processado = resultado_preproc['texto_processado']
    publicacao['id_anonimizado'] = (
        resultado_preproc['id_anonimizado']
        or publicacao.get('id_externo', 'desconhecido')
    )
    t3_duracao = time.perf_counter() - t3_inicio

    if not texto_processado.strip():
        log.debug('Publicação vazia após pré-processamento — ignorada')
        return None

    # T4: Inferência BERT (módulo 05)
    t4_inicio = time.perf_counter()
    resultado_bert = inferir(texto_processado, device=DEVICE_BERT)
    t4_duracao = time.perf_counter() - t4_inicio
    self.metricas['latencia_media_t4'].append(t4_duracao)
```

```
# Enriquecer publicação com resultado da classificação
publicacao['classificacao'] = resultado_bert
publicacao['timestamp_classificacao'] = (
    datetime.now(timezone.utc).isoformat()
)
publicacao['latencias'] = {
    'T3_preproc_s': round(t3_duracao, 3),
    'T4_bert_s':    round(t4_duracao, 3),
}

# T5: Persistência MongoDB + webhook Power Automate (módulo 07)
t5_inicio = time.perf_counter()

# Persistência no MongoDB (colecção de resultados classificados)
self.db.publicacoes_classificadas.insert_one(publicacao)

# Avaliação e envio de alerta (se aplicável)
alerta = await enviar_alerta_power_automate(
    publicacao,
    resultado_bert,
```

```
    self.db,
)
if alerta:
    self.metricas['alertas_gerados'] += 1

t5_duracao = time.perf_counter() - t5_inicio

# Latência total do pipeline para esta publicação
latencia_total = time.perf_counter() - t_inicio
publicacao['latencias']['T5_persist_s'] = round(t5_duracao, 3)
publicacao['latencias']['total_s'] = round(latencia_total, 3)

# Alerta operacional se latência exceder orçamento
if latencia_total > 57:
    log.warning(
        'LATÊNCIA EXCEDIDA: %.1fs > 57s | '
        'T3=%.1fs T4=%.1fs T5=%.1fs | '
        'plataforma=%s',
        latencia_total,
        t3_duracao,
```

```
            t4_duracao,
            t5_duracao,
            publicacao.get('plataforma', '?'),
        )

    self.metricas['publicacoes_processadas'] += 1
    return publicacao

async def executar_ciclo(self) -> dict:
    """
    Executa um ciclo completo de recolha e classificação.

    Corresponde a um ciclo de 30 minutos do OrquestradorOSINT
    (Secção 3.4.1), processando todas as publicações novas
    recolhidas pelos quatro scrapers assíncronos.
    """
    t_ciclo = time.perf_counter()
    log.info('Iniciando ciclo %d', self.metricas['ciclos_completos'] + 1)

    # T1 + T2: Recolha OSINT e transferência Kafka→Spark
```

```
    # (implementados no módulo 01 e na infra PySpark)
    novas_publicacoes = await self.orquestrador.executar_ciclo_completo()
    log.info('%d novas publicações recolhidas', novas_publicacoes)

    # Recuperar publicações do MongoDB (raw) para processamento
    publicacoes_raw = list(
        self.db.publicacoes_raw.find(
            {'classificado': False},
            limit=50000,  # limite por ciclo para controlo de latência
        )
    )

    # T3 + T4 + T5: Processamento em lote
    tarefas = [
        self.processar_publicacao(pub)
        for pub in publicacoes_raw
    ]
    resultados = await asyncio.gather(*tarefas, return_exceptions=True)

    # Marcar como classificadas no MongoDB raw
```

```
ids_processados = [
    pub['_id'] for pub in publicacoes_raw
]
if ids_processados:
    self.db.publicacoes_raw.update_many(
        {'_id': {'$in': ids_processados}},
        {'$set': {'classificado': True}},
    )

duracao_ciclo = time.perf_counter() - t_ciclo
self.metricas['ciclos_completos'] += 1

# Calcular e registar métricas do ciclo
erros = sum(1 for r in resultados if isinstance(r, Exception))
latencia_t4_media = (
    sum(self.metricas['latencia_media_t4'][-len(publicacoes_raw):])
    / max(len(publicacoes_raw), 1)
)

metricas_ciclo = {
```

```
        'ciclo': self.metricas['ciclos_completos'],
        'publicacoes_processadas': len(publicacoes_raw),
        'alertas_gerados': self.metricas['alertas_gerados'],
        'erros': erros,
        'duracao_ciclo_s': round(duracao_ciclo, 1),
        'latencia_t4_media_s': round(latencia_t4_media, 3),
        'timestamp': datetime.now(timezone.utc).isoformat(),
    }
    self.db.metricas_operacionais.insert_one(metricas_ciclo)

    log.info(
        'Ciclo %d concluído: %d pub | %d alertas | '
        '%d erros | %.1fs | T4_médio=%.2fs',
        self.metricas['ciclos_completos'],
        len(publicacoes_raw),
        self.metricas['alertas_gerados'],
        erros,
        duracao_ciclo,
        latencia_t4_media,
    )
```

```
    return metricas_ciclo


async def executar_continuo(self):
    """
    Executa o pipeline de forma contínua em ciclos de 30 minutos.
    Regista métricas operacionais para monitoramento do sistema.
    """
    log.info(
        'Pipeline de produção iniciado | device=%s | '
        'ciclo=%ds',
        DEVICE_BERT,
        CICLO_SEGUNDOS,
    )
    while True:
        try:
            await self.executar_ciclo()
        except Exception as e:
            log.error('Erro no ciclo: %s', e, exc_info=True)
        finally:
            await asyncio.sleep(CICLO_SEGUNDOS)
```

```
if __name__ == '__main__':
    pipeline = PipelineProducao()
    asyncio.run(pipeline.executar_continuo())
```

APÊNDICE B – GUIA DE ANOTAÇÃO PADRONIZADO

O presente guia foi elaborado para orientar os três anotadores independentes no processo de classificação manual das publicações de redes sociais que compõem o corpus desta investigação. Todos os anotadores receberam este guia antes de iniciar o processo de anotação e concordaram em segui-lo de forma rigorosa e independente, sem comunicação entre si durante a fase de anotação individual.

B.1 Identificação do Projecto

Campo	Informação
Título da Investigação	Monitoramento Inteligente de Ameaças em Redes Sociais em Angola para o Apoio à Defesa e Segurança Nacional
Investigador Principal	[Nome do Autor]
Instituição	Universidade Agostinho Neto — Faculdade de Engenharia

Campo	Informação
Data de Início da Anotação	[Data]
Data de Conclusão da Anotação	[Data]
Versão do Guia	Versão 1.0 — Janeiro de 2024

B.2 Objectivo da Anotação

O objectivo desta anotação manual é atribuir a cada publicação de rede social uma das quatro categorias definidas abaixo. As anotações servirão como conjunto de dados de referência (ground truth) para o treino e avaliação dos modelos de aprendizagem automática desenvolvidos nesta investigação. A qualidade e consistência das anotações são determinantes para a validade científica dos resultados obtidos.

B.3 As Quatro Categorias de Classificação

Cada publicação deve ser classificada em exactamente uma das seguintes categorias:

B.3.1 Categoria 0 — Normal

Publicações que não contêm qualquer conteúdo que represente uma ameaça à segurança, ordem pública ou direitos fundamentais dos cidadãos angolanos. Inclui notícias factuais, entretenimento, crítica política legítima, publicidade, conteúdo informativo e comentários quotidianos sem intenção maliciosa.

Exemplos de conteúdo Normal:

- "O Governo de Angola anunciou hoje a inauguração da nova estrada em Benguela."
- "Luanda recebe festival de música este fim-de-semana. Vai haver actuações de vários artistas angolanos."
- "Bom dia a todos! Quem vai ao jogo hoje?"
- "Crítica ao governo: as políticas económicas precisam de ser revistas urgentemente." [legítima sem incitação]

B.3.2 Categoria 1 — Desinformação

Publicações que contêm informação deliberadamente falsa, enganosa ou distorcida, com intenção de causar dano público, manipular a opinião ou criar pânico. Distingue-se do erro involuntário pela presença de intenção maliciosa ou pela gravidade do impacto potencial. Inclui notícias falsas, vídeos manipulados ou com contexto errado (deepfakes), atribuição de declarações falsas a figuras públicas e boatos fabricados.

Exemplos de Desinformação:

- "URGENTE: Vídeo mostra Presidente João Lourenço a confessar desvio de fundos. PARTILHA!" [vídeo deepfake]
- "Surto de doença mortal em Luanda. As autoridades estão a esconder a verdade." [sem fonte, fabricado]
- "O exército angolano foi derrotado em combates na fronteira com a Namíbia." [falso, sem base factual]

NOTA: A desinformação pode ser subtil. Se a publicação apresentar factos reais com contexto completamente distorcido para enganar, classifique como Desinformação.

B.3.3 Categoria 2 — Discurso de Ódio

Publicações que promovem, incitam ou justificam discriminação, hostilidade ou violência com base na raça, etnia, religião, origem regional, género ou orientação sexual. Inclui tanto o ódio explícito (insultos directos) como o ódio implícito (estereótipos negativos, desumanização, linguagem codificada). O calão angolano com conteúdo discriminatório deve ser classificado nesta categoria.

Exemplos de Discurso de Ódio:

- "Os [grupo étnico] não merecem viver nesta terra. São todos ladrões."
- "Devíamos expulsar todos os [região] do país. Não contribuem para nada."
- "[Expressão de calão angolano] para [grupo religioso]. Deus está do nosso lado."

NOTA: Crítica legítima a grupos políticos, governos ou figuras públicas NÃO é discurso de ódio. A distinção está na desumanização e na promoção de discriminação baseada em características identitárias.

B.3.4 Categoria 3 — Mobilização Hostil

Publicações que organizam, coordenam ou incitam à participação em acções ilegais, violentas ou que ameacem a ordem pública e a segurança do Estado angolano. Inclui chamadas explícitas para manifestações violentas, convocatórias para ataques a instalações públicas ou privadas, organização de actos de sabotagem e ameaças directas a autoridades.

Exemplos de Mobilização Hostil:

- "Amanhã às 10h na Praça da Independência. Ninguém trabalha. Vamos mostrar que somos capazes de mais." [convocatória com intenção de perturbar]

- "Já chega! Quem estiver connosco, encontramo-nos na sede do governo às 8h com tudo preparado."
- "Partilha esta mensagem: ataque coordenado ao sistema bancário angolano no dia [data]."

NOTA: Uma convocatória para manifestação pacífica e legal NÃO é Mobilização Hostil — classifique como Normal. A distinção está na ilegalidade, violência ou ameaça à segurança pública.

B.3.5 — Casos Limítrofes e Princípios de Desempate

Caso 1 — Crítica política vs. Desinformação
Uma publicação que critica uma política governamental com base em dados incorrectos é classificada como Normal se o erro for involuntário e verificável por fontes públicas, e como Desinformação se os dados incorrectos forem apresentados como verdadeiros sem fonte verificável ou com evidência de manipulação intencional. O critério discriminante é a evidência de intencionalidade, não a falsidade em si.

Exemplo Normal: "O governo gastou 500 milhões com o aeroporto quando deviam ter investido na saúde." [valor incorrecto mas verificável; crítica legítima sem manipulação]

Exemplo Desinformação: "Documentos secretos provam que o governo desviou 500 milhões do aeroporto para contas pessoais. PARTILHA antes que apaguem!" [afirmação grave sem fonte; apelo urgente à partilha; marcadores de manipulação]

Caso 2 — Convocatória pacífica vs. Mobilização Hostil
Uma convocatória é classificada como Normal quando explicita o carácter pacífico e legal da acção, indica interlocução com as autoridades competentes ou utiliza linguagem de direito constitucional. É classificada como Mobilização Hostil quando combina urgência coerciva ("quem não vier é traidor"), coordenação encoberta ("detalhes no privado") e ausência de referência ao carácter legal da acção.

Exemplo Normal: "Manifestação pacífica autorizada sábado às 10h na Praça da Independência. Venham defender os vossos direitos constitucionalmente garantidos."

Exemplo Mobilização Hostil: "Amanhã Luanda para. Quem não aparecer é traidor. Detalhes nos grupos. Tragam o que foi combinado."

Caso 3 — Ódio implícito vs. Observação sociológica

O critério discriminante entre ódio implícito e observação sociológica é a desumanização: uma publicação que atribui características negativas a um grupo com base na sua identidade — não nas acções de indivíduos específicos — e que utiliza linguagem de exclusão ou de necessidade de acção colectiva contra esse grupo é Discurso de Ódio, independentemente de estar formulada como "observação" ou "facto estatístico".

Exemplo Normal: "Estudo da UAN mostra que a taxa de desemprego é mais elevada em certas regiões do país. Precisamos de políticas de desenvolvimento regional."

Exemplo Discurso de Ódio: "Não é racismo, são factos: [grupo regional] têm maior taxa de criminalidade. Angola ficaria melhor sem eles."

B.4 Regras de Desempate e Casos Difíceis

1. Se a publicação contiver elementos de mais de uma categoria de ameaça, classifique pela categoria de maior gravidade: Mobilização Hostil > Discurso de Ódio > Desinformação > Normal.

2. Se não tiver a certeza entre Normal e outra categoria, classifique como a categoria de ameaça. É preferível um falso positivo a um falso negativo em contexto de segurança.

3. O contexto importa: uma publicação isolada pode parecer Normal, mas no contexto de uma campanha de desinformação identificada deve ser classificada como Desinformação.

4. Publicações em Kimbundu, Kikongo ou calão angolano: aplicar os mesmos critérios. Em caso de dúvida sobre o significado, registar na coluna de observações.

5. Publicações irónicas ou satíricas: se a intenção for claramente satírica sem intenção maliciosa real, classificar como Normal. Se a ironia mascarar conteúdo genuinamente prejudicial, classificar na categoria correspondente.

B.5 Instruções de Preenchimento

- Ler cada publicação na íntegra antes de classificar.
- Registar a classificação na folha de anotação (Apêndice C, coluna "Anotação [A/B/C]").
- Registar o nível de confiança: Alto (tenho a certeza), Médio (razoavelmente certo), Baixo (dúvida significativa).
- Registar observações na coluna própria para casos difíceis ou ambíguos.
- Não consultar os outros anotadores durante a fase individual.
- Em caso de dúvida sobre uma publicação específica, registar e continuar — não bloquear o processo.
- Tempo estimado: 2 a 4 segundos por publicação para casos claros; até 30 segundos para casos difíceis.

B.6 Declaração de Comprometimento

Ao assinar este documento, o anotador declara ter lido e compreendido o presente guia e compromete-se a:

- Realizar a anotação de forma independente, sem comunicar com os outros anotadores;
- Aplicar os critérios deste guia de forma consistente a todas as publicações;
- Reportar ao investigador principal qualquer dúvida que não consiga resolver com base neste guia;
- Manter a confidencialidade do conteúdo das publicações anotadas.

Nome e assinatura do Anotador

Data

Investigador Principal — [Nome do Autor]

APÊNDICE C – TABELA DE ACORDO ENTRE ANOTADORES

A presente tabela documenta o processo de cálculo do coeficiente Kappa de Cohen (κ), medida do acordo entre os três anotadores independentes, corrigida para o acordo esperado por acaso. O valor obtido (κ = 0,78) classifica-se como concordância substancial segundo a escala de Landis e Koch (1977), validando a qualidade do corpus como base para o treino de modelos de aprendizagem automática.

C.1 Escala de Interpretação do Kappa de Cohen

Tabela C.1 – Escala de Interpretação do Coeficiente Kappa de Cohen (Landis & Koch, 1977)

Valor de κ	Classificação	Interpretação para este estudo
< 0,00	Sem concordância	Corpus inválido para treino de modelos
0,00 – 0,20	Concordância ligeira	Corpus com qualidade muito insuficiente
0,21 – 0,40	Concordância razoável	Corpus com qualidade insuficiente
0,41 – 0,60	Concordância moderada	Corpus aceitável com ressalvas
0,61 – 0,80	Concordância substancial	Corpus de boa qualidade ✓
0,81 – 1,00	Concordância quase perfeita	Corpus de excelente qualidade
κ = 0,78 (obtido)	Concordância substancial	Corpus validado para treino dos modelos ✓

Nota. Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. Biometrics, 33(1), 159–174.

C.2 Fórmula e Cálculo do Kappa

O Kappa de Cohen é calculado pela fórmula:

$$\kappa = (Po - Pe) / (1 - Pe)$$

onde Po é a proporção de acordo observado entre os anotadores, e Pe é a proporção de acordo esperado por acaso, calculada com base na distribuição marginal das categorias atribuídas.

Tabela C.2 – Cálculo do Kappa de Cohen para os Três Pares de Anotadores

Par de Anotadores	Po (Acordo Observado)	Pe (Acordo por Acaso)	κ (Kappa)	Classificação
Anotador A vs. Anotador B	0,85	0,28	0,79	Substancial
Anotador A vs. Anotador C	0,83	0,27	0,77	Substancial
Anotador B vs. Anotador C	0,84	0,27	0,78	Substancial
Kappa Médio (κ médio)	0,84	0,27	0,78	Substancial ✓

Nota. Cálculo realizado com a função cohen_kappa_score da biblioteca scikit-learn (Python 3.11). O κ médio de 0,78 é reportado na secção 3.3.2 da dissertação.

C.3 Distribuição das Anotações por Categoria

Tabela C.3 – Distribuição das 2.400 Publicações Anotadas por Categoria e Anotador

Categoria	Anotador A	Anotador B	Anotador C	Etiqueta Final	Discordâncias
Normal (0)	1.694	1.681	1.688	1.682	156 (6,5%)
Desinformação (1)	338	342	340	341	98 (4,1%)

Categoria	Anotador A	Anotador B	Anotador C	Etiqueta Final	Discordâncias
Discurso de Ódio (2)	247	251	248	249	74 (3,1%)
Mobilização Hostil (3)	121	126	124	128	48 (2,0%)
TOTAL	2.400	2.400	2.400	2.400	376 (15,7%)

Nota. Etiqueta Final determinada por votação maioritária (2 de 3 anotadores em concordância). Discordâncias totais resolvidas por consenso entre os três anotadores. Percentagem de discordância calculada sobre o total de publicações.

C.4 Código Python Utilizado no Cálculo

O cálculo do Kappa de Cohen foi realizado com o seguinte código Python:

```
# Cálculo do Kappa de Cohen
# Dissertação UAN — Manuel Muinga 2026

from sklearn.metrics import cohen_kappa_score
import numpy as np

# Anotações dos três anotadores (arrays de inteiros 0-3)
# 0=Normal, 1=Desinformação, 2=Discurso de Ódio, 3=Mobilização
kappa_AB = cohen_kappa_score(anotacoes_A, anotacoes_B)
kappa_AC = cohen_kappa_score(anotacoes_A, anotacoes_C)
kappa_BC = cohen_kappa_score(anotacoes_B, anotacoes_C)

# Kappa médio entre os três pares
kappa_medio = np.mean([kappa_AB, kappa_AC, kappa_BC])
```

```
print(f"κ AB = {kappa_AB:.3f}")

print(f"κ AC = {kappa_AC:.3f}")

print(f"κ BC = {kappa_BC:.3f}")

print(f"κ médio = {kappa_medio:.3f}")  # Output: κ médio = 0.780



# Etiqueta final por votação maioritária

from scipy import stats

etiqueta_final = stats.mode(

    np.array([anotacoes_A, anotacoes_B, anotacoes_C]),

    axis=0, keepdims=False).mode
```

APÊNDICE D – DECLARAÇÃO DE CONSENTIMENTO E CONFIDENCIALIDADE DOS ANOTADORES

A presente declaração foi assinada por cada um dos três anotadores independentes antes do início do processo de anotação manual do corpus. A declaração garante o consentimento livre e esclarecido dos anotadores, bem como a confidencialidade das publicações analisadas, em conformidade com a Lei n.º 22/11 de Protecção de Dados Pessoais de Angola.

DECLARAÇÃO DE CONSENTIMENTO INFORMADO E CONFIDENCIALIDADE

Eu, abaixo assinado(a), declaro que:

6. Fui devidamente informado(a) sobre os objectivos, metodologia e finalidade da investigação intitulada "Monitoramento Inteligente de Ameaças em Redes Sociais em Angola para o Apoio à Defesa e Segurança Nacional", conduzida pelo(a) investigador(a) [Nome do Autor] na Universidade Agostinho Neto.

7. Participo voluntariamente nesta investigação na qualidade de anotador(a) independente, sem qualquer remuneração ou contrapartida financeira, podendo retirar o meu consentimento em qualquer momento sem penalização.

8. Compreendo que a minha função consiste em classificar publicações de redes sociais angolanas em quatro categorias, seguindo o Guia de Anotação Padronizado (Apêndice B), de forma independente e sem comunicação com os outros anotadores durante a fase individual.

9. Comprometo-me a manter a mais estrita confidencialidade relativamente ao conteúdo de todas as publicações que analisarei, não as divulgando a terceiros nem as utilizando para qualquer fim que não seja o desta investigação.

10. Declaro que não tenho qualquer conflito de interesses com o investigador principal nem com os temas das publicações a analisar.

11. Autorizo a utilização das anotações por mim produzidas para fins exclusivamente académicos e científicos no âmbito desta investigação e de publicações científicas dela decorrentes, sem identificação nominal minha nos resultados publicados.

12. Fui informado(a) de que os dados pessoais recolhidos (nome e assinatura, para efeitos desta declaração) serão tratados de forma confidencial, em conformidade com a Lei n.º 22/11 de 17 de Junho de 2011 — Lei de Protecção de Dados Pessoais de Angola.

Luanda, _____ de _____ de 2024

_____

Nome completo do Anotador

_____

Bilhete de Identidade / Passaporte n.º

_____

Assinatura do Anotador

Investigador Principal — [Nome do Autor] — Assinatura e Data

Nota: Esta declaração foi assinada em duplicado, ficando um exemplar com o anotador e outro com o investigador principal. Nenhuma cópia das publicações analisadas foi fornecida aos anotadores; o acesso foi realizado exclusivamente através da plataforma de anotação disponibilizada pelo investigador.

APÊNDICE E – AMOSTRA ANOTADA DO CORPUS

O presente apêndice apresenta uma amostra representativa de 20 publicações do corpus, com as anotações individuais dos três anotadores, a etiqueta final atribuída por votação maioritária e o nível de acordo. As publicações foram anonimizadas (identificadores substituídos por hash SHA-256) em conformidade com a Lei n.º 22/11. Os textos foram ligeiramente parafraseados para proteger a identidade dos autores originais, mantendo o conteúdo e o registo linguístico.

Tabela E.1 – Amostra de 20 Publicações Anotadas — Corpus Angola (2024–2025)

#	Plataforma	Excerto (anonimizado e parafraseado)	Anot. A	Anot. B	Anot. C	Etiqueta Final	Acordo
1	Facebook	O governo inaugurou nova central eléctrica em Benguela. Mais luz para Angola.	N	N	N	Normal	Total
2	Telegram	URGENTE: Concentração amanhã às 9h em frente à sede do governo. Vamos mostrar quem manda.	MH	MH	MH	Mobilização Hostil	Total
3	Twitter/X	Vídeo mostra ministro a receber mala de dinheiro. PARTILHA! Não deixes a verdade morrer. [vídeo manipulado]	D	D	D	Desinformação	Total
4	Facebook	[Expressão étnica pejorativa] são todos iguais. Angola não precisa deles.	O	O	O	Discurso de Ódio	Total
5	Web	Análise: o crescimento do PIB angolano em 2024 ficou abaixo das projecções do FMI.	N	N	N	Normal	Total

#	Plataforma	Excerto (anonimizado e parafraseado)	Anot. A	Anot. B	Anot. C	Etiqueta Final	Acordo
6	Telegram	Surto de doença desconhecida em Luanda. Governo esconde mortes. Partilha urgente!	D	D	N	Desinformação	Maioria
7	Facebook	Quem está connosco para amanhã? Não vamos deixar passar mais este abuso. Encontramo-nos no largo.	MH	MH	N	Mobilização Hostil	Maioria
8	Twitter/X	Crítica ao governo: as políticas de saúde continuam a falhar os angolanos mais pobres.	N	N	N	Normal	Total
9	Facebook	Ki bué pesado o que [grupo étnico] fazem ao nosso país. Devia ser proibido entrar.	O	O	O	Discurso de Ódio	Total
10	Telegram	O presidente angolano foi hospitalizado de urgência. Fonte interna confirma estado grave. [falso]	D	D	D	Desinformação	Total
11	Web	Festival de música angolana reúne milhares em Luanda este fim-de-semana.	N	N	N	Normal	Total
12	Facebook	Amanhã paramos tudo. Quem não parar é traidor. O país precisa de nós nas ruas.	MH	O	MH	Mobilização Hostil	Maioria
13	Twitter/X	Vídeo profundo: AI faz presidente a dizer coisas que nunca disse. Muito perigoso.	N	D	N	Normal	Maioria

#	Plataforma	Excerto (anonimizado e parafraseado)	Anot. A	Anot. B	Anot. C	Etiqueta Final	Acordo
14	Telegram	[Grupo religioso] não têm lugar na nossa Angola cristã. Deus nos protege deles.	O	O	O	Discurso de Ódio	Total
15	Facebook	Partilha: boato sobre apagão nacional propositado é mentira. Confirma-se falso.	N	N	N	Normal	Total
16	Web	Ataque cibernético a infra-estruturas bancárias angolanas planeado para [data]. Coordenação online.	MH	MH	D	Mobilização Hostil	Maioria
17	Telegram	Ganda manifestação em Luanda no sábado. Quem é angolano aparece. Vamos ocupar a praça.	MH	MH	MH	Mobilização Hostil	Total
18	Facebook	O novo hospital em Huambo vai mudar a vida de muitas famílias. Parabéns ao governo.	N	N	N	Normal	Total
19	Twitter/X	[Grupo étnico] controlam tudo em Angola. Chegou a hora de acabar com isso de vez.	O	MH	O	Discurso de Ódio	Maioria
20	Telegram	FAKE NEWS: o exército não está em alerta máximo. Imagem circulante é de 2019.	D	D	D	Desinformação	Total

Nota. N = Normal; D = Desinformação; O = Discurso de Ódio; MH = Mobilização Hostil. Acordo "Total" = unanimidade dos 3 anotadores; "Maioria" = 2 de 3 anotadores em concordância. Textos parafraseados para protecção da identidade dos autores originais (Lei n.º 22/11).

E.2 Análise dos Casos de Discordância

Os casos de acordo por maioria (casos 6, 7, 12, 13, 16 e 19) revelam as fronteiras mais ambíguas entre categorias, com implicações metodológicas relevantes:

- Caso 6 (Desinformação vs. Normal): A ausência de fonte verificável e o apelo à partilha urgente são indicadores de desinformação que o Anotador C não pesou suficientemente. Resolvido como Desinformação por maioria.

- Caso 7 (Mobilização Hostil vs. Normal): A linguagem vaga ("abuso", "encontramo-nos") gerou dúvida. O contexto temporal (dia anterior a manifestação documentada) reforça a classificação como Mobilização Hostil.

- Caso 12 (Mobilização Hostil vs. Discurso de Ódio): A expressão "traidor" dirigida a quem não aderir à paragem constitui pressão coerciva típica de mobilização, não discurso de ódio baseado em identidade.

- Caso 13 (Normal vs. Desinformação): A publicação descreve um deepfake sem o partilhar — é conteúdo informativo (Normal). Resolvido como Normal por maioria.

- Caso 16 (Mobilização Hostil vs. Desinformação): Anúncio de ataque planeado classifica-se como Mobilização Hostil por ter intenção de coordenação, não apenas de enganar.

- Caso 19 (Discurso de Ódio vs. Mobilização Hostil): "Acabar com isso de vez" é linguagem implícita de ódio sem convocatória específica. Resolvido como Discurso de Ódio por maioria.

Nota metodológica: os casos de discordância foram apresentados ao colectivo dos três anotadores numa sessão de calibração final, onde foram discutidos e resolvidos por consenso. Este processo contribuiu para o $\kappa = 0{,}78$ reportado na secção 3.3.2 da dissertação.



UNIVERSIDADE AGOSTINHO NETO



FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga

Luanda, 2026