UNIVERSIDADE AGOSTINHO NETO
FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga

Luanda
2026

UNIVERSIDADE AGOSTINHO NETO
FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Dissertação submetida à Faculdade de Engenharia da Universidade Agostinho Neto como requisito para obtenção do título de Mestre em **Engenharia e Ciência de Dados**

Manuel Gonga Muinga
Engenheiro Electrotécnico

Orientador científico:
Professor Doutor Joaquim Fortes (UAN)

Co-orientador:
Professor Doutor Judice Cumbunga (UAN)

Luanda
2026

FICHA CATALOGRÁFICA

Muinga, M. G. (2026). *Monitoramento inteligente de ameaças em redes sociais em Angola para o apoio à defesa e segurança nacional*. xiii, 65 p. + 10 p. de apêndices; il.; 30 cm.

Dissertação de Mestrado em Engenharia e Ciência de Dados (Mecdata), 2024–2026. Universidade Agostinho Neto, Faculdade de Engenharia, Departamento de Engenharia Mecânica.

Orientador: Professor Doutor Joaquim Fortes. Co-orientador: Professor Doutor Judice Cumbunga.

Palavras-chave: 1. Redes sociais. 2. Discurso de ódio. 3. Desinformação. 4. BERTimbau. 5. Adaptação de domínio. 6. Segurança nacional.

Permitida a reprodução total ou parcial deste documento, desde que citada a fonte e sem carácter comercial – O autor

EPÍGRAFE

«Todos têm o direito de exprimir, divulgar e compartilhar livremente os seus pensamentos (…)»
Constituição da República de Angola, artigo 40.º, n.º 1

DEDICATÓRIA

À minha querida esposa, Rosalina Muinga, cuja presença ilumina cada etapa da minha vida. Este trabalho é dedicado a ti, pelo amor, pela paciência e pelo apoio incondicional que sempre me ofereceste. A tua força e a tua compreensão foram fundamentais para que eu pudesse chegar até aqui. Que esta conquista seja também o reflexo da nossa caminhada conjunta, marcada pela fé, pela perseverança e pela esperança.

AGRADECIMENTOS

Tenho a honra de expressar os meus mais sinceros agradecimentos aos meus orientadores, pela orientação científica, pela disponibilidade e pelo rigor académico que tornaram possível a realização desta dissertação.

À Universidade Agostinho Neto e à Faculdade de Engenharia, pela sólida formação académica e pelo ambiente científico que proporcionaram ao longo desta jornada.

À minha família e aos meus amigos, pelo apoio incondicional, pela paciência e pelo encorajamento, que foram fundamentais para superar os desafios e alcançar esta etapa.

Às Forças Armadas Angolanas, instituição que financiou a minha formação, pelo investimento e pela confiança depositada.

Ao Comando da Brigada de Forças Especiais, pela confiança, pelo apoio institucional e pelo incentivo constante ao meu desenvolvimento académico e profissional.

Um agradecimento especial a Sua Excelência o Tenente-General Tussen, cujo incentivo e motivação foram decisivos para que eu pudesse frequentar este curso e concretizar este trabalho.

Aos anotadores que classificaram, com paciência e rigor, os comentários do corpus angolano, e aos colegas investigadores e a todos os que, de forma directa ou indirecta, contribuíram para a realização desta dissertação, manifesto a minha profunda gratidão.

RESUMO

Em Angola, as redes sociais tornaram-se um espaço onde a desinformação, o discurso de ódio e os apelos à mobilização hostil circulam ao lado da conversa quotidiana, num volume que nenhuma equipa de analistas consegue ler. Esta dissertação desenvolve e avalia um sistema que ordena essas publicações para o analista, sem o substituir. Construiu-se um corpus de 2.637 publicações públicas angolanas, sobretudo comentários do YouTube, anotadas por três anotadores em quatro categorias, com κ de Fleiss de 0,718. Combinado com três corpora brasileiros (HateBR, ToLD-BR e Fake.br), num total de 26.859 registos, serviu para comparar SVM, Floresta Aleatória, Bi-LSTM e BERTimbau. No teste (n = 3.987), o BERTimbau obteve F1-macro de 0,807 (0,797 na média de três sementes), entre 14,6 e 17,4 pontos percentuais acima dos restantes (McNemar com correcção de Bonferroni, $p < 10^{-47}$); o Bi-LSTM não se distinguiu da Floresta Aleatória. Em conteúdo angolano, porém, o F1-macro desceu para 0,533, contra 0,919 no corpus público, com a maior queda na Desinformação. Desenvolveu-se depois uma aplicação web com anonimização à entrada, segundo os princípios da Lei n.º 22/11, auditoria, fila de revisão ordenada por prioridade e alertas, sem decisões automáticas. Sem GPU, o sistema processou cada publicação em 0,6 a 0,7 segundos e colocou as primeiras na fila em 36 segundos. A antecedência de detecção não foi testada. Os contributos são o corpus angolano anotado, a medida da lacuna de domínio e uma arquitectura de triagem de baixo custo com revisão humana.

Palavras-chave: Redes sociais. Discurso de ódio. Desinformação. BERTimbau. Adaptação de domínio. Segurança nacional.

ABSTRACT

In Angola, social media have become a space where disinformation, hate speech and calls for hostile mobilisation circulate alongside everyday conversation, in a volume no team of analysts can read. This dissertation develops and evaluates a system that orders these posts for analysts without replacing them. A corpus of 2,637 public Angolan posts, mostly YouTube comments, was annotated by three annotators into four categories, with a Fleiss' kappa of 0.718. Combined with three Brazilian corpora (HateBR, ToLD-BR and Fake.br), for a total of 26,859 records, it served to compare SVM, Random Forest, Bi-LSTM and BERTimbau. On the test set (n = 3,987), BERTimbau reached a macro-F1 of 0.807 (0.797 averaged over three seeds), between 14.6 and 17.4 percentage points above the others (McNemar test with Bonferroni correction, $p < 10^{-47}$); the Bi-LSTM did not differ from the Random Forest. On Angolan content, however, macro-F1 fell to 0.533, against 0.919 on the public corpus, with the largest drop for disinformation. A web application was then developed with anonymisation at ingestion, following the principles of Angolan Law No. 22/11, auditing, a priority-ordered review queue and alerts, with no automatic decisions. Without a GPU, the system processed each post in 0.6 to 0.7 seconds and placed the first posts in the queue within 36 seconds. Detection lead time (early warning) was not tested. The contributions are the annotated Angolan corpus, the measurement of the domain gap and a low-cost triage architecture with human review.

Keywords: Social media. Hate speech. Disinformation. BERTimbau. Domain adaptation. National security.

ABREVIATURAS, SIGLAS E SÍMBOLOS

Sigla ou símbolo	Significado
API	Interface de programação de aplicações (*Application Programming Interface*)
AUC-ROC	Área sob a curva ROC (*Receiver Operating Characteristic*)
BERT	Representações bidireccionais de codificador baseadas em *Transformers*
Bi-LSTM	Rede de memória de longo e curto prazo bidireccional
CPLP	Comunidade dos Países de Língua Portuguesa
CSP	Política de segurança de conteúdo (*Content Security Policy*)
CSRF	Falsificação de pedidos entre sítios (*Cross-Site Request Forgery*)
CPU	Unidade central de processamento (*Central Processing Unit*)
CSV	Valores separados por vírgulas (formato de ficheiro)
ECE	Erro de calibração esperado (*Expected Calibration Error*)
F1	Média harmónica entre precisão e sensibilidade
GPU	Unidade de processamento gráfico
HMAC	Código de autenticação de mensagens baseado em *hash*
HTTPS	Protocolo seguro de transferência de hipertexto
IA	Inteligência artificial
IC 95%	Intervalo de confiança a 95%
JSON	Notação de objectos JavaScript (formato de dados)
LSTM	Memória de longo e curto prazo (*Long Short-Term Memory*)
NIST	Instituto Nacional de Normas e Tecnologia dos Estados Unidos
OSINT	Inteligência de fontes abertas (*Open Source Intelligence*)
OWASP	Projecto aberto de segurança de aplicações web (*Open Worldwide Application Security Project*)
PBKDF2	Função de derivação de chaves a partir de palavras-passe, versão 2
p.p.	Pontos percentuais
PDF	Formato de documento portátil
PLN	Processamento de linguagem natural
PNG	Gráficos de rede portáteis (formato de imagem)
RSS	Formato de distribuição de conteúdos web (*Really Simple Syndication*)
SHA-256	Algoritmo de *hash* seguro de 256 bits
SMOTE	Técnica de sobreamostragem sintética de minorias
SOCMINT	Inteligência de redes sociais (*Social Media Intelligence*)
SVG	Gráficos vectoriais escaláveis (formato de imagem)
SVM	Máquina de vectores de suporte (*Support Vector Machine*)
TF-IDF	Frequência do termo × inverso da frequência nos documentos
UAN	Universidade Agostinho Neto
UML	Linguagem de modelação unificada
κ	Coeficiente Kappa (de Cohen ou de Fleiss)

ÍNDICE

CAPÍTULO 1 – INTRODUÇÃO.....1
1.1 Contextualização.....1
1.2 Problema de investigação.....2
1.3 Hipóteses de investigação.....3
1.4 Objectivos.....3
1.4.1 Objectivo geral.....3
1.4.2 Objectivos específicos.....4
1.5 Justificação e relevância.....4
1.6 Delimitação do estudo.....5
1.7 Estrutura da dissertação.....5
CAPÍTULO 2 – REVISÃO DA LITERATURA.....6
2.1 Redes sociais: conceito, evolução e dimensão securitária.....6
2.1.1 Conceito e evolução.....6
2.1.2 O ecossistema digital angolano.....6
2.1.3 Inteligência de fontes abertas e de redes sociais.....7
2.2 Categorias de ameaças digitais.....7
2.3 Sistemas de monitorização de ameaças.....8
2.4 Recursos e modelos de linguagem para o português.....9
2.4.1 Corpora anotados.....9
2.4.2 Modelos de linguagem.....10
2.5 Algoritmos de classificação de texto.....10
2.6 Avaliação de classificadores.....11
2.7 Generalização entre domínios e aprendizagem de atalhos.....12
2.8 Aspectos éticos, legais e de direitos humanos.....13
2.9 Revisão humana e segurança da informação.....14
2.10 Síntese e lacuna de investigação.....14
CAPÍTULO 3 – METODOLOGIA.....15
3.1 Paradigma e desenho da investigação.....15
3.2 Considerações éticas e protecção de dados.....15
3.3 Recolha de dados do piloto angolano.....17
3.4 Anotação e acordo entre anotadores.....18
3.5 Construção do corpus híbrido.....20
3.6 Modelos e treino.....21

3.6.1 Pré-processamento e representação.....21
3.6.2 Configuração dos modelos.....21
3.6.3 Ambiente de desenvolvimento.....22
3.7 Protocolo de avaliação.....22
3.8 Arquitectura do sistema.....23
3.8.1 Requisitos.....23
3.8.2 Alternativas e decisão.....24
3.8.3 Camadas e componentes.....25
3.8.4 Casos de uso e fluxo de processamento.....28
3.8.5 Interface do analista.....29
3.8.6 Recolha automática e gestão da quota.....33
3.8.7 Gestão de contas e segurança.....34
3.9 Plano de testes e avaliação operacional.....35
3.10 Plano de implementação faseada.....36
CAPÍTULO 4 – RESULTADOS E DISCUSSÃO.....37
4.1 Corpus de avaliação e protocolo experimental.....37
4.2 Desempenho global dos modelos.....38
4.3 Significância estatística das diferenças.....39
4.4 Desempenho por categoria e análise de erros.....40
4.5 Análises de robustez.....43
4.5.1 Variabilidade entre sementes, ensemble e ablações.....43
4.5.2 Ajuste de limiares de decisão.....44
4.6 Lacuna de domínio: piloto angolano e corpus público (Hipótese H4).....45
4.7 Qualidade das probabilidades e utilidade da ordenação.....46
4.7.1 Calibração das probabilidades.....47
4.7.2 Ordenação da fila de revisão.....47
4.8 Avaliação operacional do sistema (Hipóteses H2 e H3).....49
4.8.1 Tempo de processamento (H2).....49
4.8.2 Antecedência de detecção (H3).....50
4.8.3 Implicações para o desenho operacional.....50
4.8.4 Verificação funcional do sistema.....50
4.9 Discussão e verificação formal das hipóteses.....51
CAPÍTULO 5 – CONCLUSÕES E RECOMENDAÇÕES.....53
5.1 Síntese dos objectivos.....53
5.2 Resposta às hipóteses e às perguntas de investigação.....54
5.3 Contributos.....55

5.4 Limitações..... 55
5.5 Implicações para a defesa e segurança nacional.....57
5.6 Quadro de uso responsável.....57
5.7 Recomendações e trabalho futuro.....58
5.8 Considerações finais.....59
REFERÊNCIAS BIBLIOGRÁFICAS.....60
GLOSSÁRIO.....65
APÊNDICE A – EXCERTOS DE CÓDIGO-FONTE.....A1
A.1 Anonimização à entrada (sistema/anonimizacao.py).....A1
A.2 Classificação em lote com o BERTimbau (sistema/classificador.py).....A1
APÊNDICE B – GUIA DE ANOTAÇÃO PADRONIZADO.....B1
B.1 Identificação do projecto.....B1
B.2 Objectivo da anotação.....B1
B.3 Categorias..... B1
B.3.1 Normal (rótulo Normal).....B1
B.3.2 Desinformação (rótulo Desinformacao).....B1
B.3.3 Discurso de ódio (rótulo Odio).....B2
B.3.4 Mobilização hostil (rótulo Mobilizacao).....B2
B.4 Casos limítrofes..... B2
B.5 Regras de desempate e preenchimento.....B2
APÊNDICE C – ACORDO ENTRE ANOTADORES.....C1
C.1 Escala de interpretação.....C1
C.2 Fórmulas..... C1
C.3 Resultados..... C1
C.4 Distribuição das etiquetas finais.....C2
APÊNDICE D – DECLARAÇÃO DE CONSENTIMENTO E CONFIDENCIALIDADE DOS ANOTADORES.....D1
APÊNDICE E – AMOSTRA ANOTADA DO CORPUS.....E1
APÊNDICE F – MANUAL DE INSTALAÇÃO E UTILIZAÇÃO DO SISTEMA.....F1
F.1 Instalação e configuração.....F1
F.2 Arranque e utilização..... F1
F.3 Linha de comandos.....F2

ÍNDICE DE TABELAS

Tabela 1.1 – Correspondência entre objectivos específicos e hipóteses.....4
Tabela 2.1 – Algoritmos de classificação comparados.....10
Tabela 3.1 – Características do corpus angolano anotado, por categoria final.....18
Tabela 3.2 – Configuração dos modelos.....21
Tabela 3.3 – Ambiente de desenvolvimento.....22
Tabela 3.4 – Requisitos do sistema.....23
Tabela 3.5 – Comparação das arquitecturas consideradas.....24
Tabela 3.6 – Tipos de fonte e quota do YouTube por volta.....33
Tabela 3.7 – Plano de implementação faseada.....36
Tabela 4.1 – Composição do corpus harmonizado por fonte e categoria.....37
Tabela 4.2 – Desempenho dos modelos no conjunto de teste.....38
Tabela 4.3 – Comparações emparelhadas (ΔF1-macro e McNemar).....40
Tabela 4.4 – F1 por categoria e modelo; precisão e sensibilidade do BERTimbau.....40
Tabela 4.5 – Variantes do BERTimbau: validação, teste e comparação com a referência.....43
Tabela 4.6 – Efeito do ajuste de limiares no F1-macro.....44
Tabela 4.7 – Desempenho do BERTimbau no piloto angolano e no corpus público.....45
Tabela 4.8 – Calibração e ordenação no conjunto de teste.....47
Tabela 4.9 – Tempo de processamento do protótipo com o modelo do sistema.....49
Tabela 4.10 – Verificação formal das hipóteses de investigação.....51
Tabela 5.1 – Cumprimento dos objectivos específicos.....53
Tabela 5.2 – Quadro de uso responsável: salvaguardas do sistema e obrigações institucionais.....57
Tabela C.1 – Escala de interpretação do Kappa (Landis & Koch, 1977).....C1
Tabela C.2 – Acordo entre os três anotadores.....C1
Tabela C.3 – Acordo por par de anotadores e por categoria (base do piloto e lote de léxico, n = 2.443).....C2
Tabela C.4 – Distribuição das etiquetas finais do corpus angolano.....C2
Tabela E.1 – Amostra de comentários anotados.....E1
Tabela F.1 – Comandos do sistema.....F2

ÍNDICE DE FIGURAS

Figura 1.1 – Indicadores do ecossistema digital angolano (Outubro de 2025).....1
Figura 3.1 – Desenho da investigação.....15
Figura 3.2 – Construção do corpus híbrido e divisão em treino, validação e teste.....20
Figura 3.3 – Arquitectura em camadas do sistema de triagem.....25
Figura 3.4 – Modelo de dados do sistema.....28
Figura 3.5 – Diagrama de casos de uso (UML).....29
Figura 3.6 – Diagrama de sequência (UML): da recolha à revisão.....29
Figura 3.7 – Fila de revisão na aplicação web.....31
Figura 3.8 – Mapa por província na aplicação web.....32
Figura 3.9 – Recolha automática na página das fontes.....34
Figura 3.10 – Recuperação do acesso a uma conta.....35
Figura 4.1 – Curvas ROC um-contra-todos por categoria e modelo (conjunto de teste; AUC entre parêntesis).....39
Figura 4.2 – Matrizes de confusão (4 × 4) no conjunto de teste (contagens e percentagem por linha).....42
Figura 4.3 – F1 por categoria do BERTimbau no corpus público e no piloto angolano (conjunto de teste).....45
Figura 4.4 – Curva de esforço de revisão: ameaças encontradas em função da fila revista.....48

CAPÍTULO 1 – INTRODUÇÃO

1.1 Contextualização

As redes sociais deixaram de ser apenas lugares de convívio. Hoje é nelas que muitas pessoas se informam, discutem política e combinam encontros, e é também nelas que circulam boatos, insultos dirigidos a grupos e convocatórias que podem pôr em risco a ordem pública. Por isso, em quase todos os países com acesso generalizado à Internet, as plataformas digitais passaram também a ser matéria de segurança nacional.

Em Angola, o fenómeno tem uma escala considerável. Segundo o relatório *Digital 2026: Angola*, o país tinha, em Outubro de 2025, cerca de 17,6 milhões de utilizadores da Internet (44,8% da população) e 5,50 milhões de identidades em redes sociais, o equivalente a 14,0% da população (Kemp, 2025). O telemóvel é o principal ponto de acesso. A Figura 1.1 resume estes indicadores.

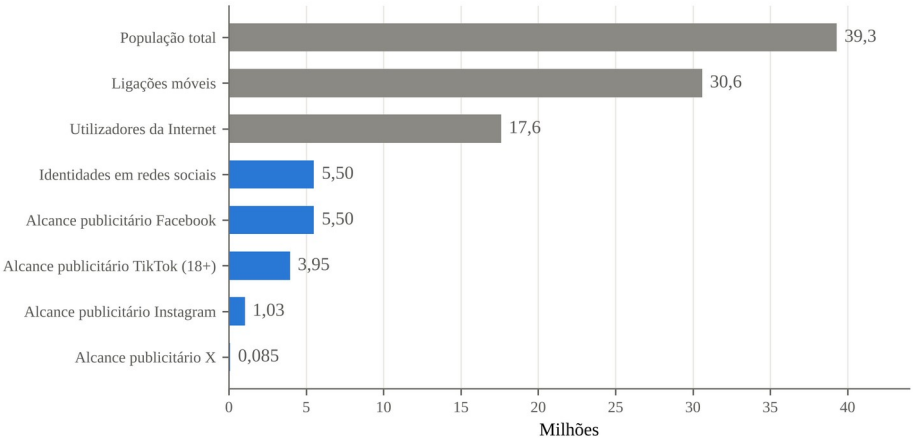


Figura 1.1 – Indicadores do ecossistema digital angolano (Outubro de 2025)

Fonte: elaborado a partir de Kemp (2025). Os valores de alcance publicitário não correspondem a utilizadores únicos.

Dois episódios ilustram o peso político deste espaço. A campanha «2022 Vais Gostar» nasceu nas redes sociais e acabou por se traduzir em manifestações em várias províncias (Hassane, 2021). A influência das redes no comportamento eleitoral dos jovens nas eleições de 2022 foi igualmente documentada (Sambaca & Pessoa, 2026). Em ambos, o que começou na Internet acabou por ter efeitos fora dela.

A relação entre o que se publica e o que acontece fora da rede não é, contudo, directa. A grande maioria das publicações sobre política, preços, serviços públicos ou desporto é conversa legítima, por vezes dura, e só uma fracção pequena contém falsidades deliberadas, ataques a grupos ou apelos à violência. Esta desproporção tem

duas consequências. A primeira é que a procura manual de conteúdos ameaçadores é lenta e cara, porque obriga a ler muito para encontrar pouco. A segunda é que um filtro automático tende a produzir mais falsos alarmes do que acertos quando aquilo que procura é muito raro, salvo se for muito específico, o que torna indispensável a verificação humana.

Para as estruturas de defesa e segurança, a dificuldade está no volume. Não é possível ler tudo o que se publica, e as ferramentas comerciais de monitorização foram concebidas para outras línguas, outros contextos e outros orçamentos. Há, por isso, espaço para um sistema que ajude o analista a decidir o que ler primeiro, adaptado ao português usado em Angola e assente em princípios claros de protecção de dados.

1.2 Problema de investigação

O problema que motiva esta dissertação tem uma dimensão técnica e outra operacional. Do lado técnico, não existe, tanto quanto foi possível apurar, um classificador de conteúdos ameaçadores treinado e avaliado com dados angolanos. Os modelos de linguagem disponíveis para o português, como o BERTimbau (Souza et al., 2020), foram pré-treinados sobretudo com texto brasileiro, e os corpora anotados para discurso de ódio e desinformação em português provêm igualmente do Brasil (Leite et al., 2020; Monteiro et al., 2018; Vargas et al., 2022). Não se sabe, portanto, quanto do desempenho reportado nesses trabalhos se mantém quando o texto é angolano.

Do lado operacional, mesmo um bom classificador comete erros, e esses erros não custam todos o mesmo. Classificar uma convocatória pacífica como mobilização hostil pode lesar direitos constitucionais; deixar passar uma convocatória para a violência pode ter consequências graves. Um sistema útil para a segurança nacional tem de ser desenhado em função desta assimetria, mantendo o analista humano no centro da decisão.

A pergunta de partida é, assim, a seguinte: **em que medida um sistema baseado em aprendizagem automática consegue apoiar, de forma fiável e juridicamente responsável, a triagem de publicações ameaçadoras em redes sociais angolanas?**

Desta pergunta derivam quatro perguntas mais específicas, que orientam a investigação. As hipóteses da Secção 1.3 respondem às três primeiras (H1 à P1, H4 à P2 e H2 à P3); a P4 é respondida pelo desenho do sistema e pelo quadro de uso responsável (OE4 e OE5). A H3 decorre do objectivo de antecipação e não de uma pergunta específica.

- **P1.** Que família de algoritmos classifica melhor as quatro categorias de ameaça, e a diferença entre eles é estatisticamente sólida?
- **P2.** Quanto se perde quando um modelo treinado sobretudo com texto brasileiro é aplicado a comentários angolanos, e onde se concentra essa perda?
- **P3.** Um sistema construído com recursos modestos consegue processar as publicações recolhidas num tempo compatível com a triagem operacional?
- **P4.** Como deve ser desenhado o sistema para que os erros do modelo não se transformem em decisões sobre pessoas, e para que o seu uso respeite o quadro jurídico angolano?

1.3 Hipóteses de investigação

Formularam-se as hipóteses de modo a serem refutáveis e a terem um critério quantitativo de decisão. Cada uma responde a um ou mais objectivos específicos (Secção 1.4).

H1. Os modelos de aprendizagem profunda (BERTimbau e Bi-LSTM) superam os modelos clássicos (SVM e Floresta Aleatória) na classificação das quatro categorias, com diferença de F1-macro de pelo menos 5 pontos percentuais e significância estatística ($p < 0{,}05$ no teste de McNemar com correcção de Bonferroni).

H2. O sistema processa cada publicação recolhida (importação, anonimização, classificação e entrada na fila de revisão) em menos de 60 segundos.

H3. O sistema detecta padrões de risco com pelo menos 48 horas de antecedência em relação a eventos de segurança documentados, numa validação retrospectiva com divisão cronológica dos dados.

H4. O desempenho do modelo seleccionado degrada-se significativamente (pelo menos 5 pontos percentuais de F1-macro) em conteúdo angolano, quando comparado com o conteúdo dos corpora públicos usados no treino.

1.4 Objectivos

1.4.1 Objectivo geral

Desenvolver e avaliar um sistema de apoio à triagem de publicações ameaçadoras em redes sociais angolanas, que combine um classificador de linguagem natural adaptado ao português com revisão humana obrigatória e com protecção de dados pessoais desde a concepção.

1.4.2 Objectivos específicos

- **OE1.** Construir um corpus de comentários públicos angolanos anotado em quatro categorias por três anotadores, medindo o acordo entre anotadores e registando a proveniência de cada lote de dados.
- **OE2.** Comparar quatro algoritmos de classificação (SVM, Floresta Aleatória, Bi-LSTM e BERTimbau) com intervalos de confiança e testes estatísticos emparelhados.
- **OE3.** Quantificar a diferença de desempenho entre o conteúdo angolano e o dos corpora públicos e identificar as suas causas prováveis.
- **OE4.** Desenvolver um protótipo de sistema de triagem com fila de revisão, painel do analista, serviço de inferência, alertas e mapa por província, e definir o protocolo da sua avaliação operacional.
- **OE5.** Propor um quadro de uso responsável do sistema, conforme a Lei n.º 22/11 de Protecção de Dados Pessoais e os direitos consagrados na Constituição da República de Angola.

A Tabela 1.1 relaciona os objectivos específicos com as hipóteses.

Tabela 1.1 – Correspondência entre objectivos específicos e hipóteses

Objectivo	Hipótese	Natureza
OE1. Corpus angolano anotado	n.a.	Construção de dados
OE2. Comparação de algoritmos	H1	Testável estatisticamente
OE3. Lacuna de domínio	H4	Testável estatisticamente
OE4. Protótipo do sistema	H2, H3	H2 testável; H3 com protocolo esboçado, não aplicado
OE5. Quadro ético e legal	n.a.	Normativo

1.5 Justificação e relevância

A investigação justifica-se por três razões. Do ponto de vista científico, o português de Angola continua pouco representado nos recursos de processamento de linguagem natural (PLN). Um corpus anotado de comentários angolanos, mesmo de dimensão modesta, permite medir pela primeira vez quanto se perde ao aplicar modelos brasileiros a este domínio, e serve de base a trabalhos futuros.

Em termos operacionais, uma ferramenta que ordene as publicações por probabilidade de serem problemáticas reduz o tempo que o analista gasta com conteúdo irrelevante, sem lhe retirar a decisão. A arquitectura proposta usa apenas

software livre e pode funcionar num único servidor, o que a torna compatível com os recursos disponíveis e com a soberania sobre os dados.

No plano institucional e jurídico, o trabalho mostra que é possível conceber estes sistemas com salvaguardas concretas: anonimização à entrada, registo de proveniência, prazos de conservação, auditoria e proibição de decisões automáticas sobre pessoas. Sem elas, um sistema deste tipo dificilmente seria aceitável num Estado de direito.

1.6 Delimitação do estudo

O estudo limita-se a texto em português publicado em espaços públicos. O corpus angolano é formado sobretudo por comentários públicos do YouTube, recolhidos pela interface oficial da plataforma, e por um conjunto menor de publicações recolhidas manualmente em páginas públicas. Não se recolheram mensagens privadas, grupos fechados nem conteúdo que exija autenticação. Imagens, áudio e vídeo ficam fora do âmbito, assim como textos escritos integralmente em línguas nacionais. A avaliação incide sobre o classificador e sobre o funcionamento do protótipo; a integração com sistemas institucionais e a avaliação com analistas em contexto real ficam para trabalho futuro.

1.7 Estrutura da dissertação

Para além desta introdução, a dissertação tem quatro capítulos. O Capítulo 2 revê a literatura sobre ameaças digitais, modelos para o português, avaliação e enquadramento legal. O Capítulo 3 descreve a metodologia: a construção do corpus, a anotação, os modelos, o protocolo de avaliação e a arquitectura do sistema. O Capítulo 4 apresenta e discute os resultados e testa as hipóteses. O Capítulo 5 sintetiza as conclusões, as limitações e as recomendações. Os apêndices reúnem excertos de código, o guia de anotação, os dados de acordo entre anotadores, a declaração dos anotadores, uma amostra anotada do corpus e o manual do protótipo.

CAPÍTULO 2 – REVISÃO DA LITERATURA

Este capítulo situa o trabalho em relação ao que já se conhece. Começa pelas redes sociais e pelo contexto angolano, define as categorias de ameaça usadas na dissertação e revê os sistemas de monitorização existentes. Depois trata dos recursos e modelos de linguagem para o português, dos métodos de avaliação de classificadores, incluindo a qualidade das probabilidades e da ordenação, e do problema da generalização entre domínios. Segue-se o enquadramento ético e legal, a revisão humana e a segurança da informação. Termina com uma síntese da lacuna que a investigação procura preencher.

2.1 Redes sociais: conceito, evolução e dimensão securitária

2.1.1 Conceito e evolução

Boyd e Ellison (2007) definem as redes sociais como serviços que permitem construir um perfil público, articular uma lista de contactos e percorrer as ligações dentro do sistema. A definição capta a estrutura das plataformas, mas não o papel que vieram a ter na vida pública. Ao longo de três décadas passou-se de redes de perfis e ligações declaradas (SixDegrees, Friendster, MySpace) para plataformas de conteúdo gerado pelos utilizadores e de seguimento assimétrico (Facebook, YouTube, Twitter) e, finalmente, para serviços móveis em que o que cada pessoa vê é decidido por algoritmos de recomendação (Instagram, TikTok, Telegram).

Esta última mudança é relevante para a segurança. Quando a recomendação privilegia o envolvimento, o conteúdo que provoca indignação, medo ou raiva tende a circular mais, independentemente da intenção de quem o publica. Castells (2013) mostrou, a propósito da Primavera Árabe, como redes horizontais permitem coordenar acções políticas sem passar pelos meios de comunicação tradicionais. Uma década depois, esta forma de coordenação deixou de ser excepcional e faz parte do funcionamento corrente das redes.

2.1.2 O ecossistema digital angolano

Os dados de Kemp (2025) mostram um ecossistema em crescimento, mas ainda concentrado: 5,50 milhões de identidades em redes sociais numa população de 39,3 milhões, com o Facebook à frente em alcance e o TikTok em segundo lugar. O acesso faz-se sobretudo por telemóvel. A concentração urbana dos utilizadores, em especial em Luanda, significa que o que se discute nas redes chega rapidamente às zonas de maior densidade populacional, e daí, por contacto pessoal, a quem não está ligado.

Dois episódios marcaram a relação entre redes sociais e segurança em Angola. A campanha «2022 Vais Gostar» começou nas redes sociais e resultou em manifestações simultâneas em várias províncias (Hassane, 2021). Nos protestos de Agosto de 2025, foram referidos conteúdos sintéticos usados para influenciar a narrativa pública (Cintra, 2025). Marcon (2019) descreve, numa perspectiva sociológica, como os jovens angolanos usam estes espaços para formas de activismo que nem sempre encontram expressão nos canais tradicionais, o que reforça a necessidade de distinguir com cuidado o protesto legítimo da mobilização hostil.

2.1.3 Inteligência de fontes abertas e de redes sociais

A recolha e a análise de informação publicada abertamente chamam-se, na literatura de segurança, inteligência de fontes abertas (OSINT). Na sua segunda geração, a fonte principal passou a ser o conteúdo gerado pelos utilizadores, e o problema deixou de ser o acesso e passou a ser a selecção (Williams & Blum, 2018). Omand, Bartlett e Miller (2012) chamam inteligência de redes sociais (SOCMINT) à aplicação destas práticas às plataformas digitais e propõem que obedeça aos princípios de outras formas de recolha de informações: causa suficiente, proporcionalidade, autoridade competente, perspectiva razoável de sucesso e necessidade. Estes princípios traduzem-se no desenho do sistema: trabalhar com publicações e agregados e não com pessoas, recolher só o que serve a finalidade declarada e registar quem faz o quê (Secções 3.2 e 3.8).

2.2 Categorias de ameaças digitais

A taxonomia adoptada tem quatro categorias: Normal, Desinformação, Discurso de Ódio e Mobilização Hostil. A escolha procurou equilibrar três critérios: cobrir as ameaças documentadas no contexto angolano, ter categorias suficientemente distintas para treinar classificadores supervisionados e ser compreensível por analistas sem formação em processamento de linguagem natural. Taxonomias mais finas, com subcategorias por alvo ou por grau de urgência, deixariam poucas amostras por classe e tornariam os alertas mais difíceis de interpretar.

Desinformação é informação falsa ou enganosa partilhada com intenção de causar dano, distinta do erro involuntário (*misinformation*) e da divulgação de informação verdadeira com intenção de prejudicar (*malinformation*) (Wardle & Derakhshan, 2017; UNESCO, 2019). Na prática, a intenção raramente é observável num texto curto; os anotadores apoiam-se em marcadores como a ausência de fonte verificável, o apelo urgente à partilha ou a atribuição de declarações a figuras públicas sem prova.

Discurso de ódio abrange conteúdos que promovem, incitam ou justificam a discriminação, a hostilidade ou a violência contra pessoas ou grupos com base em características identitárias, como a etnia, a religião, a origem regional, o género ou a orientação sexual (Conselho da Europa, 2022). Fortuna e Nunes (2018) mostram que a categoria inclui tanto o insulto explícito como formas implícitas, por exemplo estereótipos apresentados como factos, que são muito mais difíceis de detectar automaticamente. Num país com dezenas de grupos etnolinguísticos, como Angola, o discurso que opõe grupos entre si tem relevância securitária própria (Elias, 2019).

Mobilização hostil designa publicações que organizam, coordenam ou incitam à participação em acções ilegais ou violentas, ou que ameaçam a ordem pública (Hassane, 2021; Sette Câmara, 2016). É a categoria mais delicada, porque a fronteira com o exercício legítimo dos direitos de expressão e de manifestação, consagrados nos artigos 40.º e 47.º da Constituição da República de Angola (República de Angola, 2010), é ténue. O guia de anotação (Apêndice B) exige a presença conjunta de coordenação explícita, linguagem coerciva ou de violência e ausência de referência ao carácter pacífico da acção; na falta de algum destes elementos, a publicação é classificada como Normal.

A noção de **discurso perigoso** (Benesch, 2012) ajuda a situar a Mobilização Hostil: é o discurso que aumenta a probabilidade de o público aceitar ou cometer violência contra outro grupo, avaliado pelo orador, pelo público, pela mensagem, pelo contexto e pelo meio. Um classificador de texto só vê a mensagem; os outros quatro factores cabem ao analista.

Normal é a categoria residual: tudo o que não cumpre os critérios das restantes, incluindo crítica política, humor, jornalismo e conversa quotidiana. Esta definição por exclusão obriga o anotador a procurar activamente marcadores de ameaça, em vez de se limitar a reconhecer conteúdo inofensivo.

2.3 Sistemas de monitorização de ameaças

Os sistemas internacionais de referência mostram o que é tecnicamente possível, mas também porque não se transpõem directamente para Angola. O programa MediFor, da agência norte-americana DARPA, desenvolveu métodos forenses para detectar imagens e vídeos manipulados (Defense Advanced Research Projects Agency, 2016). É um programa de investigação governamental, sem mecanismo de transferência para países terceiros e sem atenção ao português.

O Palantir Gotham é uma plataforma comercial de análise de grandes volumes de dados heterogéneos usada por agências de segurança (Palantir Technologies, 2021). O

seu custo e, sobretudo, a dependência de um fornecedor e de uma infra-estrutura externos levantam problemas de soberania sobre dados sensíveis. O EU DisinfoLab publica metodologias abertas de análise de redes de desinformação baseadas em fontes abertas (EU DisinfoLab, 2020, 2021); são transferíveis em termos de método, mas foram pensadas para o contexto europeu. O AFRIPOL acompanha as ciberameaças no continente africano através de relatórios periódicos (AFRIPOL, 2023), sem uma componente automática de análise de texto em português.

A análise de redes sociais oferece um complemento útil à classificação de conteúdos. Medidas como a centralidade de grau, a centralidade de intermediação e a densidade permitem identificar contas influentes, pontes entre comunidades e padrões de publicação coordenada (Thelwall, 2009; Freire, 2015). Woolley e Howard (2017) documentam como a propaganda computacional recorre a contas automatizadas e a publicação sincronizada para simular apoio popular. O protótipo desta dissertação trabalha ao nível da publicação individual e não implementa esta dimensão relacional, que é uma extensão natural discutida no Capítulo 5.

Monaco e Arnaudo (2020) sublinham que a monitorização de redes sociais por entidades públicas exige, além da tecnologia, regras claras sobre o que se recolhe, quem acede e como se decide; daí a opção, neste trabalho, por um fluxo auditável com o analista no centro.

2.4 Recursos e modelos de linguagem para o português

2.4.1 Corpora anotados

A detecção automática de discurso de ódio e de desinformação depende de corpora anotados, e a qualidade e o alcance desses corpora condicionam o que os modelos aprendem (Poletto et al., 2021). Para o português existem três recursos públicos relevantes para esta investigação, todos de origem brasileira:

- o **ToLD-BR** reúne cerca de 21 mil publicações do Twitter anotadas para várias formas de linguagem tóxica, incluindo ataques baseados em identidade (Leite et al., 2020);
- o **HateBR** contém 7 mil comentários do Instagram anotados por especialistas para linguagem ofensiva e discurso de ódio (Vargas et al., 2022);
- o **Fake.br** contém 7.200 notícias, metade verdadeiras e metade falsas, com textos completos emparelhados por tema (Monteiro et al., 2018).

Nenhum destes recursos inclui a categoria de mobilização hostil, e nenhum contém texto angolano. A Desinformação disponível é composta por notícias

completas, um género textual muito diferente dos comentários curtos que circulam nas redes sociais, o que terá consequências na interpretação dos resultados (Secção 4.6).

2.4.2 Modelos de linguagem

O BERT (Devlin et al., 2018) introduziu o pré-treino de codificadores *Transformer* (Vaswani et al., 2017) com objectivos de modelação de linguagem mascarada, seguido de ajuste fino para tarefas específicas. O BERTimbau é a versão do BERT pré-treinada com o corpus brWaC, uma colecção de páginas web brasileiras com cerca de 2,7 mil milhões de *tokens*, e obteve resultados de referência em várias tarefas de PLN em português (Souza et al., 2020).

O BERTimbau usa um vocabulário de subpalavras (*WordPiece*). Uma palavra que não está no vocabulário não é descartada: é dividida em fragmentos conhecidos. Termos do calão de Luanda, como *kota*, *bué* ou *mujimbo*, e empréstimos do kimbundu são assim representados por sequências de fragmentos sem significado próprio, o que enfraquece a representação semântica da frase. O efeito não se resolve apenas com o ajuste fino, porque este parte das representações aprendidas no pré-treino. Gururangan et al. (2020) mostram que continuar o pré-treino com texto do domínio de aplicação (*domain-adaptive pretraining*) melhora o desempenho em domínios afastados do original, uma via que fica identificada como trabalho futuro.

Há duas alternativas ao BERTimbau. Os modelos multilingues, como o XLM-R, partilham conhecimento entre cerca de uma centena de línguas, à custa de menor capacidade para cada uma (Conneau et al., 2020). Os modelos pré-treinados com português europeu, como o Albertina PT-PT (Rodrigues et al., 2023), oferecem uma norma escrita mais próxima da usada em Angola; a hipótese de perderem menos em comentários angolanos fica para trabalho futuro.

2.5 Algoritmos de classificação de texto

Foram comparados quatro algoritmos que representam três gerações de métodos. A Tabela 2.1 resume as suas características.

Tabela 2.1 – Algoritmos de classificação comparados

Algoritmo	Representação do texto	Pontos fortes	Limitações
SVM	TF-IDF (saco de palavras e n-gramas)	Eficaz em espaços esparsos de alta dimensão; rápido em CPU	Ignora a ordem e o contexto das palavras
Floresta Aleatória	TF-IDF	Robusta ao sobreajuste; permite analisar a importância dos termos	Ignora a ordem; menos eficaz em espaços muito esparsos

Algoritmo	Representação do texto	Pontos fortes	Limitações
Bi-LSTM	Sequência de *embeddings* aprendidos	Modela a ordem e dependências nos dois sentidos	Precisa de mais dados; sem pré-treino em grande escala
BERTimbau	Subpalavras com contexto (*Transformer*)	Pré-treino em português; contexto bidireccional	Custo computacional; GPU recomendada para treino

Nota. Elaborado a partir de Cortes e Vapnik (1995), Joachims (1998), Breiman (2001), Hochreiter e Schmidhuber (1997), Schuster e Paliwal (1997) e Souza et al. (2020).

As Máquinas de Vectores de Suporte (Cortes & Vapnik, 1995) procuram o hiperplano que separa as classes com a maior margem e são, desde Joachims (1998), uma referência sólida para classificação de texto com representações TF-IDF. A Floresta Aleatória (Breiman, 2001) combina muitas árvores de decisão treinadas com amostras e subconjuntos de variáveis diferentes; é menos comum em texto, mas útil como segunda referência clássica e pela interpretabilidade da importância dos termos.

As redes LSTM (Hochreiter & Schmidhuber, 1997) foram concebidas para captar dependências longas em sequências; a versão bidireccional (Schuster & Paliwal, 1997) lê a frase nos dois sentidos. Esta capacidade é relevante para a mobilização hostil, em que a informação decisiva (hora, local, apelo final) pode surgir em qualquer ponto do texto. O BERTimbau, por fim, combina o contexto bidireccional com o conhecimento linguístico adquirido no pré-treino. A comparação entre o Bi-LSTM e o BERTimbau dá, assim, uma indicação sobre o peso do pré-treino, embora não o isole, porque os dois modelos diferem também na tokenização, no comprimento de entrada e na capacidade.

2.6 Avaliação de classificadores

Em problemas com classes desequilibradas, a exactidão é enganadora: um modelo que classifique tudo como Normal pode ter exactidão elevada e ser inútil. Sokolova e Lapalme (2009) mostram que a escolha da métrica deve reflectir os custos dos erros. Nesta dissertação, a métrica principal é o **F1-macro**, a média simples do F1 de cada categoria, que dá à Mobilização Hostil, a categoria mais rara, o mesmo peso que a categoria Normal. Reportam-se também o F1 ponderado, a exactidão, a área sob a curva ROC (AUC-ROC) e o Kappa de Cohen entre as previsões e a referência (Cohen, 1960).

Uma diferença de desempenho num conjunto de teste pode resultar do acaso. Para quantificar essa incerteza usam-se intervalos de confiança por *bootstrap*, que reamostram o conjunto de teste com reposição e recalculam a métrica (Efron & Tibshirani, 1993). Para comparar dois classificadores no mesmo conjunto de teste, Dietterich (1998) recomenda o teste de McNemar (McNemar, 1947), que considera

apenas os casos em que um modelo acerta e o outro erra. Quando se fazem várias comparações, a correcção de Bonferroni multiplica cada valor de p pelo número de comparações, controlando a probabilidade de encontrar pelo menos uma diferença espúria.

O acordo entre anotadores mede a fiabilidade das etiquetas. O Kappa de Cohen (Cohen, 1960) aplica-se a pares de anotadores; o Kappa de Fleiss (Fleiss, 1971) generaliza-o para mais de dois. Ambos corrigem a concordância observada pela concordância esperada ao acaso. A escala de Landis e Koch (1977) é a referência habitual para a sua interpretação, embora os próprios autores a apresentem como indicativa.

Quando as previsões servem para ordenar trabalho humano, interessa também a qualidade das probabilidades. Um classificador está **calibrado** quando, entre as previsões feitas com 80% de confiança, cerca de 80% estão certas; as redes neuronais modernas tendem a ser demasiado confiantes (Guo et al., 2017). A calibração mede-se com o erro de calibração esperado (ECE), a diferença média entre a confiança e a fracção de acertos por intervalo de confiança (Naeini et al., 2015), e com o índice de Brier (Brier, 1950). A ordenação mede-se com a precisão nos primeiros K itens e a precisão média (Manning et al., 2008), ou com a curva de esforço: a fracção das ameaças encontradas em função da fracção da fila revista. Para proporções pequenas, como a de ameaças entre os itens considerados normais, usa-se o intervalo de Wilson (1927).

2.7 Generalização entre domínios e aprendizagem de atalhos

Um modelo treinado num corpus pode ter bom desempenho nesse corpus e falhar noutro. Fortuna, Soler-Company e Wanner (2021) mostram que os classificadores de discurso de ódio e de linguagem ofensiva generalizam mal entre conjuntos de dados, porque cada corpus reflecte as suas plataformas, os seus temas e as suas decisões de anotação. Geirhos et al. (2020) descrevem o fenómeno mais geral da aprendizagem de atalhos (*shortcut learning*): o modelo aprende uma regularidade que separa as classes no conjunto de treino, como o comprimento ou o estilo do texto, em vez da propriedade que se pretende detectar.

Um caso particular é o enviesamento por variedade linguística: textos escritos numa variedade pouco representada nos dados de treino são marcados como ofensivos com mais frequência (Sap et al., 2019), e a linguagem ofensiva confunde-se facilmente com ódio (Davidson et al., 2017). É de esperar um efeito semelhante entre o português do Brasil e o de Angola.

Estes trabalhos têm duas consequências para esta investigação. Primeiro, o desempenho medido num teste dominado por dados brasileiros não pode ser tomado como desempenho em Angola. Segundo, quando uma categoria provém de uma única fonte com um estilo muito próprio, como a Desinformação do Fake.br, é de esperar que o modelo aprenda esse estilo. A H4 destina-se a medir directamente o primeiro efeito, e a análise por categoria da Secção 4.6 procura indícios do segundo.

2.8 Aspectos éticos, legais e de direitos humanos

A monitorização de redes sociais por entidades de segurança coloca em tensão a protecção da segurança colectiva e os direitos individuais de expressão, reunião e privacidade. A tecnologia, por si, não resolve essa tensão. Resolvem-na regras claras sobre o que se recolhe, sobre o modo como a informação é tratada e sobre quem decide.

O quadro jurídico angolano relevante inclui a Constituição da República de Angola, que consagra a liberdade de expressão e de informação (artigo 40.º) e a liberdade de reunião e de manifestação (artigo 47.º) (República de Angola, 2010). Inclui também a Lei n.º 22/11, de 17 de Junho, de Protecção de Dados Pessoais, que estabelece os princípios de finalidade, proporcionalidade, minimização e conservação limitada no tratamento de dados (República de Angola, 2011), e a Lei n.º 7/17, de 16 de Fevereiro, de Protecção das Redes e Sistemas Informáticos, relevante para a forma como os dados são obtidos (República de Angola, 2017). A mesma lei trata como sensíveis os dados que revelam, entre outros, convicções políticas, e sujeita o seu tratamento a requisitos acrescidos e ao controlo da autoridade de protecção de dados. Publicações sobre política podem revelar essas convicções mesmo depois de pseudonimizadas, o que torna indispensável um parecer jurídico antes de qualquer uso institucional. Os termos de utilização das plataformas acrescentam uma camada contratual que deve ser respeitada e declarada.

A Recomendação da UNESCO sobre a Ética da Inteligência Artificial (UNESCO, 2021) pede que os sistemas usados em contextos de segurança pública sejam proporcionais, transparentes, auditáveis e sujeitos a supervisão humana, e que os seus erros sejam avaliados por grupos linguísticos e demográficos. O Regulamento Europeu da Inteligência Artificial (União Europeia, 2024) classifica, de forma semelhante, vários usos de IA em contextos de aplicação da lei como de risco elevado. Destes princípios decorrem as salvaguardas adoptadas no sistema (Secção 3.2): recolha apenas de conteúdo público, anonimização antes do armazenamento, ausência de perfis individuais, revisão humana obrigatória e auditoria de todas as acções.

O risco mais imediato é o falso positivo na Mobilização Hostil: uma convocatória pacífica partilha com uma hostil muitos marcadores superficiais (urgência, data, local, apelo colectivo).

2.9 Revisão humana e segurança da informação

Manter uma pessoa no circuito de decisão não basta. Parasuraman e Manzey (2010) descrevem a complacência e o viés de automação: o operador deixa de verificar o que o sistema faz bem na maior parte das vezes, e a sugestão substitui o seu juízo, sobretudo quando está sobrecarregado. Daí três contramedidas adoptadas no sistema: medir o acordo com a sugestão escondida (revisão cega), rever periodicamente uma amostra do que o sistema considerou inofensivo (amostra de controlo) e mostrar ao analista as limitações do modelo (Mitchell et al., 2019). As decisões dos analistas produzem também etiquetas novas, que podem alimentar novos ciclos de treino (Amershi et al., 2014; Settles, 2009).

Um sistema que guarda conteúdos sensíveis é, ele próprio, um alvo. As falhas de controlo de acesso, as falhas criptográficas, a injecção e as falhas de autenticação estão entre os riscos mais frequentes das aplicações web (OWASP Foundation, 2021). As orientações do NIST para a autenticação digital pedem palavras-passe longas em vez de regras de composição, limite de tentativas, segredos nunca guardados em claro e mecanismos de recuperação tão cuidados como a própria autenticação (Grassi et al., 2017). Estas regras orientaram a gestão de contas do sistema (Secção 3.8.7).

2.10 Síntese e lacuna de investigação

A literatura revista permite três conclusões. Os sistemas internacionais de monitorização não estão disponíveis, não cobrem o português de Angola ou implicam dependência externa. Os recursos de PLN para o português são brasileiros e, no caso da desinformação, pertencem a um género textual diferente do das redes sociais. Por fim, sabe-se que os classificadores de conteúdo nocivo generalizam mal entre domínios e entre variedades linguísticas, embora não exista uma medida dessa perda para Angola.

Acresce que a forma como o sistema é integrado no trabalho do analista conta tanto como o desempenho do modelo.

Esta dissertação procura, por isso, fazer duas coisas: medir com dados angolanos anotados o desempenho real dos modelos disponíveis e propor um sistema que use esses modelos de forma compatível com as suas limitações, isto é, como apoio à triagem humana e não como mecanismo de decisão.

CAPÍTULO 3 – METODOLOGIA

Este capítulo descreve como se conduziu a investigação: o desenho geral, as salvaguardas éticas, a recolha e a anotação dos dados, a construção do corpus de treino, os modelos, o protocolo de avaliação e, por fim, a arquitectura do sistema que põe o modelo seleccionado ao serviço do analista.

3.1 Paradigma e desenho da investigação

A investigação segue um paradigma pragmático e aplicado, com abordagem predominantemente quantitativa. As hipóteses H1 e H4 são testadas com métricas de classificação e testes estatísticos; a H2 e a H3 dependem de medições do sistema em funcionamento, cujo protocolo se define neste capítulo. A componente de engenharia (o protótipo) é avaliada por testes automáticos (Secção 4.8.4).

O trabalho decorreu em três fases, representadas na Figura 3.1. Na fase de dados recolheram-se e anotaram-se comentários angolanos e construiu-se o corpus híbrido. Na fase de modelos treinaram-se e compararam-se os quatro classificadores. Na fase de sistema desenvolveu-se o protótipo, cujas revisões humanas podem alimentar novos ciclos de treino.

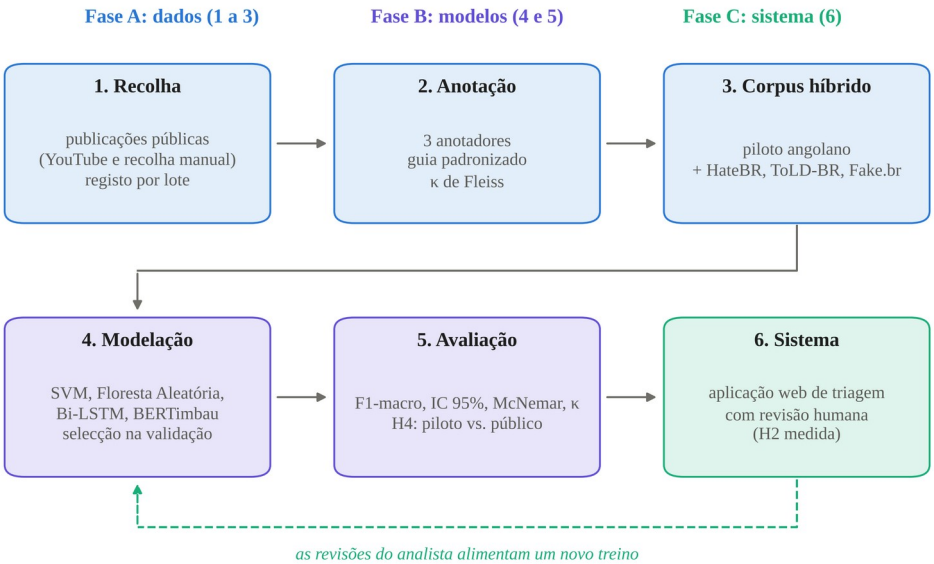


Figura 3.1 – Desenho da investigação

3.2 Considerações éticas e protecção de dados

O trabalho com conteúdos de redes sociais para fins de segurança exige salvaguardas definidas antes da recolha. As medidas adoptadas, que decorrem da Lei n.º 22/11 e dos princípios revistos na Secção 2.8, são as seguintes:

- **Conteúdo público apenas.** Recolheram-se apenas conteúdos públicos: comentários do YouTube, obtidos pela interface oficial, e publicações copiadas manualmente de páginas acessíveis sem autenticação. Não se acedeu a mensagens privadas, grupos fechados ou conteúdo que exija autenticação, nem se contornaram protecções técnicas das plataformas.
- **Anonimização antes do armazenamento.** Os nomes dos autores são substituídos por pseudónimos que não são reversíveis sem um segredo guardado fora do código, e os identificadores directos no texto (endereços web, correio electrónico, números de telefone e menções a utilizadores) são mascarados. Para nomes de pessoas privadas referidos no texto, a regra adoptada é a sua substituição por descritores do papel ou da instituição; nomes de instituições e de figuras políticas são mantidos, por serem relevantes para a classificação. No lote temático de vídeos, esta substituição só se fez depois do treino: o modelo foi treinado com esses nomes, o que constitui um desvio à regra a corrigir num novo treino. Como o lote só entra no treino, as métricas de teste não são afectadas. Em rigor jurídico, a substituição do autor por um pseudónimo é uma pseudonimização: impede a identificação directa, mas permite ligar publicações do mesmo autor. Nesta dissertação, «anonimização à entrada» designa o conjunto destas operações.
- **Proveniência registada.** Cada lote de dados fica associado à plataforma, à via de obtenção, à data e ao volume, o que permite declarar na metodologia a origem exacta de cada parte do corpus.
- **Sem perfis individuais.** O sistema apresenta agregados por categoria, período e plataforma; não existem vistas por autor.
- **Revisão humana obrigatória.** A classificação serve apenas para ordenar a revisão. Nenhuma acção sobre pessoas pode basear-se apenas no sistema.
- **Conservação limitada e auditoria.** As publicações não revistas são apagadas após um prazo configurável, e todas as acções (importação, classificação, revisão, exportação, limpeza) ficam registadas.
- **Consentimento dos anotadores.** Os anotadores assinaram uma declaração de consentimento e confidencialidade (Apêndice D).

Os termos de utilização das plataformas e a Lei n.º 7/17 devem ser objecto de parecer jurídico antes de qualquer uso institucional do sistema, como se recomenda no Capítulo 5.

3.3 Recolha de dados do piloto angolano

A maior parte dos dados angolanos veio do YouTube, plataforma em que os principais órgãos de comunicação e criadores de conteúdo angolanos publicam vídeos sobre política, economia e sociedade, e cujos comentários são públicos e acessíveis por uma interface oficial (YouTube Data API v3). A recolha seguiu quatro passos, implementados em *scripts* Python: a descoberta de vídeos por termos da actualidade angolana; a sondagem de uma pequena amostra de comentários de cada vídeo, para estimar a proporção de comentários angolanos; a selecção dos vídeos, privilegiando a diversidade de canais e temas; e a recolha dos comentários e respostas, com limite por vídeo e anonimização dos autores antes da gravação.

A quota diária da interface (10.000 unidades, com 100 unidades por pesquisa e 1 unidade por pedido de comentários) condicionou o ritmo da recolha. Para preservar a validade da comparação com os corpora brasileiros (H4), retiraram-se do piloto os casos explicitamente não angolanos, como comentários em vídeos de outros países ou de autores que se declaram de fora de Angola. Mantiveram-se os casos duvidosos, o que, quando muito, torna conservadora a estimativa da lacuna de domínio.

Uma parte menor do piloto veio de recolha manual: 180 títulos e entradas de notícias de sete órgãos de comunicação angolanos e 194 publicações e comentários copiados de páginas públicas, incluindo o Facebook. Estes itens passaram pela mesma anonimização e pela mesma anotação que os comentários do YouTube. No corpus, o piloto aparece com três origens, registadas na coluna `origem`:

- **Base do piloto** (`ate_v11`): 2.352 itens, dos quais 1.978 são comentários seleccionados aleatoriamente dos vídeos recolhidos e 374 vêm da recolha manual; são os únicos dados angolanos usados na validação e no teste. Os 374 itens manuais (180 títulos de notícias e 194 publicações copiadas) não resultam de sorteio, mas de escolha do investigador, o que deve ser tido em conta na leitura dos resultados do piloto.
- **Lote temático de vídeos** (`enriquecido_video_tema`): 284 comentários de vídeos escolhidos por tratarem temas propícios a mobilização ou a discurso de ódio, dos quais se retiraram 90 por não serem angolanos, restando 194.
- **Lote orientado por léxico** (`enriquecido_lexico`): 91 comentários priorizados para anotação por conterem termos de um léxico de candidatos.

Os dois lotes enriquecidos resultam de uma selecção não aleatória e foram anotados pelos mesmos anotadores. Por essa razão, entraram **apenas no treino**: incluí-los na avaliação inflacionaria as métricas e enviesaria a comparação da H4.

3.4 Anotação e acordo entre anotadores

Três anotadores independentes, dois angolanos e um com formação em processamento de linguagem natural, fizeram a anotação segundo o Guia de Anotação Padronizado (Apêndice B). Cada anotador classificou cada publicação numa das quatro categorias, sem acesso às classificações dos outros nem às previsões de qualquer modelo. Nos casos de desacordo, adoptou-se como regra de agregação a etiqueta mais grave escolhida por qualquer anotador (Mobilização Hostil > Discurso de Ódio > Desinformação > Normal), por analogia com a regra de desempate que o guia dá a cada anotador (Apêndice B.5), e por se considerar que, num contexto de segurança, um falso positivo sujeito a revisão é preferível a um falso negativo.

Mediu-se o acordo com o Kappa de Fleiss para os três anotadores e com o Kappa de Cohen para cada par. Nos 2.443 itens da base do piloto e do lote orientado por léxico, obteve-se κ de Fleiss de 0,718 (IC 95%: 0,695–0,741), κ de Cohen médio de 0,719 e concordância observada de 81,3%, o que corresponde a acordo substancial na escala de Landis e Koch (1977); só na base do piloto (n = 2.352), o κ de Fleiss é de 0,717. No lote temático de vídeos, o κ de Fleiss foi de 0,818 (IC 95%: 0,763–0,869), calculado sobre os 284 comentários anotados, antes da exclusão dos 90 não angolanos; este valor não é comparável com o anterior, porque uma amostra seleccionada por tema tem uma distribuição de categorias diferente. Os detalhes constam do Apêndice C.

O corpus anotado final tem 2.637 publicações, com a seguinte distribuição de etiquetas: Normal 1.664, Mobilização Hostil 364, Desinformação 326 e Discurso de Ódio 283. Após a harmonização e a remoção de duplicados (Secção 3.5), entram no corpus híbrido 2.573 registos do piloto.

A Tabela 3.1 descreve o corpus anotado por categoria. Três características têm consequências para a interpretação dos resultados.

Tabela 3.1 – Características do corpus angolano anotado, por categoria final

Categoria final	n	Palavras: mediana [Q1; Q3]	Decisão unânime	Decidida por um só voto
Normal	1.664	8 [4,0; 18,0]	100,0%	0 (0,0%)
Desinformação	326	21 [12,0; 34,0]	44,2%	106 (32,5%)
Discurso de Ódio	283	16 [8,5; 27,5]	56,9%	75 (26,5%)
Mobilização Hostil	364	16 [7,0; 24,0]	49,7%	116 (31,9%)
Total	**2.637**	11 [5,0; 22,0]	81,5%	297 (11,3%)

Nota. «Decidida por um só voto»: só um dos três anotadores escolheu a categoria final, que prevaleceu pela regra da gravidade ascendente. Por construção da regra, um item só é Normal quando os três anotadores o consideram Normal.

A primeira é o efeito da regra da gravidade ascendente: como basta um anotador escolher uma ameaça para que ela prevaleça, todos os itens Normais são unânimes e o desacordo concentra-se nas categorias de ameaça, onde só 44% a 57% das decisões foram unânimes. Ao todo, 297 itens (11,3% do corpus) são ameaças pelo voto de um único anotador. A regra favorece a sensibilidade, como convém à triagem, mas introduz ruído nas etiquetas, que contribui previsivelmente para os erros do modelo no piloto (Secção 4.6). A segunda é o comprimento: as ameaças têm cerca do dobro das palavras das publicações normais, uma regularidade que um classificador pode aprender como atalho (Secção 2.7). A terceira é a raridade das marcas lexicais da variedade angolana: só 0,3% das publicações contêm algum de 28 termos frequentes no calão de Luanda (como *bué*, *kota*, *mujimbo* ou *zungueira*), e só 96 (3,6%) mencionam uma província ou cidade reconhecida pelo sistema, 65 delas Luanda. O carácter angolano dos comentários está mais nos temas e nas referências do que no vocabulário, o que ajuda a interpretar a lacuna de domínio (Secção 4.6) e a cobertura do mapa (Secção 5.4).

Os casos de desacordo ilustram a natureza da tarefa. O comentário «Podemos paralizar mais não vandalisar prk faz recuar o país» foi considerado Normal por dois anotadores e Mobilização Hostil por um, e ficou como Mobilização pela regra da gravidade, embora o pedido expresso para não vandalizar o aproxime de um protesto pacífico. «MANOS ANGOLANOS VAMOS TIRAR ESSE FEITICEIRO DO PODER» foi visto como ódio por dois anotadores e como mobilização por um. Críticas duras ao Governo, que o guia classifica como Normais, foram lidas por alguns anotadores como ódio ou desinformação. Um modelo treinado com estas etiquetas herda esta incerteza. Rever as regras de desempate e formar os anotadores em conjunto nestes casos são melhorias simples para futuras rondas. A amostra do Apêndice E mostra, além disso, que os anotadores aplicaram por vezes critérios mais amplos do que os do guia, mesmo em itens unânimes: a Mobilização Hostil incluiu apelos genéricos sem linguagem violenta, o Discurso de Ódio incluiu insultos a partidos e a Desinformação incluiu alegações não verificadas. As categorias do piloto não são, por isso, inteiramente equivalentes às dos corpora públicos, e esta diferença de construto é uma explicação concorrente da lacuna medida na Secção 4.6.

Avaliou-se nos próprios dados anotados o léxico de candidatos usado para priorizar a anotação. No lote temático, apenas 27% dos comentários que o léxico assinalava como possíveis casos de mobilização (33 em 123) foram classificados pelos anotadores como Mobilização Hostil, contra 61% (17 em 28) no caso do discurso de ódio; num controlo de 45 comentários sem termos do léxico, não houve nenhum caso

de mobilização. O léxico é, por isso, útil para encontrar casos raros, mas insuficiente para os rotular, e não serviu de fonte de etiquetas.

3.5 Construção do corpus híbrido

O piloto angolano, por si só, é demasiado pequeno para treinar um classificador de quatro categorias. Combinou-se, por isso, com os três corpora públicos descritos na Secção 2.4.1. Mapearam-se as etiquetas originais de cada corpus para as quatro categorias da dissertação no *script* de construção do corpus. No ToLD-BR, os tweets com marcação de ataque a uma identidade passaram a Discurso de Ódio, os tweets sem qualquer marcação a Normal, e os tweets tóxicos apenas por obscenidade ou insulto sem alvo identitário foram excluídos. No HateBR, os comentários marcados como linguagem ofensiva passaram a Discurso de Ódio e os restantes a Normal, porque a versão usada fornece apenas essa etiqueta binária. Dos três corpora usou-se a partição de treino disponibilizada no Hugging Face, o que, com as exclusões do ToLD-BR e a remoção de duplicados, explica que os totais da Tabela 4.1 fiquem abaixo das dimensões originais (cerca de 21 mil no ToLD-BR e 7 mil no HateBR). No Fake.br, as notícias falsas passaram a Desinformação e as verdadeiras a Normal. Depois da junção, removeram-se os duplicados exactos.

O resultado é um corpus de 26.859 registos (238 duplicados removidos), cuja composição se apresenta na Tabela 4.1. A Figura 3.2 resume o processo e a divisão em treino, validação e teste.

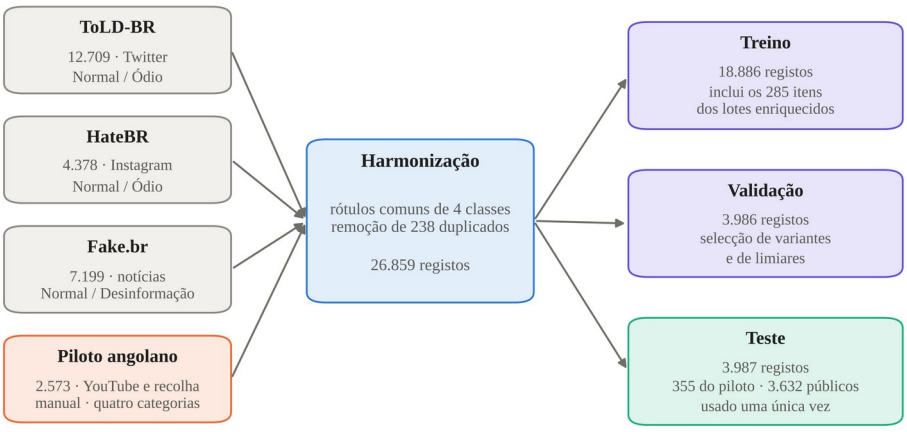


Figura 3.2 – Construção do corpus híbrido e divisão em treino, validação e teste

A divisão foi estratificada por categoria, com cerca de 70% dos dados para treino e 15% para cada um dos conjuntos de validação (3.986) e de teste (3.987). Os 285 itens dos lotes enriquecidos ficaram, por construção, no treino. Usou-se o conjunto de teste uma única vez, no fim, para cada modelo e variante.

Note-se que, no HateBR, a etiqueta usada é a de linguagem ofensiva, que é mais ampla do que o discurso de ódio tal como definido no guia de anotação; parte dos exemplos públicos de Discurso de Ódio são, por isso, insultos sem alvo identitário. Dois desequilíbrios estruturais condicionam a interpretação dos resultados. A Mobilização Hostil existe apenas no piloto e conta com 47 exemplos no teste, o que torna as estimativas desta categoria instáveis. E cerca de 91% do teste provém de corpora brasileiros, de modo que as métricas globais descrevem sobretudo o desempenho em conteúdo brasileiro. A H4 foi formulada para separar estes dois domínios.

3.6 Modelos e treino

3.6.1 Pré-processamento e representação

O pré-processamento foi deliberadamente ligeiro. O BERTimbau recebe o texto original, com pontuação e capitalização, e usa o seu próprio tokenizador de subpalavras. O Bi-LSTM converte o texto em minúsculas, divide-o em palavras e aprende as suas representações durante o treino. Os modelos clássicos usam uma representação TF-IDF limitada aos 5.000 termos mais frequentes do treino.

3.6.2 Configuração dos modelos

Tratou-se o desequilíbrio entre classes de duas formas, consoante o tipo de modelo. Nos modelos clássicos, aplicou-se SMOTE (Chawla et al., 2002) ao espaço TF-IDF do conjunto de treino, gerando exemplos sintéticos das classes minoritárias; a validação e o teste mantêm a distribuição original. Nos modelos neuronais, em vez de criar exemplos, usaram-se pesos na função de perda inversamente proporcionais à frequência de cada classe. A Tabela 3.2 resume a configuração.

Tabela 3.2 – Configuração dos modelos

Modelo	Configuração
SVM	TF-IDF (5.000 termos); SVM linear (LinearSVC); SMOTE no treino
Floresta Aleatória	TF-IDF (5.000 termos); 300 árvores; SMOTE no treino
Bi-LSTM	*Embeddings* de dimensão 100 treinados de raiz; LSTM bidireccional com 128 unidades; até 128 palavras por texto; lote 32; taxa de aprendizagem 10^{-3}; até 15 épocas com paragem antecipada (3 épocas sem melhoria do F1-macro de validação); entropia cruzada ponderada
BERTimbau	neuralmind/bert-base-portuguese-cased com ajuste fino completo e cabeça de 4 saídas; até 256 subpalavras; lote 16; taxa de aprendizagem 2×10^{-5}; 3 épocas, retendo a época com melhor F1-macro de validação; entropia cruzada ponderada

Nota. Valores por omissão dos *scripts* train_baseline.py, train_bilstm.py e train_bertimbau.py, usados sem alteração na corrida de referência. A semente aleatória é 42 em todos os modelos.

Treinou-se o BERTimbau três vezes, com as sementes 42, 43 e 44, para medir a variabilidade devida à inicialização. A execução com a semente 42 ficou definida, antes das restantes, como configuração de referência. Testaram-se ainda três variantes: a média das probabilidades das três sementes (*ensemble*), o treino sem o lote temático de vídeos (ablação) e pesos de classe suavizados (expoente 0,5 sobre o inverso da frequência).

3.6.3 Ambiente de desenvolvimento

Tabela 3.3 – Ambiente de desenvolvimento

Componente	Especificação
Sistema operativo (desenvolvimento)	Windows 11, 64 bits
Linguagem	Python 3.11
Treino dos modelos profundos	Google Colab com GPU NVIDIA T4 (16 GB)
Aprendizagem automática	PyTorch, Hugging Face Transformers, scikit-learn
Recolha de dados	YouTube Data API v3; leitura de páginas web e feeds RSS públicos (biblioteca padrão do Python, com respeito pelo robots.txt); recolha manual
Sistema	FastAPI, Jinja2 e Uvicorn (aplicação web sem dependências de compilação)
Armazenamento	SQLite 3 (base de dados num único ficheiro, com transacções e chaves estrangeiras)
Controlo de versões	Git e GitHub (repositório dissertacao-uan-angola)

Nota. As versões exactas das bibliotecas do sistema constam do ficheiro requirements.txt do protótipo.

3.7 Protocolo de avaliação

Definiu-se a avaliação antes de se conhecerem os resultados de teste, segundo as regras seguintes.

- **Métrica principal:** F1-macro no conjunto de teste, com IC 95% por *bootstrap* não paramétrico (2.000 reamostragens).
- **Métricas complementares:** F1 ponderado, exactidão, Kappa de Cohen entre previsões e referência, AUC-ROC média das quatro curvas um-contra-todos, e precisão, sensibilidade e F1 por categoria.
- **Comparação de modelos (H1):** teste de McNemar com correcção de continuidade para cada um dos seis pares de modelos, com correcção de Bonferroni ($\alpha = 0{,}05/6 \approx 0{,}0083$), e IC 95% da diferença de F1-macro por *bootstrap* emparelhado.
- **Selecção de variantes:** feita no conjunto de validação. Uma variante só substitui a referência se se distinguir dela; caso contrário, mantém-se a

referência. Os resultados de teste são reportados para todas as variantes, sem selecção pelo teste.

- **Ajuste de limiares:** vieses por classe escolhidos na validação, com o ganho esperado estimado por validação cruzada dentro da validação; o resultado principal é sempre reportado sem ajuste.
- **Lacuna de domínio (H4):** o teste é dividido em subconjunto do piloto angolano e subconjunto dos corpora públicos; compara-se o F1-macro (com IC 95%) e o Kappa do modelo seleccionado em cada um, e repete-se a comparação nas três categorias comuns para controlar a ausência de Mobilização Hostil no corpus público.

O protocolo das hipóteses H2 e H3, que dependem do sistema, é descrito na Secção 3.9.

3.8 Arquitectura do sistema

3.8.1 Requisitos

Desenhou-se a arquitectura depois de conhecidos os resultados do Capítulo 4. Um classificador com F1-macro de cerca de 0,80 no teste global, de cerca de 0,53 em conteúdo angolano e com precisão de cerca de 0,51 na Mobilização Hostil não deve tomar decisões, mas pode ajudar a ordenar o trabalho de quem decide. É desta constatação que partem os requisitos da Tabela 3.4.

Tabela 3.4 – Requisitos do sistema

Código	Requisito
RF1	Recolher publicações de fontes públicas registadas: comentários do YouTube pela interface oficial e artigos de sítios de notícias e feeds RSS que não exigem conta
RF2	Importar lotes de ficheiros de outras vias, registando a proveniência de cada lote
RF3	Anonimizar autores e identificadores directos antes de gravar
RF4	Guardar lotes, publicações, classificações, revisões e auditoria numa base de dados relacional
RF5	Classificar as publicações em lote com o modelo seleccionado
RF6	Apresentar uma fila de revisão ordenada por prioridade
RF7	Registar a decisão do analista e exportá-la para novo treino
RF8	Calcular métricas operacionais: precisão nos primeiros K, κ analista–sistema e entre analistas, sensibilidade estimada, latência
RF9	Controlar o acesso por contas individuais com dois papéis (analista e supervisor)
RF10	Permitir a avaliação independente por vários analistas, com revisão cega e amostra de controlo
RF11	Gerar alertas a partir de ameaças confirmadas por analistas e de tendências de crescimento, na aplicação e por e-mail

Código	Requisito
RF12	Mostrar num mapa, por província, a concentração e a evolução das ameaças no período escolhido
RF13	Produzir o relatório de alertas de ameaças de um período, para impressão, exportação e envio por e-mail
RF14	Mostrar a ficha do modelo em uso: desempenho global, por categoria e em conteúdo angolano, limitações e acordo observado com os analistas
RF15	Oferecer um modo de demonstração com dados fictícios, numa base de dados separada da real, e permitir passar de um modo para o outro sem fechar o sistema
RF16	Percorrer periodicamente as fontes activas, recolhendo apenas publicações novas, com estimativa do consumo da quota do YouTube
RF17	Permitir recuperar o acesso a uma conta sem serviços externos: código pessoal de uso único, pedido ao supervisor com palavra-passe temporária e reposição local pelo administrador
RNF1	Funcionar num único servidor, com software livre e sem serviços externos obrigatórios
RNF2	Conformidade com a Lei n.º 22/11: minimização, pseudonimização, conservação limitada, auditoria
RNF3	Substituir o modelo sem alterar o resto do sistema
RNF4	Código modular, testado e documentado, para replicação e manutenção
RNF5	Recolher apenas conteúdo público, sem contornar protecções técnicas nem condições de acesso dos sítios
RNF6	Interface utilizável sem acesso à Internet, sem bibliotecas nem recursos externos, operável por teclado e legível em ecrãs estreitos e em papel
RNF7	Proteger contas e sessões segundo práticas reconhecidas: palavras-passe derivadas com sal, bloqueio após tentativas falhadas, sessões no servidor que terminam quando a janela é fechada, protecção contra pedidos forjados e nunca mostrar segredos em mensagens de erro
RNF8	Permitir a cada utilizador ajustar o aspecto da interface (tema, cores, tamanho da letra e densidade) sem afectar os outros

Nota. RF: requisito funcional; RNF: requisito não funcional.

3.8.2 Alternativas e decisão

Consideraram-se duas arquitecturas. A primeira, de processamento distribuído em fluxo contínuo, combinaria recolha massiva por automatização de navegadores, uma fila de mensagens (Kafka), processamento distribuído (Spark), uma base de dados documental na nuvem e um painel comercial de inteligência empresarial. A segunda, adoptada, é uma arquitectura em camadas, leve, que corre num único servidor e cresce por substituição de componentes. A Tabela 3.5 compara as duas.

Tabela 3.5 – Comparação das arquitecturas consideradas

Critério	Distribuída em fluxo contínuo	Em camadas, leve (adoptada)
Volume suportado	Muito elevado	Adequado ao volume de recolha pela via oficial; escalável por substituição de componentes

Critério	Distribuída em fluxo contínuo	Em camadas, leve (adoptada)
Infra-estrutura	Vários serviços em cluster; operação especializada	Um servidor; Python, SQLite (ou PostgreSQL)
Custo e dependências	Licenças e/ou serviços em nuvem	Apenas software livre
Soberania dos dados	Depende do fornecedor de nuvem	Dados em infra-estrutura própria
Vias de recolha	Tendência para automatizar páginas que exigem contornar protecções	Interfaces oficiais, sítios públicos sem conta (respeitando o robots.txt), recolha manual e exportações
Adequação ao modelo	Pressupõe decisões em tempo real	Pensada para triagem com revisão humana
Reprodutibilidade	Difícil fora do ambiente original	Instalação com um ficheiro de dependências; testes automáticos

A arquitectura distribuída faria sentido se o problema fosse o volume de dados. Aqui, o que limita o sistema é a capacidade humana de rever o que o modelo sinaliza e a fiabilidade do modelo em conteúdo angolano: processar milhões de publicações por hora produziria alertas que ninguém conseguiria rever. Com a arquitectura leve, o esforço vai para a qualidade da fila, para a protecção dos dados e para a facilidade de trocar o modelo; se o volume crescer, a base de dados pode passar para PostgreSQL e a inferência pode ser replicada, sem alterar o desenho.

3.8.3 Camadas e componentes

A Figura 3.3 apresenta a arquitectura adoptada, organizada em seis camadas.

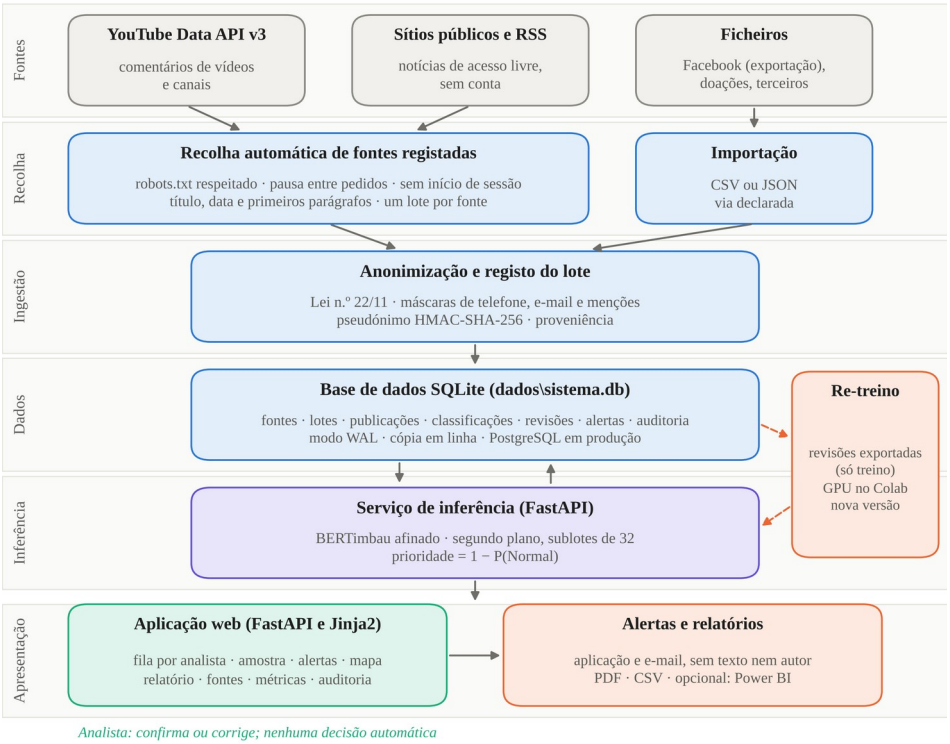


Figura 3.3 – Arquitectura em camadas do sistema de triagem

- **Fontes públicas.** O sistema recolhe ele próprio do YouTube, pela interface oficial (comentários de vídeos e dos vídeos recentes de canais, listas e pesquisas). Recolhe também de sítios de acesso livre que não exigem conta, como os portais dos órgãos de comunicação angolanos (feeds RSS, artigos e páginas de secção, a partir das quais segue ligações do mesmo sítio). O conteúdo público de redes que exigem conta, como o Facebook, entra por importação de ficheiros. Cada fonte e cada via ficam registadas com o lote.
- **Recolha.** O supervisor regista as fontes na aplicação, várias de cada vez se quiser, e o sistema detecta o tipo de cada endereço (vídeo, canal, lista ou pesquisa do YouTube, feed, página ou sítio). A recolha corre a pedido, por tarefa agendada do sistema operativo ou de forma periódica pelo próprio servidor (Secção 3.8.6). O módulo de recolha respeita o robots.txt, identifica-se como ferramenta de investigação, espera entre pedidos ao mesmo sítio e ignora páginas que pedem palavra-passe; não há rotação de endereços IP, identidades falsas nem resolução de *captchas*. De cada artigo guarda-se o título, a data e os primeiros parágrafos. Cada recolha cria um lote.
- **Ingestão.** Os registos recolhidos e os ficheiros importados passam pelo mesmo módulo. Este lê ficheiros CSV ou JSON, reconhece os nomes de colunas habituais dos *scripts* de recolha, mascara identificadores no texto e substitui o autor por um pseudónimo HMAC-SHA-256 (código de autenticação de mensagens baseado em *hash*) com um segredo guardado fora do código. Sem esse segredo, o *hash* de um nome de utilizador poderia ser revertido por dicionário. O ficheiro original não é guardado.
- **Dados.** O armazenamento usa SQLite, um motor de base de dados relacional que guarda tudo num único ficheiro (por omissão, dados\sistema.db), não precisa de servidor próprio e suporta transacções e chaves estrangeiras. A base de dados guarda as fontes de recolha, os lotes, as publicações, as classificações, as revisões (uma por analista e publicação), a amostra de controlo, os utilizadores e as sessões, as definições e o registo de auditoria (Figura 3.4). Duas tabelas servem os alertas: uma liga cada publicação às províncias que menciona e outra guarda os alertas e quem já os viu. O modo de diário WAL permite que a classificação em segundo plano grave enquanto os analistas consultam a fila. A cópia de segurança é feita em linha, sem parar o serviço.
- **Inferência.** O serviço carrega o BERTimbau afinado uma única vez e classifica as publicações pendentes em segundo plano, gravando os resultados por sublotes de 32, para que as primeiras publicações cheguem à fila sem esperar pelo lote inteiro. A prioridade de cada publicação é a probabilidade de não ser

Normal, 1 − P(Normal). Como a fila mostra por omissão apenas os itens cuja categoria mais provável não é Normal, esta ordenação só actua sobre esses itens; os restantes só chegam ao analista pela amostra de controlo (Secção 4.7.2).

- **Apresentação.** Uma aplicação web, acedida pelo navegador, mostra a fila de revisão, a amostra de controlo, o panorama agregado, os alertas, o mapa por província, o relatório de alertas, a ficha do modelo e os lotes e, para o supervisor, as métricas, as contas e a auditoria. As métricas podem ser exportadas para relatórios, incluindo ferramentas como o Power BI, sem que estas tenham acesso aos textos.
- **Alertas e relatório.** Os alertas nascem apenas de decisões humanas. Um alerta de ameaça confirmada surge quando o número de analistas definido pelo supervisor (um, por omissão) escolhe uma categoria de ameaça e há mais decisões de ameaça do que de Normal. Um alerta de tendência surge quando as ameaças confirmadas numa província, ou no país, chegam a um mínimo de casos numa janela (cinco em sete dias, por omissão), crescem pelo menos 50% face à janela anterior e ganham peso no total de publicações recolhidas. Esta última condição impede que um simples aumento da recolha pareça um aumento de ameaça. Os alertas aparecem na aplicação e são enviados por e-mail aos destinatários definidos pelo supervisor, sem o texto da publicação nem o pseudónimo do autor, apenas com a categoria, a província, a data e a ligação para o sistema. Nunca são enviados automaticamente a terceiros. O relatório de alertas de ameaças de um período pode ser impresso, guardado em PDF, exportado em CSV ou enviado por e-mail.

A localização usada nos alertas e no mapa é o lugar mencionado na publicação, não a localização de quem a escreveu, que os dados públicos não revelam. À entrada, o texto e o contexto são comparados com uma lista de topónimos (nomes das províncias, capitais e municípios mais citados), da qual se excluíram nomes com outro significado corrente, como Belas ou Cela, e termos ambíguos, como Kwanza sem Norte ou Sul. A localização fica ao nível da província, para não se aproximar de um perfil de pessoas, e as publicações sem lugar mencionado contam como «sem localização». O mapa usa as 18 províncias com os limites em vigor de 2011 a 2024, anteriores à divisão político-administrativa que entrou em vigor em Janeiro de 2025, a partir dos limites do geoBoundaries, de domínio público (Runfola et al., 2020). A cor de cada província é a taxa de ameaças confirmadas sobre as publicações que a mencionam, de modo que falar muito de Luanda não a torne, por si só, a província mais ameaçada; abaixo de

cinco publicações, a taxa não é calculada. Setas indicam a variação face ao período anterior com a mesma duração (Figura 3.8).

As revisões do analista são exportadas com a origem `revisao_sistema` e podem ser usadas num novo ciclo de treino. Como são etiquetas de um só analista sobre itens escolhidos pelo modelo, entram apenas no treino e nunca no teste.

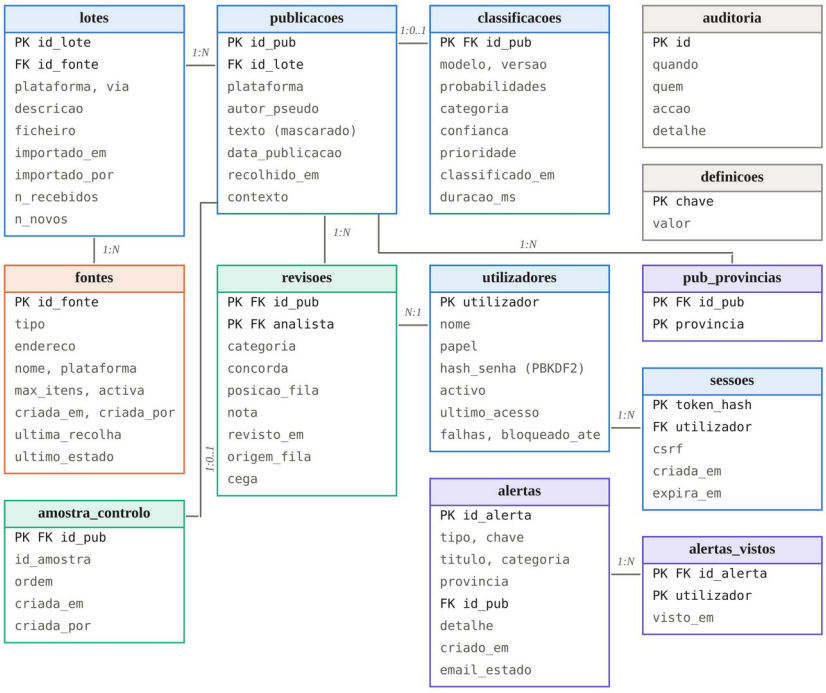


Figura 3.4 – Modelo de dados do sistema

3.8.4 Casos de uso e fluxo de processamento

O sistema tem cinco actores (Figura 3.5). O analista revê a sua fila e a amostra de controlo, consulta o panorama, os alertas e o mapa e gera o relatório de alertas. O supervisor, que também pode rever, regista as fontes públicas e lança a recolha, importa lotes, define as regras e os destinatários dos alertas, envia o relatório por e-mail, sorteia a amostra de controlo, gere as contas, consulta métricas e auditoria, activa a revisão cega e aplica o prazo de conservação. O serviço de inferência classifica em segundo plano cada lote recolhido ou importado. O investigador exporta as revisões e treina novas versões do modelo. O destinatário do e-mail, designado pelo supervisor, recebe os alertas e o resumo do relatório sem ter acesso ao sistema.

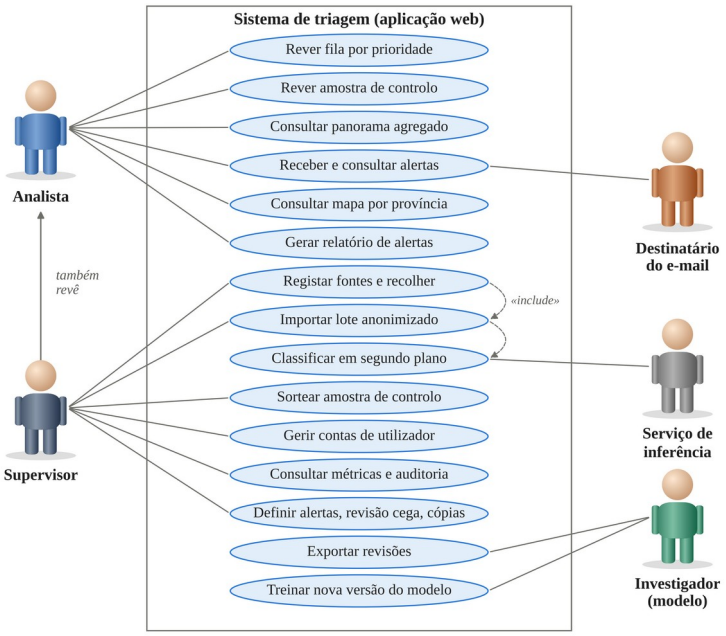


Figura 3.5 – Diagrama de casos de uso (UML)

A Figura 3.6 mostra a sequência de operações desde a recolha ou importação de um lote até à gravação da decisão do analista e aos alertas que dela resultam.

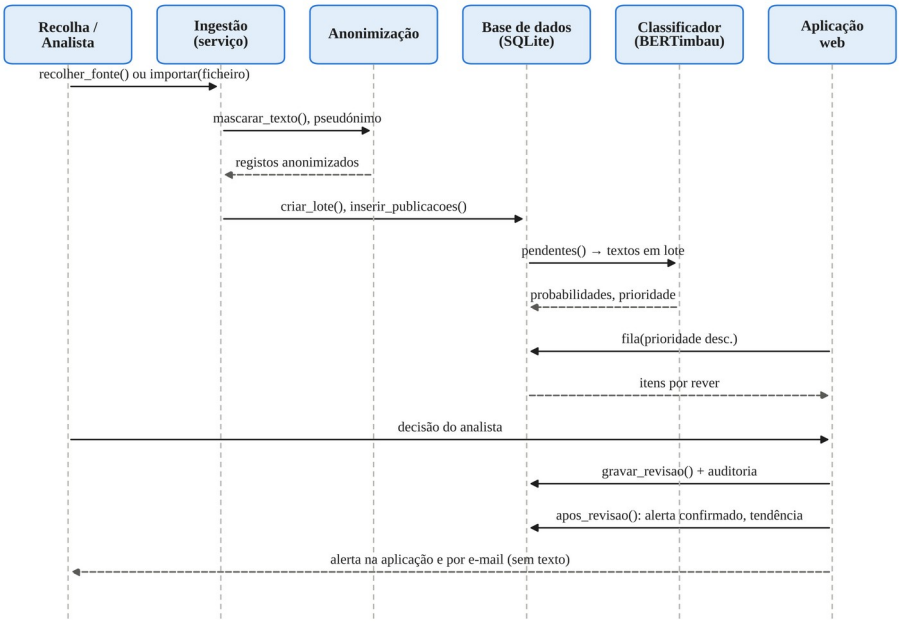


Figura 3.6 – Diagrama de sequência (UML): da recolha à revisão

3.8.5 Interface do analista

A interface é uma aplicação web servida pelo próprio sistema (FastAPI com modelos Jinja2), acedida pelo navegador, sem instalação nos postos dos analistas nem dependências de compilação. Cada pessoa entra com uma conta individual (Secção

3.8.7). Há dois papéis: o analista revê; o supervisor importa lotes, gere contas, consulta métricas e auditoria e define as opções de avaliação.

O desenho da interface obedeceu a quatro princípios. O primeiro é a autonomia: a folha de estilo, o código JavaScript, os ícones e as ilustrações são próprios do sistema, sem bibliotecas, tipos de letra ou serviços externos, e a política de segurança de conteúdo do navegador (CSP) só admite recursos do próprio servidor. A aplicação funciona, por isso, numa rede sem acesso à Internet, e nenhum terceiro fica a saber que páginas são consultadas. O segundo é a melhoria progressiva: todas as páginas são geradas no servidor e funcionam sem JavaScript; o código do navegador apenas acrescenta rapidez e conforto. O terceiro é a acessibilidade: todas as acções têm atalho de teclado, o foco é sempre visível, os números usam algarismos de largura fixa para se alinharem nas tabelas, as animações são desligadas quando o sistema operativo o pede, há um tema escuro, automático ou escolhido pelo utilizador, e as páginas adaptam-se a ecrãs estreitos e à impressão em A4. O quarto é a honestidade sobre o modelo: as probabilidades estão sempre visíveis e a ficha do modelo explica onde ele falha.

Na fila (Figura 3.7), cada publicação aparece com a categoria prevista, as probabilidades das quatro categorias e quatro botões de decisão, que respondem também às teclas 1 a 4; os lugares reconhecidos e os dados anonimizados aparecem realçados no texto. A decisão grava-se sem recarregar a página, com a posição que o item ocupava, e pode ser desfeita durante cinco segundos, antes de qualquer e-mail de alerta sair do sistema. Cada analista tem a sua própria fila, o que permite medir o acordo entre analistas de forma independente. Duas funções servem a avaliação da Secção 3.9: a revisão cega, que esconde a sugestão do modelo para que a concordância não seja inflacionada por ela, e a amostra de controlo, que sorteia, com semente registada, publicações classificadas como Normal para os analistas reverem sem sugestão e estimarem o que a fila deixa passar.



Figura 3.7 – Fila de revisão na aplicação web

Nota. Modo de demonstração, com dados fictícios e classificador simulado.

Os alertas chegam sem recarregar a página: o navegador consulta o servidor a cada 20 segundos, enquanto a página está visível, e actualiza o contador do menu e o sino. Uma paleta de comandos, aberta com Ctrl+K, permite chegar a qualquer página ou acção escrevendo parte do nome.

O mapa (Figura 3.8) é interactivo. Ao passar o cursor sobre uma província, um cartão mostra o número de publicações que a mencionam, as ameaças, a taxa, o valor do período anterior e a variação; um clique destaca a linha correspondente na tabela por província e um clique na tabela destaca a província no mapa. O botão de reprodução percorre o período semana a semana (dia a dia em períodos até 14 dias), colorindo cada província pelo número de ameaças nessa semana, o que mostra onde e quando a concentração cresceu. O mapa pode ser descarregado em SVG ou em PNG, já com título, período, legenda e fonte dos limites, para ser usado em relatórios.

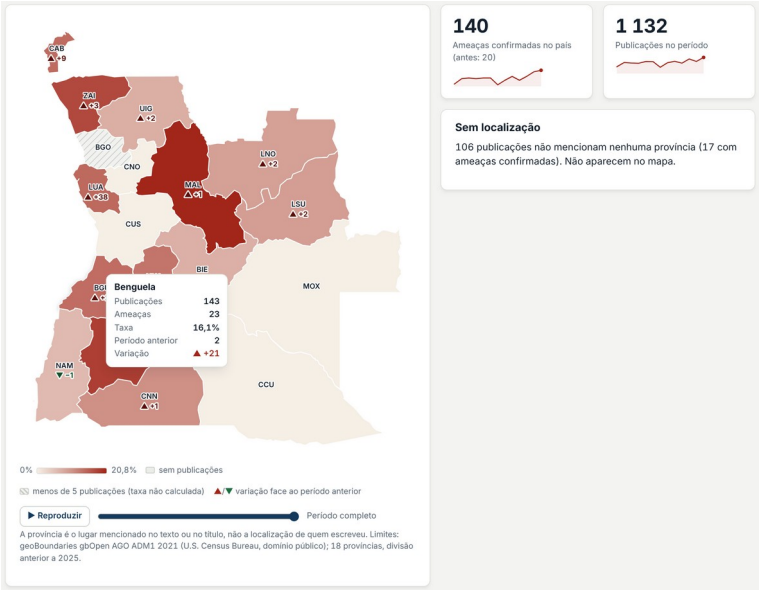


Figura 3.8 – Mapa por província na aplicação web

Nota. Modo de demonstração, com dados fictícios, últimos 90 dias; cartão de Benguela ao passar o cursor.

A página Sobre o modelo é a ficha do modelo em uso, no espírito das fichas de modelo propostas por Mitchell et al. (2019). Mostra a identificação, a data de treino e a configuração, o desempenho no teste por categoria ao lado do desempenho em conteúdo angolano (Secção 4.6) e as limitações conhecidas, escritas em linguagem corrente: a queda de cerca de 39 pontos percentuais em conteúdo angolano, a falha quase sistemática na Desinformação em comentários e a baixa precisão na Mobilização Hostil. Abaixo, a mesma página calcula o acordo observado entre analistas e modelo nessa instalação. A ficha é lida de um ficheiro que acompanha o modelo, de modo que um modelo novo traz a sua própria ficha. O objectivo é que o analista leia cada sugestão com a confiança que ela merece, e não com a que um número global de 0,81 sugeriria.

Duas funções servem a formação e a apresentação do sistema. Na primeira entrada, uma visita guiada de até dezoito passos percorre as partes do sistema a que o utilizador tem acesso, realçando cada uma. O modo de demonstração usa uma base de dados separada com cerca de 1.300 publicações fictícias de dezasseis semanas, compostas a partir de temas, lugares e registos variados, com casos de fronteira e episódios que dão forma ao mapa e aos alertas, e com sugestões de um classificador simulado que erra como o modelo real. Neste modo, nenhum e-mail é enviado. O supervisor pode passar da demonstração para o sistema real, e vice-versa, sem fechar o programa, e as páginas abertas recarregam-se quando o servidor está pronto. Cada utilizador pode ainda ajustar o aspecto da interface (tema, cores, tamanho da letra, densidade e cores do mapa), sem afectar os outros.

As principais funções estão também disponíveis numa interface de programação JSON, protegida por chave, para integração com outros componentes, e numa linha de comandos, para tarefas agendadas como a recolha periódica das fontes, a importação, a verificação de tendências, o relatório periódico, a limpeza e as cópias de segurança. O manual de instalação e utilização consta do Apêndice F.

3.8.6 Recolha automática e gestão da quota

Para que o sistema acompanhe as fontes sem intervenção, o servidor verifica de 30 em 30 segundos se chegou a hora da próxima volta, com a frequência escolhida pelo supervisor entre 15 minutos e um dia (Figura 3.9). Em cada volta percorre todas as fontes activas: nos canais, listas e pesquisas do YouTube, vê os vídeos mais recentes e os seus comentários mais recentes; nos feeds e nos sítios, procura artigos novos. Só entra o que ainda não existe na base de dados, as publicações novas são classificadas e entram na fila, e cada volta fica nos lotes e na auditoria. A interface do YouTube tem uma quota diária, habitualmente de 10.000 unidades, e uma pesquisa custa cem vezes mais do que uma página de comentários; a página estima, por isso, o consumo de cada volta e do dia a partir das fontes activas (Tabela 3.6) e avisa quando a estimativa se aproxima do limite.

Tabela 3.6 – Tipos de fonte e quota do YouTube por volta

Tipo de fonte	O que é lido em cada volta	Unidades por volta
Vídeo do YouTube	Comentários e respostas mais recentes, até ao máximo definido	1 por cada 100 comentários
Canal do YouTube	Os 10 vídeos mais recentes e os seus comentários	cerca de 12
Lista de reprodução do YouTube	Os 10 vídeos da lista e os seus comentários	cerca de 11
Pesquisa no YouTube	Os 10 vídeos mais recentes com os termos indicados (região Angola, língua portuguesa) e os seus comentários	cerca de 110
Feed RSS ou Atom	Entradas novas do feed	0
Página web pública	Título, data e primeiros parágrafos	0
Sítio web público	Página inicial de uma secção e as ligações para artigos do mesmo sítio	0

Nota. Estimativa usada pela aplicação. Os sítios web não gastam quota do YouTube, mas o sistema espera alguns segundos entre pedidos ao mesmo sítio e respeita o robots.txt.

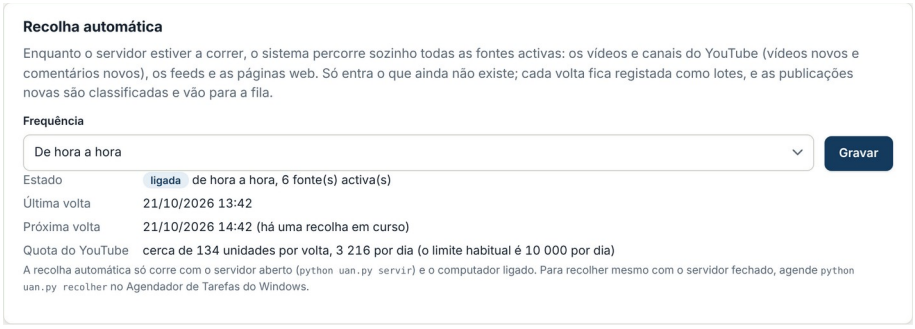


Figura 3.9 – Recolha automática na página das fontes

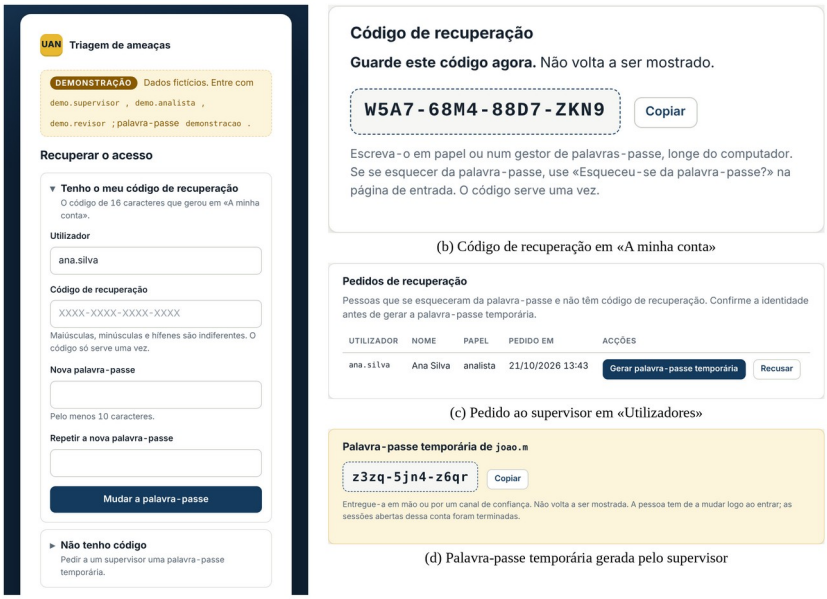
Nota. Sistema real numa instalação de teste, com seis fontes de exemplo (um canal, um vídeo, uma lista, uma pesquisa, um feed e um sítio).

A recolha automática só corre com o servidor em execução; com ele parado, a recolha pode ser agendada no sistema operativo. Como a chave do YouTube viaja no endereço de cada pedido, as mensagens de erro são limpas antes de gravadas, para que a chave nunca apareça no ecrã nem nos registos.

3.8.7 Gestão de contas e segurança

As contas seguem as orientações revistas na Secção 2.9. As palavras-passe têm pelo menos dez caracteres e são guardadas como derivação PBKDF2-SHA-256 com sal e 240.000 iterações; cinco tentativas falhadas bloqueiam a conta durante cinco minutos. A sessão fica no servidor, num cookie sem validade própria, e cada formulário leva um código anti-falsificação. Ao fechar o separador ou a janela, o navegador pergunta se a pessoa quer sair; se a janela fechar e nenhuma página do sistema reabrir em 20 segundos, a sessão termina e fica na auditoria.

A recuperação do acesso dispensa correio electrónico e serviços externos (Figura 3.10). Cada utilizador pode gerar um código de recuperação pessoal de dezasseis caracteres (cerca de 80 bits), mostrado uma só vez, guardado como derivação e válido uma vez. Sem código, a pessoa pede ajuda ao supervisor na página de entrada, com uma resposta igual exista ou não a conta; o supervisor confirma a identidade e gera uma palavra-passe temporária, que tem de ser mudada no primeiro acesso. Se o único supervisor perder o acesso, um comando local no servidor repõe a palavra-passe. Outro comando mostra a configuração que o sistema está a ler, sem revelar os valores. Todos os passos ficam na auditoria.



(a) Página «Recuperar o acesso»

(b) Código de recuperação em «A minha conta»

(c) Pedido ao supervisor em «Utilizadores»

(d) Palavra-passe temporária gerada pelo supervisor

Figura 3.10 – Recuperação do acesso a uma conta

Nota. (a) modo de demonstração; (b) a (d) sistema real numa instalação de teste, com contas de exemplo.

3.9 Plano de testes e avaliação operacional

O sistema tem 121 testes automáticos (Secção 4.8.4). Cobrem a anonimização, a importação, a recolha (com um sítio de notícias e um cliente do YouTube simulados localmente, verificando o respeito pelo robots.txt e a exclusão de páginas com início de sessão), a recolha automática, os alertas e os e-mails sem texto nem autor. Cobrem também a detecção de províncias, o mapa e o relatório, o fluxo completo de importação, classificação, revisão, métricas e exportação, a conservação, as cópias de segurança e o carregamento do BERTimbau. Na aplicação web, testam o controlo de acesso, o bloqueio, a protecção CSRF, o escape de texto, a revisão independente e cega, a amostra de controlo, a interface do analista, o modo de demonstração e a gestão de contas, incluindo a recuperação do acesso e o fim da sessão ao fechar a janela. Correm com `python -m pytest -q`.

A avaliação operacional, que corresponde às hipóteses H2 e H3, segue o protocolo seguinte:

- **Latência (H2).** O comando `medir-latencia` importa, anonimiza e classifica um lote numa base de dados temporária e reporta a mediana do tempo total e por publicação; o intervalo entre a publicação original e a recolha deve ser reportado à parte.
- **Utilidade da fila.** Num lote novo, nunca usado no treino, e com a revisão cega activa, pelo menos dois analistas revêem a fila por ordem, de forma independente. Calcula-se a precisão nos primeiros K itens (K = 10, 25, 50,

100), a concordância e o κ entre cada analista e o sistema, e o κ entre analistas. Para estimar a sensibilidade, os analistas revêem também a amostra de controlo de itens classificados como Normal; a fracção considerada ameaça é reportada com IC 95% de Wilson.

- **Antecedência (H3).** Exige um corpus datado em torno de eventos documentados, dividido cronologicamente, e uma lista de eventos de referência independente do corpus. Um padrão conta como detectado quando o sistema emite um alerta de tendência (Secção 3.8.3) para a província ou para o país; a antecedência é o intervalo entre esse alerta e a data do evento, e a H3 confirma-se se a mediana for de pelo menos 48 horas. Este protocolo fica esboçado, mas não foi aplicado.

3.10 Plano de implementação faseada

A passagem do protótipo a uma ferramenta institucional deve ser gradual e condicionada a resultados. A Tabela 3.7 propõe três fases.

Tabela 3.7 – Plano de implementação faseada

Fase	Actividades	Condição para avançar
1. Piloto académico	Novo treino do BERTimbau; medição da latência; avaliação da fila com analistas num lote novo; parecer jurídico	Precisão nos primeiros 50 itens e κ analista–sistema aceites pela instituição; parecer favorável
2. Piloto institucional	Instalação em servidor próprio; formação de analistas; recolha agendada; ampliação do corpus angolano com revisões	Auditoria independente; desempenho em conteúdo angolano medido e reportado por categoria
3. Consolidação	Pré-treino adaptado ao domínio angolano; extensão a outras plataformas por vias oficiais; procedimentos de supervisão	Quadro normativo para uso de IA em segurança; revisão periódica do impacto

CAPÍTULO 4 – RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados experimentais obtidos com o corpus híbrido harmonizado e verifica formalmente as hipóteses formuladas na Secção 1.3. Recalcularam-se todos os valores a partir das previsões guardadas de cada modelo no conjunto de teste e reproduzem os ficheiros de métricas gerados pelo pipeline. A Secção 4.1 descreve o protocolo de avaliação. As Secções 4.2 a 4.5 tratam do desempenho global, da significância estatística, do desempenho por categoria e da estabilidade dos resultados. A Secção 4.6 testa a lacuna de domínio entre o piloto angolano e o corpus público (H4). A Secção 4.7 analisa a qualidade das probabilidades e a utilidade da ordenação que o sistema faz com elas. A Secção 4.8 trata da avaliação operacional (H2 e H3) e da verificação funcional do sistema, e a Secção 4.9 reúne a verificação das hipóteses.

Nas tabelas, por economia de espaço, as categorias Discurso de Ódio e Mobilização Hostil aparecem abreviadas como Ódio e Mobilização.

4.1 Corpus de avaliação e protocolo experimental

O corpus de treino e avaliação resulta da harmonização de três corpora públicos em português (ToLD-BR, Fake.br e HateBR) com o piloto angolano anotado nesta investigação. Após a remoção de 238 duplicados, o corpus contém 26.859 registos, distribuídos conforme a Tabela 4.1.

Tabela 4.1 – Composição do corpus harmonizado por fonte e categoria

Fonte	Normal	Desinformação	Ódio	Mobilização	Total
ToLD-BR	11.682	0	1.027	0	12.709
Fake.br	3.600	3.599	0	0	7.199
HateBR	2.195	0	2.183	0	4.378
Piloto angolano	1.613	318	283	359	2.573
Total	**19.090**	**3.917**	**3.493**	**359**	**26.859**

Nota. Valores após deduplicação (27.097 → 26.859). A categoria Mobilização Hostil existe apenas no piloto angolano. O piloto inclui 2.288 itens da base do piloto (comentários do YouTube amostrados aleatoriamente e itens de recolha manual) e 285 itens de lotes enriquecidos (194 por selecção temática de vídeos e 91 por léxico), usados exclusivamente no treino.

Recorde-se que os lotes enriquecidos do piloto entraram apenas no treino, que as configurações e variantes foram escolhidas na validação e que os resultados são reportados tal como saíram de cada execução, sem selecção pelo teste.

O conjunto de validação contém 3.986 itens e o de teste 3.987 itens (Normal 2.843; Desinformação 580; Discurso de Ódio 517; Mobilização Hostil 47). Dos itens

de teste, 355 (8,9%) provêm do piloto angolano e 3.632 (91,1%) dos corpora públicos brasileiros. Esta composição significa que as métricas globais descrevem sobretudo o desempenho em conteúdo brasileiro; o desempenho em conteúdo angolano é analisado separadamente na Secção 4.6.

A métrica principal é o F1-macro, que atribui o mesmo peso às quatro categorias e, por isso, não é dominada pela classe Normal. Reportam-se também o F1 ponderado, a exactidão, o Kappa de Cohen entre as previsões e a referência, e a AUC-ROC média das quatro curvas um-contra-todos. Obtiveram-se os intervalos de confiança a 95% (IC 95%) por *bootstrap* não paramétrico com 2.000 reamostragens do conjunto de teste. As comparações entre modelos usam o teste de McNemar com correcção de continuidade sobre os acertos e erros emparelhados, com correcção de Bonferroni para as seis comparações entre os quatro modelos (α corrigido = 0,0083). A diferença de F1-macro entre pares é acompanhada do respectivo IC 95% por *bootstrap* emparelhado.

4.2 Desempenho global dos modelos

A Tabela 4.2 apresenta o desempenho dos quatro modelos no conjunto de teste, sem ajuste de limiares de decisão.

Tabela 4.2 – Desempenho dos modelos no conjunto de teste

Modelo	F1-macro [IC 95%]	F1 ponderado	Exactidão	Kappa (κ)	AUC-ROC [IC 95%]
Floresta Aleatória	0,659 [0,621; 0,694]	0,831	0,834	0,624	0,906 [0,891; 0,919]
SVM	0,633 [0,606; 0,657]	0,791	0,772	0,566	0,909 [0,900; 0,917]
Bi-LSTM	0,660 [0,628; 0,689]	0,823	0,819	0,621	0,915 [0,901; 0,926]
BERTimbau	0,807 [0,774; 0,838]	0,924	0,924	0,832	0,979 [0,973; 0,983]

Nota. n = 3.987. AUC-ROC: média das quatro AUC um-contra-todos. IC 95% por *bootstrap* (2.000 reamostragens para o F1; 1.000 para a AUC). BERTimbau com ajuste fino, semente 42 (configuração de referência).

O BERTimbau obteve F1-macro de 0,807 (IC 95% [0,774; 0,838]), entre 14,6 e 17,4 pontos percentuais (p.p.) acima dos restantes modelos, cujos F1-macro se situam entre 0,633 e 0,660. O intervalo de confiança do BERTimbau não se sobrepõe ao de nenhum outro modelo. O BERTimbau é também o primeiro no Kappa e na AUC-ROC; entre os restantes, a ordem varia com a métrica, e as diferenças são pequenas.

A distância entre o F1 ponderado (0,924) e o F1-macro (0,807) do BERTimbau resulta do desequilíbrio das classes: o F1 ponderado é dominado pela classe Normal, que representa 71,3% do teste, enquanto o F1-macro dá à Mobilização Hostil (1,2% do teste) o mesmo peso das outras categorias. Por esta razão, o F1-macro é a métrica usada

na verificação das hipóteses. A Figura 4.1 apresenta as curvas ROC de cada modelo por categoria.

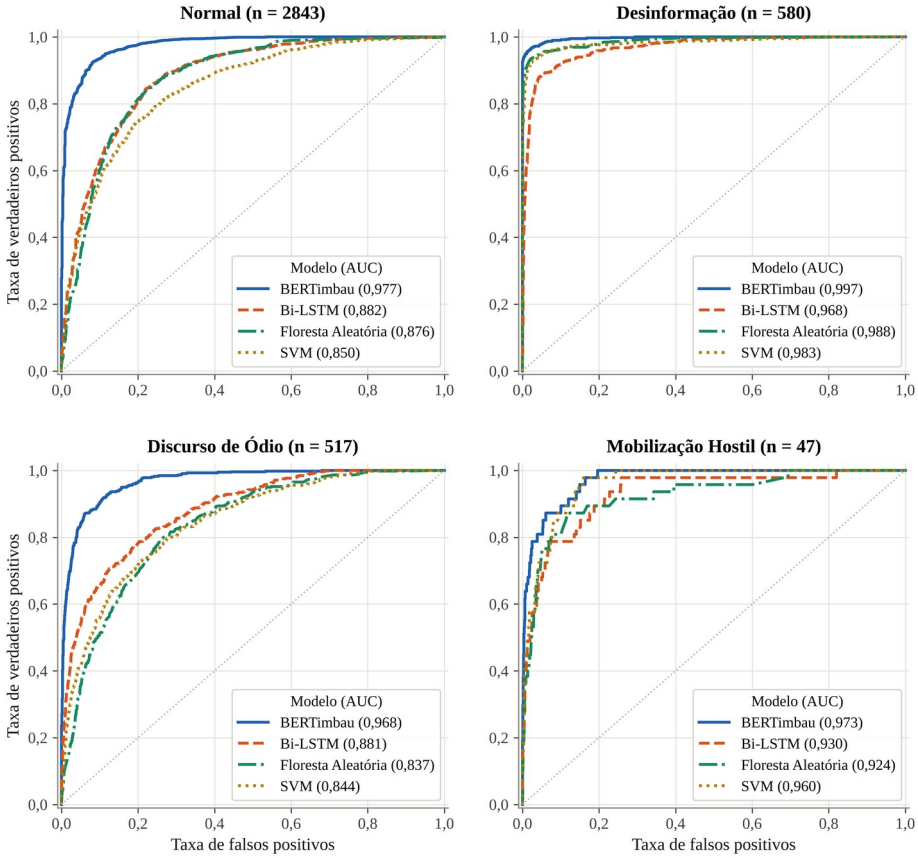


Figura 4.1 – Curvas ROC um-contra-todos por categoria e modelo (conjunto de teste; AUC entre parêntesis)

As curvas mostram que a vantagem do BERTimbau se concentra nas categorias Normal e Discurso de Ódio, onde as AUC dos restantes modelos descem para 0,837–0,882. Na Desinformação, todos os modelos ultrapassam 0,96, um resultado cuja interpretação é revista na Secção 4.6. Na Mobilização Hostil, as AUC são elevadas (0,924–0,973), mas assentam em apenas 47 exemplos positivos, pelo que as curvas apresentam degraus largos e a estimativa é instável.

4.3 Significância estatística das diferenças

A Tabela 4.3 apresenta as seis comparações emparelhadas entre os quatro modelos. As colunas *b* e *c* indicam, respectivamente, o número de itens que apenas o primeiro modelo do par classificou correctamente e o número de itens que apenas o segundo classificou correctamente.

Tabela 4.3 – Comparações emparelhadas (ΔF1-macro e McNemar)

Par	ΔF1-macro, p.p. [IC 95%]	b / c	χ^2	p (Bonferroni)	Signif.
BERTimbau vs. Bi-LSTM	14,6 [10,9; 18,4]	529 / 110	273,43	$1{,}2 \times 10^{-60}$	Sim
BERTimbau vs. Floresta Aleatória	14,8 [10,8; 18,8]	473 / 115	216,75	$2{,}8 \times 10^{-48}$	Sim
BERTimbau vs. SVM	17,4 [14,4; 20,4]	714 / 110	441,27	$3{,}4 \times 10^{-97}$	Sim
Bi-LSTM vs. Floresta Aleatória	0,2 [-4,0; 4,2]	348 / 409	4,76	0,175	Não
Bi-LSTM vs. SVM	2,8 [-0,3; 5,7]	519 / 334	39,69	$1{,}8 \times 10^{-9}$	Sim
Floresta Aleatória vs. SVM	2,6 [-0,9; 6,0]	524 / 278	74,84	$3{,}1 \times 10^{-17}$	Sim

Nota. n = 3.987. ΔF1 = F1-macro do primeiro modelo menos F1-macro do segundo. p (Bonferroni) = p do teste de McNemar multiplicado por 6 (limitado a 1). O teste de McNemar compara as proporções de acertos e erros; não testa directamente o F1-macro, razão pela qual se apresenta também o IC da diferença de F1.

O BERTimbau supera os três modelos de referência com diferenças de F1-macro entre 14,6 e 17,4 p.p., cujos intervalos de confiança excluem largamente o zero, e com p corrigido inferior a 10^{-47} em todos os casos. Em cada par, o número de itens que só o BERTimbau acerta (473–714) é 4,1 a 6,5 vezes superior ao número de itens que só o outro modelo acerta (110–115).

Entre os modelos de referência, o quadro é diferente. O Bi-LSTM e a Floresta Aleatória têm F1-macro praticamente iguais (ΔF1 = 0,2 p.p., IC 95% [-4,0; 4,2]) e a diferença nos acertos não é significativa após correcção (p = 0,175); a Floresta Aleatória acerta, aliás, mais itens isolados do que o Bi-LSTM (409 contra 348). O Bi-LSTM e a Floresta Aleatória acertam significativamente mais itens do que o SVM, mas as diferenças de F1-macro (2,8 e 2,6 p.p.) têm intervalos que incluem o zero. Só o BERTimbau se distingue, portanto, dos restantes. O Bi-LSTM não mostra vantagem consistente sobre os modelos clássicos neste corpus.

4.4 Desempenho por categoria e análise de erros

A Tabela 4.4 desagrega o F1 por categoria. Para o BERTimbau, apresentam-se também a precisão, a sensibilidade (*recall*) e o IC 95% do F1 de cada categoria.

Tabela 4.4 – F1 por categoria e modelo; precisão e sensibilidade do BERTimbau

Categoria	F. Aleatória	SVM	Bi-LSTM	BERTimbau F1 [IC 95%]	Precisão [a]	Sensib. [a]
Normal (n = 2.843)	0,889	0,836	0,875	**0,952** [0,95; 0,96]	0,952	0,951
Desinformação (n = 580)	0,922	0,871	0,815	**0,947** [0,93; 0,96]	0,947	0,948
Ódio (n = 517)	0,455	0,497	0,585	**0,778** [0,75; 0,80]	0,783	0,774
Mobilização (n = 47)	0,368	0,326	0,367	**0,549** [0,42; 0,66]	0,509	0,596

Categoria	F. Aleatória	SVM	Bi-LSTM	BERTimbau F1 [IC 95%]	Precisão [a]	Sensib. [a]
F1-macro	0,659	0,633	0,660	**0,807**	0,798	0,817

Nota. [a] Precisão e sensibilidade do BERTimbau; na última linha, médias macro.

O BERTimbau alcança F1 de 0,952 na Normal e 0,947 na Desinformação, 0,778 no Discurso de Ódio e 0,549 na Mobilização Hostil. A vantagem sobre os modelos de referência é maior no Discurso de Ódio (0,778 contra 0,455–0,585), categoria em que a Floresta Aleatória classifica como Normal a maioria dos itens de ódio, e na Mobilização Hostil (0,549 contra 0,326–0,368). Na Desinformação, a diferença é menor (0,947 contra 0,815–0,922), porque todos os modelos obtêm valores elevados nesta categoria.

A Mobilização Hostil é a categoria de maior relevância operacional e a de estimativa menos precisa. O BERTimbau identificou 28 dos 47 itens de teste (sensibilidade de 0,596) e produziu 27 falsos positivos (precisão de 0,509). O IC 95% do F1 desta categoria, [0,42; 0,66], tem uma amplitude superior a 20 p.p., consequência directa do número reduzido de exemplos. A Figura 4.2 apresenta as matrizes de confusão dos quatro modelos.

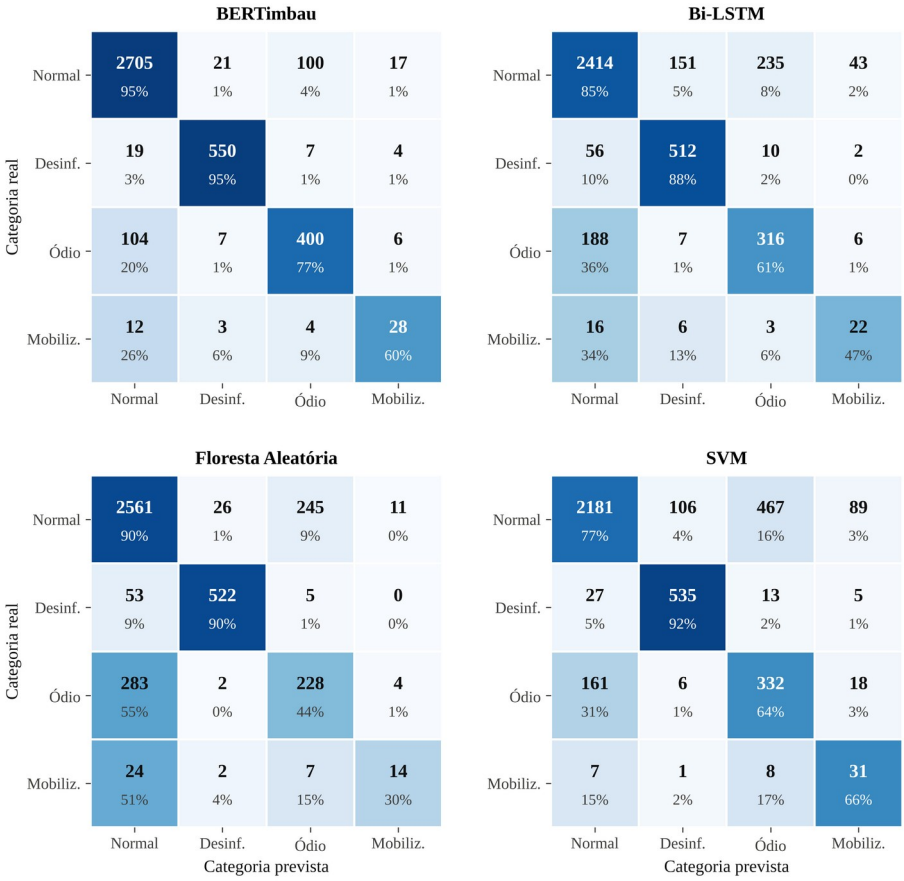


Figura 4.2 – Matrizes de confusão (4 × 4) no conjunto de teste (contagens e percentagem por linha)

Três padrões de erro são comuns aos quatro modelos. O primeiro, e mais frequente, é a confusão entre Normal e Discurso de Ódio: no BERTimbau, 100 itens Normais foram classificados como Discurso de Ódio e 104 itens de Discurso de Ódio como Normais, o que corresponde a 20% dos itens de ódio. Trata-se de uma fronteira conceptualmente difícil, que envolve ódio implícito, ironia e insulto sem alvo identitário. O segundo padrão é a classificação de Mobilização Hostil como Normal (12 dos 47 itens no BERTimbau; 16 no Bi-LSTM, 24 na Floresta Aleatória e 7 no SVM), que reproduz a fronteira, assumida no Guia de Anotação, entre convocatória legítima e mobilização hostil. O terceiro padrão, no BERTimbau, é a raridade das confusões que envolvem a Desinformação, que se analisa na Secção 4.6.

Do ponto de vista operacional, uma sensibilidade de cerca de 0,60 com precisão de cerca de 0,51 na Mobilização Hostil significa que o modelo deixa escapar aproximadamente quatro em cada dez itens desta categoria e que cerca de metade dos seus alertas desta categoria são falsos positivos. Estes valores são incompatíveis com qualquer uso automático das classificações e sustentam o desenho do sistema como ferramenta de triagem com revisão humana obrigatória (Secção 4.8).

4.5 Análises de robustez

4.5.1 Variabilidade entre sementes, ensemble e ablações

Para avaliar a estabilidade do resultado do BERTimbau, repetiu-se o ajuste fino com três sementes aleatórias (42, 43 e 44) e testaram-se três variantes: a média das probabilidades das três sementes (*ensemble*), o treino sem o lote enriquecido por selecção temática de vídeos (ablação) e pesos de classe suavizados (expoente 0,5 sobre o inverso da frequência). A Tabela 4.5 reúne os resultados.

Tabela 4.5 – Variantes do BERTimbau: validação, teste e comparação com a referência

Variante	F1-macro validação	p vs. referência (validação)	F1-macro teste [IC 95%]	F1 Mobil. (teste)	p vs. referência (teste)
Referência (semente 42)	0,814	—	0,807 [0,774; 0,838]	0,549	—
Semente 43	0,811	0,721	0,785 [0,752; 0,816]	0,472	0,059
Semente 44	0,816	0,181	0,801 [0,769; 0,830]	0,549	0,002
Ensemble (média das 3 sementes)	0,820	0,824	0,807 [0,775; 0,836]	0,545	0,520
Sem lote de vídeos temáticos	0,815	0,506	0,799 [0,765; 0,830]	0,529	0,406
Pesos de classe suavizados (0,5)	0,826	0,219	0,799 [0,761; 0,832]	0,518	0,718

Nota. Média ± desvio-padrão do F1-macro de teste nas três sementes: 0,797 ± 0,011. Valores de p do teste de McNemar, sem correcção para comparações múltiplas; a decisão usa apenas os da validação.

O F1-macro de teste varia entre 0,785 e 0,807 consoante a semente, com média de 0,797 ± 0,011. A semente 42 é a configuração de referência, definida antes das restantes execuções, mas é também a que obteve o valor de teste mais elevado; por isso, a média das três sementes (0,797) constitui a estimativa mais representativa do desempenho esperado do BERTimbau neste protocolo. A variabilidade concentra-se na Mobilização Hostil, cujo F1 oscila entre 0,472 e 0,549. As sementes 42 e 44 diferem significativamente nos itens que acertam ($p = 0,002$), apesar de F1-macro e F1 de Mobilização Hostil semelhantes: modelos com desempenho agregado equivalente tomam decisões individuais diferentes, o que reforça a necessidade de revisão humana item a item.

Na validação, onde o critério da Secção 3.7 manda decidir, nenhuma variante nem nenhuma semente se distingue da referência (McNemar, $p \geq 0,18$), pelo que se manteve a configuração de referência. A variante com pesos suavizados obteve o melhor F1-macro de validação (0,826), sem diferença significativa nos acertos, e no teste ficou em 0,799, com F1 de Mobilização Hostil inferior (0,518). Os valores de teste apresentam-se apenas para informação: também aí nenhuma das três variantes se

distingue da referência (p > 0,40). A ablação do lote de vídeos temáticos reduziu o F1-macro de 0,807 para 0,799 e o F1 de Mobilização Hostil de 0,549 para 0,529, diferenças que não são estatisticamente distinguíveis (p = 0,41): o contributo desse lote existe na direcção esperada, mas não é demonstrável com a dimensão actual do teste.

O modelo usado no protótipo do sistema (Secção 3.8) resulta de um novo treino com a configuração de referência, porque os pesos da corrida original não foram guardados. A divisão dos dados foi reconstruída e verificada item a item: as etiquetas de validação e de teste coincidem integralmente com as da corrida de referência. O novo modelo obteve F1-macro de 0,808 (IC 95% [0,773; 0,839]), contra 0,807 na referência; a diferença (0,1 p.p., IC 95% [-1,5; 1,8]) não é significativa (McNemar, p = 0,41), e os dois modelos dão a mesma previsão em 97,4% dos itens de teste. Os resultados deste capítulo referem-se à corrida de referência; o modelo do protótipo é, para efeitos práticos, equivalente.

4.5.2 Ajuste de limiares de decisão

Avaliou-se também o ajuste de vieses por classe sobre as pontuações de cada modelo (log-probabilidades nos modelos probabilísticos; pontuações de decisão no SVM), escolhidos no conjunto de validação. Como os vieses são escolhidos nos mesmos dados em que se medem, o ganho na validação é optimista; por isso, estimou-se o ganho esperado por validação cruzada dentro do conjunto de validação e confirmou-se no teste (Tabela 4.6).

Tabela 4.6 – Efeito do ajuste de limiares no F1-macro

Modelo	Ganho esperado (VC), p.p.	F1-macro teste (sem → com)	Δ teste, p.p. [IC 95%]	Decisão
BERTimbau	-1,2 ± 0,6	0,807 → 0,799	-0,7 [-1,9; 0,3]	Não aplicar
Bi-LSTM	+1,7 ± 0,7	0,660 → 0,655	-0,5 [-3,1; 1,8]	Não aplicar
Floresta Aleatória	-1,3 ± 0,6	0,659 → 0,648	-1,1 [-1,9; -0,4]	Não aplicar
SVM	+3,5 ± 0,7	0,632 → 0,664	+3,2 [0,0; 5,9]	Análise de sensibilidade

Nota. VC: validação cruzada dentro do conjunto de validação (média ± desvio-padrão). Δ teste: diferença no conjunto de teste com IC 95% por *bootstrap* emparelhado.

O ajuste não melhora o BERTimbau nem a Floresta Aleatória: o ganho esperado é negativo e confirma-se no teste. No Bi-LSTM, o ganho esperado positivo não se confirma no teste (IC inclui o zero). Apenas o SVM beneficia, e de forma marginal (+3,2 p.p., IC [0,0; 5,9]), passando para F1-macro de 0,664, valor que não altera a ordenação dos modelos. Por coerência, todas as tabelas deste capítulo reportam os modelos sem ajuste, e o valor ajustado do SVM é tratado apenas como análise de sensibilidade.

4.6 Lacuna de domínio: piloto angolano e corpus público (Hipótese H4)

Conforme a formulação da Secção 1.3, testa-se se o desempenho do modelo seleccionado se degrada significativamente (ΔF1-macro ≥ 5 p.p.) em conteúdo angolano, comparando o subconjunto de teste proveniente do piloto angolano com o subconjunto proveniente dos corpora públicos. A Tabela 4.7 e a Figura 4.3 apresentam os resultados do BERTimbau em cada subconjunto.

Tabela 4.7 – Desempenho do BERTimbau no piloto angolano e no corpus público

Subconjunto	n	Cl.	F1-macro [IC 95%]	κ	F1 Norm.	F1 Desinf.	F1 Ódio	F1 Mobil.
Piloto angolano	355	4	0,533 [0,470; 0,592]	0,436	0,825	0,235	0,518	0,554
Corpus público	3.632	3	0,919 [0,908; 0,929]	0,879	0,963	0,992	0,802	—

Nota. Δ F1-macro (público − piloto) = 38,6 p.p. O corpus público não contém itens de Mobilização Hostil, pelo que o seu F1-macro é calculado sobre três classes.

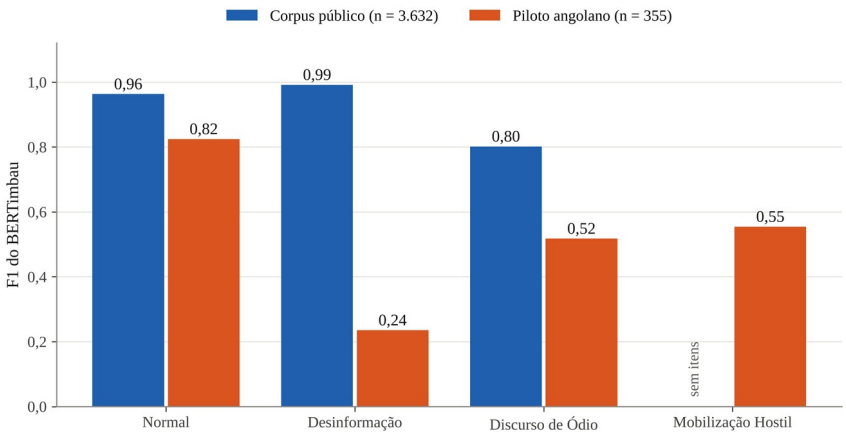


Figura 4.3 – F1 por categoria do BERTimbau no corpus público e no piloto angolano (conjunto de teste)

No piloto angolano, o BERTimbau obteve F1-macro de 0,533 (IC 95% [0,470; 0,592]) e κ de 0,436, contra 0,919 (IC 95% [0,908; 0,929]) e κ de 0,879 no corpus público. A diferença, de 38,6 p.p., excede largamente o limiar de 5 p.p. e os intervalos de confiança não se sobrepõem.

A comparação tem um factor de confusão evidente: a Mobilização Hostil, a categoria mais difícil, existe apenas no piloto, e o F1-macro do corpus público é calculado sobre três classes. Para reduzir este efeito, considerou-se no piloto apenas a média do F1 das três categorias comuns, que é de aproximadamente 0,53. A diferença mantém-se na mesma ordem de grandeza (cerca de 39 p.p.), pelo que a degradação não se explica pela composição das classes. Esta média é calculada sobre as previsões do problema de quatro classes e não tem intervalo de confiança; uma comparação refeita sem a Mobilização Hostil fica por fazer. Note-se ainda que o κ do modelo no piloto

(0,436) fica bem abaixo do acordo entre anotadores (0,718), que funciona como tecto prático.

O resultado mais revelador é o da Desinformação: F1 de 0,992 no corpus público e de 0,235 no piloto. Nos corpora públicos, toda a Desinformação provém do Fake.br, constituído por notícias completas, enquanto o piloto contém sobretudo comentários curtos. A combinação de um desempenho quase perfeito no domínio de origem com um desempenho muito baixo no domínio angolano é um indício forte de que o modelo aprendeu sobretudo marcas de estilo e de formato do Fake.br (registo jornalístico, extensão, estrutura) e não propriedades da desinformação enquanto tal. O mesmo mecanismo pode afectar, em menor grau, o Discurso de Ódio (0,802 contra 0,518), cujos exemplos públicos provêm de comentários do Instagram e do Twitter brasileiros. Por isso, o F1 global de 0,807 e, em particular, o F1 de 0,947 na Desinformação sobrestimam o desempenho que o sistema terá em conteúdo angolano; a estimativa realista para este domínio é a do piloto (F1-macro de 0,533).

Duas limitações condicionam este teste. O subconjunto do piloto é pequeno (n = 355), o que alarga o intervalo de confiança, e o desenho não permite separar as diferentes componentes da lacuna de domínio: variedade linguística (calão urbano, empréstimos de línguas nacionais), plataforma (comentários de YouTube contra notícias, Instagram e Twitter) e registo. A caracterização do piloto (Secção 3.4) sugere, aliás, que o calão é um factor menor: apenas uma fracção muito pequena dos comentários contém termos de calão de uma lista ilustrativa, pelo que a diferença virá sobretudo dos temas, das referências e da forma de argumentar. A H4 confirma, por isso, a existência de uma lacuna de domínio substancial, mas não atribui essa lacuna especificamente ao calão ou às línguas nacionais.

4.7 Qualidade das probabilidades e utilidade da ordenação

O sistema mostra as probabilidades do modelo ao analista e ordena a fila pela prioridade 1 − P(Normal) (Secção 3.8.3). Esta secção analisa, no conjunto de teste, se as probabilidades merecem a confiança que exprimem e quanto trabalho a ordenação poupa, para o BERTimbau, o Bi-LSTM e a Floresta Aleatória (o SVM linear não produz probabilidades). Como 91% do teste é brasileiro e 28,7% dos itens são ameaças, proporção muito superior à de um fluxo real, os valores são um limite superior do que o sistema fará em conteúdo angolano. A análise não foi repetida no subconjunto angolano (n = 355), verificação que se recomenda no Capítulo 5.

4.7.1 Calibração das probabilidades

A Tabela 4.8 apresenta, para cada modelo, a confiança média da categoria prevista, a exactidão, o erro de calibração esperado (ECE, calculado com 15 intervalos) e o índice de Brier, juntamente com as medidas de ordenação usadas na secção seguinte.

Tabela 4.8 – Calibração e ordenação no conjunto de teste

Medida	BERTimbau	Bi-LSTM	F. Aleatória
Confiança média da categoria prevista	0,962	0,922	0,757
Exactidão	0,924	0,819	0,834
ECE (menor é melhor)	**0,039**	0,106	0,083
Índice de Brier (menor é melhor)	**0,125**	0,297	0,262
AUC-ROC ameaça contra Normal	**0,977**	0,882	0,876
Precisão média (AP) da ordenação	**0,954**	0,788	0,782
Precisão nos primeiros 50 / 100 / 500	1,00 / 1,00 / 1,00	0,94 / 0,94 / 0,89	0,86 / 0,92 / 0,94
Fila revista para encontrar 80% das ameaças	24,7%	36,9%	36,2%
Fila revista para encontrar 95% das ameaças	37,3%	67,3%	73,8%

Nota. n = 3.987, dos quais 1.144 ameaças (28,7%). Ordenação pela prioridade 1 − P(Normal), como no sistema. ECE com 15 intervalos de igual amplitude sobre a confiança da categoria prevista.

O BERTimbau é o modelo mais bem calibrado (ECE de 0,039), mas é ligeiramente confiante em excesso: a confiança média, de 0,962, excede a exactidão, de 0,924, em cerca de 4 pontos percentuais. A diferença concentra-se nas previsões de confiança intermédia. Dois terços das previsões (67%) têm confiança de pelo menos 0,99, e destas 99% estão certas; já nas cerca de 10% de previsões com confiança entre 0,5 e 0,9, a confiança média é de 0,75 e só 64% estão certas. O Bi-LSTM é bastante mais confiante do que justificam os seus acertos (confiança de 0,922 para uma exactidão de 0,819), e a Floresta Aleatória, ao contrário, é pouco confiante (0,757 para 0,834), o que é habitual em métodos que fazem a média de muitas árvores (Niculescu-Mizil & Caruana, 2005).

Para o analista, uma percentagem muito alta do BERTimbau é, no conteúdo do teste, uma estimativa razoável, e uma intermédia sobrestima a probabilidade de acerto. Em conteúdo angolano, onde o modelo acerta menos (Secção 4.6), a sobrestimação será maior. O escalamento por temperatura corrige-a com um único parâmetro ajustado num conjunto de validação (Guo et al., 2017), que, para ser útil, teria de ser angolano.

4.7.2 Ordenação da fila de revisão

A Figura 4.4 mostra a curva de esforço de cada modelo: a fracção das 1.144 ameaças do teste que um analista encontraria ao rever a fila por ordem de prioridade.

Com o BERTimbau, revendo 25% da fila encontram-se 80% das ameaças, muito perto do ideal (23%, que corresponderia a ter todas as ameaças no topo); para chegar a 95%, basta rever 37%. Com o Bi-LSTM e a Floresta Aleatória, os mesmos 95% exigem rever 67% e 74% da fila. Os primeiros 500 itens da fila do BERTimbau são todos ameaças, contra 89% no Bi-LSTM e 94% na Floresta Aleatória.

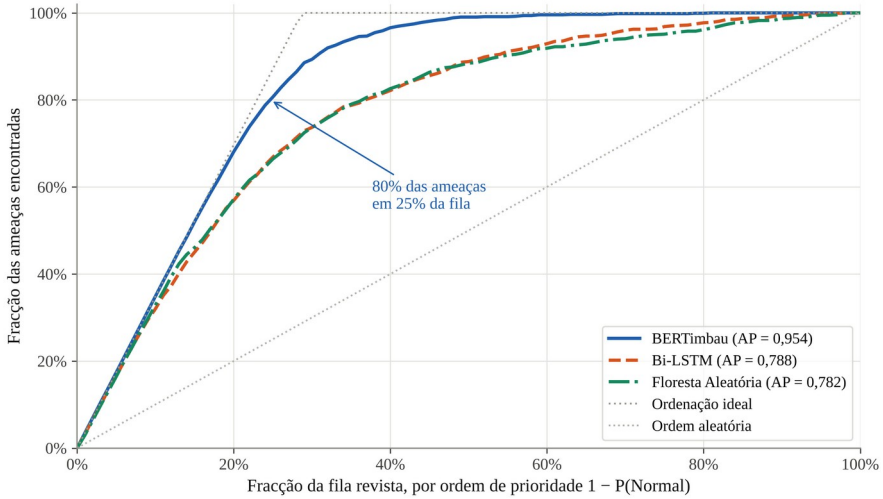


Figura 4.4 – Curva de esforço de revisão: ameaças encontradas em função da fila revista

Este resultado global esconde, no entanto, um desequilíbrio entre categorias. Os primeiros 500 itens da fila do BERTimbau são todos de Desinformação, e a mediana da posição dos 47 itens de Mobilização Hostil é a 927.ª; nenhum deles aparece nos primeiros 10% da fila. A explicação está na Secção 4.6: as notícias do Fake.br são classificadas com probabilidade quase nula de serem Normais e ocupam o topo, enquanto os comentários de mobilização, mais ambíguos, recebem prioridades mais moderadas. Num fluxo angolano real não haverá notícias do Fake.br, mas o mecanismo mantém-se: a categoria em que o modelo é mais confiante ocupa o topo da fila, e essa não é necessariamente a mais grave nem aquela em que o modelo é mais fiável.

O filtro por categoria da fila já permite contornar este efeito. Ordenar cada categoria pela sua própria probabilidade seria mais directo: os 47 itens com maior probabilidade de Mobilização Hostil contêm 25 dos 47 casos reais, e os primeiros 100 contêm 32. Filas por categoria, ou uma prioridade ponderada pela gravidade, são uma melhoria natural do sistema (Capítulo 5).

Por fim, a fila mostra por omissão apenas os itens não classificados como Normais. Entre os 2.840 itens que o BERTimbau classificou como Normais estão 135 ameaças (11,8% do total: 104 de Discurso de Ódio, 19 de Desinformação e 12 de Mobilização Hostil); mesmo entre os 1.885 com P(Normal) de pelo menos 0,99 há 10

ameaças (0,5%; IC 95% de Wilson de 0,3% a 1,0%). Em grande volume, são muitos os casos que nenhum analista verá se se limitar a rever a fila, e em conteúdo angolano a fracção será previsivelmente maior. É isto que justifica a amostra de controlo (Secção 3.8.5), cujos itens são também os mais úteis para novos ciclos de treino.

4.8 Avaliação operacional do sistema (Hipóteses H2 e H3)

As Hipóteses H2 (processamento de cada publicação em menos de 60 segundos) e H3 (antecedência de pelo menos 48 horas em relação a eventos de segurança) referem-se ao sistema em operação e não ao classificador. A H2 foi medida com o protótipo e o modelo do sistema; a H3 não pôde ser testada.

4.8.1 Tempo de processamento (H2)

A medição seguiu o protocolo da Secção 3.9. O comando de medição importou, anonimizou e classificou um lote de 200 comentários reais da base do piloto, numa base de dados temporária nova em cada repetição; 2 comentários foram descartados na importação por terem menos de três caracteres, restando 198. Repetiu-se o ensaio 3 vezes num computador pessoal, sem GPU, com processador Intel N100 (quatro núcleos, de baixo consumo) e 8 GB de memória RAM. Trata-se de equipamento modesto, pelo que os tempos obtidos tendem a ser conservadores face a um servidor de produção. A Tabela 4.9 resume os resultados.

Tabela 4.9 – Tempo de processamento do protótipo com o modelo do sistema

Medida	Gravação no fim do lote	Gravação por sublotes de 32
Publicações por lote	198	198
Repetições	3	3
Tempo total por lote (mediana)	125,5 s	139,7 s
Tempo médio por publicação	0,63 s	0,71 s
Primeiras publicações na fila	125,5 s (todas no fim)	36,1 s
Intervalo entre sublotes	—	cerca de 20 s
Lote máximo com todas as publicações em menos de 60 s	cerca de 94	cerca de 64

Nota. O tempo inclui a leitura do ficheiro, a anonimização, a gravação na base de dados e a classificação com o BERTimbau (até 256 subpalavras, lotes de inferência de 32). Não inclui o carregamento inicial do modelo, que ocorre uma vez no arranque do serviço, nem o intervalo entre a publicação original e a sua recolha.

O custo por publicação, de cerca de 0,63 segundos, está muito abaixo do limiar de 60 segundos. Com a gravação das classificações no fim do lote, porém, todas as publicações entravam na fila ao mesmo tempo, e a primeira só ficava disponível ao fim de cerca de 125 segundos; o critério só era cumprido para lotes até cerca de 94

publicações. O sistema passou por isso a gravar por sublotes de 32 publicações (Secção 3.8.3), e repetiu-se a medição no mesmo computador e com o mesmo lote (três repetições). As primeiras 32 publicações ficaram disponíveis em 36,1 segundos (mediana), e cada sublote seguinte chegou cerca de 20 segundos depois; o lote completo demorou 139,7 segundos (0,71 s por publicação, um pouco mais porque a aplicação web corria em simultâneo; Tabela 4.9, coluna da direita). Com recolhas de até cerca de 64 publicações, todas ficam disponíveis em menos de 60 segundos. A medição cobre o processamento interno, não o intervalo entre a publicação na plataforma e a recolha, que, com recolhas periódicas de 15 minutos ou mais, é a parcela dominante do atraso. A H2 confirma-se, por isso, apenas para recolhas até cerca de 64 publicações.

4.8.2 Antecedência de detecção (H3)

A H3 exige um corpus com datas de publicação, dividido cronologicamente (treino anterior ao período de teste), e um conjunto de eventos de referência independentes do corpus; sem estes elementos, qualquer medida de antecedência seria circular. Como o corpus desta investigação não foi construído em torno de eventos datados, a H3 fica por testar.

4.8.3 Implicações para o desenho operacional

Os resultados das Secções 4.4 a 4.6 têm, no entanto, consequências directas para o desenho operacional. Com precisão de 0,509 e sensibilidade de 0,596 na Mobilização Hostil, e com desempenho em conteúdo angolano inferior ao global, o sistema só é defensável como apoio ao analista: uma fila de revisão ordenada pela confiança do modelo, com confirmação humana obrigatória antes de qualquer acção e sem decisões automáticas sobre indivíduos. Neste enquadramento, as métricas operacionais relevantes passam a ser a precisão nos primeiros K itens da fila, o tempo de processamento e a concordância entre analista e sistema, medidas que o protótipo foi concebido para registar (Secção 3.9). A análise da Secção 4.7 antecipa, no conjunto de teste, duas destas medidas: a ordenação concentra as ameaças no início da fila, mas de forma desigual entre categorias, e uma fracção pequena mas não nula das ameaças fica entre os itens que o modelo considera normais.

4.8.4 Verificação funcional do sistema

Os 121 testes automáticos descritos na Secção 3.9 verificaram o funcionamento do sistema e passaram todos na versão final do protótipo, numa execução de cerca de 40 segundos: 14 do núcleo de dados e do modelo, 17 da recolha, 21 dos alertas, do mapa e do relatório, 17 do controlo de acesso, 36 da interface do analista e 16 da gestão

de contas. Os testes que envolvem rede usam clientes e sítios simulados localmente. Verificam que o sistema faz o que foi especificado, mas não substituem a avaliação com analistas, que dirá se o que foi especificado é útil.

4.9 Discussão e verificação formal das hipóteses

A Tabela 4.10 sintetiza a verificação das quatro hipóteses face aos critérios definidos na Secção 1.3.

Tabela 4.10 – Verificação formal das hipóteses de investigação

Hipótese e critério	Evidência	Decisão
H1. Modelos profundos superam os clássicos ($\Delta F1 \geq 5$ p.p.; $p < 0{,}05$ com Bonferroni)	BERTimbau: $\Delta F1$ de 14,6 a 17,4 p.p., $p < 10^{-47}$. Bi-LSTM: $\Delta F1$ de 0,2 e 2,8 p.p. (IC incluem 0)	**Parcialmente confirmada**
H2. Processamento de cada publicação em menos de 60 s	0,63 s por publicação em CPU; com sublotes, primeiras publicações na fila em 36 s; todas em menos de 60 s para recolhas até cerca de 64 publicações; não cumprido para lotes maiores	**Confirmada com condições**
H3. Antecedência ≥ 48 h face a eventos	Sem corpus datado nem divisão cronológica	**Não testada**
H4. Degradação ≥ 5 p.p. em conteúdo angolano	$\Delta F1$-macro = 38,6 p.p.; IC sem sobreposição; κ 0,436 contra 0,879	**Confirmada** (com reservas)

Nota. A designação «não testada» significa que os dados disponíveis não permitem confirmar nem rejeitar a hipótese.

H1: parcialmente confirmada. A hipótese previa que ambos os modelos de aprendizagem profunda superassem os clássicos. O BERTimbau cumpre o critério com margem ampla ($\Delta F1$-macro ≥ 14,6 p.p.; p corrigido < 10^{-47}). O Bi-LSTM não o cumpre: não se distingue da Floresta Aleatória e a sua vantagem sobre o SVM (2,8 p.p.) fica abaixo do limiar de 5 p.p., com intervalo que inclui o zero. A explicação mais plausível é o pré-treino: o BERTimbau parte de representações aprendidas num grande corpus de português, ao passo que o Bi-LSTM as aprende apenas com o corpus de treino.

H2: confirmada com condições. O protótipo processa cada publicação em cerca de 0,63 segundos sem GPU; com a gravação por sublotes, as primeiras publicações chegam à fila em 36 segundos e todas em menos de 60 segundos para recolhas até cerca de 64 publicações; para lotes maiores, o critério não é cumprido. A medição cobre o processamento interno, não o intervalo até à recolha.

H3: não testada. A verificação exige um corpus datado em torno de eventos documentados, que não existe nesta fase, e constitui trabalho futuro.

H4: confirmada, com reservas. A degradação do desempenho em conteúdo angolano é grande (38,6 p.p.), que se mantém quando se exclui a Mobilização Hostil da média e é consistente no Kappa. As reservas referem-se à dimensão do subconjunto do piloto, à impossibilidade de separar os efeitos de língua, plataforma e registo, à diferença de construto entre as etiquetas do piloto e as dos corpora públicos (Secção 3.4) e ao indício de aprendizagem de atalhos de estilo na Desinformação, que os dados não permitem separar daquela diferença. Este último ponto tem uma implicação metodológica que ultrapassa a H4: corpora de desinformação constituídos por notícias completas não são adequados para treinar detectores de desinformação em comentários de redes sociais, e o desempenho nesta categoria deve ser medido em conteúdo do domínio de aplicação.

Os resultados concordam com a literatura. A vantagem do modelo pré-treinado é o padrão habitual (Souza et al., 2020), e a queda fora do domínio de treino é coerente com a fraca generalização entre conjuntos de dados descrita por Fortuna, Soler-Company e Wanner (2021). A falha na Desinformação é compatível com a aprendizagem de atalhos (Geirhos et al., 2020) e a dificuldade em separar mobilização de protesto confirma que o discurso perigoso depende de contexto que o texto não contém (Benesch, 2012). A Secção 4.7 acrescenta que, medido pela ordenação no teste, o BERTimbau poupa trabalho ao analista, concentrando quatro quintos das ameaças no primeiro quarto da fila, mas que a ordem reflecte a confiança do modelo e não a gravidade, e que uma parte das ameaças fica no fundo. A revisão cega e a amostra de controlo são as funções que permitem detectar estes problemas em operação.

Destes resultados tiram-se três conclusões. Entre os modelos avaliados, só o BERTimbau serve como classificador principal, e a sua vantagem é estatisticamente sólida. O desempenho global, com F1-macro de cerca de 0,80, foi obtido sobretudo em conteúdo brasileiro e não deve ser apresentado como desempenho do sistema em Angola, onde a estimativa disponível ronda 0,53. Por último, a Mobilização Hostil, a categoria com mais interesse para a segurança, é aquela em que a evidência é mais frágil.

CAPÍTULO 5 – CONCLUSÕES E RECOMENDAÇÕES

Esta dissertação partiu de uma pergunta: em que medida a aprendizagem automática consegue apoiar, de forma fiável e responsável, a triagem de publicações ameaçadoras nas redes sociais angolanas. Os resultados sugerem que pode ajudar a ordenar o trabalho do analista, mas não o substitui nem deve substituí-lo; essa utilidade foi medida num teste dominado por conteúdo brasileiro e, em conteúdo angolano e com analistas, está por demonstrar.

5.1 Síntese dos objectivos

A Tabela 5.1 resume o grau de cumprimento dos objectivos específicos.

Tabela 5.1 – Cumprimento dos objectivos específicos

Objectivo	Resultado	Estado
OE1. Corpus angolano anotado	2.637 publicações públicas angolanas anotadas por 3 anotadores; κ de Fleiss 0,718; proveniência registada por lote	Cumprido
OE2. Comparação de algoritmos	BERTimbau F1-macro 0,807 [0,774; 0,838]; superior aos restantes com $p < 10^{-47}$; Bi-LSTM sem vantagem sobre a Floresta Aleatória	Cumprido
OE3. Lacuna de domínio	F1-macro 0,533 no piloto contra 0,919 no corpus público (Δ 38,6 p.p.); indício de atalhos de estilo na Desinformação	Cumprido
OE4. Protótipo do sistema	Aplicação web com contas e papéis, ingestão anonimizada, base de dados auditada, classificação em segundo plano, fila por analista, revisão cega e amostra de controlo; recolha integrada do YouTube e de sítios públicos; base de dados SQLite; alertas na aplicação (actualizados a cada 20 s) e por e-mail, mapa interactivo por província com evolução semanal e relatório de alertas; ficha do modelo com o desempenho em conteúdo angolano; modo de demonstração com dados fictícios e troca de modo com o sistema aberto; recolha automática periódica com estimativa da quota; recuperação do acesso sem serviços externos e fim da sessão ao fechar a janela; aspecto ajustável por utilizador; interface própria, sem recursos externos, utilizável sem Internet; 121 testes; tempo de processamento medido (0,63 s por publicação em CPU; primeiras publicações na fila em 36 s com sublotes); avaliação com analistas por fazer	Parcialmente cumprido
OE5. Quadro ético e legal	Salvaguardas implementadas no sistema (pseudonimização, minimização, conservação, auditoria, revisão humana) e obrigações institucionais propostas (Secção 5.6); parecer jurídico recomendado	Cumprido como proposta; conformidade dependente de parecer jurídico

5.2 Resposta às hipóteses e às perguntas de investigação

A **H1** foi parcialmente confirmada. O BERTimbau superou os modelos clássicos por 14,6 a 17,4 pontos percentuais de F1-macro, com diferenças estatisticamente significativas. Já o Bi-LSTM não se distinguiu da Floresta Aleatória (ΔF1 = 0,2 p.p.), o que é compatível com a ideia de que, neste volume de dados, o factor decisivo é o pré-treino linguístico, embora o desenho não o isole. Os modelos de referência foram treinados com uma única semente.

A **H2** foi confirmada com condições. O sistema processa cada publicação em cerca de 0,6 a 0,7 segundos num computador sem GPU. Com a gravação por sublotes, as primeiras publicações de qualquer lote chegam à fila em 36 segundos, e todas chegam em menos de 60 segundos quando cada recolha traz até cerca de 64 publicações; para lotes maiores, o critério não é cumprido, e o intervalo entre a publicação e a recolha não foi medido. A **H3** não foi testada: exige um corpus datado em torno de eventos documentados, que não existe nesta fase.

A **H4** foi confirmada, com reservas. Em conteúdo angolano, o F1-macro do BERTimbau desce 38,6 pontos percentuais, e a diferença mantém-se quando se exclui a Mobilização Hostil da média. A queda na Desinformação, de 0,99 para 0,24, é compatível com a aprendizagem do estilo das notícias do Fake.br, mas também com a diferença de construto entre as etiquetas do piloto e as do Fake.br; os dados não permitem separar as duas explicações.

As perguntas de investigação têm, assim, as seguintes respostas. À **P1**: o BERTimbau é o melhor dos quatro algoritmos, com vantagem estatisticamente sólida no teste global; a comparação não foi repetida apenas em conteúdo angolano. À **P2**: perdem-se cerca de 39 pontos percentuais de F1-macro, sobretudo na Desinformação e no Discurso de Ódio. À **P3**: sim, para o processamento interno de recolhas pequenas; o intervalo até à recolha não foi medido. À **P4**: com revisão humana obrigatória, sem perfis de pessoas, com alertas apenas por decisão humana e com as obrigações institucionais da Secção 5.6; a conformidade jurídica depende de um parecer ainda por obter.

Quanto à pergunta de partida, em conteúdo angolano o classificador não é fiável como decisor (F1-macro de cerca de 0,53) e só pode apoiar a triagem como ordenador sujeito a revisão humana. A utilidade dessa ordenação para analistas reais e a responsabilidade jurídica do uso estão ainda por demonstrar.

5.3 Contributos

- **Corpus angolano anotado.** Tanto quanto foi possível apurar, é o primeiro corpus de comentários angolanos anotado para estas quatro categorias, com acordo entre anotadores medido e proveniência documentada.
- **Medida da lacuna de domínio.** A dissertação quantifica, com intervalos de confiança, quanto se perde ao aplicar a conteúdo angolano um modelo treinado sobretudo com dados brasileiros, e aponta uma causa provável (a aprendizagem de atalhos de estilo na Desinformação).
- **Avaliação com controlo estatístico.** Intervalos de confiança, testes emparelhados com correcção para comparações múltiplas, repetição com várias sementes e selecção de variantes na validação, sem escolha pelo teste. A avaliação vai além da exactidão e mede também a calibração das probabilidades e o esforço de revisão que a ordenação poupa, que são as propriedades de que depende o uso do modelo numa fila de triagem.
- **Arquitectura de triagem responsável.** Um protótipo de código aberto, testado e documentado, que incorpora a protecção de dados desde a concepção e mantém o analista no centro da decisão, adequado aos recursos disponíveis e à soberania sobre os dados. A interface mostra ao analista, na página Sobre o modelo, onde o modelo falha, em vez de lhe apresentar apenas o desempenho global.

5.4 Limitações

Dimensão e composição do corpus angolano. O piloto tem 2.637 publicações, das quais cerca de 86% são comentários do YouTube. A Mobilização Hostil conta com apenas 47 exemplos no teste, o que torna as estimativas desta categoria instáveis (IC 95% do F1 entre 0,42 e 0,66) e sensíveis à semente de treino.

Validade das etiquetas do piloto. Os anotadores aplicaram, por vezes, critérios mais amplos do que os do guia, e a regra de agregação pela categoria mais grave alarga ainda mais as categorias de ameaça. As etiquetas do piloto não são, por isso, inteiramente equivalentes às dos corpora públicos, o que pode explicar parte da lacuna medida na H4. Os modelos de referência (SVM, Floresta Aleatória e Bi-LSTM) foram treinados com uma única semente.

Predomínio de dados brasileiros. Cerca de 91% do conjunto de teste provém de corpora brasileiros. O desempenho global descreve, por isso, sobretudo conteúdo brasileiro; a estimativa disponível para Angola é a do piloto (F1-macro de cerca de 0,53), baseada em 355 itens.

Desinformação. A única fonte pública de desinformação são notícias completas, um género muito diferente dos comentários. O valor elevado desta categoria no teste global não deve ser interpretado como capacidade de detectar desinformação em redes sociais.

Variação linguística. O corpus não tem marcação de calão ou de línguas nacionais, pelo que não é possível separar o efeito da variedade linguística do efeito da plataforma e do registo. Textos integralmente em kimbundu, kikongo, umbundu ou tchokwe ficam fora do alcance do sistema.

Avaliação operacional. Mediu-se o tempo de processamento num único computador, com um único lote, e não inclui o intervalo entre a publicação e a sua recolha. A utilidade da fila para analistas reais e a capacidade de antecipação não foram medidas. O protótipo funciona e está testado, mas a sua eficácia operacional está por demonstrar.

Probabilidades e ordenação. A calibração e a curva de esforço foram medidas num teste dominado por conteúdo brasileiro. Em conteúdo angolano, a sobrestimação da confiança e a fracção de ameaças que ficam entre os itens Normais serão previsivelmente maiores. A ordenação pela probabilidade de não ser Normal favorece a categoria em que o modelo é mais confiante, o que, no teste, afastou a Mobilização Hostil do topo da fila.

Localização. O mapa e os alertas por província usam o lugar mencionado nas publicações, não a localização de quem as escreveu. Uma província muito citada em notícias nacionais pode aparecer com mais ameaças do que aquelas que nela ocorrem, e as publicações sem lugar mencionado ficam fora do mapa. A lista de topónimos deixa de fora nomes ambíguos, o que reduz os falsos positivos à custa de alguma cobertura. No corpus anotado, só 3,6% das publicações mencionam uma província (65 delas Luanda); o mapa e os alertas provinciais cobrem, por isso, uma fracção pequena do fluxo e exigirão volumes de recolha elevados.

Segurança do protótipo. O sistema segue práticas reconhecidas de autenticação e de protecção das aplicações web, mas não foi objecto de uma auditoria de segurança independente nem de testes de intrusão. Em instalação institucional, deve ser servido por HTTPS e o acesso ao servidor deve ser restringido à rede interna.

Fronteira entre protesto e mobilização hostil. Esta fronteira é ambígua mesmo para anotadores humanos. Nenhum resultado desta dissertação autoriza o uso do sistema para fundamentar acções sobre pessoas sem revisão humana e sem enquadramento jurídico.

5.5 Implicações para a defesa e segurança nacional

Para as estruturas de defesa e segurança, os resultados têm três implicações práticas. A automação reduz o volume de leitura, mas não a dispensa: no teste, rever um quarto da fila bastou para encontrar quatro em cada cinco ameaças, mas este valor depende da proporção de ameaças (28,7% no teste) e não se transpõe para um fluxo real, onde essa proporção é muito menor. Só a avaliação com analistas permitirá dimensionar as equipas. O sistema dirige a atenção para temas e lugares e não tem vistas por autor, embora o pseudónimo permita, a quem aceda à base de dados, agrupar publicações do mesmo autor; as obrigações institucionais da Secção 5.6 existem para impedir esse uso. E a capacidade técnica pode ser desenvolvida internamente, com software livre e recursos modestos, desde que se invista em dados angolanos anotados e em pessoas que os produzam e mantenham o sistema.

5.6 Quadro de uso responsável

O quinto objectivo específico pedia um quadro de uso responsável do sistema. As salvaguardas técnicas estão implementadas no protótipo, mas um sistema deste tipo só é responsável se a instituição que o usa assumir também obrigações que o software não pode impor. A Tabela 5.2 junta as duas partes, organizadas pelos princípios revistos no Capítulo 2.

Tabela 5.2 – Quadro de uso responsável: salvaguardas do sistema e obrigações institucionais

Princípio	Salvaguarda no sistema	Obrigação da instituição
Finalidade e necessidade	Recolha apenas de fontes registadas e públicas; registo da proveniência de cada lote	Definir por escrito a finalidade, os temas e as fontes autorizadas; rever a lista periodicamente
Proporcionalidade e minimização	Anonimização à entrada; sem vistas por autor; localização apenas ao nível da província; prazo de conservação	Não cruzar os dados com outras bases para identificar autores sem autorização judicial
Decisão humana	Classificação apenas para ordenar; decisões e alertas só por analistas; revisão cega e amostra de controlo	Proibir qualquer acção sobre pessoas fundamentada apenas no sistema; formar os analistas nas limitações do modelo
Transparência	Ficha do modelo com o desempenho em Angola e as limitações; probabilidades visíveis	Publicar a existência do sistema, a sua finalidade e as regras de uso, nos termos que a lei permitir
Responsabilização	Contas individuais; auditoria de todas as acções; fim da sessão ao fechar a janela	Designar um responsável pelo tratamento; auditoria independente anual dos registos
Segurança	Palavras-passe derivadas, bloqueio, recuperação sem serviços externos, funcionamento sem Internet	Servidor próprio em rede interna, HTTPS, cópias de segurança cifradas, testes de intrusão
Melhoria e correcção	Exportação das decisões para novo treino; métricas operacionais	Medir o desempenho em conteúdo angolano em cada versão; retirar o modelo se o desempenho cair

A coluna da direita não é opcional. Sem ela, as salvaguardas do sistema podem ser contornadas por quem tem acesso ao servidor, e a revisão humana pode tornar-se uma formalidade. O parecer jurídico recomendado em seguida deve, por isso, incidir tanto sobre o sistema como sobre estas obrigações.

5.7 Recomendações e trabalho futuro

As recomendações estão ordenadas por prioridade. As três primeiras são condições para qualquer uso institucional.

1. Avaliar o sistema com analistas. Aplicar o protocolo da Secção 3.9 a um lote novo, com analistas: precisão nos primeiros K itens, κ analista–sistema e sensibilidade estimada numa amostra aleatória dos itens classificados como Normal. O sistema já tem as funções necessárias (revisão cega, fila independente por analista e amostra de controlo). Em paralelo, repetir a medição da H2 em equipamento de produção, com recolhas agendadas e pequenas, e calcular a calibração, a curva de esforço e o F1 por origem (comentários e títulos de notícias) no subconjunto angolano.

2. Obter parecer jurídico. Antes de qualquer integração institucional, obter parecer sobre a recolha de conteúdos públicos à luz da Lei n.º 22/11, da Lei n.º 7/17 e dos termos de utilização das plataformas, e sobre os limites constitucionais à monitorização de publicações de cidadãos.

3. Ampliar o corpus angolano e medir sempre em Angola. Aumentar o número de exemplos anotados, em especial de Mobilização Hostil e de Desinformação em comentários, e diversificar as plataformas por vias oficiais. O desempenho em conteúdo angolano deve passar a ser a métrica principal do sistema.

4. Substituir a fonte de desinformação. Construir ou adoptar exemplos de desinformação em formato de publicação curta, de preferência angolanos, para evitar que o modelo aprenda o estilo jornalístico em vez do fenómeno.

5. Adaptar o modelo ao domínio. Continuar o pré-treino do BERTimbau com comentários angolanos não anotados, quando houver um volume suficiente (da ordem das dezenas de milhares de textos), seguindo Gururangan et al. (2020). Em paralelo, comparar com um modelo pré-treinado em português europeu, como o Albertina PT-PT (Rodrigues et al., 2023), cuja norma escrita está mais próxima da usada em Angola.

6. Melhorar a fila de revisão. Ordenar cada categoria pela sua própria probabilidade, ou ponderar a prioridade pela gravidade da categoria, para que a Mobilização Hostil não fique atrás das categorias em que o modelo é mais confiante;

calibrar as probabilidades por escalamento de temperatura num conjunto de validação angolano; mostrar na fila também os itens previstos como Normais com prioridade acima de um limiar escolhido na validação; e usar as decisões da amostra de controlo como exemplos prioritários de novos ciclos de treino, na lógica da aprendizagem activa (Settles, 2009).

7. Marcar a variedade linguística. Acrescentar ao guia de anotação a marcação de calão e de línguas nacionais, para permitir medir separadamente o seu efeito, e envolver linguistas na construção de recursos para as línguas nacionais.

8. Validar a antecipação (H3). Constituir um corpus datado em torno de eventos documentados, com divisão cronológica estrita, e verificar se os alertas de tendência do sistema surgem antes desses eventos; acrescentar métricas de análise de redes para detectar publicação coordenada.

9. Cooperação e enquadramento normativo. Partilhar recursos e metodologias com instituições do espaço da CPLP que enfrentam problemas semelhantes, e contribuir para um enquadramento nacional sobre o uso de inteligência artificial em segurança, com requisitos de transparência, auditoria e supervisão humana.

5.8 Considerações finais

Os resultados mostram que um modelo de linguagem pré-treinado em português supera com folga os métodos clássicos, mas também que esse desempenho não se transfere intacto para o conteúdo angolano. Esta segunda conclusão é talvez a mais útil, porque indica onde investir: em dados angolanos anotados, em avaliação no domínio real e em sistemas que tratem a classificação como uma sugestão e não como um veredicto. O protótipo desenvolvido segue esse princípio e fica disponível como base para as fases seguintes.

Há ainda uma lição de engenharia. Várias funções do sistema, como a recuperação do acesso sem serviços externos ou o fim da sessão ao fechar a janela, nasceram de dificuldades encontradas ao instalar e usar o protótipo. Um sistema destinado a uma instituição só fica completo quando é usado por quem o vai operar.

REFERÊNCIAS BIBLIOGRÁFICAS

AFRIPOL. (2023). *African cyberthreat assessment report*. African Union Mechanism for Police Cooperation; INTERPOL.

Amershi, S., Cakmak, M., Knox, W. B., & Kulesza, T. (2014). Power to the people: The role of humans in interactive machine learning. *AI Magazine, 35*(4), 105–120. https://doi.org/10.1609/aimag.v35i4.2513

Benesch, S. (2012). *Dangerous speech: A proposal to prevent group violence*. World Policy Institute.

Boyd, D. M., & Ellison, N. B. (2007). Social network sites: Definition, history, and scholarship. *Journal of Computer-Mediated Communication, 13*(1), 210–230. https://doi.org/10.1111/j.1083-6101.2007.00393.x

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review, 78*(1), 1–3. https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2

Castells, M. (2013). *Redes de indignação e esperança: Movimentos sociais na era da Internet*. Zahar.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research, 16*, 321–357. https://doi.org/10.1613/jair.953

Cintra, E. S. (2025). *Desafios midiáticos digitais contemporâneos: Um estudo da ciência das redes como contribuição ao Ministério da Defesa do Brasil sobre as aplicações do terrorismo peer-to-peer* [Dissertação de mestrado, Escola Superior de Guerra].

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement, 20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., & Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 8440–8451). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.acl-main.747

Conselho da Europa. (2022). *Recomendação CM/Rec(2022)16 do Comité de Ministros aos Estados-membros sobre o combate ao discurso de ódio*. Conselho da Europa.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning, 20*(3), 273–297. https://doi.org/10.1007/BF00994018

Davidson, T., Warmsley, D., Macy, M., & Weber, I. (2017). Automated hate speech detection and the problem of offensive language. In *Proceedings of the Eleventh International AAAI Conference on Web and Social Media* (pp. 512–515). AAAI Press.

Defense Advanced Research Projects Agency. (2016). *Media forensics (MediFor)*. U.S. Department of Defense. https://www.darpa.mil/research/programs/media-forensics

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). *BERT: Pre-training of deep bidirectional transformers for language understanding* (arXiv:1810.04805). arXiv. https://arxiv.org/abs/1810.04805

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation, 10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Elias, L. (2019). O terrorismo transnacional contemporâneo: Segurança, justiça e cooperação. *Nação e Defesa, 152*, 78–112.

EU DisinfoLab. (2020). *Methodologies for mapping disinformation networks and social network analysis*. EU DisinfoLab. https://www.disinfo.eu/

EU DisinfoLab. (2021). *Indian chronicles: Deep dive into a 15-year operation targeting the EU and UN*. EU DisinfoLab.

Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin, 76*(5), 378–382. https://doi.org/10.1037/h0031619

Fortuna, P., & Nunes, S. (2018). A survey on automatic detection of hate speech in text. *ACM Computing Surveys, 51*(4), Artigo 85. https://doi.org/10.1145/3232676

Fortuna, P., Soler-Company, J., & Wanner, L. (2021). How well do hate speech, toxicity, abusive and offensive language classification models generalize across datasets? *Information Processing & Management, 58*(3), Artigo 102524. https://doi.org/10.1016/j.ipm.2021.102524

Freire, C. P. (2015). *Método de monitoramento de redes sociais: Epistemologia, técnicas e propostas de mineração de banco de dados para conteúdos gerados por fãs de telenovela em redes sociais* [Tese de doutoramento, Universidade de São Paulo].

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence, 2*(11), 665–673. https://doi.org/10.1038/s42256-020-00257-z

Grassi, P. A., Fenton, J. L., Newton, E. M., Perlner, R. A., Regenscheid, A. R., Burr, W. E., Richer, J. P., Lefkovitz, N. B., Danker, J. M., Choong, Y.-Y., Greene, K. K., & Theofanos, M. F. (2017). *Digital identity guidelines: Authentication and lifecycle management* (NIST Special Publication 800-63B). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.800-63b

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning* (pp. 1321–1330). PMLR.

Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., & Smith, N. A. (2020). Don't stop pretraining: Adapt language models to domains and tasks. In *Proceedings of the 58th Annual Meeting of the Association for*

Computational Linguistics (pp. 8342–8360). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.acl-main.740

Hassane, A. C. J. (2021). 2022 vais gostar: A onda de manifestações da juventude em Angola. *Revista Relações Internacionais e Diplomacia em Análise, 2*(3), 28–40.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. In C. Nédellec & C. Rouveirol (Eds.), *Machine Learning: ECML-98* (pp. 137–142). Springer. https://doi.org/10.1007/BFb0026683

Kemp, S. (2025). *Digital 2026: Angola*. DataReportal. https://datareportal.com/reports/digital-2026-angola

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics, 33*(1), 159–174. https://doi.org/10.2307/2529310

Leite, J. A., Silva, D., Bontcheva, K., & Scarton, C. (2020). Toxic language detection in social media for Brazilian Portuguese: New dataset and multilingual analysis. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing* (pp. 914–924). Association for Computational Linguistics.

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

Marcon, F. (2019). Agências estetizadas: Juventudes, mobilizações e ativismos em Angola. *Crítica e Sociedade, 9*(2). https://doi.org/10.14393/CEv9n2-2019

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika, 12*(2), 153–157. https://doi.org/10.1007/BF02295996

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

Monaco, N., & Arnaudo, D. (2020). *Análise de dados para o monitoramento de redes sociais*. National Democratic Institute.

Monteiro, R. A., Santos, R. L. S., Pardo, T. A. S., de Almeida, T. A., Ruiz, E. E. S., & Vale, O. A. (2018). Contributions to the study of fake news in Portuguese: New corpus and automatic detection results. In *Computational Processing of the Portuguese Language: PROPOR 2018* (pp. 324–334). Springer. https://doi.org/10.1007/978-3-319-99722-3_33

Naeini, M. P., Cooper, G. F., & Hauskrecht, M. (2015). Obtaining well calibrated probabilities using Bayesian binning. In *Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence* (pp. 2901–2907). AAAI Press.

Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning* (pp. 625–632). ACM. https://doi.org/10.1145/1102351.1102430

Omand, D., Bartlett, J., & Miller, C. (2012). Introducing social media intelligence (SOCMINT). *Intelligence and National Security, 27*(6), 801–823. https://doi.org/10.1080/02684527.2012.716965

OWASP Foundation. (2021). *OWASP Top 10: 2021*. https://owasp.org/Top10/

Palantir Technologies. (2021). *Palantir Gotham: Enterprise platform for mission planning and intelligence analysis*. Digital Marketplace, UK Government.

Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors*, *52*(3), 381–410. https://doi.org/10.1177/0018720810376055

Poletto, F., Basile, V., Sanguinetti, M., Bosco, C., & Patti, V. (2021). Resources and benchmark corpora for hate speech detection: A systematic review. *Language Resources and Evaluation, 55*(2), 477–523. https://doi.org/10.1007/s10579-020-09502-8

República de Angola. (2010). *Constituição da República de Angola*. Assembleia Nacional.

República de Angola. (2011). Lei n.º 22/11, de 17 de Junho: Lei da Protecção de Dados Pessoais. *Diário da República*, I Série, n.º 114.

República de Angola. (2017). Lei n.º 7/17, de 16 de Fevereiro: Lei de Protecção das Redes e Sistemas Informáticos. *Diário da República*, I Série.

Rodrigues, J., Gomes, L., Silva, J., Branco, A., Santos, R., Lopes Cardoso, H., & Osório, T. (2023). Advancing neural encoding of Portuguese with Transformer Albertina PT-. *In* Progress in Artificial Intelligence: EPIA 2023* (pp. 441–453). Springer. https://doi.org/10.1007/978-3-031-49008-8_35

Runfola, D., Anderson, A., Baier, H., Crittenden, M., Dowker, E., Fuhrig, S., Goodman, S., Grimsley, G., Layko, R., Melville, G., Mulder, M., Oberman, R., Panganiban, J., Peck, A., Seitz, L., Shea, S., Slevin, H., Youngerman, R., & Hobbs, L. (2020). geoBoundaries: A global database of political administrative boundaries. *PLoS ONE, 15*(4), e0231866. https://doi.org/10.1371/journal.pone.0231866

Sambaca, S. C., & Pessoa, S. N. (2026). *Eleições em Angola: A influência das redes sociais no comportamento eleitoral dos jovens angolanos em 2022*. Zenodo. https://doi.org/10.5281/zenodo.18363947

Sap, M., Card, D., Gabriel, S., Choi, Y., & Smith, N. A. (2019). The risk of racial bias in hate speech detection. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics* (pp. 1668–1678). Association for Computational Linguistics. https://doi.org/10.18653/v1/P19-1163

Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing, 45*(11), 2673–2681. https://doi.org/10.1109/78.650093

Sette Câmara, T. (2016). Terrorismo na era da Internet: O uso de redes sociais pelo Estado Islâmico. *Revista Relações Internacionais no Mundo Atual, 21*(1), 196–221.

Settles, B. (2009). *Active learning literature survey* (Computer Sciences Technical Report 1648). University of Wisconsin–Madison.

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management, 45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

Souza, F., Nogueira, R., & Lotufo, R. (2020). BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Intelligent Systems: BRACIS 2020* (pp. 403–417). Springer. https://doi.org/10.1007/978-3-030-61377-8_28

Thelwall, M. (2009). Social network sites: Users and uses. *Advances in Computers, 76*, 19–73. https://doi.org/10.1016/S0065-2458(09)01002-X

UNESCO. (2019). *Journalism, fake news & disinformation: Handbook for journalism education and training*. UNESCO.

UNESCO. (2021). *Recommendation on the ethics of artificial intelligence*. UNESCO.

União Europeia. (2024). Regulamento (UE) 2024/1689 do Parlamento Europeu e do Conselho, de 13 de junho de 2024, que cria regras harmonizadas em matéria de inteligência artificial. *Jornal Oficial da União Europeia*, Série L.

Vargas, F., Carvalho, I., Rodrigues de Góes, F., Pardo, T., & Benevenuto, F. (2022). HateBR: A large expert annotated corpus of Brazilian Instagram comments for offensive language and hate speech detection. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference* (pp. 7174–7183). European Language Resources Association.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems 30* (pp. 5998–6008). Curran Associates.

Wardle, C., & Derakhshan, H. (2017). *Information disorder: Toward an interdisciplinary framework for research and policy making* (Relatório DGI(2017)09). Conselho da Europa.

Williams, H. J., & Blum, I. (2018). *Defining second generation open source intelligence (OSINT) for the defense enterprise* (RR-1964-OSD). RAND Corporation. https://doi.org/10.7249/RR1964

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953

Woolley, S. C., & Howard, P. N. (2017). *Computational propaganda worldwide: Executive summary* (Working Paper 2017.11). Oxford Internet Institute.

GLOSSÁRIO

Ajuste fino. Treino adicional de um modelo pré-treinado numa tarefa específica, com dados anotados dessa tarefa.

Aprendizagem de atalhos. Fenómeno em que o modelo aprende uma regularidade acidental dos dados de treino (por exemplo, o estilo de uma fonte) em vez da propriedade que se pretende detectar.

Bootstrap. Método de reamostragem com reposição usado para estimar a variabilidade de uma estatística e construir intervalos de confiança.

Calibração. Propriedade de um classificador cujas probabilidades correspondem às frequências observadas: entre as previsões feitas com 80% de confiança, cerca de 80% estão certas.

F1 ponderado. Média dos F1 das categorias ponderada pelo número de exemplos de cada uma; é dominado pelas categorias frequentes.

F1-macro. Média simples dos F1 das categorias; dá a mesma importância a todas, independentemente da sua frequência.

Kappa de Cohen. Medida de acordo entre dois avaliadores corrigida pelo acordo esperado ao acaso.

Kappa de Fleiss. Generalização do Kappa para três ou mais avaliadores.

Lacuna de domínio. Diferença de desempenho de um modelo entre os dados semelhantes aos de treino e dados de outro domínio (plataforma, região, variedade linguística ou género textual).

Precisão. Fracção das previsões de uma categoria que estão correctas.

Precisão nos primeiros K. Fracção de ameaças, segundo a referência disponível (etiquetas de teste ou decisão do analista), entre os K primeiros itens da fila de revisão.

Pseudonimização. Substituição de identificadores pessoais por códigos que não permitem identificar a pessoa sem informação adicional guardada separadamente.

Sensibilidade. Fracção dos exemplos de uma categoria que o modelo identifica (em inglês, *recall*).

Subpalavra. Fragmento de palavra usado pelo tokenizador dos modelos BERT; palavras fora do vocabulário são divididas em subpalavras conhecidas.

Teste de McNemar. Teste estatístico para comparar dois classificadores no mesmo conjunto de teste, com base nos casos em que apenas um deles acerta.

Transformer. Arquitectura de rede neuronal baseada em mecanismos de atenção, que processa toda a sequência em paralelo (Vaswani et al., 2017).

APÊNDICE A – EXCERTOS DE CÓDIGO-FONTE

Excertos reproduzidos sem alterações do código do protótipo; o código completo está em https://github.com/manuelmuinga/dissertacao-uan-angola.

A.1 Anonimização à entrada (sistema/anonimizacao.py)

```
_PADROES: list[tuple[re.Pattern[str], str]] = [
    (re.compile(r"https?://\S+|www\.\S+", re.IGNORECASE), "[URL]"),
    (re.compile(r"\b[\w.+-]+@[\w-]+\.[\w.-]+\b"), "[EMAIL]"),
    # Telefones: +244 9xx xxx xxx, 9xxxxxxxx e variantes com espaços/hífenes.
    (re.compile(r"(?<!\w)(?:\+?244[\s-]?)?9\d{2}[\s-]?\d{3}[\s-]?\d{3}(?!\w)"),
"[TELEFONE]"),
    (re.compile(r"(?<!\w)@[\w.]{2,}"), "@[UTILIZADOR]"),
]


def mascarar_texto(texto: str) -> str:
    """Substitui identificadores directos no texto por marcadores."""
    if not texto:
        return ""
    for padrao, marcador in _PADROES:
        texto = padrao.sub(marcador, texto)
    return re.sub(r"\s+", " ", texto).strip()


def pseudonimo_autor(autor: str | None, segredo: str) -> str | None:
    """Pseudónimo irreversível do autor (HMAC-SHA-256, 16 hex)."""
    if not autor:
        return None
    if not segredo:
        raise ValueError(
            "Defina UAN_SEGREDO_HASH: sem segredo, o hash de um nome de utilizador "
            "pode ser revertido por dicionário."
        )
    digest = hmac.new(segredo.encode("utf-8"), autor.strip().lower().encode("utf-8"),
hashlib.sha256)
    return digest.hexdigest()[:16]
```

A.2 Classificação em lote com o BERTimbau (sistema/classificador.py)

```
    def classificar(self, textos: list[str]) -> list[Resultado]:
        torch = self._torch
        resultados: list[Resultado] = []
        for i in range(0, len(textos), self.tamanho_lote):
            lote = textos[i : i + self.tamanho_lote]
            enc = self.tokenizer(lote, truncation=True, max_length=self.max_length,
padding=True, return_tensors="pt")
            enc = {k: v.to(self.dispositivo) for k, v in enc.items()}
            with torch.no_grad():
                probs = torch.softmax(self.modelo(**enc).logits, dim=-1).cpu().tolist()
            resultados.extend(Resultado(dict(zip(self.rotulos, map(float, p)))) for p in
probs)
        return resultados
```

APÊNDICE B – GUIA DE ANOTAÇÃO PADRONIZADO

Este guia orientou os três anotadores na classificação dos comentários do corpus angolano. Todos o receberam antes de começar e comprometeram-se a segui-lo de forma independente, sem comunicar entre si durante a anotação.

B.1 Identificação do projecto

Campo	Informação
Título da investigação	Monitoramento inteligente de ameaças em redes sociais em Angola para o apoio à defesa e segurança nacional
Investigador principal	Manuel Gonga Muinga
Instituição	Universidade Agostinho Neto, Faculdade de Engenharia
Período de anotação	Junho a Outubro de 2026

B.2 Objectivo da anotação

Atribuir a cada comentário uma, e só uma, das quatro categorias definidas abaixo. As anotações constituem a referência para treinar e avaliar os modelos, pelo que a sua consistência determina a validade dos resultados.

B.3 Categorias

B.3.1 Normal (rótulo Normal)

Comentários que não representam ameaça à segurança, à ordem pública ou aos direitos fundamentais. Inclui notícias factuais, entretenimento, crítica política legítima, humor e conversa quotidiana. Exemplos: «O Governo anunciou hoje a inauguração da nova estrada em Benguela»; «As políticas económicas precisam de ser revistas urgentemente» (crítica sem incitação).

B.3.2 Desinformação (rótulo Desinformacao)

Informação falsa, enganosa ou deliberadamente distorcida, com potencial para causar dano público, manipular a opinião ou criar pânico. Inclui notícias fabricadas, vídeos fora de contexto ou manipulados e declarações falsamente atribuídas a figuras públicas. Exemplos: «URGENTE: vídeo mostra um governante a confessar desvio de fundos. PARTILHA!» (vídeo manipulado); «Surto de doença mortal em Luanda, as autoridades estão a esconder a verdade» (sem fonte). Se a publicação apresentar factos reais com contexto distorcido para enganar, classifique como Desinformação.

B.3.3 Discurso de ódio (rótulo Odio)

Conteúdo que promove, incita ou justifica discriminação, hostilidade ou violência com base em etnia, religião, origem regional, género ou orientação sexual, de forma explícita ou implícita (estereótipos, desumanização, linguagem codificada). O calão com conteúdo discriminatório entra nesta categoria. A crítica a governos, partidos ou figuras públicas não é discurso de ódio; o critério é a desumanização ou a discriminação por identidade.

B.3.4 Mobilização hostil (rótulo Mobilizacao)

Comentários que organizam, coordenam ou incitam à participação em acções ilegais ou violentas, ou que ameacem a ordem pública. Exemplos: «Amanhã Luanda pára. Quem não aparecer é traidor. Tragam o que foi combinado.» Uma convocatória para manifestação pacífica e legal **não** é Mobilização Hostil e deve ser classificada como Normal.

B.4 Casos limítrofes

Crítica política ou desinformação. Dados incorrectos numa crítica são Normal se o erro parecer involuntário e verificável; são Desinformação se forem apresentados como verdade sem fonte, com marcadores de manipulação (por exemplo, «partilha antes que apaguem»).

Convocatória pacífica ou mobilização hostil. É Normal quando explicita o carácter pacífico e legal da acção; é Mobilização Hostil quando combina coordenação, linguagem coerciva ou de violência e ausência de referência ao carácter legal.

Ódio implícito ou observação. É Discurso de Ódio quando atribui características negativas a um grupo pela sua identidade e usa linguagem de exclusão, mesmo que formulada como «facto».

B.5 Regras de desempate e preenchimento

Se a publicação tiver elementos de mais de uma categoria, escolha a mais grave: Mobilização Hostil > Discurso de Ódio > Desinformação > Normal. Em comentários com calão ou expressões de línguas nacionais, aplique os mesmos critérios; em caso de dúvida sobre o significado, registe-a na coluna de observações. Ironia e sátira sem intenção de dano são Normal; ironia que mascara conteúdo nocivo segue a categoria correspondente. Ler cada comentário na íntegra antes de classificar, registar uma observação nos casos difíceis e não consultar os outros anotadores durante a fase individual.

APÊNDICE C – ACORDO ENTRE ANOTADORES

Este apêndice documenta o cálculo do acordo entre os três anotadores do corpus angolano.

C.1 Escala de interpretação

Tabela C.1 – Escala de interpretação do Kappa (Landis & Koch, 1977)

Valor de κ	Grau de acordo
< 0,00	Pobre
0,00–0,20	Ligeiro
0,21–0,40	Razoável
0,41–0,60	Moderado
0,61–0,80	Substancial
0,81–1,00	Quase perfeito

C.2 Fórmulas

O Kappa de Cohen, para um par de anotadores, é $\kappa = (Po - Pe) / (1 - Pe)$, onde Po é a proporção de acordo observado e Pe a proporção de acordo esperada ao acaso, calculada a partir das distribuições marginais de cada anotador (Cohen, 1960). O Kappa de Fleiss generaliza esta medida para três ou mais anotadores, calculando Po como a média, por item, da proporção de pares de anotadores em acordo e Pe a partir da distribuição global das categorias (Fleiss, 1971).

C.3 Resultados

Tabela C.2 – Acordo entre os três anotadores

Subconjunto	Medida	Valor
Base do piloto e lote de léxico	κ de Fleiss [IC 95%]	0,718 [0,695; 0,741]
Base do piloto e lote de léxico	κ de Cohen médio (3 pares)	0,719
Base do piloto e lote de léxico	Concordância observada	81,3%
Lote temático de vídeos (284 itens)	κ de Fleiss [IC 95%]	0,818 [0,763; 0,869]

Nota. O κ do lote temático, calculado antes da exclusão dos 90 comentários não angolanos, não é comparável com o da base do piloto, por resultar de uma selecção não aleatória com distribuição de categorias diferente.

A Tabela C.3 detalha o acordo na base do piloto e no lote orientado por léxico (2.443 itens com etiqueta dos três anotadores), por par de anotadores e por categoria. Os anotadores são identificados por letras. O par menos concordante fica em 0,684 e o mais concordante em 0,772, todos no intervalo substancial. Por categoria, a

Desinformação é a que reúne menos acordo (0,625), o que é coerente com a dificuldade de a distinguir da crítica política sem verificar os factos alegados.

Tabela C.3 – Acordo por par de anotadores e por categoria (base do piloto e lote de léxico, n = 2.443)

Desagregação	Medida	Valor
Par A–B	κ de Cohen	0,700
Par A–C	κ de Cohen	0,684
Par B–C	κ de Cohen	0,772
Média dos pares [IC 95%]	κ de Cohen	0,719 [0,696; 0,741]
Normal	κ de Fleiss	0,738
Desinformação	κ de Fleiss	0,625
Discurso de Ódio	κ de Fleiss	0,753
Mobilização Hostil	κ de Fleiss	0,731
Base do piloto, sem lotes enriquecidos (n = 2.352)	κ de Fleiss	0,717
Lote enriquecido por léxico (n = 91)	κ de Fleiss	0,697

Nota. O κ de Fleiss por categoria trata cada categoria contra as restantes. Valores calculados pelo *script* compute_pilot_kappa.py (ficheiro kappa_piloto.json).

C.4 Distribuição das etiquetas finais

Tabela C.4 – Distribuição das etiquetas finais do corpus angolano

Categoria	Comentários	Percentagem
Normal	1.664	63,1%
Mobilização Hostil	364	13,8%
Desinformação	326	12,4%
Discurso de Ódio	283	10,7%
Total	**2.637**	**100%**

Nota. Inclui a base do piloto e os dois lotes enriquecidos, antes da deduplicação feita na harmonização do corpus.

APÊNDICE D – DECLARAÇÃO DE CONSENTIMENTO E CONFIDENCIALIDADE DOS ANOTADORES

Esta declaração foi assinada por cada anotador antes do início da anotação.

Eu, abaixo assinado(a), declaro que:

- Fui informado(a) sobre os objectivos, a metodologia e a finalidade da investigação «Monitoramento inteligente de ameaças em redes sociais em Angola para o apoio à defesa e segurança nacional», conduzida por Manuel Gonga Muinga na Universidade Agostinho Neto.
- Participo voluntariamente como anotador(a), sem remuneração, e posso retirar o meu consentimento a qualquer momento sem penalização.
- A minha função consiste em classificar comentários de redes sociais em quatro categorias, seguindo o Guia de Anotação (Apêndice B), de forma independente.
- Comprometo-me a manter a confidencialidade do conteúdo analisado e a não o usar para outro fim.
- Não tenho conflitos de interesses com o investigador nem com os temas analisados.
- Autorizo o uso das minhas anotações para fins exclusivamente académicos e científicos, sem identificação nominal nos resultados publicados.
- Fui informado(a) de que os meus dados pessoais (nome e assinatura) serão tratados de forma confidencial, nos termos da Lei n.º 22/11, de 17 de Junho.

Luanda, ____ de _____ de 2026

Nome do(a) anotador(a): _____

Assinatura: _____

Investigador principal: Manuel Gonga Muinga _____

APÊNDICE E – AMOSTRA ANOTADA DO CORPUS

Este apêndice apresenta 20 comentários reais do corpus angolano, com as anotações individuais e a etiqueta final. A amostra foi extraída do ficheiro corpus_ground_truth_com_texto_v13.csv por sorteio com semente fixa (42), cinco comentários por categoria, entre os comentários de YouTube sorteados da base do piloto cuja etiqueta final coincide com a maioria dos anotadores. Ficaram de fora as publicações de imprensa e de organizações e os lotes enriquecidos. Os textos mantêm a grafia original. Os nomes de pessoas foram substituídos por descritores entre parênteses rectos, e os comentários longos foram reduzidos ao trecho relevante, assinalado com (…).

Tabela E.1 – Amostra de comentários anotados

N.º	Excerto (anonimizado)	A	B	C	Final	Unânime
1	Mesmo no Brasil 🇧🇷 creio que são piores	N	N	N	N	Sim
2	Minha Angola 😔😔	N	N	N	N	Sim
3	Meu Deus do céu como pode uma pessoa se aproveitar da pobreza dos outros	N	N	N	N	Sim
4	Máximo respeito Gangster.	N	N	N	N	Sim
5	Axo muito bem força mano deus esta com nosco, nao tenha medo	N	N	N	N	Sim
6	E [pessoa referida]? Laranjas e chocolates, e uma mansão de 6 milhões comprada em plena pandemia.	D	D	D	D	Sim
7	Só Deus para nós livrar das garras desses senhores que se intitulam donos de Angola e de todos os recursos que existe neste País. Verdade bem dita.	D	D	N	D	Não
8	(…) isso cá no meu país é proibido passar em órgãos públicos! Eu garanto que o Mplá é a máfia mais perigosa do mundo (…)	N	D	D	D	Não
9	[político brasileiro] deu palestra e ganhou meio milhão. Seu sobrinho faturou legal tb.	D	D	D	D	Sim
10	Essa reportagem é encomendada por [líder religioso] e a Universal. A Universal está nesse momento sendo expulsa de Angola, por conta de crimes cometidos e por conta (…)	D	D	N	D	Não
11	GOVERNO DE ESQUERDA É MARAVILHOSO QUE O DIGA O DIGA O POVO VENEZUELANO E NORTE COREANO!!!!!🤣🤣🤣🤣🤣🤣🤣🤣🤣🤣🤣🤣🤣	O	O	O	O	Sim
12	😢😢😢😢😢	O	O	N	O	Não
13	(…) o povo angolano anda muito atrasado pois mesmo se apercebendo duq tem acontecido ñ faz nada contra a causa' apenas obcerva a sua própria destruição por parte dos dirigentes pa p#t@ do país. (…)	O	O	O	O	Sim

N.º	Excerto (anonimizado)	A	B	C	Final	Unânime
14	Nada justifica o que??? É medo que você tem de apoiar o povo. Tem sim uma justificativa 💔 deixa disso homem do MPLA	N	O	O	O	Não
15	Mano essa currupcao será difícil acaba cm MPLA n poder	O	O	D	O	Não
16	Força vamos libertar o país	M	M	M	M	Sim
17	O povo no puder. Viva povo de Angola. 😂😂😂	M	M	M	M	Sim
18	Os fins justificam os meios... Estou orgulhoso de vocês 👌🏾	M	M	D	M	Não
19	Está faltar chegarmos até aos condomínios 👌 eles moram lá 👆🤔😏🙄	M	M	M	M	Sim
20	O POVO É QUE SE UNEM E VÃO NO PALÁCIO..E NÃO CULPO ESTE POVO SOFREDOR E ABANDONADO 😢	M	M	M	M	Sim

Nota. N = Normal; D = Desinformação; O = Discurso de Ódio; M = Mobilização Hostil. A amostra não foi escolhida para ilustrar casos claros, e mostra também o ruído da anotação e o uso, por vezes, de critérios mais amplos do que os do guia (Secção 3.4): o comentário 12, composto apenas por emojis, recebeu a etiqueta Discurso de Ódio de dois anotadores, e o 11 é sarcasmo político, de fronteira discutível com a categoria Normal. Casos como estes ajudam a explicar o κ substancial, mas não quase perfeito, do Apêndice C.

APÊNDICE F – MANUAL DE INSTALAÇÃO E UTILIZAÇÃO DO SISTEMA

O sistema está na pasta sistema_uan do repositório do projecto. Os comandos destinam-se à linha de comandos do Windows (cmd), na pasta do sistema. O README do sistema descreve todas as opções.

F.1 Instalação e configuração

```
python -m pip install -r requirements.txt
python -m pytest -q
python -c "import secrets; print(secrets.token_urlsafe(32))"
python uan.py verificar-config
```

A configuração fica no ficheiro uan.env, criado a partir de uan.env.exemplo e nunca guardado no repositório. As variáveis essenciais são UAN_MODELO (pasta do modelo; vazio activa um classificador de demonstração), UAN_SEGREDO_HASH (segredo dos pseudónimos, gerado ao acaso com o terceiro comando e nunca mudado depois da primeira recolha), UAN_YOUTUBE_CHAVE (chave da YouTube Data API v3) e, para os alertas por e-mail, UAN_SMTP_SERVIDOR e UAN_SMTP_REMETENTE. O comando verificar-config mostra que ficheiro é lido e que variáveis estão definidas, sem os valores.

F.2 Arranque e utilização

```
python uan.py servir
python uan.py servir --demonstracao
```

O sistema abre em http://127.0.0.1:8000. Na primeira utilização pede a conta do supervisor, que cria as dos analistas em Utilizadores. O modo de demonstração usa a base dados\demonstracao.db, com dados fictícios e as contas demo.supervisor, demo.analista e demo.revisor (palavra-passe demonstracao); o supervisor pode trocar de modo com o sistema aberto. Na fila, as teclas 1 a 4 decidem, J e K mudam de item, U desfaz, D abre o detalhe e ? mostra todos os atalhos; Ctrl+K abre a procura de páginas e acções. Em Fontes e recolha, o supervisor cola um ou vários endereços (vídeo, canal, lista ou pesquisa do YouTube, feed, página ou sítio), recolhe a pedido e escolhe a frequência da recolha automática. Cada utilizador gera em A minha conta o seu código de recuperação; quem se esquece da palavra-passe usa a ligação «Esqueceu-se da palavra-passe?» na entrada.

F.3 Linha de comandos

Tabela F.1 – Comandos do sistema

Comando	Função
python uan.py servir [--demonstracao]	Arranca a aplicação web
python uan.py criar-utilizador ana --nome "Ana" --papel analista	Cria uma conta
python uan.py repor-senha utilizador [--temporaria]	Repõe a palavra-passe e desbloqueia a conta
python uan.py importar ficheiro.csv --plataforma YouTube --via api_oficial	Importa e anonimiza um lote
python uan.py fonte-adicionar --endereco URL "termos"	Regista fontes; o tipo é detectado
python uan.py recolher	Recolhe as fontes activas e classifica
python uan.py alertas	Verifica tendências e envia os alertas
python uan.py relatorio --dias 30 --email	Relatório de alertas do período
python uan.py metricas / exportar revisoes.csv	Métricas operacionais; revisões para novo treino
python uan.py limpar --dias 180 / copia	Prazo de conservação; cópia de segurança
python uan.py medir-latencia ficheiro.csv	Mede o tempo de processamento (H2)

Nota. O modelo treinado no Google Colab deve ser guardado no formato da biblioteca Transformers, com o ficheiro colab_guardar_modelo.py, e acompanhado do ficheiro ficha_modelo.json, que a página Sobre o modelo apresenta.