UNIVERSIDADE AGOSTINHO NETO
FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Manuel Gonga Muinga
Engenheiro Electrotécnico

Orientador científico: Professor Doutor Joaquim Fortes
Co-orientador: Professor Doutor Judice Cumbunga

Luanda
2026

UNIVERSIDADE AGOSTINHO NETO
FACULDADE DE ENGENHARIA

MONITORAMENTO INTELIGENTE DE AMEAÇAS EM REDES SOCIAIS EM ANGOLA PARA O APOIO À DEFESA E SEGURANÇA NACIONAL

Dissertação submetida à Faculdade de Engenharia da Universidade Agostinho Neto como requisito para obtenção do título de Mestre em **Engenharia e Ciência de Dados**

Manuel Gonga Muinga
Engenheiro Electrotécnico

Orientador científico:
Professor Doutor Joaquim Fortes (UAN)

Co-orientador:
Professor Doutor Judice Cumbunga (UAN)

Luanda
2026

FICHA CATALOGRÁFICA

Muinga, M. G. (2026). *Monitoramento inteligente de ameaças em redes sociais em Angola para o apoio à defesa e segurança nacional*. xiii, 54 p. + 11 p. de glossário e apêndices; il.; 30 cm.

Dissertação de Mestrado em Engenharia e Ciência de Dados (Mecdata), 2024–2026. Universidade Agostinho Neto, Faculdade de Engenharia, Departamento de Engenharia Mecânica.

Orientador: Professor Doutor Joaquim Fortes. Co-orientador: Professor Doutor Judice Cumbunga.

Palavras-chave: 1. Redes sociais. 2. Discurso de ódio. 3. Desinformação. 4. BERTimbau. 5. Adaptação de domínio. 6. Segurança nacional.

Permitida a reprodução total ou parcial deste documento, desde que citada a fonte e sem carácter comercial – O autor

EPÍGRAFE

"Todos têm o direito de exprimir, divulgar e compartilhar livremente os seus pensamentos (…)"
Constituição da República de Angola, artigo 40.º, n.º 1

DEDICATÓRIA

À minha querida esposa, Rosalina Muinga, cuja presença ilumina cada etapa da minha vida. Este trabalho é dedicado a ti, pelo amor, pela paciência e pelo apoio incondicional que sempre me ofereceste. A tua força e a tua compreensão foram fundamentais para que eu pudesse chegar até aqui. Que esta conquista seja também o reflexo da nossa caminhada conjunta, marcada pela fé, pela perseverança e pela esperança.

AGRADECIMENTOS

Tenho a honra de expressar os meus mais sinceros agradecimentos aos meus orientadores, pela orientação científica, pela disponibilidade e pelo rigor académico que tornaram possível a realização desta dissertação.

À Universidade Agostinho Neto e à Faculdade de Engenharia, pela sólida formação académica e pelo ambiente científico que proporcionaram ao longo desta jornada.

À minha família e aos meus amigos, pelo apoio incondicional, pela paciência e pelo encorajamento, que foram fundamentais para superar os desafios e alcançar esta etapa.

Às Forças Armadas Angolanas, instituição que financiou a minha formação, pelo investimento e pela confiança depositada.

Ao Comando da Brigada de Forças Especiais, pela confiança, pelo apoio institucional e pelo incentivo constante ao meu desenvolvimento académico e profissional.

Um agradecimento especial a Sua Excelência o Tenente-General Tussen, cujo incentivo e motivação foram decisivos para que eu pudesse frequentar este curso e concretizar este trabalho.

Aos anotadores que classificaram, com paciência e rigor, os comentários do corpus angolano, e aos colegas investigadores e a todos os que, de forma directa ou indirecta, contribuíram para a realização desta dissertação, manifesto a minha profunda gratidão.

RESUMO

Nas redes sociais angolanas, a desinformação, o discurso de ódio e os apelos à mobilização hostil circulam ao lado da conversa quotidiana, num volume que nenhuma equipa de analistas consegue ler. Esta dissertação desenvolve e avalia um sistema que ordena essas publicações para o analista, sem o substituir. Construiu-se um corpus de 2.637 publicações públicas angolanas, sobretudo comentários do YouTube, anotadas por três anotadores em quatro categorias, com κ de Fleiss de 0,718 (n = 2.443). Juntando-lhe três corpora brasileiros (HateBR, ToLD-BR e Fake.br; 26.859 registos no total), compararam-se SVM, Floresta Aleatória, Bi-LSTM e BERTimbau. No teste (n = 3.987), o BERTimbau obteve F1-macro de 0,807 (0,797 na média de três sementes), 14,6 a 17,4 pontos percentuais acima dos restantes (McNemar com Bonferroni, $p < 10^{-47}$); o Bi-LSTM não superou a Floresta Aleatória. Em conteúdo angolano, porém, o F1-macro desceu para 0,533, contra 0,919 no corpus público, com a maior queda na Desinformação. Desenvolveu-se depois uma aplicação web com pseudonimização dos autores à entrada, segundo a Lei n.º 22/11, auditoria, fila de revisão por prioridade e alertas, sem decisões automáticas. Sem placa gráfica dedicada, processou cada publicação em 0,6 a 0,7 segundos; as primeiras chegaram à fila em 36 segundos e, em recolhas até 64 publicações, todas em menos de 60. A utilidade da fila com analistas e a antecedência de detecção não foram testadas. Os contributos são o corpus anotado, a medida da lacuna de domínio e uma arquitectura de triagem de baixo custo.

Palavras-chave: Redes sociais. Discurso de ódio. Desinformação. BERTimbau. Adaptação de domínio. Segurança nacional.

ABSTRACT

On Angolan social media, disinformation, hate speech and calls for hostile mobilisation circulate alongside everyday conversation, in a volume no team of analysts can read. This dissertation develops and evaluates a system that ranks these posts for analysts without replacing them. A corpus of 2,637 public Angolan posts, mostly YouTube comments, was annotated by three annotators into four categories (Fleiss' kappa 0.718, n = 2,443). Combined with three Brazilian corpora (HateBR, ToLD-BR and Fake.br; 26,859 records in total), it was used to compare SVM, Random Forest, Bi-LSTM and BERTimbau. On the test set (n = 3,987), BERTimbau reached a macro-F1 of 0.807 (0.797 averaged over three seeds), 14.6 to 17.4 percentage points above the others (McNemar test with Bonferroni correction, $p < 10^{-47}$); the Bi-LSTM did not outperform the Random Forest. On Angolan content, however, macro-F1 fell to 0.533, compared with 0.919 on the public corpora, with the largest drop in disinformation. A web application was then developed with author pseudonymisation at ingestion, in line with Angolan Law No. 22/11, audit logging, a priority-ranked review queue and alerts, and no automated decisions. Without a GPU, it processed each post in 0.6–0.7 seconds; the first posts reached the queue within 36 seconds and, for batches of up to 64 posts, all posts within 60 seconds. Neither the usefulness of the queue for analysts nor the detection lead time was tested. The main contributions are the annotated corpus, the measurement of the domain gap and a low-cost triage architecture.

Keywords: Social media. Hate speech. Disinformation. BERTimbau. Domain adaptation. National security.

ABREVIATURAS, SIGLAS E SÍMBOLOS

Sigla ou símbolo	Significado
API	Interface de programação de aplicações (*Application Programming Interface*)
AUC-ROC	Área sob a curva ROC (*Receiver Operating Characteristic*)
BERT	Representações bidireccionais de codificador baseadas em *Transformers*
Bi-LSTM	Rede de memória de longo e curto prazo bidireccional
CPLP	Comunidade dos Países de Língua Portuguesa
CSP	Política de segurança de conteúdo (*Content Security Policy*)
CSRF	Falsificação de pedidos entre sítios (*Cross-Site Request Forgery*)
CPU	Unidade central de processamento (*Central Processing Unit*)
CSV	Valores separados por vírgulas (formato de ficheiro)
ECE	Erro de calibração esperado (*Expected Calibration Error*)
F1	Média harmónica entre precisão e sensibilidade
GPU	Unidade de processamento gráfico
HMAC	Código de autenticação de mensagens baseado em *hash*
HTTPS	Protocolo seguro de transferência de hipertexto
IA	Inteligência artificial
IC 95%	Intervalo de confiança a 95%
JSON	Notação de objectos JavaScript (formato de dados)
LSTM	Memória de longo e curto prazo (*Long Short-Term Memory*)
NIST	Instituto Nacional de Normas e Tecnologia dos Estados Unidos
OSINT	Inteligência de fontes abertas (*Open Source Intelligence*)
OWASP	Projecto aberto de segurança de aplicações web (*Open Worldwide Application Security Project*)
PBKDF2	Função de derivação de chaves a partir de palavras-passe, versão 2
p.p.	Pontos percentuais
PDF	Formato de documento portátil
PLN	Processamento de linguagem natural
PNG	Gráficos de rede portáteis (formato de imagem)
RSS	Formato de distribuição de conteúdos web (*Really Simple Syndication*)
SHA-256	Algoritmo de *hash* seguro de 256 bits
SMOTE	Técnica de sobreamostragem sintética de minorias
SOCMINT	Inteligência de redes sociais (*Social Media Intelligence*)
SVG	Gráficos vectoriais escaláveis (formato de imagem)
SVM	Máquina de vectores de suporte (*Support Vector Machine*)
TF-IDF	Frequência do termo × inverso da frequência nos documentos
UAN	Universidade Agostinho Neto
UML	Linguagem de modelação unificada
κ	Coeficiente Kappa (de Cohen ou de Fleiss)

ÍNDICE

CAPÍTULO 1 – INTRODUÇÃO.....1
1.1 Contextualização.....1
1.2 Problema de investigação.....2
1.3 Hipóteses de investigação.....3
1.4 Objectivos.....3
1.4.1 Objectivo geral.....3
1.4.2 Objectivos específicos.....3
1.5 Justificação e relevância.....4
1.6 Delimitação e estrutura do estudo.....4
CAPÍTULO 2 – REVISÃO DA LITERATURA.....5
2.1 Redes sociais: conceito, evolução e dimensão securitária.....5
2.1.1 Conceito e evolução.....5
2.1.2 O ecossistema digital angolano.....5
2.1.3 Inteligência de fontes abertas e de redes sociais.....6
2.2 Categorias de ameaças digitais.....6
2.3 Sistemas de monitorização de ameaças.....7
2.4 Recursos e modelos de linguagem para o português.....8
2.4.1 Corpora anotados.....8
2.4.2 Modelos de linguagem.....8
2.5 Algoritmos de classificação de texto.....9
2.6 Avaliação de classificadores.....10
2.7 Generalização entre domínios e aprendizagem de atalhos.....11
2.8 Aspectos éticos, legais e de direitos humanos.....11
2.9 Revisão humana e segurança da informação.....12
2.10 Síntese e lacuna de investigação.....12
CAPÍTULO 3 – METODOLOGIA.....13
3.1 Paradigma e desenho da investigação.....13
3.2 Considerações éticas e protecção de dados.....13
3.3 Recolha de dados do piloto angolano.....14
3.4 Anotação e acordo entre anotadores.....15
3.5 Construção do corpus híbrido.....17
3.6 Modelos e treino.....18
3.6.1 Pré-processamento e representação.....18

3.6.2 Configuração dos modelos.....18
3.6.3 Ambiente de desenvolvimento.....19
3.7 Protocolo de avaliação.....19
3.8 Arquitectura do sistema.....20
3.8.1 Requisitos.....20
3.8.2 Alternativas e decisão.....21
3.8.3 Camadas e componentes.....22
3.8.4 Casos de uso e fluxo de processamento.....24
3.8.5 Interface do analista.....25
3.8.6 Recolha automática, contas e segurança.....27
3.9 Plano de testes e avaliação operacional.....28
CAPÍTULO 4 – RESULTADOS E DISCUSSÃO.....29
4.1 Corpus de avaliação e protocolo experimental.....29
4.2 Desempenho global dos modelos.....30
4.3 Significância estatística das diferenças.....31
4.4 Desempenho por categoria e análise de erros.....32
4.5 Análises de robustez.....34
4.5.1 Variabilidade entre sementes, ensemble e ablações.....34
4.5.2 Ajuste de limiares de decisão.....35
4.6 Lacuna de domínio: piloto angolano e corpus público (Hipótese H4).....36
4.7 Qualidade das probabilidades e utilidade da ordenação.....38
4.7.1 Calibração das probabilidades.....38
4.7.2 Ordenação da fila de revisão.....39
4.8 Avaliação operacional do sistema (Hipóteses H2 e H3).....40
4.8.1 Tempo de processamento (H2).....40
4.8.2 Antecedência de detecção (H3).....41
4.8.3 Implicações para o desenho operacional.....41
4.8.4 Verificação funcional do sistema.....42
4.9 Discussão e verificação formal das hipóteses.....42
CAPÍTULO 5 – CONCLUSÕES.....44
5.1 Síntese dos objectivos.....44
5.2 Resposta às hipóteses e às perguntas de investigação.....44
5.3 Contributos.....45
5.4 Limitações.....46
5.5 Implicações para a defesa e segurança nacional.....47
5.6 Quadro de uso responsável.....48

5.7 Considerações finais....48
CAPÍTULO 6 – RECOMENDAÇÕES....49
REFERÊNCIAS BIBLIOGRÁFICAS....50
GLOSSÁRIO....G1
APÊNDICE A – EXCERTOS DE CÓDIGO-FONTE....A1
A.1 Anonimização à entrada (sistema/anonimizacao.py)....A1
A.2 Classificação em lote com o BERTimbau (sistema/classificador.py)....A1
APÊNDICE B – GUIA DE ANOTAÇÃO PADRONIZADO....B1
B.1 Identificação do projecto....B1
B.2 Objectivo da anotação....B1
B.3 Categorias....B1
B.3.1 Normal (rótulo Normal)....B1
B.3.2 Desinformação (rótulo Desinformacao)....B1
B.3.3 Discurso de ódio (rótulo Odio)....B2
B.3.4 Mobilização hostil (rótulo Mobilizacao)....B2
B.4 Casos limítrofes....B2
B.5 Regras de desempate e preenchimento....B2
APÊNDICE C – ACORDO ENTRE ANOTADORES....C1
C.1 Escala de interpretação....C1
C.2 Fórmulas....C1
C.3 Resultados....C1
C.4 Distribuição das etiquetas finais....C2
APÊNDICE D – DECLARAÇÃO DE CONSENTIMENTO E CONFIDENCIALIDADE DOS ANOTADORES....D1
APÊNDICE E – AMOSTRA ANOTADA DO CORPUS....E1
APÊNDICE F – MANUAL DE INSTALAÇÃO E UTILIZAÇÃO DO SISTEMA....F1
F.1 Instalação e configuração....F1
F.2 Arranque e utilização....F1
F.3 Linha de comandos....F1
F.4 Verificação dos requisitos....F2

ÍNDICE DE TABELAS

Tabela 1.1 – Correspondência entre objectivos específicos e hipóteses.....4
Tabela 2.1 – Algoritmos de classificação comparados.....9
Tabela 3.1 – Características do corpus angolano anotado, por categoria final.....16
Tabela 3.2 – Configuração dos modelos.....18
Tabela 3.3 – Requisitos do sistema.....20
Tabela 3.4 – Comparação das arquitecturas consideradas.....21
Tabela 4.1 – Composição do corpus harmonizado por fonte e categoria.....29
Tabela 4.2 – Desempenho dos modelos no conjunto de teste.....30
Tabela 4.3 – Comparações emparelhadas (ΔF1-macro e McNemar).....31
Tabela 4.4 – F1 por categoria e modelo; precisão e sensibilidade do BERTimbau.....32
Tabela 4.5 – Variantes do BERTimbau: validação, teste e comparação com a referência.....34
Tabela 4.6 – Efeito do ajuste de limiares no F1-macro.....35
Tabela 4.7 – Desempenho do BERTimbau no piloto angolano e no corpus público.....36
Tabela 4.8 – Calibração e ordenação no conjunto de teste.....38
Tabela 4.9 – Tempo de processamento do protótipo com o modelo do sistema.....41
Tabela 4.10 – Verificação formal das hipóteses de investigação.....42
Tabela 5.1 – Cumprimento dos objectivos específicos.....44
Tabela 5.2 – Quadro de uso responsável: salvaguardas do sistema e obrigações institucionais.....48
Tabela C.1 – Escala de interpretação do Kappa (Landis & Koch, 1977).....C1
Tabela C.2 – Acordo entre os três anotadores.....C1
Tabela C.3 – Acordo por par de anotadores e por categoria (base do piloto e lote de léxico, n = 2.443).....C2
Tabela C.4 – Distribuição das etiquetas finais do corpus angolano.....C2
Tabela E.1 – Amostra de comentários anotados.....E1
Tabela F.1 – Comandos do sistema.....F2
Tabela F.2 – Requisitos e testes automáticos.....F2

ÍNDICE DE FIGURAS

Figura 1.1 – Indicadores do ecossistema digital angolano (Outubro de 2025).....1
Figura 3.1 – Desenho da investigação.....13
Figura 3.2 – Construção do corpus híbrido e divisão em treino, validação e teste.....18
Figura 3.3 – Arquitectura em camadas do sistema de triagem.....22
Figura 3.4 – Modelo de dados do sistema.....24
Figura 3.5 – Diagrama de casos de uso (UML).....25
Figura 3.6 – Diagrama de sequência (UML): da recolha à revisão.....25
Figura 3.7 – Fila de revisão na aplicação web.....26
Figura 3.8 – Mapa por província na aplicação web.....26
Figura 4.1 – Curvas ROC um-contra-todos por categoria e modelo (conjunto de teste; AUC entre parêntesis).....31
Figura 4.2 – Matrizes de confusão (4 × 4) no conjunto de teste (contagens e percentagem por linha).....33
Figura 4.3 – F1 por categoria do BERTimbau no corpus público e no piloto angolano (conjunto de teste).....36
Figura 4.4 – Curva de esforço de revisão: ameaças encontradas em função da fila revista.....39

CAPÍTULO 1 – INTRODUÇÃO

1.1 Contextualização

As redes sociais deixaram de ser um lugar de convívio e passaram a ser um lugar onde se faz política. É nelas que muitos angolanos se informam, discutem o preço do pão e a falta de água, e combinam encontros. É também por elas que circulam boatos, ataques a grupos e convocatórias que podem pôr em risco a ordem pública. Daí que as plataformas digitais tenham entrado, em quase todos os países, na agenda da segurança nacional.

Em Angola a escala já não é marginal. Em Outubro de 2025 o país tinha cerca de 17,6 milhões de utilizadores da Internet (44,8% da população) e 5,50 milhões de identidades em redes sociais, ou seja, 14,0% da população (Kemp, 2025). O acesso faz-se sobretudo pelo telemóvel. A Figura 1.1 reúne estes indicadores.

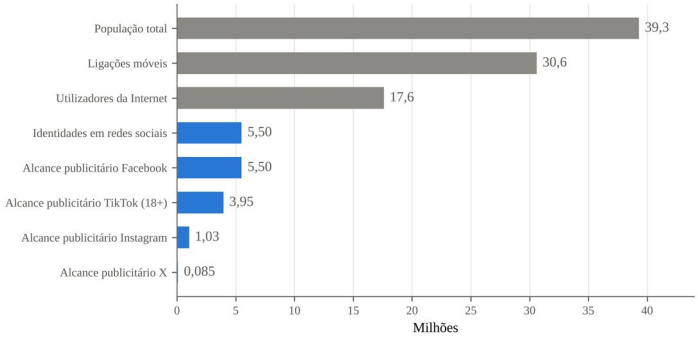


Figura 1.1 – Indicadores do ecossistema digital angolano (Outubro de 2025)

Fonte: elaborado a partir de Kemp (2025). Os valores de alcance publicitário não correspondem a utilizadores únicos.

A passagem da rede para a rua tem precedentes. A campanha "2022 Vais Gostar" começou no Facebook, no WhatsApp e no TikTok e acabou em manifestações em várias províncias (Hassane, 2021, pp. 37–38). Em 2022, as redes pesaram também no comportamento eleitoral dos jovens (Sambaca & Pessoa, 2026).

Mas o que se publica e o que acontece fora da rede não estão ligados de forma simples. Quase tudo o que se escreve sobre política, preços ou desporto é conversa legítima, às vezes dura, e só uma fracção pequena contém falsidades deliberadas, ataques a grupos ou apelos à violência. Esta desproporção tem dois efeitos. Procurar à mão é lento, porque obriga a ler muito para encontrar pouco. E um filtro automático, quando procura algo raro, tende a produzir mais falsos alarmes do que acertos, o que torna a verificação humana inevitável.

Para as estruturas de defesa e segurança, o obstáculo é o volume, e as ferramentas comerciais foram feitas para outras línguas e outros orçamentos. Faz falta um sistema que diga ao analista o que ler primeiro, que conheça o português de Angola e que trate os dados pessoais com regras claras.

1.2 Problema de investigação

O problema tem uma face técnica e outra operacional. Na técnica, não se encontrou nenhum classificador de conteúdos ameaçadores treinado e avaliado com dados angolanos. O BERTimbau, o modelo de linguagem de referência para o português (Souza et al., 2020), foi pré-treinado sobretudo com texto brasileiro, e os corpora anotados de discurso de ódio e desinformação em português são também brasileiros (Leite et al., 2020; Monteiro et al., 2018; Vargas et al., 2022). Ninguém sabe, por isso, quanto do desempenho publicado sobrevive quando o texto é angolano.

Na face operacional, mesmo um bom classificador erra, e os erros não pesam o mesmo. Tomar uma convocatória pacífica por mobilização hostil pode lesar direitos constitucionais; deixar passar um apelo à violência pode custar caro. Um sistema para a segurança nacional tem de ser desenhado a partir desta assimetria, com o analista humano no centro da decisão.

Daqui resulta a pergunta de partida: **em que medida um sistema baseado em aprendizagem automática consegue apoiar, de forma fiável e juridicamente responsável, a triagem de publicações ameaçadoras em redes sociais angolanas?**

A pergunta desdobra-se em quatro. As hipóteses da Secção 1.3 respondem às três primeiras (H1 à P1, H4 à P2 e H2 à P3). A P4 responde-se com o desenho do sistema e o quadro de uso responsável (OE4 e OE5), e a H3 decorre do OE4, a avaliação operacional do protótipo.

- **P1.** Que família de algoritmos classifica melhor as quatro categorias de ameaça, e a diferença é estatisticamente sólida?
- **P2.** Quanto se perde quando um modelo treinado sobretudo com texto brasileiro é aplicado a comentários angolanos, e onde se concentra a perda?
- **P3.** Um sistema construído com recursos modestos processa as publicações num tempo compatível com a triagem?
- **P4.** Como desenhar o sistema para que os erros do modelo não se tornem decisões sobre pessoas e para que o seu uso respeite o direito angolano?

1.3 Hipóteses de investigação

Cada hipótese tem um critério quantitativo fixado antes dos resultados.

H1. Os modelos de aprendizagem profunda (BERTimbau e Bi-LSTM) superam os modelos clássicos (SVM e Floresta Aleatória) na classificação das quatro categorias, com diferença de F1-macro de pelo menos 5 pontos percentuais e significância estatística ($p < 0,05$ no teste de McNemar com correcção de Bonferroni).

H2. O sistema processa cada publicação recolhida (importação, pseudonimização, classificação e entrada na fila de revisão) em menos de 60 segundos.

H3. O sistema detecta padrões de risco com pelo menos 48 horas de antecedência em relação a eventos de segurança documentados, numa validação retrospectiva com divisão cronológica dos dados.

H4. O desempenho do modelo seleccionado degrada-se significativamente (pelo menos 5 pontos percentuais de F1-macro) em conteúdo angolano, quando comparado com o conteúdo dos corpora públicos usados no treino.

1.4 Objectivos

1.4.1 Objectivo geral

Desenvolver e avaliar um sistema de apoio à triagem de publicações ameaçadoras em redes sociais angolanas, que combine um classificador de linguagem natural adaptado ao português com revisão humana obrigatória e com protecção de dados pessoais desde a concepção.

1.4.2 Objectivos específicos

- **OE1.** Construir um corpus de publicações públicas angolanas anotado em quatro categorias por três anotadores, medindo o acordo entre anotadores e registando a proveniência de cada lote de dados.
- **OE2.** Comparar quatro algoritmos de classificação (SVM, Floresta Aleatória, Bi-LSTM e BERTimbau) com intervalos de confiança e testes estatísticos emparelhados.
- **OE3.** Quantificar a diferença de desempenho entre o conteúdo angolano e o dos corpora públicos e identificar as suas causas prováveis.
- **OE4.** Desenvolver um protótipo de sistema de triagem com fila de revisão, painel do analista, serviço de inferência, alertas e mapa por província, e definir o protocolo da sua avaliação operacional.

- **OE5.** Propor um quadro de uso responsável do sistema, conforme a Lei n.º 22/11 de Protecção de Dados Pessoais e os direitos consagrados na Constituição da República de Angola.

A Tabela 1.1 liga os objectivos às hipóteses.

Tabela 1.1 – Correspondência entre objectivos específicos e hipóteses

Objectivo	Hipótese	Natureza
OE1. Corpus angolano anotado	n.a.	Construção de dados
OE2. Comparação de algoritmos	H1	Testável estatisticamente
OE3. Lacuna de domínio	H4	Testável estatisticamente
OE4. Protótipo do sistema	H2, H3	H2 testável; H3 com protocolo esboçado, não aplicado
OE5. Quadro ético e legal	n.a.	Normativo

1.5 Justificação e relevância

O português de Angola está quase ausente dos recursos de processamento de linguagem natural (PLN). Um corpus anotado de comentários angolanos, ainda que modesto, permite medir pela primeira vez o custo de aplicar modelos brasileiros a este domínio. Na prática, uma ferramenta que ordene as publicações pela probabilidade de serem problemáticas pode poupar tempo ao analista sem lhe tirar a decisão, poupança que aqui se mede em laboratório e não em operação; e, por usar só software livre num único servidor, cabe nos recursos disponíveis e deixa os dados sob controlo nacional.

Há ainda uma razão jurídica. Um sistema destes só é aceitável num Estado de direito com salvaguardas concretas: pseudonimização à entrada, registo de proveniência, prazos de conservação, auditoria e proibição de decisões automáticas sobre pessoas. O trabalho mostra que podem ser construídas no próprio software.

1.6 Delimitação e estrutura do estudo

O estudo trata texto em português publicado em espaços públicos: sobretudo comentários do YouTube, recolhidos pela interface oficial, e um conjunto menor de publicações copiadas à mão de páginas públicas. Ficaram de fora mensagens privadas, grupos fechados, conteúdo atrás de autenticação, imagens, áudio, vídeo e textos escritos só em línguas nacionais. Avalia-se o classificador e o protótipo; a integração institucional e a avaliação com analistas ficam para depois.

Seguem-se a revisão da literatura (Capítulo 2), a metodologia (Capítulo 3), os resultados e a sua discussão (Capítulo 4), as conclusões (Capítulo 5) e as recomendações (Capítulo 6).

CAPÍTULO 2 – REVISÃO DA LITERATURA

O capítulo segue o caminho do próprio problema: das redes sociais e do caso angolano às categorias de ameaça e aos sistemas existentes, depois aos recursos de linguagem, à avaliação e à generalização entre domínios, e por fim ao enquadramento ético e legal e à lacuna que justifica o trabalho.

2.1 Redes sociais: conceito, evolução e dimensão securitária

2.1.1 Conceito e evolução

Boyd e Ellison (2007) definem as redes sociais como serviços que permitem construir um perfil público, articular uma lista de contactos e percorrer as ligações dentro do sistema. A definição descreve bem a arquitectura, mas não o papel público que as plataformas vieram a ter. Em três décadas passou-se das redes de perfis e ligações declaradas (SixDegrees, Friendster, MySpace) para plataformas de conteúdo gerado pelos utilizadores e seguimento assimétrico (Facebook, YouTube, Twitter) e, por fim, para serviços móveis em que um algoritmo de recomendação escolhe o que cada pessoa vê (Instagram, TikTok, Telegram).

É esta última passagem que interessa à segurança. Quando o algoritmo premeia o envolvimento, o conteúdo que provoca indignação, medo ou raiva circula mais, seja qual for a intenção de quem o publica. Castells (2013) mostrou, a propósito da Primavera Árabe, que redes horizontais bastam para coordenar acção política sem passar pelos meios de comunicação tradicionais.

2.1.2 O ecossistema digital angolano

O ecossistema angolano cresce, mas está concentrado: 5,50 milhões de identidades em redes sociais numa população de 39,3 milhões, com o Facebook à frente em alcance e o TikTok em segundo (Kemp, 2025). Como os utilizadores se concentram nas cidades, sobretudo em Luanda, o que se discute em linha chega depressa às zonas mais densas e, por contacto pessoal, a quem não está ligado.

O peso político destes espaços está documentado. A campanha “2022 Vais Gostar” começou nas redes e terminou em manifestações simultâneas em várias províncias (Hassane, 2021, pp. 37–38), e as redes pesaram na participação política dos jovens nas eleições de 2022 (Sambaca & Pessoa, 2026). Marcon (2019) descreve uma juventude que se mobiliza pelas redes digitais com formas de protesto cada vez mais estéticas, feitas de imagem, som, escrita e performance, o que avisa qualquer classificador de que muito do que parece agitação é protesto legítimo. Ao mesmo tempo, a desinformação ganhou ferramentas novas, como conteúdos sintéticos

(*deepfakes*), contas automatizadas e campanhas coordenadas, usadas para influenciar eleições e dividir sociedades (Cintra, 2025, p. 101).

2.1.3 Inteligência de fontes abertas e de redes sociais

A recolha e a análise de informação publicada abertamente chamam-se, na literatura de segurança, inteligência de fontes abertas (OSINT). Na sua segunda geração, a fonte principal passou a ser o conteúdo gerado pelos utilizadores, e o problema deixou de ser o acesso para passar a ser a selecção (Williams & Blum, 2018). Omand, Bartlett e Miller (2012) chamam inteligência de redes sociais (SOCMINT) à aplicação destas práticas às plataformas digitais e defendem que obedeça aos princípios das outras formas de recolha de informações: causa suficiente, integridade do motivo, proporcionalidade e necessidade dos métodos, autoridade competente sujeita a supervisão, perspectiva razoável de sucesso e recurso a meios encobertos só quando as fontes abertas não bastam. No sistema proposto, estes princípios tornam-se regras de desenho: trabalhar com publicações e agregados, e não com pessoas; recolher só o que serve a finalidade; registar quem faz o quê (Secções 3.2 e 3.8).

2.2 Categorias de ameaças digitais

A taxonomia tem quatro categorias: Normal, Desinformação, Discurso de Ódio e Mobilização Hostil. Três critérios orientaram a escolha. As categorias tinham de cobrir as ameaças documentadas em Angola, de ser suficientemente distintas para treinar um classificador supervisionado e de ser compreensíveis para um analista sem formação em processamento de linguagem natural.

Desinformação é informação falsa ou enganosa partilhada com intenção de causar dano. Distingue-se do erro involuntário (*misinformation*) e da divulgação de informação verdadeira para prejudicar (*malinformation*) (Wardle & Derakhshan, 2017; Ireton & Posetti, 2018). A intenção, porém, raramente se vê num texto curto. Os anotadores apoiam-se, por isso, em sinais indirectos: a falta de fonte verificável, o apelo urgente à partilha, a atribuição de declarações a figuras públicas sem prova.

Discurso de ódio abrange conteúdos que promovem, incitam ou justificam a discriminação, a hostilidade ou a violência contra pessoas ou grupos com base em características identitárias, como a etnia, a religião, a origem regional, o género ou a orientação sexual (Conselho da Europa, 2022). A categoria vai do insulto explícito a formas implícitas, como o estereótipo apresentado como facto, que são muito mais difíceis de detectar (Fortuna & Nunes, 2018). Criar tensões entre grupos religiosos, raciais ou étnicos é um objectivo habitual de campanhas violentas em sociedades

multiculturais (Elias, 2019, p. 85). Num país com dezenas de grupos etnolinguísticos, o discurso que opõe grupos entre si tem relevância securitária própria.

Mobilização hostil designa publicações que organizam, coordenam ou incitam à participação em acções ilegais ou violentas, ou que ameaçam a ordem pública. A categoria é uma construção desta dissertação. O seu fundamento empírico é duplo: a mobilização a partir das redes está documentada no caso angolano (Hassane, 2021), e o uso das redes para recrutar, incitar e mobilizar para a violência está documentado no caso do terrorismo (Sette Câmara, 2016, pp. 202–209; Elias, 2019). É também a categoria mais delicada, porque a fronteira com a liberdade de expressão e de manifestação, garantidas pelos artigos 40.º e 47.º da Constituição (República de Angola, 2010), é fina. O guia de anotação (Apêndice B) exige três elementos em conjunto: coordenação explícita, linguagem coerciva ou de violência e ausência de referência ao carácter pacífico e legal da acção. Faltando um, a publicação é Normal.

A noção de **discurso perigoso** (Benesch, 2012) ajuda a perceber o limite de qualquer classificador nesta categoria. O discurso perigoso é o que aumenta a probabilidade de o público aceitar ou cometer violência contra outro grupo, e avalia-se pelo orador, pelo público, pela mensagem, pelo contexto e pelo meio. O classificador só vê a mensagem; os outros quatro factores ficam com o analista.

Normal é a categoria residual: crítica política, humor, jornalismo, conversa quotidiana.

2.3 Sistemas de monitorização de ameaças

Os sistemas internacionais mostram o que é possível e porque não se transpõem para Angola. O programa MediFor, da agência norte-americana DARPA, desenvolveu métodos forenses para detectar imagens e vídeos manipulados (Defense Advanced Research Projects Agency, 2016), mas é investigação governamental, sem transferência para países terceiros nem atenção ao português. O Palantir Gotham é uma plataforma comercial de planeamento de missões e de investigação sobre dados heterogéneos, desenvolvida com agências militares, de informações e policiais (Palantir Technologies, 2024). O custo pesa, mas pesa mais a dependência de um fornecedor e de uma infra-estrutura externos para guardar dados sensíveis.

O EU DisinfoLab publica investigações de redes de desinformação baseadas em fontes abertas, com o método documentado (EU DisinfoLab, 2020); o método transfere-se, o contexto não. A INTERPOL acompanha as ciberameaças em África através de relatórios periódicos (INTERPOL, 2023), sem uma componente automática de análise de texto em português. Monaco e Arnaudo (2020) lembram que a

monitorização de redes por entidades públicas exige, além da tecnologia, regras claras sobre o que se recolhe, quem acede e como se decide.

A análise de redes oferece um complemento que este trabalho não explora. Medidas como a centralidade de grau, a centralidade de intermediação e a densidade revelam contas influentes, pontes entre comunidades e padrões de publicação coordenada (Thelwall, 2009; Freire, 2015), e a propaganda computacional recorre precisamente a contas automatizadas e a publicação sincronizada para simular apoio popular (Woolley & Howard, 2017). O protótipo trabalha ao nível da publicação individual; a dimensão relacional fica como extensão (Capítulo 6).

2.4 Recursos e modelos de linguagem para o português

2.4.1 Corpora anotados

Um classificador supervisionado só aprende o que os corpora anotados lhe mostram, e a qualidade e o alcance desses corpora condicionam o resultado (Poletto et al., 2021). Para o português há três recursos públicos relevantes, todos brasileiros:

- o **ToLD-BR**, com cerca de 21 mil publicações do Twitter anotadas para várias formas de linguagem tóxica, incluindo ataques baseados em identidade (Leite et al., 2020);
- o **HateBR**, com 7 mil comentários do Instagram anotados por especialistas para linguagem ofensiva e discurso de ódio (Vargas et al., 2022);
- o **Fake.br**, com 7.200 notícias completas, metade verdadeiras e metade falsas, emparelhadas por tema (Monteiro et al., 2018).

Nenhum inclui mobilização hostil e nenhum contém texto angolano. Mais grave para a Desinformação: a única fonte disponível são notícias completas, um género textual muito diferente do comentário curto. Esta diferença vai pesar na leitura dos resultados (Secção 4.6).

2.4.2 Modelos de linguagem

O BERT (Devlin et al., 2018) introduziu o pré-treino de codificadores *Transformer* (Vaswani et al., 2017) com um objectivo de modelação de linguagem mascarada, seguido de ajuste fino para cada tarefa. O BERTimbau aplica a mesma receita ao corpus brWaC, uma colecção de páginas web brasileiras com cerca de 2,7 mil milhões de *tokens*, e obteve resultados de referência em várias tarefas de PLN em português (Souza et al., 2020).

O vocabulário do BERTimbau é de subpalavras (*WordPiece*). Uma palavra desconhecida não é descartada: parte-se em fragmentos conhecidos. É o que acontece

ao calão de Luanda, como *kota*, *bué* ou *mujimbo*, e aos empréstimos do kimbundu, que ficam representados por sequências de fragmentos sem significado próprio. Gururangan et al. (2020) mostram que continuar o pré-treino com texto do domínio (*domain-adaptive pretraining*) melhora o desempenho em domínios afastados do original, uma via que fica para trabalho futuro.

Há duas alternativas. Os modelos multilingues, como o XLM-R, partilham conhecimento entre cerca de uma centena de línguas, à custa de menor capacidade para cada uma (Conneau et al., 2020). Os modelos pré-treinados com português europeu, como o Albertina PT-PT (Rodrigues et al., 2023), escrevem numa norma mais próxima da angolana; se perdem menos em comentários angolanos é uma pergunta em aberto.

2.5 Algoritmos de classificação de texto

Os quatro algoritmos comparados representam três gerações de métodos (Tabela 2.1).

Tabela 2.1 – Algoritmos de classificação comparados

Algoritmo	Representação do texto	Pontos fortes	Limitações
SVM	TF-IDF (saco de palavras e n-gramas)	Eficaz em espaços esparsos de alta dimensão; rápido em CPU	Ignora a ordem e o contexto das palavras
Floresta Aleatória	TF-IDF	Robusta ao sobreajuste; permite analisar a importância dos termos	Ignora a ordem; menos eficaz em espaços muito esparsos
Bi-LSTM	Sequência de *embeddings* aprendidos	Modela a ordem e dependências nos dois sentidos	Precisa de mais dados; sem pré-treino em grande escala
BERTimbau	Subpalavras com contexto (*Transformer*)	Pré-treino em português; contexto bidireccional	Custo computacional; GPU recomendada para treino

Nota. Elaborado a partir de Cortes e Vapnik (1995), Joachims (1998), Breiman (2001), Hochreiter e Schmidhuber (1997), Schuster e Paliwal (1997) e Souza et al. (2020).

As Máquinas de Vectores de Suporte (Cortes & Vapnik, 1995) procuram o hiperplano que separa as classes com a maior margem e são, desde Joachims (1998), a referência para classificar texto com representações TF-IDF. A Floresta Aleatória (Breiman, 2001) combina muitas árvores de decisão treinadas com amostras e subconjuntos de variáveis diferentes e serve de segunda referência clássica.

As redes LSTM (Hochreiter & Schmidhuber, 1997) foram concebidas para captar dependências longas, e a versão bidireccional (Schuster & Paliwal, 1997) lê a frase nos dois sentidos. Numa convocatória, a informação decisiva (a hora, o local, o apelo final) pode estar em qualquer ponto do texto, o que dá a esta arquitectura uma

vantagem teórica. O BERTimbau junta o contexto bidireccional ao conhecimento adquirido no pré-treino. Comparar os dois dá uma indicação sobre o peso do pré-treino, mas não o isola, porque os modelos diferem também na tokenização, no comprimento de entrada e na capacidade.

2.6 Avaliação de classificadores

Com classes desequilibradas, a exactidão engana: um modelo que chame Normal a tudo pode ter exactidão alta e não servir para nada. A métrica deve reflectir o custo dos erros (Sokolova & Lapalme, 2009). Por isso a métrica principal é o **F1-macro**, a média simples do F1 de cada categoria, que dá à Mobilização Hostil, a mais rara, o mesmo peso que à Normal. Reportam-se também o F1 ponderado, a exactidão, a área sob a curva ROC (AUC-ROC) e o Kappa de Cohen entre previsões e referência (Cohen, 1960).

Uma diferença num conjunto de teste pode ser obra do acaso. Os intervalos de confiança por *bootstrap* reamostram o teste com reposição e recalculam a métrica, o que dá uma medida dessa incerteza (Efron & Tibshirani, 1993). Para comparar dois classificadores no mesmo teste, Dietterich (1998) recomenda o teste de McNemar (McNemar, 1947), que olha apenas para os casos em que um acerta e o outro erra. Com várias comparações, a correcção de Bonferroni multiplica cada valor de p pelo número de comparações e controla o risco de encontrar uma diferença espúria.

O acordo entre anotadores mede a fiabilidade das próprias etiquetas. O Kappa de Cohen (Cohen, 1960) aplica-se a pares de anotadores e o de Fleiss (Fleiss, 1971) a mais de dois; ambos descontam a concordância esperada ao acaso, e a escala de Landis e Koch (1977) é a referência para os interpretar.

Quando as previsões servem para ordenar trabalho humano, contam também as probabilidades. Um classificador está **calibrado** quando, entre as previsões feitas com 80% de confiança, cerca de 80% estão certas; as redes neuronais modernas tendem a ser demasiado confiantes (Guo et al., 2017). A calibração mede-se com o erro de calibração esperado (ECE), a diferença média entre confiança e acertos por intervalo (Naeini et al., 2015), e com o índice de Brier (Brier, 1950). A ordenação mede-se com a precisão nos primeiros K itens e a precisão média (Manning et al., 2008), ou com a curva de esforço, que relaciona a fracção de ameaças encontradas com a fracção da fila revista. Para proporções pequenas, como a de ameaças entre os itens considerados normais, usa-se o intervalo de Wilson (1927).

2.7 Generalização entre domínios e aprendizagem de atalhos

Um modelo pode ser excelente no corpus onde foi treinado e falhar noutro. Fortuna, Soler-Company e Wanner (2021) mostram que os classificadores de discurso de ódio e de linguagem ofensiva generalizam mal entre conjuntos de dados, e que a generalização depende do modelo, das categorias usadas no treino e no teste e da proporção de vocabulário fora do domínio. Geirhos et al. (2020) dão nome ao mecanismo geral, a aprendizagem de atalhos (*shortcut learning*): o modelo aprende uma regularidade que separa as classes no treino, como o comprimento ou o estilo, em vez da propriedade que se quer detectar. Textos numa variedade linguística pouco representada no treino são, além disso, marcados como ofensivos com mais frequência (Sap et al., 2019), e a linguagem ofensiva confunde-se facilmente com ódio (Davidson et al., 2017). É razoável esperar um efeito parecido entre o português do Brasil e o de Angola.

Daqui resultam duas precauções. O desempenho medido num teste dominado por dados brasileiros não é desempenho em Angola, e a H4 existe para medir essa diferença. E quando uma categoria vem de uma única fonte com estilo muito marcado, como a Desinformação do Fake.br, o modelo pode estar a aprender o estilo; a Secção 4.6 procura sinais disso.

2.8 Aspectos éticos, legais e de direitos humanos

Monitorizar redes sociais para fins de segurança põe frente a frente a segurança colectiva e os direitos de expressão, reunião e privacidade, e o conflito resolve-se com regras, não com técnica. O quadro angolano começa na Constituição, que garante a liberdade de expressão e de informação (artigo 40.º) e a de reunião e manifestação (artigo 47.º) (República de Angola, 2010). A Lei n.º 22/11, de 17 de Junho, de Protecção de Dados Pessoais, impõe os princípios de finalidade, proporcionalidade, minimização e conservação limitada (República de Angola, 2011), e a Lei n.º 7/17, de 16 de Fevereiro, de Protecção das Redes e Sistemas Informáticos, condiciona a forma como os dados são obtidos (República de Angola, 2017). A Lei n.º 22/11 trata como sensíveis os dados que revelam convicções políticas e sujeita o seu tratamento a requisitos acrescidos e ao controlo da autoridade de protecção de dados. Ora, uma publicação sobre política pode revelar essas convicções mesmo depois de pseudonimizada. Daí que um parecer jurídico seja indispensável antes de qualquer uso institucional; a própria investigação tratou estes dados sem esse parecer, apenas com pseudonimização e minimização. Os termos de utilização das plataformas juntam uma camada contratual que tem de ser respeitada e declarada.

A Recomendação da UNESCO sobre a Ética da Inteligência Artificial pede proporcionalidade, transparência, auditabilidade e supervisão humana, e a prevenção de resultados discriminatórios (UNESCO, 2021). O Regulamento Europeu da Inteligência Artificial classifica vários usos de IA na aplicação da lei como de risco elevado (União Europeia, 2024). Não vincula Angola, mas oferece uma medida de boas práticas. Destes princípios saem as salvaguardas do sistema (Secção 3.2): só conteúdo público, pseudonimização antes de gravar, nenhum perfil individual, revisão humana obrigatória e auditoria de todas as acções.

2.9 Revisão humana e segurança da informação

Pôr uma pessoa no circuito não chega. Parasuraman e Manzey (2010) descrevem a complacência e o viés de automação: o operador deixa de verificar o que o sistema costuma fazer bem, e a sugestão acaba por substituir o seu juízo, sobretudo quando está sobrecarregado. O sistema responde com três contramedidas: esconder a sugestão numa parte da fila para medir o acordo (revisão cega), rever periodicamente uma amostra do que o modelo considerou inofensivo (amostra de controlo) e mostrar ao analista as limitações do modelo (Mitchell et al., 2019). As decisões dos analistas tornam-se, por sua vez, etiquetas novas para treinar de novo o modelo (Amershi et al., 2014; Settles, 2009).

Um sistema que guarda conteúdos sensíveis é também um alvo. As falhas de controlo de acesso, as falhas criptográficas, a injecção e as falhas de autenticação estão entre os riscos mais frequentes das aplicações web (OWASP Foundation, 2021). O NIST recomenda palavras-passe longas em vez de regras de composição, limite de tentativas, segredos nunca guardados em claro e uma recuperação de acesso tão cuidada como a própria autenticação (Grassi et al., 2017). A gestão de contas do sistema segue estas regras (Secção 3.8.6).

2.10 Síntese e lacuna de investigação

A literatura deixa três pontos assentes. Os sistemas internacionais não estão disponíveis, não cobrem o português de Angola ou criam dependência externa. Os recursos de PLN para o português são brasileiros e, na desinformação, pertencem a outro género textual. E sabe-se que os classificadores de conteúdo nocivo perdem desempenho fora do domínio de treino, mas ninguém mediu essa perda para Angola.

A dissertação ataca as duas faltas: mede, com dados angolanos anotados, o desempenho real dos modelos e propõe um sistema que os usa à medida das suas limitações, como apoio à triagem e não como decisor.

CAPÍTULO 3 – METODOLOGIA

O capítulo descreve o que foi feito e porquê: o desenho da investigação, as salvaguardas éticas, a recolha e a anotação dos dados, o corpus de treino, os modelos, o protocolo de avaliação e a arquitectura do sistema que põe o modelo ao serviço do analista.

3.1 Paradigma e desenho da investigação

A investigação é aplicada e de orientação pragmática, com abordagem sobretudo quantitativa. As hipóteses H1 e H4 testam-se com métricas de classificação e testes estatísticos. A H2 e a H3 dependem do sistema em funcionamento: o protocolo da H2 define-se aqui, o da H3 fica apenas esboçado. O protótipo, enquanto peça de engenharia, é verificado por testes automáticos (Secção 4.8.4).

O trabalho teve três fases (Figura 3.1). Na primeira recolheram-se e anotaram-se comentários angolanos e construiu-se o corpus híbrido. Na segunda treinaram-se e compararam-se quatro classificadores. Na terceira construiu-se o protótipo, cujas revisões humanas podem voltar a alimentar o treino.

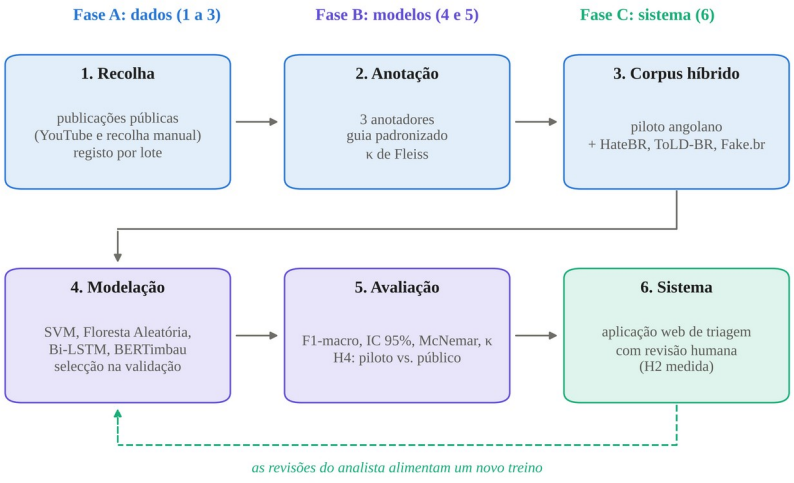


Figura 3.1 – Desenho da investigação

3.2 Considerações éticas e protecção de dados

Trabalhar com redes sociais para fins de segurança exige regras fixadas antes de recolher o primeiro comentário. As que se adoptaram decorrem da Lei n.º 22/11 e dos princípios da Secção 2.8:

- **Só conteúdo público.** Comentários do YouTube obtidos pela interface oficial e publicações copiadas à mão de páginas acessíveis sem autenticação. Nada de

mensagens privadas, grupos fechados, conteúdo atrás de autenticação ou contorno de protecções técnicas.

- **Pseudonimização antes de gravar.** O nome do autor é substituído por um pseudónimo que não se reverte sem um segredo guardado fora do código, e os identificadores directos no texto (endereços web, correio electrónico, telefones, menções a utilizadores) são mascarados. Em rigor jurídico, isto é pseudonimização e não anonimização: impede identificar o autor, mas permite ligar publicações do mesmo autor. Os nomes de pessoas privadas referidos no texto devem dar lugar a descritores do papel ou da instituição; os de instituições e figuras políticas mantêm-se, porque contam para a classificação. No lote temático de vídeos, cinco nomes próprios cuja natureza pública ou privada não foi determinada ficaram no corpus v13 e entraram nos dois treinos, incluindo o do modelo do protótipo (Secção 4.5.1). É um desvio à regra, declarado. Como o lote só entra no treino, as métricas de teste não são afectadas.
- **Proveniência registada.** Cada lote fica associado à plataforma, à via de obtenção, à data e ao volume.
- **Sem perfis individuais.** O sistema mostra agregados por categoria, período e plataforma; não há vistas por autor.
- **Revisão humana obrigatória.** A classificação só ordena o trabalho. Nenhuma acção sobre pessoas pode apoiar-se apenas no sistema.
- **Conservação limitada e auditoria.** As publicações não revistas são apagadas após um prazo configurável, e todas as acções ficam registadas.
- **Consentimento dos anotadores.** Os três anotadores assinaram uma declaração de consentimento e confidencialidade (Apêndice D).

Os termos de utilização das plataformas e a Lei n.º 7/17 pedem parecer jurídico antes de qualquer uso institucional (Capítulo 6).

3.3 Recolha de dados do piloto angolano

A maior parte dos dados angolanos veio do YouTube. Os principais órgãos de comunicação e criadores de conteúdo do país publicam ali vídeos sobre política, economia e sociedade, e os comentários são públicos e acessíveis por uma interface oficial (YouTube Data API v3). A recolha teve quatro passos, implementados em *scripts* Python: descobrir vídeos por termos da actualidade angolana; sondar uma pequena amostra de comentários de cada vídeo para estimar a proporção de comentários angolanos; escolher os vídeos, privilegiando a diversidade de canais e

temas; e recolher comentários e respostas, com limite por vídeo e pseudonimização dos autores antes de gravar.

A quota diária da interface (10.000 unidades; 100 por pesquisa e 1 por pedido de comentários) ditou o ritmo. Para não contaminar a comparação com os corpora brasileiros (H4), retiraram-se os casos explicitamente não angolanos, como comentários em vídeos de outros países ou de autores que se declaram de fora. Os casos duvidosos ficaram, o que, quando muito, torna a estimativa da lacuna conservadora.

Uma parte menor veio de recolha manual: 180 títulos e entradas de notícias de sete órgãos de comunicação angolanos e 194 publicações e comentários copiados de páginas públicas, incluindo o Facebook. Passaram pela mesma pseudonimização e pela mesma anotação. No corpus, o piloto tem três origens, registadas na coluna *origem*:

- **Base do piloto** (*ate_v11*): 2.352 itens, dos quais 1.978 comentários sorteados dos vídeos recolhidos e 374 itens de recolha manual. São os únicos dados angolanos usados na validação e no teste. Os 374 itens manuais não foram sorteados, foram escolhidos pelo investigador, e isso pesa na leitura dos resultados do piloto.
- **Lote temático de vídeos** (*enriquecido_video_tema*): 284 comentários de vídeos escolhidos por tratarem temas propícios a mobilização ou a ódio; retiraram-se 90 por não serem angolanos e ficaram 194.
- **Lote orientado por léxico** (*enriquecido_lexico*): 91 comentários priorizados por conterem termos de um léxico de candidatos.

Os dois lotes enriquecidos não são aleatórios e, por isso, entraram **só no treino**. Usá-los na avaliação inflacionaria as métricas e enviesaria a H4.

3.4 Anotação e acordo entre anotadores

Três anotadores independentes, dois angolanos e um com formação em processamento de linguagem natural, seguiram o Guia de Anotação Padronizado (Apêndice B). Cada um atribuiu a cada publicação uma das quatro categorias, sem ver as escolhas dos outros nem as previsões de qualquer modelo. Nos desacordos prevaleceu a etiqueta mais grave escolhida por qualquer anotador (Mobilização Hostil > Discurso de Ódio > Desinformação > Normal). A regra transpõe para a agregação o critério de desempate que o guia dá a cada anotador (Apêndice B.5) e parte de um juízo sobre custos: num contexto de segurança, um falso positivo que vai ser revisto custa menos do que um falso negativo.

O acordo mediu-se com o Kappa de Fleiss para os três anotadores e com o de Cohen para cada par. Nos 2.443 itens da base do piloto e do lote orientado por léxico, o κ de Fleiss foi de 0,718 (IC 95%: 0,695–0,741), o κ de Cohen médio de 0,719 e a concordância observada de 81,3%: acordo substancial na escala de Landis e Koch (1977). Só na base do piloto (n = 2.352), o κ de Fleiss é de 0,717. No lote temático, o κ foi de 0,818 (IC 95%: 0,763–0,869), mas calculado sobre os 284 comentários antes de retirar os 90 não angolanos e numa amostra escolhida por tema, com outra distribuição de categorias; não é comparável. O Apêndice C dá os pormenores.

O corpus anotado tem 2.637 publicações: Normal 1.664, Mobilização Hostil 364, Desinformação 326 e Discurso de Ódio 283. Depois da harmonização e da remoção de duplicados (Secção 3.5), entram no corpus híbrido 2.573 registos do piloto. A Tabela 3.1 descreve-o por categoria.

Tabela 3.1 – Características do corpus angolano anotado, por categoria final

Categoria final	n	Palavras: mediana [Q1; Q3]	Decisão unânime	Decidida por um só voto
Normal	1.664	8 [4,0; 18,0]	100,0%	0 (0,0%)
Desinformação	326	21 [12,0; 34,0]	44,2%	106 (32,5%)
Discurso de Ódio	283	16 [8,5; 27,5]	56,9%	75 (26,5%)
Mobilização Hostil	364	16 [7,0; 24,0]	49,7%	116 (31,9%)
Total	**2.637**	11 [5,0; 22,0]	81,5%	297 (11,3%)

Nota. "Decidida por um só voto": só um dos três anotadores escolheu a categoria final, que prevaleceu pela regra da gravidade. Por construção, um item só é Normal quando os três anotadores o consideram Normal.

A tabela mostra três coisas que vão pesar nos resultados. Primeiro, a regra da gravidade concentra o desacordo nas categorias de ameaça: todos os Normais são unânimes, mas nas ameaças só 44% a 57% das decisões o são, e 297 itens (11,3% do corpus) são ameaças pelo voto de um único anotador. A regra favorece a sensibilidade, como convém à triagem, mas mete ruído nas etiquetas. Segundo, as ameaças têm cerca do dobro das palavras das publicações normais, uma regularidade que um classificador pode aprender como atalho (Secção 2.7). Terceiro, as marcas lexicais da variedade angolana são raras: só 0,3% das publicações contêm algum de 28 termos frequentes no calão de Luanda (como *bué*, *kota*, *mujimbo* ou *zungueira*), e só 96 (3,6%) mencionam uma província ou cidade reconhecida pelo sistema, 65 delas Luanda. O que torna estes comentários angolanos são os temas e as referências, não o vocabulário.

Os desacordos mostram onde está a dificuldade. "Podemos paralizar mais não vandalisar prk faz recuar o país" foi Normal para dois anotadores e Mobilização Hostil para um, e ficou Mobilização pela regra da gravidade, embora o pedido expresso para não vandalizar o aproxime de um protesto pacífico. "MANOS ANGOLANOS

VAMOS TIRAR ESSE FEITICEIRO DO PODER” foi ódio para dois e mobilização para um. A amostra do Apêndice E mostra ainda que os anotadores aplicaram por vezes critérios mais amplos do que os do guia, mesmo em itens unânimes: apelos genéricos sem linguagem violenta como Mobilização Hostil, insultos a partidos como Discurso de Ódio, alegações não verificadas como Desinformação. As categorias do piloto não são, por isso, inteiramente equivalentes às dos corpora públicos. Esta diferença de construto é uma explicação concorrente para a lacuna medida na Secção 4.6, e um modelo treinado com estas etiquetas herda a sua incerteza.

O léxico de candidatos usado para priorizar a anotação foi avaliado nos próprios dados. No lote temático, só 27% dos comentários que o léxico assinalava como possível mobilização (33 em 123) foram classificados como Mobilização Hostil, contra 61% (17 em 28) no discurso de ódio; num controlo de 45 comentários sem termos do léxico, não houve nenhum caso de mobilização. O léxico serve para encontrar casos raros, não para os rotular, e não foi usado como fonte de etiquetas.

3.5 Construção do corpus híbrido

O piloto, sozinho, é pequeno demais para treinar um classificador de quatro categorias. Juntou-se-lhe os três corpora públicos da Secção 2.4.1, com as etiquetas originais mapeadas para as quatro categorias. No ToLD-BR, os tweets com ataque a uma identidade passaram a Discurso de Ódio, os tweets sem marcação a Normal, e os tóxicos apenas por obscenidade ou insulto sem alvo identitário foram excluídos. No HateBR, a versão disponível só tem a etiqueta binária de linguagem ofensiva: os comentários ofensivos passaram a Discurso de Ódio e os restantes a Normal. Esta escolha alarga a categoria, porque parte dos exemplos públicos de ódio são insultos sem alvo identitário. No Fake.br, as notícias falsas passaram a Desinformação e as verdadeiras a Normal. Usou-se a partição de treino que cada corpus disponibiliza no Hugging Face, o que, com as exclusões do ToLD-BR, explica que os totais da Tabela 4.1 fiquem abaixo das dimensões originais (cerca de 21 mil no ToLD-BR e 7 mil no HateBR).

Da junção resultaram 27.097 registos; retirados 238 duplicados exactos, ficaram 26.859 (Tabela 4.1). A divisão foi estratificada por categoria: cerca de 70% para treino e 15% para cada um dos conjuntos de validação (3.986) e de teste (3.987). Os 285 itens dos lotes enriquecidos ficaram, por construção, no treino, e o teste usou-se uma única vez, no fim, para cada modelo e variante (Figura 3.2).

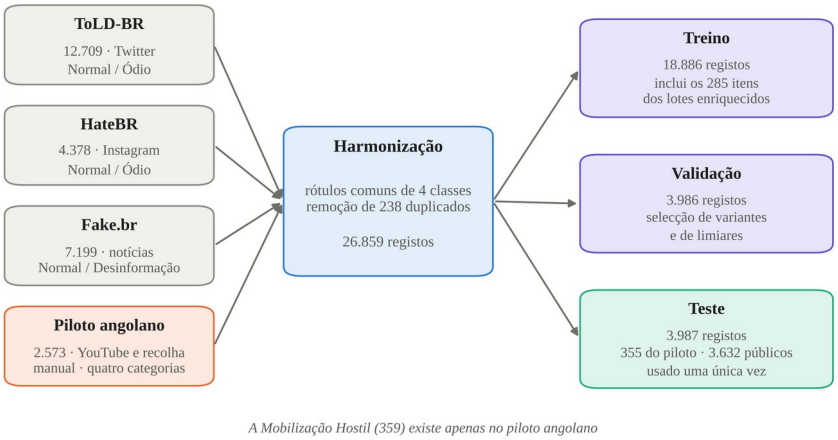


Figura 3.2 – Construção do corpus híbrido e divisão em treino, validação e teste

Dois desequilíbrios estruturais ficam desde já à vista. A Mobilização Hostil só existe no piloto e tem 47 exemplos no teste, o que torna as estimativas desta categoria instáveis. E cerca de 91% do teste vem de corpora brasileiros, pelo que as métricas globais descrevem sobretudo conteúdo brasileiro. A H4 foi formulada para separar os dois domínios.

3.6 Modelos e treino

3.6.1 Pré-processamento e representação

O pré-processamento foi mínimo, de propósito. O BERTimbau recebe o texto original, com pontuação e maiúsculas, e usa o seu próprio tokenizador de subpalavras. O Bi-LSTM passa o texto a minúsculas, divide-o em palavras e aprende as suas representações no treino. Os modelos clássicos usam uma representação TF-IDF limitada aos 5.000 termos mais frequentes do treino.

3.6.2 Configuração dos modelos

O desequilíbrio entre classes tratou-se de duas formas. Nos modelos clássicos, aplicou-se SMOTE (Chawla et al., 2002) ao espaço TF-IDF do treino, gerando exemplos sintéticos das classes minoritárias; validação e teste mantêm a distribuição original. Nos modelos neuronais, em vez de criar exemplos, pesou-se a função de perda pelo inverso da frequência de cada classe (Tabela 3.2).

Tabela 3.2 – Configuração dos modelos

Modelo	Configuração
SVM	TF-IDF (5.000 termos); SVM linear (LinearSVC); SMOTE no treino
Floresta Aleatória	TF-IDF (5.000 termos); 300 árvores; SMOTE no treino

Modelo	Configuração
Bi-LSTM	*Embeddings* de dimensão 100 treinados de raiz; LSTM bidireccional com 128 unidades; até 128 palavras por texto; lote 32; taxa de aprendizagem 10^{-3}; até 15 épocas com paragem antecipada (3 épocas sem melhoria do F1-macro de validação); entropia cruzada ponderada
BERTimbau	neuralmind/bert-base-portuguese-cased com ajuste fino completo e cabeça de 4 saídas; até 256 subpalavras; lote 16; taxa de aprendizagem 2×10^{-5}; 3 épocas, retendo a época com melhor F1-macro de validação; entropia cruzada ponderada

Nota. Valores por omissão dos *scripts* train_baseline.py, train_bilstm.py e train_bertimbau.py, usados sem alteração na corrida de referência. A semente aleatória é 42 em todos os modelos.

O BERTimbau foi treinado três vezes, com as sementes 42, 43 e 44, para medir a variabilidade devida à inicialização; a semente 42 foi fixada como referência antes das outras execuções. Testaram-se ainda três variantes: a média das probabilidades das três sementes (*ensemble*), o treino sem o lote temático (ablação) e pesos de classe suavizados (expoente 0,5 sobre o inverso da frequência). Os modelos de referência foram também treinados com as sementes 43 e 44, num caderno que reconstrói a divisão e confirma, pela impressão digital das etiquetas, que o teste é o mesmo.

3.6.3 Ambiente de desenvolvimento

O desenvolvimento fez-se em Windows 11 com Python 3.11. Os modelos profundos foram treinados no Google Colab, com uma GPU NVIDIA T4 de 16 GB, usando PyTorch, Hugging Face Transformers e scikit-learn. O sistema assenta em FastAPI, Jinja2 e Uvicorn, guarda os dados em SQLite 3 e está versionado em Git, no repositório dissertacao-uan-angola; as versões exactas das bibliotecas constam do ficheiro requirements.txt.

3.7 Protocolo de avaliação

As regras de avaliação foram fixadas antes de se conhecerem os resultados de teste.

- **Métrica principal:** F1-macro no conjunto de teste, com IC 95% por *bootstrap* não paramétrico (2.000 reamostragens).
- **Métricas complementares:** F1 ponderado, exactidão, Kappa de Cohen entre previsões e referência, AUC-ROC média das quatro curvas um-contra-todos, e precisão, sensibilidade e F1 por categoria.
- **Comparação de modelos (H1):** teste de McNemar com correcção de continuidade para os seis pares de modelos, com correcção de Bonferroni ($\alpha = 0{,}05/6 \approx 0{,}0083$), e IC 95% da diferença de F1-macro por *bootstrap* emparelhado.

- **Selecção de variantes:** feita na validação. Uma variante só substitui a referência se se distinguir dela; os resultados de teste são reportados para todas, sem escolha pelo teste.
- **Ajuste de limiares:** vieses por classe escolhidos na validação, com o ganho esperado estimado por validação cruzada dentro da validação; o resultado principal é sempre o sem ajuste.
- **Lacuna de domínio (H4):** o teste divide-se em subconjunto do piloto e subconjunto dos corpora públicos; compara-se o F1-macro (com IC 95%) e o Kappa em cada um, e repete-se a comparação nas três categorias comuns, para neutralizar a ausência de Mobilização Hostil no corpus público.

O protocolo das hipóteses H2 e H3, que dependem do sistema, está na Secção 3.9.

3.8 Arquitectura do sistema

3.8.1 Requisitos

A arquitectura foi desenhada depois de conhecidos os resultados do Capítulo 4, e é deles que parte. Um classificador com F1-macro de cerca de 0,80 no teste global, de cerca de 0,53 em conteúdo angolano e com precisão de cerca de 0,51 na Mobilização Hostil não pode decidir, mas pode ordenar o trabalho de quem decide. Os requisitos da Tabela 3.3 traduzem esta conclusão.

Tabela 3.3 – Requisitos do sistema

Código	Requisito
RF1	Recolher publicações de fontes públicas registadas: comentários do YouTube pela interface oficial e artigos de sítios de notícias e feeds RSS que não exigem conta
RF2	Importar lotes de ficheiros de outras vias, registando a proveniência de cada lote
RF3	Pseudonimizar autores e mascarar identificadores directos antes de gravar
RF4	Guardar lotes, publicações, classificações, revisões e auditoria numa base de dados relacional
RF5	Classificar as publicações em lote com o modelo seleccionado
RF6	Apresentar uma fila de revisão ordenada por prioridade
RF7	Registar a decisão do analista e exportá-la para novo treino
RF8	Calcular métricas operacionais: precisão nos primeiros K, κ analista–sistema e entre analistas, sensibilidade estimada, latência
RF9	Controlar o acesso por contas individuais com dois papéis (analista e supervisor)
RF10	Permitir a avaliação independente por vários analistas, com revisão cega e amostra de controlo
RF11	Gerar alertas a partir de ameaças confirmadas por analistas e de tendências de crescimento, na aplicação e por e-mail

Código	Requisito
RF12	Mostrar num mapa, por província, a concentração e a evolução das ameaças no período escolhido
RF13	Produzir o relatório de alertas de ameaças de um período, para impressão, exportação e envio por e-mail
RF14	Mostrar a ficha do modelo em uso: desempenho global, por categoria e em conteúdo angolano, limitações e acordo observado com os analistas
RF15	Oferecer um modo de demonstração com dados fictícios, numa base de dados separada da real
RF16	Percorrer periodicamente as fontes activas, recolhendo apenas publicações novas, com estimativa do consumo da quota do YouTube
RF17	Permitir recuperar o acesso a uma conta sem serviços externos
RNF1	Funcionar num único servidor, com software livre e sem serviços externos obrigatórios
RNF2	Conformidade com a Lei n.º 22/11: minimização, pseudonimização, conservação limitada, auditoria
RNF3	Substituir o modelo sem alterar o resto do sistema
RNF4	Código modular, testado e documentado
RNF5	Recolher apenas conteúdo público, sem contornar protecções técnicas nem condições de acesso dos sítios
RNF6	Interface utilizável sem Internet, sem recursos externos, operável por teclado e legível em ecrãs estreitos e em papel
RNF7	Proteger contas e sessões segundo práticas reconhecidas e nunca mostrar segredos em mensagens de erro

Nota. RF: requisito funcional; RNF: requisito não funcional.

3.8.2 Alternativas e decisão

Pesaram-se duas arquitecturas. Uma, distribuída e em fluxo contínuo, juntaria recolha massiva por automatização de navegadores, uma fila de mensagens (Kafka), processamento distribuído (Spark), uma base de dados documental na nuvem e um painel comercial. A outra, adoptada, é em camadas, leve, corre num único servidor e cresce por substituição de componentes (Tabela 3.4).

Tabela 3.4 – Comparação das arquitecturas consideradas

Critério	Distribuída em fluxo contínuo	Em camadas, leve (adoptada)
Volume suportado	Muito elevado	Adequado à recolha pela via oficial; escalável por substituição de componentes
Infra-estrutura	Vários serviços em cluster; operação especializada	Um servidor; Python, SQLite (ou PostgreSQL)
Custo e dependências	Licenças e/ou serviços em nuvem	Apenas software livre
Soberania dos dados	Depende do fornecedor de nuvem	Dados em infra-estrutura própria
Vias de recolha	Tendência para automatizar páginas que exigem contornar protecções	Interfaces oficiais, sítios públicos sem conta, recolha manual e exportações
Adequação ao modelo	Pressupõe decisões em tempo real	Pensada para triagem com revisão humana

A arquitectura distribuída resolveria um problema que este sistema não tem. O que limita a triagem não é o volume de dados, é a capacidade humana de rever o que o modelo assinala e a fiabilidade do modelo em conteúdo angolano. Processar milhões de publicações por hora produziria alertas que ninguém conseguiria ler. Com a arquitectura leve, o esforço vai para a qualidade da fila, a protecção dos dados e a facilidade de trocar o modelo; se o volume crescer, a base de dados pode passar a PostgreSQL e a inferência pode ser replicada sem mudar o desenho.

3.8.3 Camadas e componentes

A Figura 3.3 mostra as seis camadas da arquitectura adoptada.

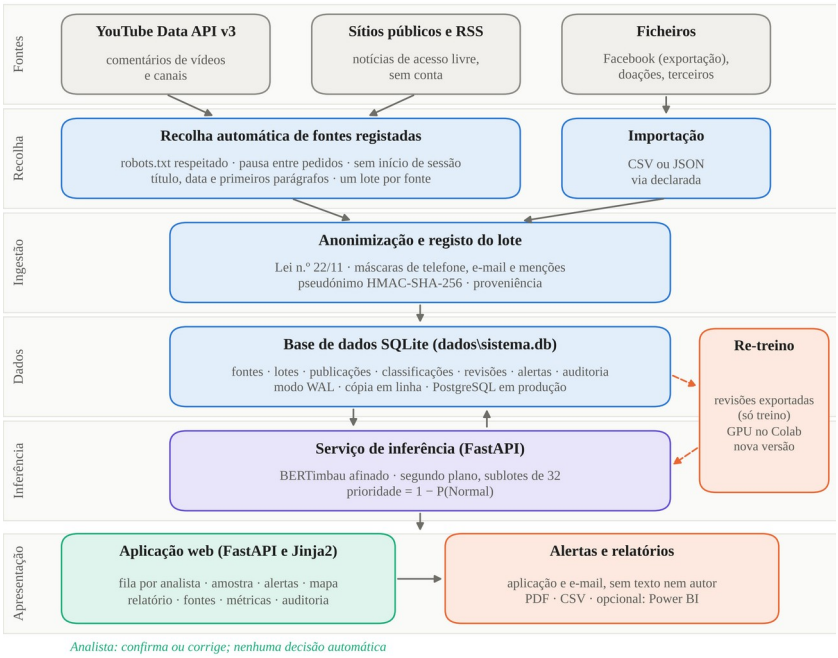


Figura 3.3 – Arquitectura em camadas do sistema de triagem

- **Fontes públicas e recolha.** O sistema recolhe do YouTube pela interface oficial (comentários de vídeos e dos vídeos recentes de canais, listas e pesquisas) e de sítios de acesso livre, como os portais dos órgãos de comunicação angolanos (feeds RSS, artigos e páginas de secção). O conteúdo público de redes que exigem conta, como o Facebook, entra por importação de ficheiros. A recolha respeita o robots.txt, identifica-se como ferramenta de investigação, espera entre pedidos ao mesmo sítio e ignora páginas com palavra-passe; não há rotação de endereços IP, identidades falsas nem resolução de *captchas*. Cada recolha cria um lote.
- **Ingestão.** Recolhas e ficheiros importados (CSV ou JSON) passam pelo mesmo módulo, que mascara os identificadores no texto e substitui o autor por um pseudónimo HMAC-SHA-256 (código de autenticação de mensagens baseado em *hash*) com um segredo guardado fora do código. Sem o segredo, o

hash de um nome de utilizador poderia ser revertido por dicionário. O ficheiro original não é guardado.

- **Dados.** Uma base SQLite, num único ficheiro e sem servidor próprio, guarda fontes, lotes, publicações, classificações, revisões (uma por analista e publicação), amostra de controlo, utilizadores, sessões, definições, alertas e auditoria (Figura 3.4). O modo de diário WAL deixa a classificação em segundo plano gravar enquanto os analistas consultam a fila, e a cópia de segurança faz-se sem parar o serviço.
- **Inferência.** O BERTimbau afinado é carregado uma vez e classifica as publicações pendentes em segundo plano, gravando por sublotes de 32, para que as primeiras cheguem à fila sem esperar pelo lote inteiro. A prioridade de cada publicação é 1 − P(Normal). Como a fila mostra por omissão só os itens cuja categoria mais provável não é Normal, a ordenação só actua sobre esses; os restantes chegam ao analista apenas pela amostra de controlo (Secção 4.7.2).
- **Apresentação.** Uma aplicação web mostra a fila, a amostra de controlo, o panorama agregado, os alertas, o mapa, o relatório, a ficha do modelo e os lotes e, ao supervisor, as métricas, as contas e a auditoria. As métricas podem ser exportadas para relatórios, incluindo o Power BI, sem que estas ferramentas tenham acesso aos textos.
- **Alertas e relatório.** Os alertas nascem apenas de decisões humanas. Há alerta de ameaça confirmada quando o número de analistas definido pelo supervisor (um, por omissão) escolhe uma categoria de ameaça e as decisões de ameaça superam as de Normal. Há alerta de tendência quando as ameaças confirmadas numa província, ou no país, atingem um mínimo de casos numa janela (cinco em sete dias, por omissão), crescem pelo menos 50% face à janela anterior e ganham peso no total recolhido; esta última condição impede que mais recolha pareça mais ameaça. Os alertas aparecem na aplicação e seguem por e-mail para os destinatários definidos pelo supervisor, sem texto nem pseudónimo do autor, e nunca seguem automaticamente para terceiros. O relatório de um período pode ser impresso, exportado ou enviado por e-mail.

A localização usada nos alertas e no mapa é o lugar mencionado na publicação, não o paradeiro de quem a escreveu, que os dados públicos não revelam. O texto é comparado com uma lista de topónimos, sem nomes ambíguos como Belas, Cela ou Kwanza, e a localização fica ao nível da província, para não se aproximar de um perfil de pessoas. O mapa usa as 18 províncias com os limites de 2011 a 2024, anteriores à divisão que entrou em vigor em Janeiro de 2025, a partir do geoBoundaries, de domínio público (Runfola et al., 2020). Cada província é colorida pela taxa de ameaças

confirmadas sobre as publicações que a mencionam, para que falar muito de Luanda não a torne, só por isso, a mais ameaçada; abaixo de cinco publicações, a taxa não se calcula.

As revisões do analista são exportadas com a origem *revisao_sistema* e podem alimentar um novo ciclo de treino. Como são etiquetas de um só analista sobre itens escolhidos pelo modelo, entram apenas no treino e nunca no teste.

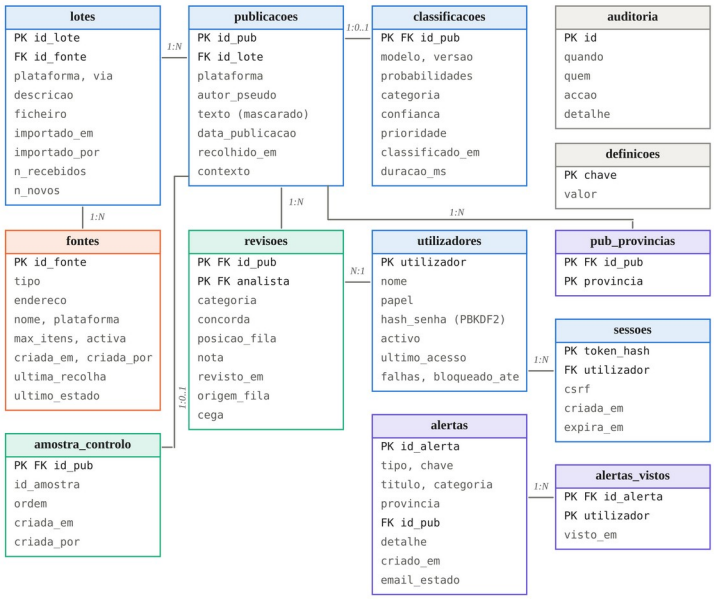


Figura 3.4 – Modelo de dados do sistema

3.8.4 Casos de uso e fluxo de processamento

O sistema tem cinco actores (Figura 3.5). O analista revê a sua fila e a amostra de controlo, consulta o panorama, os alertas e o mapa e gera o relatório. O supervisor, que também pode rever, regista fontes e lança a recolha, importa lotes, define as regras e os destinatários dos alertas, sorteia a amostra de controlo, gere contas, consulta métricas e auditoria, activa a revisão cega e aplica o prazo de conservação. O serviço de inferência classifica cada lote em segundo plano. O investigador exporta as revisões e treina novas versões do modelo. O destinatário do e-mail recebe os alertas e o resumo do relatório sem acesso ao sistema. A Figura 3.6 segue um lote desde a recolha até à decisão do analista e aos alertas que dela resultam.

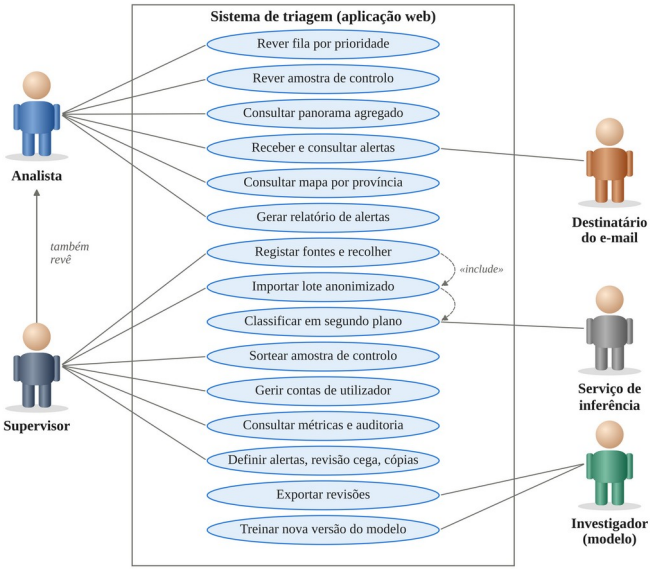


Figura 3.5 – Diagrama de casos de uso (UML)

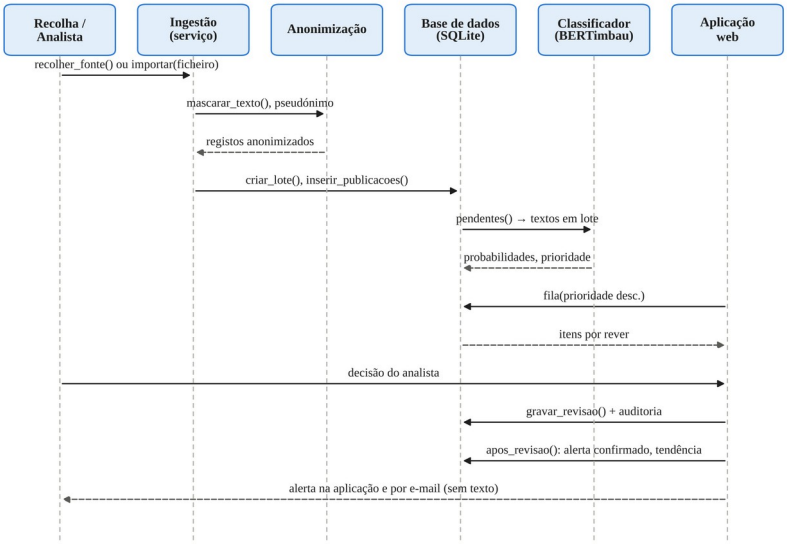


Figura 3.6 – Diagrama de sequência (UML): da recolha à revisão

3.8.5 Interface do analista

A interface é uma aplicação web servida pelo próprio sistema (FastAPI com modelos Jinja2), sem nada para instalar nos postos dos analistas. Quatro princípios guiaram o desenho. Autonomia: estilos, código, ícones e ilustrações são do próprio sistema, e a política de segurança de conteúdo (CSP) só admite recursos do servidor, pelo que a aplicação funciona numa rede sem Internet e nenhum terceiro sabe que páginas se consultam. Melhoria progressiva: as páginas são geradas no servidor e funcionam sem JavaScript, que só acrescenta rapidez. Acessibilidade: atalhos de teclado para todas as acções, foco sempre visível, tema escuro, adaptação a ecrãs estreitos e à impressão em A4. E honestidade sobre o modelo: as probabilidades estão sempre visíveis.

Na fila (Figura 3.7), cada publicação aparece com a categoria prevista, as probabilidades das quatro categorias e quatro botões de decisão, que respondem também às teclas 1 a 4; os lugares reconhecidos e os dados mascarados aparecem realçados. A decisão grava-se sem recarregar a página e pode ser desfeita durante cinco segundos, antes de sair qualquer e-mail de alerta. Cada analista tem a sua fila, o que permite medir o acordo entre analistas de forma independente. Duas funções servem a avaliação da Secção 3.9: a revisão cega, que esconde a sugestão do modelo para que a concordância não seja inflacionada por ela, e a amostra de controlo, que sorteia, com semente registada, publicações classificadas como Normal para revisão sem sugestão.



Figura 3.7 – Fila de revisão na aplicação web

Nota. Modo de demonstração, com dados fictícios e classificador simulado.

O mapa (Figura 3.8) mostra, ao passar o cursor sobre uma província, as publicações que a mencionam, as ameaças, a taxa e a variação face ao período anterior. Um botão percorre o período semana a semana, o que deixa ver onde e quando a concentração cresceu, e o mapa pode ser descarregado com título, período, legenda e fonte dos limites.

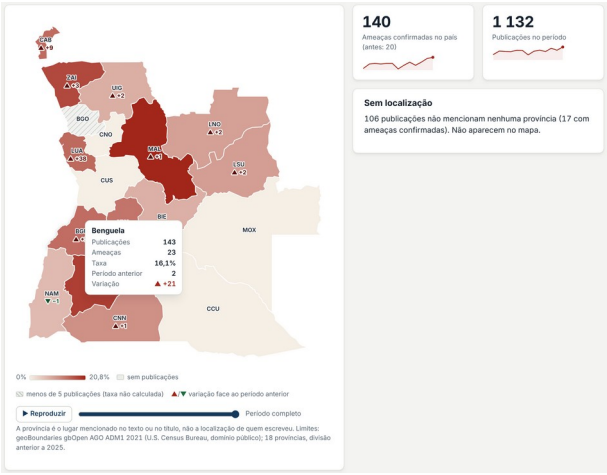


Figura 3.8 – Mapa por província na aplicação web

Nota. Modo de demonstração, com dados fictícios, últimos 90 dias; cartão de Benguela ao passar o cursor.

A página Sobre o modelo é a ficha do modelo em uso, no espírito das fichas propostas por Mitchell et al. (2019). Põe o desempenho no teste ao lado do desempenho em conteúdo angolano (Secção 4.6) e enumera, em linguagem corrente, as limitações conhecidas: a queda de cerca de 39 pontos em conteúdo angolano, a falha quase sistemática na Desinformação em comentários e a baixa precisão na Mobilização Hostil. A mesma página calcula o acordo observado entre analistas e modelo naquela instalação. O propósito é simples: que o analista leia cada sugestão com a confiança que ela merece, e não com a que um número global de 0,81 sugeriria.

Um modo de demonstração, numa base separada com cerca de 1.300 publicações fictícias e um classificador simulado que erra como o modelo real, serve para formação, sem enviar e-mails. As funções principais existem também numa interface de programação JSON, protegida por chave, e numa linha de comandos (Apêndice F).

3.8.6 Recolha automática, contas e segurança

O servidor pode percorrer sozinho as fontes activas, com a frequência escolhida pelo supervisor entre 15 minutos e um dia. Em cada volta lê os vídeos e comentários mais recentes dos canais, listas e pesquisas do YouTube e os artigos novos dos feeds e sítios; só entra o que ainda não existe, o que entra é classificado, e cada volta fica nos lotes e na auditoria. A quota diária do YouTube, habitualmente de 10.000 unidades, é o recurso escasso: uma pesquisa custa cem vezes mais do que uma página de comentários. A página das fontes estima, por isso, o consumo de cada volta e do dia e avisa quando a estimativa se aproxima do limite. As mensagens de erro são limpas antes de gravadas, para que a chave do YouTube nunca apareça no ecrã nem nos registos.

As contas seguem as orientações da Secção 2.9. As palavras-passe têm pelo menos dez caracteres e são guardadas como derivação PBKDF2-SHA-256 com sal e 240.000 iterações; cinco tentativas falhadas bloqueiam a conta durante cinco minutos. A sessão fica no servidor, cada formulário leva um código anti-falsificação, e a sessão termina se a janela fechar e nenhuma página do sistema reabrir em 20 segundos. A recuperação do acesso dispensa correio electrónico: cada utilizador pode gerar um código pessoal de uso único, de dezasseis caracteres (cerca de 80 bits); sem ele, pede ajuda ao supervisor, que gera uma palavra-passe temporária a mudar no primeiro acesso; e, se o único supervisor perder o acesso, um comando local no servidor repõe a palavra-passe. Todos os passos ficam na auditoria.

3.9 Plano de testes e avaliação operacional

O protótipo tem 121 testes automáticos (Tabela F.2). A avaliação operacional, que corresponde às hipóteses H2 e H3, segue o protocolo seguinte:

- **Latência (H2).** O comando *medir-latencia* importa, pseudonimiza e classifica um lote numa base de dados temporária e reporta a mediana do tempo total e por publicação; o intervalo entre a publicação original e a recolha reporta-se à parte.
- **Utilidade da fila.** Num lote novo, nunca usado no treino, e com a revisão cega activa, pelo menos dois analistas revêem a fila por ordem, de forma independente. Calcula-se a precisão nos primeiros K itens (K = 10, 25, 50, 100), a concordância e o κ entre cada analista e o sistema, e o κ entre analistas. Para estimar a sensibilidade, os analistas revêem também a amostra de controlo; a fracção considerada ameaça reporta-se com IC 95% de Wilson.
- **Antecedência (H3).** Exige um corpus datado em torno de eventos documentados, dividido cronologicamente, e uma lista de eventos de referência independente do corpus. Um padrão conta como detectado quando o sistema emite um alerta de tendência para a província ou para o país, calculado sobre decisões de analistas sem conhecimento dos eventos ou, em alternativa declarada, sobre as previsões do modelo; a antecedência é o intervalo entre esse alerta e o evento, e a H3 confirma-se se a mediana for de pelo menos 48 horas. Este protocolo fica esboçado, mas não foi aplicado.

A passagem do protótipo a ferramenta institucional deve fazer-se por fases e depender de resultados. Primeiro, um piloto académico (novo treino, medição da latência, avaliação da fila com analistas num lote novo e parecer jurídico), que só avança se a precisão no topo da fila e o κ analista–sistema forem aceites pela instituição e o parecer for favorável. Depois, um piloto institucional em servidor próprio, com formação de analistas e recolha agendada, condicionado a auditoria independente e a desempenho em conteúdo angolano medido por categoria. Por fim, a consolidação, com pré-treino adaptado ao domínio e extensão a outras plataformas por vias oficiais, dentro de um quadro normativo para o uso de IA em segurança.

CAPÍTULO 4 – RESULTADOS E DISCUSSÃO

O capítulo começa pelo classificador e acaba no sistema. As Secções 4.1 a 4.5 comparam os quatro modelos e testam a estabilidade dos resultados; a 4.6 mede a lacuna de domínio (H4); a 4.7 pergunta se as probabilidades merecem confiança e quanto trabalho a ordenação poupa; a 4.8 trata do sistema em funcionamento (H2 e H3); e a 4.9 verifica as hipóteses. Todos os valores foram recalculados a partir das previsões guardadas de cada modelo e coincidem com os ficheiros de métricas do pipeline. Nas tabelas, Discurso de Ódio e Mobilização Hostil aparecem abreviados como Ódio e Mobilização.

4.1 Corpus de avaliação e protocolo experimental

O corpus de treino e avaliação resulta da harmonização de três corpora públicos em português (ToLD-BR, Fake.br e HateBR) com o piloto angolano anotado nesta investigação. Após a remoção de 238 duplicados, o corpus contém 26.859 registos, distribuídos conforme a Tabela 4.1.

Tabela 4.1 – Composição do corpus harmonizado por fonte e categoria

Fonte	Normal	Desinformação	Ódio	Mobilização	Total
ToLD-BR	11.682	0	1.027	0	12.709
Fake.br	3.600	3.599	0	0	7.199
HateBR	2.195	0	2.183	0	4.378
Piloto angolano	1.613	318	283	359	2.573
Total	**19.090**	**3.917**	**3.493**	**359**	**26.859**

Nota. Valores após deduplicação (27.097 → 26.859). A categoria Mobilização Hostil existe apenas no piloto angolano. O piloto inclui 2.288 itens da base do piloto (comentários do YouTube amostrados aleatoriamente e itens de recolha manual) e 285 itens de lotes enriquecidos (194 por selecção temática de vídeos e 91 por léxico), usados exclusivamente no treino.

O conjunto de validação contém 3.986 itens e o de teste 3.987 itens (Normal 2.843; Desinformação 580; Discurso de Ódio 517; Mobilização Hostil 47). Dos itens de teste, 355 (8,9%) provêm do piloto angolano e 3.632 (91,1%) dos corpora públicos brasileiros. Esta composição significa que as métricas globais descrevem sobretudo o desempenho em conteúdo brasileiro; o desempenho em conteúdo angolano é analisado separadamente na Secção 4.6.

A avaliação segue o protocolo da Secção 3.7: F1-macro como métrica principal, com IC 95% por *bootstrap* (2.000 reamostragens), e McNemar com correcção de Bonferroni para as seis comparações (α corrigido = 0,0083).

4.2 Desempenho global dos modelos

A Tabela 4.2 dá o desempenho dos quatro modelos no teste, sem ajuste de limiares.

Tabela 4.2 – Desempenho dos modelos no conjunto de teste

Modelo	F1-macro [IC 95%]	F1 ponderado	Exactidão	Kappa (κ)	AUC-ROC [IC 95%]
Floresta Aleatória	0,659 [0,621; 0,694]	0,831	0,834	0,624	0,906 [0,891; 0,919]
SVM	0,633 [0,606; 0,657]	0,791	0,772	0,566	0,909 [0,900; 0,917]
Bi-LSTM	0,660 [0,628; 0,689]	0,823	0,819	0,621	0,915 [0,901; 0,926]
BERTimbau	0,807 [0,774; 0,838]	0,924	0,924	0,832	0,979 [0,973; 0,983]

Nota. n = 3.987. AUC-ROC: média das quatro AUC um-contra-todos. IC 95% por *bootstrap* (2.000 reamostragens para o F1; 1.000 para a AUC). BERTimbau com ajuste fino, semente 42 (configuração de referência).

O BERTimbau obteve F1-macro de 0,807 (IC 95% [0,774; 0,838]), entre 14,6 e 17,4 pontos percentuais (p.p.) acima dos restantes modelos, cujos F1-macro se situam entre 0,633 e 0,660. O intervalo de confiança do BERTimbau não se sobrepõe ao de nenhum outro modelo. O BERTimbau é também o primeiro no Kappa e na AUC-ROC; entre os restantes, a ordem varia com a métrica, e as diferenças são pequenas.

A distância entre o F1 ponderado (0,924) e o F1-macro (0,807) mostra o efeito do desequilíbrio: o primeiro é dominado pela classe Normal (71,3% do teste), o segundo dá à Mobilização Hostil (1,2%) o mesmo peso que às outras categorias. A Figura 4.1 mostra as curvas ROC por categoria.

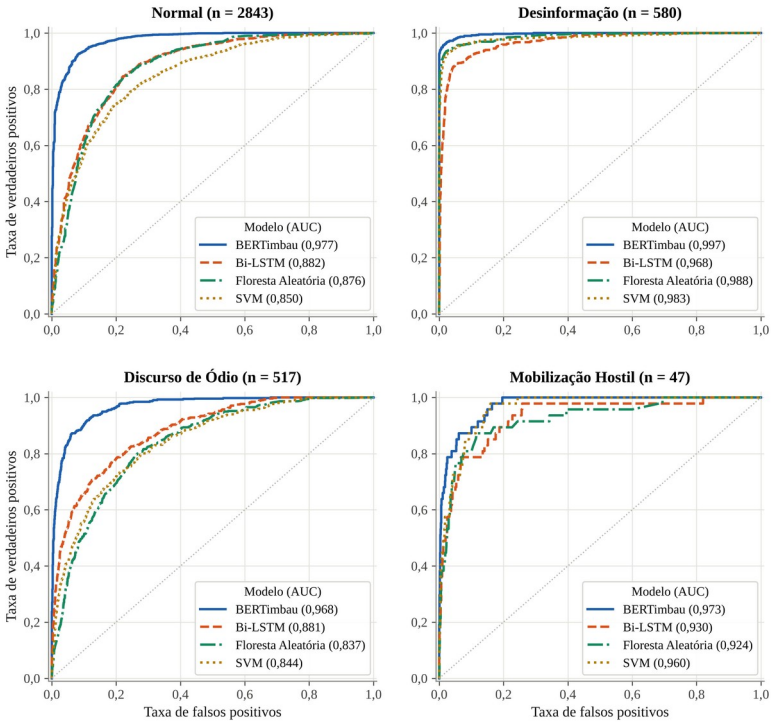


Figura 4.1 – Curvas ROC um-contra-todos por categoria e modelo (conjunto de teste; AUC entre parêntesis)

As curvas mostram que a vantagem do BERTimbau se concentra nas categorias Normal e Discurso de Ódio, onde as AUC dos restantes modelos descem para 0,837–0,882. Na Desinformação, todos os modelos ultrapassam 0,96, um resultado cuja interpretação é revista na Secção 4.6. Na Mobilização Hostil, as AUC são elevadas (0,924–0,973), mas assentam em apenas 47 exemplos positivos, pelo que as curvas apresentam degraus largos e a estimativa é instável.

4.3 Significância estatística das diferenças

A Tabela 4.3 apresenta as seis comparações emparelhadas; *b* e *c* contam os itens que só o primeiro e só o segundo modelo do par acertam.

Tabela 4.3 – Comparações emparelhadas (ΔF1-macro e McNemar)

Par	ΔF1-macro, p.p. [IC 95%]	b / c	χ^2	p (Bonferroni)	Signif.
BERTimbau vs. Bi-LSTM	14,6 [10,9; 18,4]	529 / 110	273,43	$1{,}2 \times 10^{-60}$	Sim
BERTimbau vs. Floresta Aleatória	14,8 [10,8; 18,8]	473 / 115	216,75	$2{,}8 \times 10^{-48}$	Sim
BERTimbau vs. SVM	17,4 [14,4; 20,4]	714 / 110	441,27	$3{,}4 \times 10^{-97}$	Sim
Bi-LSTM vs. Floresta Aleatória	0,2 [-4,0; 4,2]	348 / 409	4,76	0,175	Não
Bi-LSTM vs. SVM	2,8 [-0,3; 5,7]	519 / 334	39,69	$1{,}8 \times 10^{-9}$	Sim
Floresta Aleatória vs. SVM	2,6 [-0,9; 6,0]	524 / 278	74,84	$3{,}1 \times 10^{-17}$	Sim

Nota. n = 3.987. ΔF1 = F1-macro do primeiro modelo menos F1-macro do segundo. p (Bonferroni) = p do teste de McNemar multiplicado por 6 (limitado a 1). O teste de McNemar compara as proporções de acertos e erros; não testa directamente o F1-macro, razão pela qual se apresenta também o IC da diferença de F1.

O BERTimbau supera os três modelos de referência com diferenças de F1-macro entre 14,6 e 17,4 p.p., cujos intervalos de confiança excluem largamente o zero, e com p corrigido inferior a 10^{-47} em todos os casos. Em cada par, o número de itens que só o BERTimbau acerta (473–714) é 4,1 a 6,5 vezes superior ao número de itens que só o outro modelo acerta (110–115).

Entre os modelos de referência, o quadro é diferente. O Bi-LSTM e a Floresta Aleatória têm F1-macro praticamente iguais (ΔF1 = 0,2 p.p., IC 95% [-4,0; 4,2]) e a diferença nos acertos não é significativa após correcção (p = 0,175); a Floresta Aleatória acerta, aliás, mais itens isolados do que o Bi-LSTM (409 contra 348). O Bi-LSTM e a Floresta Aleatória acertam significativamente mais itens do que o SVM, mas as diferenças de F1-macro (2,8 e 2,6 p.p.) têm intervalos que incluem o zero. Só o BERTimbau se distingue, portanto, dos restantes. O Bi-LSTM não mostra vantagem consistente sobre os modelos clássicos neste corpus.

4.4 Desempenho por categoria e análise de erros

A Tabela 4.4 desagrega o F1 por categoria. Para o BERTimbau, apresentam-se também a precisão, a sensibilidade (*recall*) e o IC 95% do F1 de cada categoria.

Tabela 4.4 – F1 por categoria e modelo; precisão e sensibilidade do BERTimbau

Categoria	F. Aleatória	SVM	Bi-LSTM	BERTimbau F1 [IC 95%]	Precisão [a]	Sensib. [a]
Normal (n = 2.843)	0,889	0,836	0,875	**0,952** [0,95; 0,96]	0,952	0,951
Desinformação (n = 580)	0,922	0,871	0,815	**0,947** [0,93; 0,96]	0,947	0,948
Ódio (n = 517)	0,455	0,497	0,585	**0,778** [0,75; 0,80]	0,783	0,774
Mobilização (n = 47)	0,368	0,326	0,367	**0,549** [0,42; 0,66]	0,509	0,596
F1-macro	0,659	0,633	0,660	**0,807**	0,798	0,817

Nota. [a] Precisão e sensibilidade do BERTimbau; na última linha, médias macro.

O BERTimbau alcança F1 de 0,952 na Normal e 0,947 na Desinformação, 0,778 no Discurso de Ódio e 0,549 na Mobilização Hostil. A vantagem sobre os modelos de referência é maior no Discurso de Ódio (0,778 contra 0,455–0,585), categoria em que a Floresta Aleatória classifica como Normal a maioria dos itens de ódio, e na Mobilização Hostil (0,549 contra 0,326–0,368). Na Desinformação, a diferença é menor (0,947 contra 0,815–0,922), porque todos os modelos obtêm valores elevados nesta categoria.

A Mobilização Hostil é a categoria de maior relevância operacional e a de estimativa menos precisa. O BERTimbau identificou 28 dos 47 itens de teste (sensibilidade de 0,596) e produziu 27 falsos positivos (precisão de 0,509). O IC 95% do F1 desta categoria, [0,42; 0,66], tem uma amplitude superior a 20 p.p., consequência directa do número reduzido de exemplos. A Figura 4.2 apresenta as matrizes de confusão dos quatro modelos.

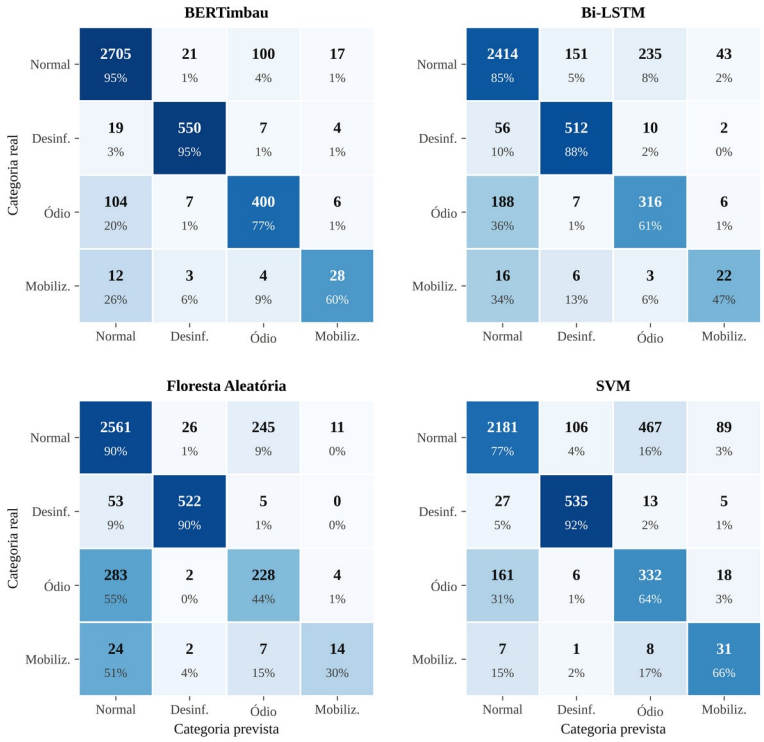


Figura 4.2 – Matrizes de confusão (4 × 4) no conjunto de teste (contagens e percentagem por linha)

Dois padrões de erro são comuns aos quatro modelos. O primeiro, e mais frequente, é a confusão entre Normal e Discurso de Ódio: no BERTimbau, 100 itens Normais foram classificados como Discurso de Ódio e 104 itens de Discurso de Ódio como Normais, o que corresponde a 20% dos itens de ódio. Trata-se de uma fronteira conceptualmente difícil, que envolve ódio implícito, ironia e insulto sem alvo identitário. O segundo padrão é a classificação de Mobilização Hostil como Normal (12 dos 47 itens no BERTimbau; 16 no Bi-LSTM, 24 na Floresta Aleatória e 7 no SVM), que reproduz a fronteira, assumida no Guia de Anotação, entre convocatória legítima e mobilização hostil. Um terceiro é próprio do BERTimbau: a raridade das confusões que envolvem a Desinformação, que se analisa na Secção 4.6.

Traduzido para a operação: com sensibilidade de cerca de 0,60 e precisão de cerca de 0,51 na Mobilização Hostil, o modelo deixa escapar quatro em cada dez casos e metade do que assinala nesta categoria é falso alarme. Nenhum uso automático das

classificações resiste a estes números; a revisão humana não é uma precaução, é uma necessidade (Secção 4.8).

4.5 Análises de robustez

4.5.1 Variabilidade entre sementes, ensemble e ablações

A Tabela 4.5 reúne as três sementes do BERTimbau e as três variantes descritas na Secção 3.6.2.

Tabela 4.5 – Variantes do BERTimbau: validação, teste e comparação com a referência

Variante	F1-macro validação	p vs. referência (validação)	F1-macro teste [IC 95%]	F1 Mobil. (teste)	p vs. referência (teste)
Referência (semente 42)	0,814	—	0,807 [0,774; 0,838]	0,549	—
Semente 43	0,811	0,721	0,785 [0,752; 0,816]	0,472	0,059
Semente 44	0,816	0,181	0,801 [0,769; 0,830]	0,549	0,002
Ensemble (média das 3 sementes)	0,820	0,824	0,807 [0,775; 0,836]	0,545	0,520
Sem lote de vídeos temáticos	0,815	0,506	0,799 [0,765; 0,830]	0,529	0,406
Pesos de classe suavizados (0,5)	0,826	0,219	0,799 [0,761; 0,832]	0,518	0,718

Nota. Média ± desvio-padrão do F1-macro de teste nas três sementes: 0,797 ± 0,011. Valores de p do teste de McNemar, sem correcção para comparações múltiplas; a decisão usa apenas os da validação.

O F1-macro de teste varia entre 0,785 e 0,807 consoante a semente, com média de 0,797 ± 0,011. A semente 42 é a configuração de referência, definida antes das restantes execuções, mas é também a que obteve o valor de teste mais elevado; por isso, a média das três sementes (0,797) constitui a estimativa mais representativa do desempenho esperado do BERTimbau neste protocolo. A variabilidade concentra-se na Mobilização Hostil, cujo F1 oscila entre 0,472 e 0,549. As sementes 42 e 44 diferem significativamente nos itens que acertam ($p = 0,002$), apesar de F1-macro e F1 de Mobilização Hostil semelhantes: modelos com desempenho agregado equivalente tomam decisões individuais diferentes, o que reforça a necessidade de revisão humana item a item.

Os modelos de referência foram também treinados com as sementes 43 e 44; a semente 42 reproduz os valores da Tabela 4.2. Na média das três sementes, o F1-macro é de 0,652 ± 0,009 na Floresta Aleatória, 0,645 ± 0,016 no Bi-LSTM e 0,631 ± 0,001 no SVM. O BERTimbau supera cada um deles em todas as sementes, por 14,6 a 17,8 p.p. (McNemar, $p < 10^{-48}$). O Bi-LSTM, o mais instável, nunca supera a Floresta Aleatória:

a diferença é de +0,2 p.p. na semente 42 e de −0,9 e −1,3 p.p. nas sementes 43 e 44, nestas duas a favor da Floresta ($p < 10^{-4}$).

Na validação, onde o critério da Secção 3.7 manda decidir, nenhuma variante nem nenhuma semente se distingue da referência (McNemar, $p \geq 0{,}18$), pelo que se manteve a configuração de referência. A variante com pesos suavizados obteve o melhor F1-macro de validação (0,826), sem diferença significativa nos acertos, e no teste ficou em 0,799, com F1 de Mobilização Hostil inferior (0,518). Os valores de teste apresentam-se apenas para informação: também aí nenhuma das três variantes se distingue da referência ($p > 0{,}40$). A ablação do lote de vídeos temáticos reduziu o F1-macro de 0,807 para 0,799 e o F1 de Mobilização Hostil de 0,549 para 0,529, diferenças que não são estatisticamente distinguíveis ($p = 0{,}41$): o contributo desse lote existe na direcção esperada, mas não é demonstrável com a dimensão actual do teste.

O modelo usado no protótipo do sistema (Secção 3.8) resulta de um novo treino com a configuração de referência, porque os pesos da corrida original não foram guardados. A divisão dos dados foi reconstruída e verificada item a item: as etiquetas de validação e de teste coincidem integralmente com as da corrida de referência. O novo modelo obteve F1-macro de 0,808 (IC 95% [0,773; 0,839]), contra 0,807 na referência; a diferença (0,1 p.p., IC 95% [-1,5; 1,8]) não é significativa (McNemar, $p = 0{,}41$), e os dois modelos dão a mesma previsão em 97,4% dos itens de teste. Os resultados deste capítulo referem-se à corrida de referência; o modelo do protótipo é, para efeitos práticos, equivalente. Este novo treino usou o mesmo corpus v13, incluindo os nomes próprios do lote temático referidos na Secção 3.2; a sua substituição fica pendente.

4.5.2 Ajuste de limiares de decisão

Ajustaram-se também vieses por classe sobre as pontuações de cada modelo (log-probabilidades nos modelos probabilísticos; pontuações de decisão no SVM). Como escolher os vieses e medi-los nos mesmos dados dá um ganho optimista, o ganho esperado estimou-se por validação cruzada dentro da validação e confirmou-se no teste (Tabela 4.6).

Tabela 4.6 – Efeito do ajuste de limiares no F1-macro

Modelo	Ganho esperado (VC), p.p.	F1-macro teste (sem → com)	Δ teste, p.p. [IC 95%]	Leitura
BERTimbau	-1,2 ± 0,6	0,807 → 0,799	-0,7 [-1,9; 0,3]	Sem ganho
Bi-LSTM	+1,7 ± 0,7	0,660 → 0,655	-0,5 [-3,1; 1,8]	Ganho não confirmado
Floresta Aleatória	-1,3 ± 0,6	0,659 → 0,648	-1,1 [-1,9; -0,4]	Sem ganho
SVM	+3,5 ± 0,7	0,633 → 0,664	+3,2 [0,0; 5,9]	Ganho marginal

Nota. VC: validação cruzada dentro do conjunto de validação (média ± desvio-padrão). Δ teste: diferença no conjunto de teste com IC 95% por *bootstrap* emparelhado. Por protocolo (Secção 3.7), os resultados principais são reportados sem ajuste; o teste serve apenas para verificar a estimativa da validação.

O ajuste não melhora o BERTimbau nem a Floresta Aleatória: o ganho esperado é negativo e confirma-se no teste. No Bi-LSTM, o ganho esperado positivo não se confirma no teste (IC inclui o zero). Apenas o SVM beneficia, e de forma marginal (+3,2 p.p., IC [0,0; 5,9]), passando para F1-macro de 0,664, valor que não altera a ordenação dos modelos. Por coerência, todas as tabelas deste capítulo reportam os modelos sem ajuste, e o valor ajustado do SVM é tratado apenas como análise de sensibilidade.

4.6 Lacuna de domínio: piloto angolano e corpus público (Hipótese H4)

Conforme a formulação da Secção 1.3, testa-se se o desempenho do modelo seleccionado se degrada significativamente (ΔF1-macro ≥ 5 p.p.) em conteúdo angolano, comparando o subconjunto de teste proveniente do piloto angolano com o subconjunto proveniente dos corpora públicos. A Tabela 4.7 e a Figura 4.3 apresentam os resultados do BERTimbau em cada subconjunto.

Tabela 4.7 – Desempenho do BERTimbau no piloto angolano e no corpus público

Subconjunto	n	Cl.	F1-macro [IC 95%]	κ	F1 Norm.	F1 Desinf.	F1 Ódio	F1 Mobil.
Piloto angolano	355	4	0,533 [0,470; 0,592]	0,436	0,825	0,235	0,518	0,554
Corpus público	3.632	3	0,919 [0,908; 0,929]	0,879	0,963	0,992	0,802	—

Nota. Δ F1-macro (público − piloto) = 38,6 p.p. O corpus público não contém itens de Mobilização Hostil, pelo que o seu F1-macro é calculado sobre três classes.

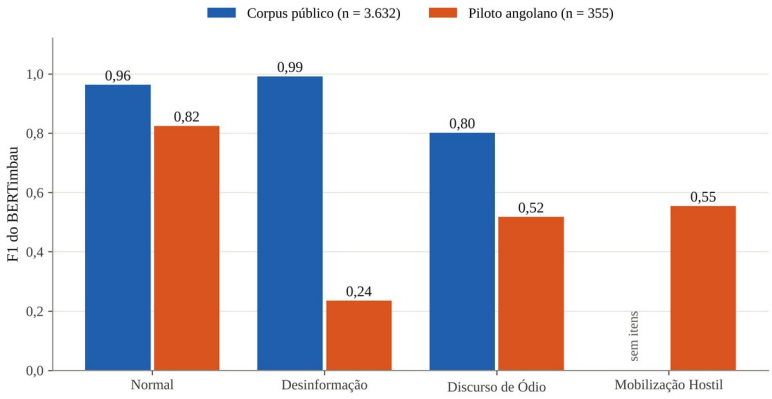


Figura 4.3 – F1 por categoria do BERTimbau no corpus público e no piloto angolano (conjunto de teste)

No piloto angolano, o BERTimbau obteve F1-macro de 0,533 (IC 95% [0,470; 0,592]) e κ de 0,436, contra 0,919 (IC 95% [0,908; 0,929]) e κ de 0,879 no corpus

público. A diferença, de 38,6 p.p., excede largamente o limiar de 5 p.p. e os intervalos de confiança não se sobrepõem.

A comparação tem um factor de confusão evidente: a Mobilização Hostil, a categoria mais difícil, existe apenas no piloto, e o F1-macro do corpus público é calculado sobre três classes. Para reduzir este efeito, excluíram-se do piloto os itens de Mobilização Hostil (n = 308) e calculou-se o F1-macro nas três categorias comuns, contando como erro qualquer previsão de Mobilização: 0,545 (IC 95% 0,474–0,613), contra 0,919 no corpus público. A diferença, de 37,3 p.p. (IC 95% por *bootstrap* de 30,6 a 44,7), mantém-se na mesma ordem de grandeza, pelo que a degradação não se explica pela composição das classes. Note-se ainda que o κ do modelo no piloto (0,436) fica bem abaixo do acordo entre anotadores (0,718), que dá uma ordem de grandeza da dificuldade da tarefa.

O resultado mais revelador é o da Desinformação: F1 de 0,992 no corpus público e de 0,235 no piloto. Nos corpora públicos, toda a Desinformação provém do Fake.br, constituído por notícias completas, enquanto o piloto contém sobretudo comentários curtos. A combinação de um desempenho quase perfeito no domínio de origem com um desempenho muito baixo no domínio angolano é compatível com a hipótese de que o modelo aprendeu sobretudo marcas de estilo e de formato do Fake.br (registo jornalístico, extensão, estrutura) e não propriedades da desinformação enquanto tal. O Discurso de Ódio também desce (0,802 contra 0,518). Por isso, o F1 global de 0,807 e, em particular, o F1 de 0,947 na Desinformação sobrestimam o desempenho que o sistema terá em conteúdo angolano; a estimativa realista para este domínio é a do piloto (F1-macro de 0,533).

Há, contudo, explicações concorrentes que este desenho não separa: (i) as etiquetas do piloto aplicam por vezes critérios mais amplos do que os do guia, alargados pela regra da categoria mais grave (Secção 3.4); (ii) no Discurso de Ódio, os exemplos públicos do HateBR são linguagem ofensiva, noção mais ampla do que a do guia; e (iii) 297 etiquetas do piloto resultam de um só voto. Uma parte da lacuna pode, por isso, ser de medida e não de modelo. Os itens escolhidos pelo investigador, com acordo baixo entre anotadores (κ de 0,42 e 0,28), não a explicam: nos 289 comentários do YouTube sorteados, o F1-macro é de 0,535 (IC 95% 0,457–0,603; κ de 0,443), praticamente o do subconjunto completo.

Falta dizer o que o teste não permite. Com n = 355, o intervalo de confiança é largo. E o desenho não separa as componentes da lacuna: variedade linguística, plataforma (comentários do YouTube contra notícias, Instagram e Twitter) e registo. Como só 0,3% dos comentários contêm calão de uma lista ilustrativa (Secção 3.4), é

provável que a diferença venha mais dos temas, das referências e da forma de argumentar do que do vocabulário, mas essa hipótese não foi testada. A H4 confirma uma lacuna substancial sem a atribuir ao calão ou às línguas nacionais.

4.7 Qualidade das probabilidades e utilidade da ordenação

O sistema mostra as probabilidades do modelo ao analista e ordena a fila pela prioridade 1 − P(Normal) (Secção 3.8.3). Esta secção analisa, no conjunto de teste, se as probabilidades merecem a confiança que exprimem e quanto trabalho a ordenação poupa, para o BERTimbau, o Bi-LSTM e a Floresta Aleatória (o SVM linear não produz probabilidades). Como 91% do teste é brasileiro e 28,7% dos itens são ameaças, proporção muito superior à de um fluxo real, a precisão nos primeiros K e a precisão média são um limite superior do que o sistema fará em conteúdo angolano; a fracção da fila a rever depende da prevalência e não é comparável. No fim da secção, a análise repete-se no subconjunto angolano (n = 355).

4.7.1 Calibração das probabilidades

A Tabela 4.8 reúne as medidas de calibração e de ordenação.

Tabela 4.8 – Calibração e ordenação no conjunto de teste

Medida	BERTimbau	Bi-LSTM	F. Aleatória
Confiança média da categoria prevista	0,962	0,922	0,757
Exactidão	0,924	0,819	0,834
ECE (menor é melhor)	**0,039**	0,106	0,083
Índice de Brier (menor é melhor)	**0,125**	0,297	0,262
AUC-ROC ameaça contra Normal	**0,977**	0,882	0,876
Precisão média (AP) da ordenação	**0,954**	0,788	0,782
Precisão nos primeiros 50 / 100 / 500	1,00 / 1,00 / 1,00	0,94 / 0,94 / 0,89	0,86 / 0,92 / 0,94
Fila revista para encontrar 80% das ameaças	24,7%	36,9%	36,2%
Fila revista para encontrar 95% das ameaças	37,3%	67,3%	73,8%

Nota. n = 3.987, dos quais 1.144 ameaças (28,7%). Ordenação de todos os itens do teste pela prioridade 1 − P(Normal). A fila do sistema mostra por omissão apenas os 1.147 itens não classificados como Normais (28,8%), que contêm 88,2% das ameaças; acima desse valor, as restantes só se encontram pela amostra de controlo. ECE com 15 intervalos de igual amplitude sobre a confiança da categoria prevista.

O BERTimbau é o modelo mais bem calibrado (ECE de 0,039), mas é ligeiramente confiante em excesso: a confiança média, de 0,962, excede a exactidão, de 0,924, em cerca de 4 pontos percentuais. A diferença concentra-se nas previsões de confiança intermédia. Dois terços das previsões (67%) têm confiança de pelo menos 0,99, e destas 99% estão certas; já nas cerca de 10% de previsões com confiança entre 0,5 e 0,9, a confiança média é de 0,75 e só 64% estão certas. O Bi-LSTM é bastante

mais confiante do que justificam os seus acertos (confiança de 0,922 para uma exactidão de 0,819), e a Floresta Aleatória, ao contrário, é pouco confiante (0,757 para 0,834), o que é habitual em métodos que fazem a média de muitas árvores (Niculescu-Mizil & Caruana, 2005).

Para o analista, uma percentagem muito alta do BERTimbau é, no conteúdo do teste, uma estimativa razoável, e uma intermédia sobrestima a probabilidade de acerto. Em conteúdo angolano, onde o modelo acerta menos (Secção 4.6), a sobrestimação é maior, como se mostra no fim desta secção. O escalamento por temperatura corrige-a com um único parâmetro ajustado num conjunto de validação (Guo et al., 2017), que, para ser útil, teria de ser angolano.

4.7.2 Ordenação da fila de revisão

A Figura 4.4 mostra a curva de esforço de cada modelo: a fracção das 1.144 ameaças do teste que um analista encontraria ao rever, por ordem de prioridade, uma ordenação de todo o conjunto de teste, e não apenas a fila por omissão. Com o BERTimbau, revendo 25% da fila encontram-se 80% das ameaças, muito perto do ideal (23%, que corresponderia a ter todas as ameaças no topo); para chegar a 95%, basta rever 37%. Com o Bi-LSTM e a Floresta Aleatória, os mesmos 95% exigem rever 67% e 74% da fila. Os primeiros 500 itens da fila do BERTimbau são todos ameaças, contra 89% no Bi-LSTM e 94% na Floresta Aleatória.

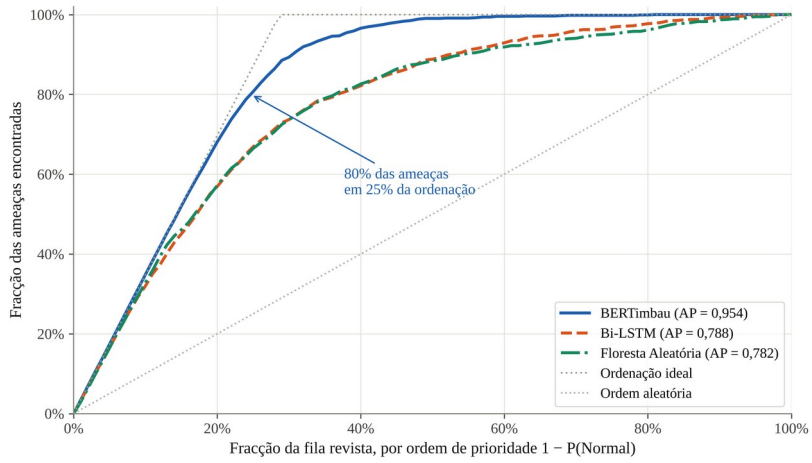


Figura 4.4 – Curva de esforço de revisão: ameaças encontradas em função da fila revista

Este resultado global esconde, no entanto, um desequilíbrio entre categorias. Os primeiros 500 itens da fila do BERTimbau são todos de Desinformação, e a mediana da posição dos 47 itens de Mobilização Hostil é a 927.ª; nenhum deles aparece nos primeiros 10% da fila. A explicação está na Secção 4.6: as notícias do Fake.br são classificadas com probabilidade quase nula de serem Normais e ocupam o topo, enquanto os comentários de mobilização, mais ambíguos, recebem prioridades mais

moderadas. Num fluxo angolano real não haverá notícias do Fake.br, mas o mecanismo mantém-se: a categoria em que o modelo é mais confiante ocupa o topo da fila, e essa não é necessariamente a mais grave nem aquela em que o modelo é mais fiável.

O filtro por categoria da fila já contorna o efeito, mas ordenar cada categoria pela sua própria probabilidade seria mais directo: os 47 itens com maior probabilidade de Mobilização Hostil contêm 25 dos 47 casos reais, e os primeiros 100 contêm 32 (Capítulo 6).

Por fim, a fila mostra por omissão apenas os itens não classificados como Normais. Entre os 2.840 itens que o BERTimbau classificou como Normais estão 135 ameaças (11,8% do total: 104 de Discurso de Ódio, 19 de Desinformação e 12 de Mobilização Hostil); mesmo entre os 1.885 com P(Normal) de pelo menos 0,99 há 10 ameaças (0,5%; IC 95% de Wilson de 0,3% a 1,0%). É isto que justifica a amostra de controlo (Secção 3.8.5), cujos itens são também os mais úteis para novos ciclos de treino.

No subconjunto angolano (n = 355, com 34,4% de ameaças), o quadro é pior. A confiança média (0,85) excede a exactidão (0,69) em 15 pontos percentuais e o ECE sobe para 0,160. Para encontrar 80% das ameaças é preciso rever 49% da ordenação (o ideal seria 27,5%), e 95% exigem 77%. Das 122 ameaças, 35 (28,7%) foram classificadas como Normais e não chegariam à fila por omissão, contra 11,8% no teste completo. Em conteúdo angolano, a amostra de controlo é ainda mais necessária.

4.8 Avaliação operacional do sistema (Hipóteses H2 e H3)

A H2 e a H3 dizem respeito ao sistema em operação, não ao classificador. A H2 foi medida com o protótipo e o modelo do sistema; a H3 não pôde ser testada.

4.8.1 Tempo de processamento (H2)

A medição seguiu o protocolo da Secção 3.9. O comando de medição importou, pseudonimizou e classificou um lote de 200 comentários reais da base do piloto, numa base de dados temporária nova em cada repetição; 2 comentários foram descartados na importação por terem menos de três caracteres, restando 198. Repetiu-se o ensaio 3 vezes num computador pessoal sem GPU, com processador Intel N100 (quatro núcleos de baixo consumo) e 8 GB de RAM; num servidor de produção os tempos serão menores (Tabela 4.9).

Tabela 4.9 – Tempo de processamento do protótipo com o modelo do sistema

Medida	Gravação no fim do lote	Gravação por sublotes de 32
Publicações por lote	198	198
Repetições	3	3
Tempo total por lote (mediana)	125,5 s	139,7 s
Tempo médio por publicação	0,63 s	0,71 s
Primeiras publicações na fila	125,5 s (todas no fim)	36,1 s
Intervalo entre sublotes	—	cerca de 20 s
Lote máximo com todas as publicações em menos de 60 s	cerca de 94	cerca de 64

Nota. O tempo inclui a leitura do ficheiro, a pseudonimização, a gravação na base de dados e a classificação com o BERTimbau (até 256 subpalavras, lotes de inferência de 32). Não inclui o carregamento inicial do modelo, que ocorre uma vez no arranque do serviço, nem o intervalo entre a publicação original e a sua recolha.

O custo por publicação, de cerca de 0,63 segundos, está muito abaixo do limiar de 60 segundos. Com a gravação das classificações no fim do lote, porém, todas as publicações entravam na fila ao mesmo tempo, e a primeira só ficava disponível ao fim de cerca de 125 segundos; o critério só era cumprido para lotes até cerca de 94 publicações. O sistema passou por isso a gravar por sublotes de 32 publicações (Secção 3.8.3), e repetiu-se a medição no mesmo computador e com o mesmo lote (três repetições). As primeiras 32 publicações ficaram disponíveis em 36,1 segundos (mediana), e cada sublote seguinte chegou cerca de 20 segundos depois; o lote completo demorou 139,7 segundos (0,71 s por publicação, um pouco mais porque a aplicação web corria em simultâneo, pelo que as duas medições não decorreram nas mesmas condições; Tabela 4.9, coluna da direita). Com recolhas de até cerca de 64 publicações, todas ficam disponíveis em menos de 60 segundos. A medição cobre o processamento interno, não o intervalo entre a publicação na plataforma e a recolha, que, com recolhas periódicas de 15 minutos ou mais, é a parcela dominante do atraso. A H2 confirma-se, por isso, apenas para recolhas até cerca de 64 publicações.

4.8.2 Antecedência de detecção (H3)

A H3 exige um corpus datado, dividido cronologicamente, e eventos de referência independentes do corpus; sem eles, qualquer medida de antecedência seria circular. O corpus desta investigação não foi construído em torno de eventos datados, e a H3 fica por testar.

4.8.3 Implicações para o desenho operacional

Os resultados das Secções 4.4 a 4.6 têm, no entanto, consequências directas para o desenho operacional. Com precisão de 0,509 e sensibilidade de 0,596 na Mobilização Hostil, e com desempenho em conteúdo angolano inferior ao global, o sistema só é

defensável como apoio ao analista: uma fila de revisão ordenada pela confiança do modelo, com confirmação humana obrigatória antes de qualquer acção e sem decisões automáticas sobre indivíduos. Neste enquadramento, as métricas operacionais relevantes passam a ser a precisão nos primeiros K itens da fila, o tempo de processamento e a concordância entre analista e sistema, medidas que o protótipo foi concebido para registar (Secção 3.9). A análise da Secção 4.7 antecipa, no conjunto de teste, duas destas medidas: a ordenação concentra as ameaças no início da fila, mas de forma desigual entre categorias, e uma fracção pequena mas não nula das ameaças fica entre os itens que o modelo considera normais.

4.8.4 Verificação funcional do sistema

Os 121 testes automáticos passam todos na versão final do protótipo, numa execução de cerca de 40 segundos; os que envolvem rede usam clientes e sítios simulados localmente, e a Tabela F.2 liga cada requisito aos seus testes. Os testes mostram que o sistema faz o que foi especificado. Se o que foi especificado é útil, só a avaliação com analistas o dirá.

4.9 Discussão e verificação formal das hipóteses

A Tabela 4.10 sintetiza a verificação das quatro hipóteses face aos critérios definidos na Secção 1.3.

Tabela 4.10 – Verificação formal das hipóteses de investigação

Hipótese e critério	Evidência	Decisão
H1. Modelos profundos superam os clássicos (ΔF1 ≥ 5 p.p.; $p < 0{,}05$ com Bonferroni)	BERTimbau: ΔF1 de 14,6 a 17,4 p.p., $p < 10^{-47}$. Bi-LSTM: ΔF1 de 0,2 e 2,8 p.p. (IC incluem 0)	**Parcialmente confirmada**
H2. Processamento de cada publicação em menos de 60 s	0,63 s por publicação em CPU; com sublotes, primeiras publicações na fila em 36 s; todas em menos de 60 s para recolhas até cerca de 64 publicações; não cumprido para lotes maiores	**Confirmada com condições**
H3. Antecedência ≥ 48 h face a eventos	Sem corpus datado nem divisão cronológica	**Não testada**
H4. Degradação ≥ 5 p.p. em conteúdo angolano	ΔF1-macro = 38,6 p.p.; IC sem sobreposição; κ 0,436 contra 0,879	**Confirmada** (com reservas)

Nota. A designação "não testada" significa que os dados disponíveis não permitem confirmar nem rejeitar a hipótese.

H1: parcialmente confirmada. A hipótese previa que ambos os modelos de aprendizagem profunda superassem os clássicos. O BERTimbau cumpre o critério com margem ampla (ΔF1-macro ≥ 14,6 p.p.; p corrigido $< 10^{-47}$). O Bi-LSTM não o cumpre: não se distingue da Floresta Aleatória na semente de referência, fica abaixo

dela nas sementes 43 e 44 (Secção 4.5.1), e a sua vantagem sobre o SVM (2,8 p.p.) fica abaixo do limiar de 5 p.p., com intervalo que inclui o zero. Uma explicação plausível, que o desenho não isola, é o pré-treino: o BERTimbau parte de representações aprendidas num grande corpus de português, ao passo que o Bi-LSTM as aprende apenas com o corpus de treino.

H2: confirmada com condições (Secção 4.8.1), só para recolhas até cerca de 64 publicações e só quanto ao processamento interno. **H3: não testada.**

H4: confirmada, com reservas. A degradação do desempenho em conteúdo angolano é grande (38,6 p.p.), mantém-se quando se exclui a Mobilização Hostil da média (37,3 p.p., IC 95% de 30,6 a 44,7) e é consistente no Kappa. As reservas, discutidas na Secção 4.6, são a dimensão do piloto e as explicações concorrentes que o desenho não separa (língua, plataforma, registo, construto das etiquetas e atalhos de estilo). Se o efeito de estilo se confirmar, corpora de notícias completas não servirão para treinar detectores de desinformação em comentários, e o desempenho nesta categoria terá de ser medido no domínio de aplicação.

Os resultados concordam com a literatura. A vantagem do modelo pré-treinado é o padrão habitual (Souza et al., 2020), e a queda fora do domínio de treino é coerente com a fraca generalização entre conjuntos de dados descrita por Fortuna, Soler-Company e Wanner (2021): em nove corpora em inglês, a transferência variava com o modelo, era pior no discurso de ódio do que em categorias mais amplas, como linguagem tóxica ou ofensiva, e dependia da proporção de vocabulário fora do domínio. A falha na Desinformação é compatível com a aprendizagem de atalhos (Geirhos et al., 2020), e a dificuldade em separar mobilização de protesto confirma que o discurso perigoso depende de um contexto que o texto não contém (Benesch, 2012).

Ficam três resultados. Só o BERTimbau serve como classificador principal. O F1-macro global de cerca de 0,80 foi obtido sobretudo em conteúdo brasileiro; em Angola, a estimativa ronda 0,53. E a Mobilização Hostil, a categoria que mais interessa à segurança, é aquela em que a evidência é mais frágil.

CAPÍTULO 5 – CONCLUSÕES

A pergunta de partida era se a aprendizagem automática consegue apoiar, de forma fiável e juridicamente responsável, a triagem de publicações ameaçadoras nas redes sociais angolanas. A resposta curta é que pode ordenar o trabalho do analista, mas não o substitui nem deve substituí-lo. E mesmo essa utilidade foi medida num teste dominado por conteúdo brasileiro: em conteúdo angolano e com analistas reais, está por demonstrar.

5.1 Síntese dos objectivos

A Tabela 5.1 resume o que se cumpriu de cada objectivo específico.

Tabela 5.1 – Cumprimento dos objectivos específicos

Objectivo	Resultado	Estado
OE1. Corpus angolano anotado	2.637 publicações públicas angolanas anotadas por 3 anotadores; κ de Fleiss 0,718; proveniência registada por lote	Cumprido
OE2. Comparação de algoritmos	BERTimbau F1-macro 0,807 [0,774; 0,838]; superior aos restantes com $p < 10^{-47}$; Bi-LSTM sem vantagem sobre a Floresta Aleatória	Cumprido
OE3. Lacuna de domínio	F1-macro 0,533 no piloto contra 0,919 no corpus público (Δ 38,6 p.p.); duas explicações concorrentes para a queda na Desinformação	Parcialmente cumprido (causas por separar)
OE4. Protótipo do sistema	Aplicação web com fila por analista, revisão cega, amostra de controlo, recolha automática, alertas, mapa, relatório e ficha do modelo; pseudonimização e auditoria; funciona sem Internet; 121 testes; 0,6 a 0,7 s por publicação em CPU; avaliação com analistas por fazer	Parcialmente cumprido
OE5. Quadro ético e legal	Salvaguardas implementadas no sistema (pseudonimização, minimização, conservação, auditoria, revisão humana) e obrigações institucionais propostas (Secção 5.6); parecer jurídico recomendado	Cumprido como proposta; conformidade dependente de parecer jurídico

5.2 Resposta às hipóteses e às perguntas de investigação

A **H1** foi parcialmente confirmada. O BERTimbau superou os modelos clássicos por 14,6 a 17,4 pontos percentuais de F1-macro, com diferenças estatisticamente significativas. Já o Bi-LSTM não se distinguiu da Floresta Aleatória (ΔF1 = 0,2 p.p.) e, repetido o treino com três sementes, nunca a superou, o que é compatível com a ideia de que, neste volume de dados, o factor decisivo é o pré-treino linguístico, embora o desenho não o isole.

A **H2** foi confirmada com condições: 0,6 a 0,7 segundos por publicação sem GPU; no lote medido (198 itens, Intel N100), as primeiras publicações chegaram à fila em 36 segundos, e todas chegam em menos de 60 segundos se cada recolha trouxer até cerca de 64; o intervalo entre a publicação e a recolha não foi medido. A **H3** não foi testada, por falta de um corpus datado em torno de eventos.

A **H4** foi confirmada, com reservas. Em conteúdo angolano, o F1-macro do BERTimbau desce 38,6 pontos percentuais, e a diferença mantém-se quando se exclui a Mobilização Hostil da média. A queda na Desinformação, de 0,99 para 0,24, é compatível com a aprendizagem do estilo das notícias do Fake.br, mas também com a diferença de construto entre as etiquetas do piloto e as do Fake.br; os dados não permitem separar as duas explicações.

As perguntas de investigação têm, assim, as seguintes respostas. À **P1**: o BERTimbau é o melhor dos quatro algoritmos, com vantagem estatisticamente sólida no teste global; a comparação não foi repetida apenas em conteúdo angolano. À **P2**: perdem-se cerca de 39 pontos percentuais de F1-macro, sobretudo na Desinformação e no Discurso de Ódio. À **P3**: sim, para o processamento interno de recolhas pequenas; o intervalo até à recolha não foi medido. À **P4**: com revisão humana obrigatória, sem perfis de pessoas, com alertas apenas por decisão humana e com as obrigações institucionais da Secção 5.6; a conformidade jurídica depende de um parecer ainda por obter.

Quanto à pergunta de partida, em conteúdo angolano o classificador não é fiável como decisor (F1-macro de cerca de 0,53) e só pode apoiar a triagem como ordenador sujeito a revisão humana. A utilidade dessa ordenação para analistas reais e a responsabilidade jurídica do uso estão ainda por demonstrar.

5.3 Contributos

- **Corpus angolano anotado.** Tanto quanto foi possível apurar, é o primeiro corpus de publicações angolanas anotado para estas quatro categorias, com acordo entre anotadores medido e proveniência documentada.
- **Medida da lacuna de domínio.** A dissertação quantifica, com intervalos de confiança, quanto se perde ao aplicar a conteúdo angolano um modelo treinado sobretudo com dados brasileiros, e identifica duas explicações concorrentes, que os dados não permitem separar: a aprendizagem do estilo jornalístico do Fake.br e a diferença de construto entre as etiquetas.
- **Avaliação com controlo estatístico.** Intervalos de confiança, testes emparelhados com correcção para comparações múltiplas, repetição com

várias sementes e selecção de variantes na validação, sem escolha pelo teste. A avaliação vai além da exactidão e mede também a calibração das probabilidades e o esforço de revisão que a ordenação poupa, que são as propriedades de que depende o uso do modelo numa fila de triagem.

- **Arquitectura de triagem responsável.** Um protótipo de código aberto, testado e documentado, que incorpora a protecção de dados desde a concepção e mantém o analista no centro da decisão, adequado aos recursos disponíveis e à soberania sobre os dados. A interface mostra ao analista, na página Sobre o modelo, onde o modelo falha, em vez de lhe apresentar apenas o desempenho global.

5.4 Limitações

Dimensão e composição do corpus angolano. O piloto tem 2.637 publicações, das quais cerca de 86% são comentários do YouTube. A Mobilização Hostil conta com apenas 47 exemplos no teste, o que torna as estimativas desta categoria instáveis (IC 95% do F1 entre 0,42 e 0,66) e sensíveis à semente de treino. Cada modelo foi treinado com apenas três sementes, e o Bi-LSTM varia 3,2 p.p. entre elas.

Validade das etiquetas do piloto. Os anotadores aplicaram, por vezes, critérios mais amplos do que os do guia, e a regra de agregação pela categoria mais grave alarga ainda mais as categorias de ameaça. As etiquetas do piloto não são, por isso, inteiramente equivalentes às dos corpora públicos, o que pode explicar parte da lacuna medida na H4. Parte dos itens do teste angolano foi escolhida pelo investigador, e esses itens têm acordo baixo (κ de 0,42 nos 104 itens do piloto original e de 0,28 nos 180 títulos de notícias); sem eles, nos 289 comentários sorteados, o F1-macro é praticamente o mesmo (0,535).

Predomínio de dados brasileiros. Cerca de 91% do conjunto de teste provém de corpora brasileiros. O desempenho global descreve, por isso, sobretudo conteúdo brasileiro; a estimativa disponível para Angola é a do piloto (F1-macro de cerca de 0,53), baseada em 355 itens. Como a única fonte pública de desinformação são notícias completas, o valor elevado desta categoria não indica capacidade de detectar desinformação em redes sociais.

Variação linguística. Sem marcação de calão ou de línguas nacionais no corpus, não se separa o efeito da variedade linguística do da plataforma e do registo. Textos integralmente em kimbundu, kikongo, umbundu ou tchokwe ficam fora do alcance do sistema.

Avaliação operacional. Mediu-se o tempo de processamento num único computador, com um único lote; a medição não inclui o intervalo entre a publicação e a sua recolha. A utilidade da fila para analistas reais e a capacidade de antecipação não foram medidas. O protótipo funciona e está testado, mas a sua eficácia operacional está por demonstrar.

Probabilidades e ordenação. No subconjunto angolano, a calibração é pior (ECE de 0,160), encontrar 80% das ameaças exige rever 49% da ordenação, e 28,7% das ameaças ficam entre os itens classificados como Normais. A ordenação pela probabilidade de não ser Normal favorece a categoria em que o modelo é mais confiante, o que, no teste, afastou a Mobilização Hostil do topo da fila.

Localização. O mapa usa o lugar mencionado, não o paradeiro de quem escreve, e uma província muito citada em notícias nacionais pode parecer mais ameaçada do que está. No corpus anotado, só 3,6% das publicações mencionam uma província (65 delas Luanda): o mapa e os alertas provinciais cobrem uma fracção pequena do fluxo e exigirão volumes de recolha elevados.

Segurança do protótipo. O sistema segue práticas reconhecidas, mas não teve auditoria independente nem testes de intrusão; em instalação institucional, deve correr com HTTPS e só na rede interna.

Fronteira entre protesto e mobilização hostil. Esta fronteira é ambígua mesmo para anotadores humanos. Nenhum resultado desta dissertação autoriza o uso do sistema para fundamentar acções sobre pessoas sem revisão humana e sem enquadramento jurídico.

5.5 Implicações para a defesa e segurança nacional

Para as estruturas de defesa e segurança, ficam três implicações práticas. A primeira: a automação reduz a leitura, mas não a dispensa. Numa ordenação de todo o conjunto de teste, rever um quarto bastou para encontrar quatro em cada cinco ameaças, mas este valor depende da proporção de ameaças (28,7% no teste) e não se transpõe para um fluxo real, onde essa proporção é muito menor. Só a avaliação com analistas permitirá dimensionar as equipas. A segunda: o sistema dirige a atenção para temas e lugares e não tem vistas por autor, embora o pseudónimo permita, a quem aceda à base de dados, agrupar publicações do mesmo autor; as obrigações institucionais da Secção 5.6 existem para impedir esse uso. A terceira: a capacidade técnica pode ser desenvolvida internamente, com software livre e recursos modestos, desde que se invista em dados angolanos anotados e em pessoas que os produzam e mantenham o sistema.

5.6 Quadro de uso responsável

O OE5 pedia um quadro de uso responsável. As salvaguardas técnicas estão no protótipo, mas um sistema destes só é responsável se a instituição que o usa assumir obrigações que o software não consegue impor. A Tabela 5.2 junta as duas partes, organizadas pelos princípios do Capítulo 2.

Tabela 5.2 – Quadro de uso responsável: salvaguardas do sistema e obrigações institucionais

Princípio	Salvaguarda no sistema	Obrigação da instituição
Finalidade e necessidade	Recolha apenas de fontes registadas e públicas; registo da proveniência de cada lote	Definir por escrito a finalidade, os temas e as fontes autorizadas; rever a lista periodicamente
Proporcionalidade e minimização	Pseudonimização à entrada; sem vistas por autor; localização apenas ao nível da província; prazo de conservação	Não cruzar os dados com outras bases para identificar autores sem autorização judicial
Decisão humana	Classificação apenas para ordenar; decisões e alertas só por analistas; revisão cega e amostra de controlo	Proibir qualquer acção sobre pessoas fundamentada apenas no sistema; formar os analistas nas limitações do modelo
Transparência	Ficha do modelo com o desempenho em Angola e as limitações; probabilidades visíveis	Publicar a existência do sistema, a sua finalidade e as regras de uso, nos termos que a lei permitir
Responsabilização	Contas individuais; auditoria de todas as acções; fim da sessão ao fechar a janela	Designar um responsável pelo tratamento; auditoria independente anual dos registos
Segurança	Palavras-passe derivadas, bloqueio, recuperação sem serviços externos, funcionamento sem Internet	Servidor próprio em rede interna, HTTPS, cópias de segurança cifradas, testes de intrusão
Melhoria e correcção	Exportação das decisões para novo treino; métricas operacionais	Medir o desempenho em conteúdo angolano em cada versão; retirar o modelo se o desempenho cair

A coluna da direita não é opcional. Sem ela, quem tem acesso ao servidor contorna as salvaguardas do sistema e a revisão humana degenera em formalidade. O parecer jurídico recomendado no Capítulo 6 deve, por isso, incidir tanto sobre o sistema como sobre estas obrigações.

5.7 Considerações finais

Um modelo de linguagem pré-treinado em português supera com folga os métodos clássicos, e esse desempenho não se transfere intacto para o conteúdo angolano. Das duas conclusões, a segunda é a que mais serve, porque diz onde investir: em dados angolanos anotados, em avaliação no domínio real e em sistemas que tratem a classificação como sugestão e não como veredicto. O protótipo foi construído sobre esse princípio e só ficará completo quando for usado por quem o vai operar.

CAPÍTULO 6 – RECOMENDAÇÕES

As recomendações vão por ordem de prioridade; as três primeiras são condições para qualquer uso institucional.

1. Avaliar o sistema com analistas. Aplicar o protocolo da Secção 3.9 a um lote novo, com analistas: precisão nos primeiros K itens, κ analista–sistema e sensibilidade estimada na amostra de controlo, funções que o sistema já tem. Repetir a medição da H2 em equipamento de produção, com recolhas agendadas e pequenas.

2. Obter parecer jurídico. Antes de qualquer integração institucional, obter parecer sobre a recolha de conteúdos públicos à luz da Lei n.º 22/11, da Lei n.º 7/17, dos termos das plataformas e dos limites constitucionais à monitorização de cidadãos.

3. Ampliar o corpus angolano e medir sempre em Angola. Aumentar os exemplos anotados, sobretudo de Mobilização Hostil e de Desinformação em comentários, diversificar as plataformas por vias oficiais, marcar no guia de anotação o calão e as línguas nacionais, para medir o seu efeito, e tornar o desempenho em conteúdo angolano a métrica principal do sistema.

4. Substituir a fonte de desinformação. Usar exemplos de desinformação em publicações curtas, de preferência angolanas, para que o modelo não aprenda o estilo jornalístico em vez do fenómeno.

5. Adaptar o modelo ao domínio. Continuar o pré-treino do BERTimbau com comentários angolanos não anotados, quando houver dezenas de milhares de textos (Gururangan et al., 2020), e compará-lo com o Albertina PT-PT (Rodrigues et al., 2023), mais próximo da norma usada em Angola.

6. Melhorar a fila de revisão. Ordenar cada categoria pela sua probabilidade, ou ponderar a prioridade pela gravidade, para que a Mobilização Hostil não fique atrás das categorias em que o modelo é mais confiante; calibrar as probabilidades por escalamento de temperatura num conjunto de validação angolano; e usar as decisões da amostra de controlo como exemplos prioritários de novo treino (Settles, 2009).

7. Validar a antecipação (H3). Constituir um corpus datado em torno de eventos documentados, com divisão cronológica estrita, verificar se os alertas de tendência os antecedem e acrescentar análise de redes para detectar publicação coordenada.

8. Cooperação e enquadramento normativo. Partilhar recursos com instituições da CPLP e contribuir para um enquadramento nacional do uso de inteligência artificial em segurança, com transparência, auditoria e supervisão humana.

REFERÊNCIAS BIBLIOGRÁFICAS

Amershi, S., Cakmak, M., Knox, W. B., & Kulesza, T. (2014). Power to the people: The role of humans in interactive machine learning. *AI Magazine, 35*(4), 105–120. https://doi.org/10.1609/aimag.v35i4.2513

Benesch, S. (2012). *Dangerous speech: A proposal to prevent group violence*. World Policy Institute.

Boyd, D. M., & Ellison, N. B. (2007). Social network sites: Definition, history, and scholarship. *Journal of Computer-Mediated Communication, 13*(1), 210–230. https://doi.org/10.1111/j.1083-6101.2007.00393.x

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review, 78*(1), 1–3. https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2

Castells, M. (2013). *Redes de indignação e esperança: Movimentos sociais na era da Internet*. Zahar.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research, 16*, 321–357. https://doi.org/10.1613/jair.953

Cintra, E. S. (2025). *Desafios midiáticos digitais contemporâneos: Um estudo da ciência das redes como contribuição ao Ministério da Defesa do Brasil sobre as aplicações do terrorismo peer-to-peer* [Dissertação de mestrado, Escola Superior de Guerra].

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement, 20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., & Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 8440–8451). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.acl-main.747

Conselho da Europa. (2022). *Recomendação CM/Rec(2022)16 do Comité de Ministros aos Estados-membros sobre o combate ao discurso de ódio*. Conselho da Europa.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning, 20*(3), 273–297. https://doi.org/10.1007/BF00994018

Davidson, T., Warmsley, D., Macy, M., & Weber, I. (2017). Automated hate speech detection and the problem of offensive language. In *Proceedings of the Eleventh International AAAI Conference on Web and Social Media* (pp. 512–515). AAAI Press.

Defense Advanced Research Projects Agency. (2016). *Media forensics (MediFor)*. U.S. Department of Defense. https://www.darpa.mil/research/programs/media-forensics

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). *BERT: Pre-training of deep bidirectional transformers for language understanding* (arXiv:1810.04805). arXiv. https://arxiv.org/abs/1810.04805

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation, 10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Elias, L. (2019). O terrorismo transnacional contemporâneo: Segurança, justiça e cooperação. *Nação e Defesa, 152*, 78–112.

EU DisinfoLab. (2020). *Indian chronicles: Deep dive into a 15-year operation targeting the EU and UN to serve Indian interests*. https://www.disinfo.eu/publications/indian-chronicles-deep-dive-into-a-15-year-operation-targeting-the-eu-and-un-to-serve-indian-interests/

Fleiss, J. L. (1971). Measuring nominal scale agreement among many raters. *Psychological Bulletin, 76*(5), 378–382. https://doi.org/10.1037/h0031619

Fortuna, P., & Nunes, S. (2018). A survey on automatic detection of hate speech in text. *ACM Computing Surveys, 51*(4), Artigo 85. https://doi.org/10.1145/3232676

Fortuna, P., Soler-Company, J., & Wanner, L. (2021). How well do hate speech, toxicity, abusive and offensive language classification models generalize across datasets? *Information Processing & Management, 58*(3), Artigo 102524. https://doi.org/10.1016/j.ipm.2021.102524

Freire, C. P. (2015). *Método de monitoramento de redes sociais: Epistemologia, técnicas e propostas de mineração de banco de dados para conteúdos gerados por fãs de telenovela em redes sociais* [Tese de doutoramento, Universidade de São Paulo].

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence, 2*(11), 665–673. https://doi.org/10.1038/s42256-020-00257-z

Grassi, P. A., Fenton, J. L., Newton, E. M., Perlner, R. A., Regenscheid, A. R., Burr, W. E., Richer, J. P., Lefkovitz, N. B., Danker, J. M., Choong, Y.-Y., Greene, K. K., & Theofanos, M. F. (2017). *Digital identity guidelines: Authentication and lifecycle management* (NIST Special Publication 800-63B). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.SP.800-63b

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning* (pp. 1321–1330). PMLR.

Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D., & Smith, N. A. (2020). Don't stop pretraining: Adapt language models to domains and tasks. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 8342–8360). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.acl-main.740

Hassane, A. C. J. (2021). 2022 vais gostar: A onda de manifestações da juventude em Angola – Que lição para juventude moçambicana (2020-2021)? *Revista Relações Internacionais e Diplomacia em Análise, 2*(3), 28–40.

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

INTERPOL. (2023). *African cyberthreat assessment report 2023: Cyberthreat trends*. INTERPOL Africa Cybercrime Operations Desk.

Ireton, C., & Posetti, J. (Eds.). (2018). *Journalism, "fake news" & disinformation: Handbook for journalism education and training*. UNESCO.

Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. In C. Nédellec & C. Rouveirol (Eds.), *Machine Learning: ECML-98* (pp. 137–142). Springer. https://doi.org/10.1007/BFb0026683

Kemp, S. (2025). *Digital 2026: Angola*. DataReportal. https://datareportal.com/reports/digital-2026-angola

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics, 33*(1), 159–174. https://doi.org/10.2307/2529310

Leite, J. A., Silva, D., Bontcheva, K., & Scarton, C. (2020). Toxic language detection in social media for Brazilian Portuguese: New dataset and multilingual analysis. In *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing* (pp. 914–924). Association for Computational Linguistics.

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

Marcon, F. (2019). Agências estetizadas: Juventudes, mobilizações e ativismos em Angola. *Crítica e Sociedade, 9*(2), 191–208. https://doi.org/10.14393/RCS-v9n2-2019-56679

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika, 12*(2), 153–157. https://doi.org/10.1007/BF02295996

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. In *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

Monaco, N., & Arnaudo, D. (2020). *Análise de dados para o monitoramento de redes sociais*. National Democratic Institute.

Monteiro, R. A., Santos, R. L. S., Pardo, T. A. S., de Almeida, T. A., Ruiz, E. E. S., & Vale, O. A. (2018). Contributions to the study of fake news in Portuguese: New corpus and automatic detection results. In *Computational Processing of the Portuguese Language: PROPOR 2018* (pp. 324–334). Springer. https://doi.org/10.1007/978-3-319-99722-3_33

Naeini, M. P., Cooper, G. F., & Hauskrecht, M. (2015). Obtaining well calibrated probabilities using Bayesian binning. In *Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence* (pp. 2901–2907). AAAI Press.

Niculescu-Mizil, A., & Caruana, R. (2005). Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning* (pp. 625–632). ACM. https://doi.org/10.1145/1102351.1102430

Omand, D., Bartlett, J., & Miller, C. (2012). Introducing social media intelligence (SOCMINT). *Intelligence and National Security, 27*(6), 801–823. https://doi.org/10.1080/02684527.2012.716965

OWASP Foundation. (2021). *OWASP Top 10: 2021*. https://owasp.org/Top10/

Palantir Technologies. (2024). *Palantir Platform: Gotham – Service definition document* (G-Cloud 14). Digital Marketplace, UK Government. https://www.applytosupply.digitalmarketplace.service.gov.uk/g-cloud-14/services/801146272055049

Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors, 52*(3), 381–410. https://doi.org/10.1177/0018720810376055

Poletto, F., Basile, V., Sanguinetti, M., Bosco, C., & Patti, V. (2021). Resources and benchmark corpora for hate speech detection: A systematic review. *Language Resources and Evaluation, 55*(2), 477–523. https://doi.org/10.1007/s10579-020-09502-8

República de Angola. (2010). *Constituição da República de Angola*. Assembleia Nacional.

República de Angola. (2011). Lei n.º 22/11, de 17 de Junho: Lei da Protecção de Dados Pessoais. *Diário da República*, I Série, n.º 114.

República de Angola. (2017). Lei n.º 7/17, de 16 de Fevereiro: Lei de Protecção das Redes e Sistemas Informáticos. *Diário da República*, I Série.

Rodrigues, J., Gomes, L., Silva, J., Branco, A., Santos, R., Lopes Cardoso, H., & Osório, T. (2023). Advancing neural encoding of Portuguese with Transformer Albertina PT-*. In *Progress in Artificial Intelligence: EPIA 2023* (pp. 441–453). Springer. https://doi.org/10.1007/978-3-031-49008-8_35

Runfola, D., Anderson, A., Baier, H., Crittenden, M., Dowker, E., Fuhrig, S., Goodman, S., Grimsley, G., Layko, R., Melville, G., Mulder, M., Oberman, R., Panganiban, J., Peck, A., Seitz, L., Shea, S., Slevin, H., Youngerman, R., & Hobbs, L. (2020). geoBoundaries: A global database of political administrative boundaries. *PLoS ONE, 15*(4), e0231866. https://doi.org/10.1371/journal.pone.0231866

Sambaca, S. C., & Pessoa, S. N. (2026). Eleições em Angola: A influência das redes sociais no comportamento eleitoral dos jovens angolanos em 2022. *Revista Tópicos, 4*(29). https://doi.org/10.5281/zenodo.18363947

Sap, M., Card, D., Gabriel, S., Choi, Y., & Smith, N. A. (2019). The risk of racial bias in hate speech detection. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics* (pp. 1668–1678). Association for Computational Linguistics. https://doi.org/10.18653/v1/P19-1163

Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. *IEEE Transactions on Signal Processing, 45*(11), 2673–2681. https://doi.org/10.1109/78.650093

Sette Câmara, T. (2016). Terrorismo na era da Internet: O uso de redes sociais pelo Estado Islâmico. *Revista Relações Internacionais no Mundo Atual, 1*(21), 196–221.

Settles, B. (2009). *Active learning literature survey* (Computer Sciences Technical Report 1648). University of Wisconsin–Madison.

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management, 45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

Souza, F., Nogueira, R., & Lotufo, R. (2020). BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Intelligent Systems: BRACIS 2020* (pp. 403–417). Springer. https://doi.org/10.1007/978-3-030-61377-8_28

Thelwall, M. (2009). Social network sites: Users and uses. *Advances in Computers, 76*, 19–73. https://doi.org/10.1016/S0065-2458(09)01002-X

UNESCO. (2021). *Recommendation on the ethics of artificial intelligence*. UNESCO.

União Europeia. (2024). Regulamento (UE) 2024/1689 do Parlamento Europeu e do Conselho, de 13 de junho de 2024, que cria regras harmonizadas em matéria de inteligência artificial. *Jornal Oficial da União Europeia*, Série L.

Vargas, F., Carvalho, I., Rodrigues de Góes, F., Pardo, T., & Benevenuto, F. (2022). HateBR: A large expert annotated corpus of Brazilian Instagram comments for offensive language and hate speech detection. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference* (pp. 7174–7183). European Language Resources Association.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems 30* (pp. 5998–6008). Curran Associates.

Wardle, C., & Derakhshan, H. (2017). *Information disorder: Toward an interdisciplinary framework for research and policy making* (Relatório DGI(2017)09). Conselho da Europa.

Williams, H. J., & Blum, I. (2018). *Defining second generation open source intelligence (OSINT) for the defense enterprise* (RR-1964-OSD). RAND Corporation. https://doi.org/10.7249/RR1964

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953

Woolley, S. C., & Howard, P. N. (2017). *Computational propaganda worldwide: Executive summary* (Working Paper 2017.11). Oxford Internet Institute.

GLOSSÁRIO

Ajuste fino. Treino adicional de um modelo pré-treinado numa tarefa específica, com dados anotados dessa tarefa.

Aprendizagem de atalhos. Fenómeno em que o modelo aprende uma regularidade acidental dos dados de treino (por exemplo, o estilo de uma fonte) em vez da propriedade que se pretende detectar.

Bootstrap. Método de reamostragem com reposição usado para estimar a variabilidade de uma estatística e construir intervalos de confiança.

Calibração. Propriedade de um classificador cujas probabilidades correspondem às frequências observadas: entre as previsões feitas com 80% de confiança, cerca de 80% estão certas.

F1 ponderado. Média dos F1 das categorias ponderada pelo número de exemplos de cada uma; é dominado pelas categorias frequentes.

F1-macro. Média simples dos F1 das categorias; dá a mesma importância a todas, independentemente da sua frequência.

Kappa de Cohen. Medida de acordo entre dois avaliadores corrigida pelo acordo esperado ao acaso.

Kappa de Fleiss. Generalização do Kappa para três ou mais avaliadores.

Lacuna de domínio. Diferença de desempenho de um modelo entre os dados semelhantes aos de treino e dados de outro domínio (plataforma, região, variedade linguística ou género textual).

Precisão. Fracção das previsões de uma categoria que estão correctas.

Precisão nos primeiros K. Fracção de ameaças, segundo a referência disponível (etiquetas de teste ou decisão do analista), entre os K primeiros itens da fila de revisão.

Pseudonimização. Substituição de identificadores pessoais por códigos que não permitem identificar a pessoa sem informação adicional guardada separadamente.

Sensibilidade. Fracção dos exemplos de uma categoria que o modelo identifica (em inglês, *recall*).

Subpalavra. Fragmento de palavra usado pelo tokenizador dos modelos BERT; palavras fora do vocabulário são divididas em subpalavras conhecidas.

Teste de McNemar. Teste estatístico para comparar dois classificadores no mesmo conjunto de teste, com base nos casos em que apenas um deles acerta.

Transformer. Arquitectura de rede neuronal baseada em mecanismos de atenção, que processa toda a sequência em paralelo (Vaswani et al., 2017).

APÊNDICE A – EXCERTOS DE CÓDIGO-FONTE

Excertos reproduzidos sem alterações do código do protótipo; o código completo está em https://github.com/manuelmuinga/dissertacao-uan-angola.

A.1 Anonimização à entrada (sistema/anonimizacao.py)

No comentário do código, “irreversível” significa irreversível sem o segredo; em termos jurídicos, trata-se de pseudonimização (Secção 3.2).

```
_PADROES: list[tuple[re.Pattern[str], str]] = [
    (re.compile(r"https?://\S+|www\.\S+", re.IGNORECASE), "[URL]"),
    (re.compile(r"\b[\w.+-]+@[\w-]+\.[\w.-]+\b"), "[EMAIL]"),
    # Telefones: +244 9xx xxx xxx, 9xxxxxxxx e variantes com espaços/hífenes.
    (re.compile(r"(?<!\w)(?:\+?244[\s-]?)?9\d{2}[\s-]?\d{3}[\s-]?\d{3}(?!\w)"),
"[TELEFONE]"),
    (re.compile(r"(?<!\w)@[\w.]{2,}"), "@[UTILIZADOR]"),
]


def mascarar_texto(texto: str) -> str:
    """Substitui identificadores directos no texto por marcadores."""
    if not texto:
        return ""
    for padrao, marcador in _PADROES:
        texto = padrao.sub(marcador, texto)
    return re.sub(r"\s+", " ", texto).strip()


def pseudonimo_autor(autor: str | None, segredo: str) -> str | None:
    """Pseudónimo irreversível do autor (HMAC-SHA-256, 16 hex)."""
    if not autor:
        return None
    if not segredo:
        raise ValueError(
            "Defina UAN_SEGREDO_HASH: sem segredo, o hash de um nome de utilizador "
            "pode ser revertido por dicionário."
        )
    digest = hmac.new(segredo.encode("utf-8"), autor.strip().lower().encode("utf-8"),
hashlib.sha256)
    return digest.hexdigest()[:16]
```

A.2 Classificação em lote com o BERTimbau (sistema/classificador.py)

```
    def classificar(self, textos: list[str]) -> list[Resultado]:
        torch = self._torch
        resultados: list[Resultado] = []
        for i in range(0, len(textos), self.tamanho_lote):
            lote = textos[i : i + self.tamanho_lote]
            enc = self.tokenizer(lote, truncation=True, max_length=self.max_length,
padding=True, return_tensors="pt")
            enc = {k: v.to(self.dispositivo) for k, v in enc.items()}
            with torch.no_grad():
                probs = torch.softmax(self.modelo(**enc).logits, dim=-1).cpu().tolist()
            resultados.extend(Resultado(dict(zip(self.rotulos, map(float, p)))) for p in
probs)
        return resultados
```

APÊNDICE B – GUIA DE ANOTAÇÃO PADRONIZADO

Este guia orientou os três anotadores na classificação dos comentários do corpus angolano. Todos o receberam antes de começar e comprometeram-se a segui-lo de forma independente, sem comunicar entre si durante a anotação.

B.1 Identificação do projecto

Campo	Informação
Título da investigação	Monitoramento inteligente de ameaças em redes sociais em Angola para o apoio à defesa e segurança nacional
Investigador principal	Manuel Gonga Muinga
Instituição	Universidade Agostinho Neto, Faculdade de Engenharia
Período de anotação	Junho a Outubro de 2026

B.2 Objectivo da anotação

Atribuir a cada comentário uma, e só uma, das quatro categorias definidas abaixo. As anotações constituem a referência para treinar e avaliar os modelos, pelo que a sua consistência determina a validade dos resultados.

B.3 Categorias

B.3.1 Normal (rótulo Normal)

Comentários que não representam ameaça à segurança, à ordem pública ou aos direitos fundamentais. Inclui notícias factuais, entretenimento, crítica política legítima, humor e conversa quotidiana. Exemplos: “O Governo anunciou hoje a inauguração da nova estrada em Benguela”; “As políticas económicas precisam de ser revistas urgentemente” (crítica sem incitação).

B.3.2 Desinformação (rótulo Desinformacao)

Informação falsa, enganosa ou deliberadamente distorcida, com potencial para causar dano público, manipular a opinião ou criar pânico. Inclui notícias fabricadas, vídeos fora de contexto ou manipulados e declarações falsamente atribuídas a figuras públicas. Exemplos: “URGENTE: vídeo mostra um governante a confessar desvio de fundos. PARTILHA!” (vídeo manipulado); “Surto de doença mortal em Luanda, as autoridades estão a esconder a verdade” (sem fonte). Se a publicação apresentar factos reais com contexto distorcido para enganar, classifique como Desinformação.

B.3.3 Discurso de ódio (rótulo Odio)

Conteúdo que promove, incita ou justifica discriminação, hostilidade ou violência com base em etnia, religião, origem regional, género ou orientação sexual, de forma explícita ou implícita (estereótipos, desumanização, linguagem codificada). O calão com conteúdo discriminatório entra nesta categoria. A crítica a governos, partidos ou figuras públicas não é discurso de ódio; o critério é a desumanização ou a discriminação por identidade.

B.3.4 Mobilização hostil (rótulo Mobilizacao)

Comentários que organizam, coordenam ou incitam à participação em acções ilegais ou violentas, ou que ameacem a ordem pública. Exemplos: “Amanhã Luanda pára. Quem não aparecer é traidor. Tragam o que foi combinado.” Uma convocatória para manifestação pacífica e legal **não** é Mobilização Hostil e deve ser classificada como Normal.

B.4 Casos limítrofes

Crítica política ou desinformação. Dados incorrectos numa crítica são Normal se o erro parecer involuntário e verificável; são Desinformação se forem apresentados como verdade sem fonte, com marcadores de manipulação (por exemplo, “partilha antes que apaguem”).

Convocatória pacífica ou mobilização hostil. É Normal quando explicita o carácter pacífico e legal da acção; é Mobilização Hostil quando combina coordenação, linguagem coerciva ou de violência e ausência de referência ao carácter pacífico e legal.

Ódio implícito ou observação. É Discurso de Ódio quando atribui características negativas a um grupo pela sua identidade e usa linguagem de exclusão, mesmo que formulada como “facto”.

B.5 Regras de desempate e preenchimento

Se a publicação tiver elementos de mais de uma categoria, escolha a mais grave: Mobilização Hostil > Discurso de Ódio > Desinformação > Normal. Em comentários com calão ou expressões de línguas nacionais, aplique os mesmos critérios; em caso de dúvida sobre o significado, registe-a na coluna de observações. Ironia e sátira sem intenção de dano são Normal; ironia que mascara conteúdo nocivo segue a categoria correspondente. Ler cada comentário na íntegra antes de classificar e não consultar os outros anotadores durante a fase individual.

APÊNDICE C – ACORDO ENTRE ANOTADORES

Este apêndice documenta o cálculo do acordo entre os três anotadores do corpus angolano.

C.1 Escala de interpretação

A Tabela C.1 apresenta a escala de Landis e Koch (1977) usada para interpretar os valores de κ.

Tabela C.1 – Escala de interpretação do Kappa (Landis & Koch, 1977)

Valor de κ	Grau de acordo
< 0,00	Pobre
0,00–0,20	Ligeiro
0,21–0,40	Razoável
0,41–0,60	Moderado
0,61–0,80	Substancial
0,81–1,00	Quase perfeito

C.2 Fórmulas

O Kappa de Cohen, para um par de anotadores, é κ = (Po − Pe) / (1 − Pe), onde Po é a proporção de acordo observado e Pe a proporção de acordo esperada ao acaso, calculada a partir das distribuições marginais de cada anotador (Cohen, 1960). O Kappa de Fleiss generaliza esta medida para três ou mais anotadores, calculando Po como a média, por item, da proporção de pares de anotadores em acordo e Pe a partir da distribuição global das categorias (Fleiss, 1971).

C.3 Resultados

A Tabela C.2 resume o acordo entre os três anotadores na base do piloto e no lote temático.

Tabela C.2 – Acordo entre os três anotadores

Subconjunto	Medida	Valor
Base do piloto e lote de léxico	κ de Fleiss [IC 95%]	0,718 [0,695; 0,741]
Base do piloto e lote de léxico	κ de Cohen médio (3 pares)	0,719
Base do piloto e lote de léxico	Concordância observada	81,3%
Lote temático de vídeos (284 itens)	κ de Fleiss [IC 95%]	0,818 [0,763; 0,869]

Nota. O κ do lote temático, calculado antes da exclusão dos 90 comentários não angolanos, não é comparável com o da base do piloto, por resultar de uma selecção não aleatória com distribuição de categorias diferente.

A Tabela C.3 detalha o acordo na base do piloto e no lote orientado por léxico (2.443 itens com etiqueta dos três anotadores), por par de anotadores e por categoria. Os anotadores são identificados por letras. O par menos concordante fica em 0,684 e o mais concordante em 0,772, todos no intervalo substancial. Por categoria, a Desinformação é a que reúne menos acordo (0,625), o que é coerente com a dificuldade de a distinguir da crítica política sem verificar os factos alegados.

Tabela C.3 – Acordo por par de anotadores e por categoria (base do piloto e lote de léxico, n = 2.443)

Desagregação	Medida	Valor
Par A–B	κ de Cohen	0,700
Par A–C	κ de Cohen	0,684
Par B–C	κ de Cohen	0,772
Média dos pares [IC 95%]	κ de Cohen	0,719 [0,696; 0,741]
Normal	κ de Fleiss	0,738
Desinformação	κ de Fleiss	0,625
Discurso de Ódio	κ de Fleiss	0,753
Mobilização Hostil	κ de Fleiss	0,731
Base do piloto, sem lotes enriquecidos (n = 2.352)	κ de Fleiss	0,717
Lote enriquecido por léxico (n = 91)	κ de Fleiss	0,697

Nota. O κ de Fleiss por categoria trata cada categoria contra as restantes. Valores calculados pelo *script* compute_pilot_kappa.py (ficheiro kappa_piloto.json).

C.4 Distribuição das etiquetas finais

A Tabela C.4 apresenta a distribuição das etiquetas finais do corpus angolano.

Tabela C.4 – Distribuição das etiquetas finais do corpus angolano

Categoria	Publicações	Percentagem
Normal	1.664	63,1%
Mobilização Hostil	364	13,8%
Desinformação	326	12,4%
Discurso de Ódio	283	10,7%
Total	**2.637**	**100%**

Nota. Inclui a base do piloto e os dois lotes enriquecidos, antes da deduplicação feita na harmonização do corpus.

APÊNDICE D – DECLARAÇÃO DE CONSENTIMENTO E CONFIDENCIALIDADE DOS ANOTADORES

Esta declaração foi assinada por cada anotador antes do início da anotação.

Eu, abaixo assinado(a), declaro que:

- Fui informado(a) sobre os objectivos, a metodologia e a finalidade da investigação "Monitoramento inteligente de ameaças em redes sociais em Angola para o apoio à defesa e segurança nacional", conduzida por Manuel Gonga Muinga na Universidade Agostinho Neto.
- Participo voluntariamente como anotador(a), sem remuneração, e posso retirar o meu consentimento a qualquer momento sem penalização.
- A minha função consiste em classificar comentários de redes sociais em quatro categorias, seguindo o Guia de Anotação (Apêndice B), de forma independente.
- Comprometo-me a manter a confidencialidade do conteúdo analisado e a não o usar para outro fim.
- Não tenho conflitos de interesses com o investigador nem com os temas analisados.
- Autorizo o uso das minhas anotações para fins exclusivamente académicos e científicos, sem identificação nominal nos resultados publicados.
- Fui informado(a) de que os meus dados pessoais (nome e assinatura) serão tratados de forma confidencial, nos termos da Lei n.º 22/11, de 17 de Junho.

Luanda, ____ de _____ de 2026

Nome do(a) anotador(a): _____

Assinatura: _____

Investigador principal: Manuel Gonga Muinga _____

APÊNDICE E – AMOSTRA ANOTADA DO CORPUS

Este apêndice apresenta 20 comentários reais do corpus angolano, com as anotações individuais e a etiqueta final. A amostra foi extraída do ficheiro corpus_ground_truth_com_texto_v13.csv por sorteio com semente fixa (42), cinco comentários por categoria, entre os comentários de YouTube sorteados da base do piloto cuja etiqueta final coincide com a maioria dos anotadores. Ficaram de fora as publicações de imprensa e de organizações e os lotes enriquecidos. Os textos mantêm a grafia original. Os nomes de pessoas foram substituídos por descritores entre parênteses rectos, e os comentários longos foram reduzidos ao trecho relevante, assinalado com (…). Os emojis aparecem descritos entre parênteses rectos.

A Tabela E.1 apresenta a amostra.

Tabela E.1 – Amostra de comentários anotados

N.º	Excerto (anonimizado)	A	B	C	Final	Unânime
1	Mesmo no Brasil [emoji: bandeira do Brasil] creio que são piores	N	N	N	N	Sim
2	Minha Angola [emoji: rosto pensativo ×2]	N	N	N	N	Sim
3	Meu Deus do céu como pode uma pessoa se aproveitar da pobreza dos outros	N	N	N	N	Sim
4	Máximo respeito Gangster.	N	N	N	N	Sim
5	Axo muito bem força mano deus esta com nosco, nao tenha medo	N	N	N	N	Sim
6	E [pessoa referida]? Laranjas e chocolates, e uma mansão de 6 milhões comprada em plena pandemia.	D	D	D	D	Sim
7	Só Deus para nós livrar das garras desses senhores que se intitulam donos de Angola e de todos os recursos que existe neste País. Verdade bem dita.	D	D	N	D	Não
8	(…) isso cá no meu país é proibido passar em órgãos públicos! Eu garanto que o Mplá é a máfia mais perigosa do mundo (…)	N	D	D	D	Não
9	[político brasileiro] deu palestra e ganhou meio milhão. Seu sobrinho faturou legal tb.	D	D	D	D	Sim
10	Essa reportagem é encomendada por [líder religioso] e a Universal. A Universal está nesse momento sendo expulsa de Angola, por conta de crimes cometidos e por conta (…)	D	D	N	D	Não
11	GOVERNO DE ESQUERDA É MARAVILHOSO QUE O DIGA O DIGA O POVO VENEZUELANO E NORTE COREANO!!!!![emoji: a rolar de rir ×12]	O	O	O	O	Sim
12	[emoji: rosto a chorar ×5]	O	O	N	O	Não

N.º	Excerto (anonimizado)	A	B	C	Final	Unânime
13	(…) o povo angolano anda muito atrasado pois mesmo se apercebendo duq tem acontecido ñ faz nada contra a causa' apenas obcerva a sua própria destruição por parte dos dirigentes pa p#t@ do país. (…)	O	O	O	O	Sim
14	Nada justifica o que??? É medo que você tem de apoiar o povo. Tem sim uma justificativa [emoji: coração partido] deixa disso homem do MPLA	N	O	O	O	Não
15	Mano essa currupcao será difícil acaba cm MPLA n poder	O	O	D	O	Não
16	Força vamos libertar o país	M	M	M	M	Sim
17	O povo no puder. Viva povo de Angola. [emoji: lágrimas de riso ×3]	M	M	M	M	Sim
18	Os fins justificam os meios... Estou orgulhoso de vocês [emoji: sinal de OK]	M	M	D	M	Não
19	Está faltar chegarmos até aos condomínios [emoji: sinal de OK] eles moram lá [emoji: dedo para cima, rosto pensativo, sorriso de lado, olhos a revirar]	M	M	M	M	Sim
20	O POVO É QUE SE UNEM E VÃO NO PALÁCIO..E NÃO CULPO ESTE POVO SOFREDOR E ABANDONADO [emoji: rosto a chorar]	M	M	M	M	Sim

Nota. N = Normal; D = Desinformação; O = Discurso de Ódio; M = Mobilização Hostil. A amostra não foi escolhida para ilustrar casos claros, e mostra também o ruído da anotação e o uso, por vezes, de critérios mais amplos do que os do guia (Secção 3.4): o comentário 12, composto apenas por emojis, recebeu a etiqueta Discurso de Ódio de dois anotadores, e o 11 é sarcasmo político, de fronteira discutível com a categoria Normal. Casos como estes ajudam a explicar o κ substancial, mas não quase perfeito, do Apêndice C.

APÊNDICE F – MANUAL DE INSTALAÇÃO E UTILIZAÇÃO DO SISTEMA

O sistema está na pasta sistema_uan do repositório do projecto. Os comandos destinam-se à linha de comandos do Windows (cmd), na pasta do sistema. O README do sistema descreve todas as opções.

F.1 Instalação e configuração

```
python -m pip install -r requirements.txt
python -m pytest -q
python -c "import secrets; print(secrets.token_urlsafe(32))"
python uan.py verificar-config
```

A configuração fica no ficheiro uan.env, criado a partir de uan.env.exemplo e nunca guardado no repositório. As variáveis essenciais são UAN_MODELO (pasta do modelo; vazio activa um classificador de demonstração), UAN_SEGREDO_HASH (segredo dos pseudónimos, gerado ao acaso com o terceiro comando e nunca mudado depois da primeira recolha), UAN_YOUTUBE_CHAVE (chave da YouTube Data API v3) e, para os alertas por e-mail, UAN_SMTP_SERVIDOR e UAN_SMTP_REMETENTE. O comando verificar-config mostra que ficheiro é lido e que variáveis estão definidas, sem os valores.

F.2 Arranque e utilização

```
python uan.py servir
python uan.py servir --demonstracao
```

O sistema abre em http://127.0.0.1:8000. Na primeira utilização pede a conta do supervisor, que cria as dos analistas em Utilizadores. O modo de demonstração usa a base dados\demonstracao.db, com dados fictícios e as contas demo.supervisor, demo.analista e demo.revisor (palavra-passe demonstracao); o supervisor pode trocar de modo com o sistema aberto. Na fila, as teclas 1 a 4 decidem, J e K mudam de item, U desfaz, D abre o detalhe e ? mostra todos os atalhos; Ctrl+K abre a procura de páginas e acções. Em Fontes e recolha, o supervisor cola um ou vários endereços (vídeo, canal, lista ou pesquisa do YouTube, feed, página ou sítio), recolhe a pedido e escolhe a frequência da recolha automática. Cada utilizador gera em A minha conta o seu código de recuperação; quem se esquece da palavra-passe usa a ligação “Esqueceu-se da palavra-passe?” na entrada.

F.3 Linha de comandos

A Tabela F.1 resume os comandos do sistema.

Tabela F.1 – Comandos do sistema

Comando	Função
python uan.py servir [--demonstracao]	Arranca a aplicação web
python uan.py criar-utilizador ana --nome "Ana" --papel analista	Cria uma conta
python uan.py repor-senha utilizador [--temporaria]	Repõe a palavra-passe e desbloqueia a conta
python uan.py importar ficheiro.csv --plataforma YouTube --via api_oficial	Importa e anonimiza um lote
python uan.py fonte-adicionar --endereco URL "termos"	Regista fontes; o tipo é detectado
python uan.py recolher	Recolhe as fontes activas e classifica
python uan.py alertas	Verifica tendências e envia os alertas
python uan.py relatorio --dias 30 --email	Relatório de alertas do período
python uan.py metricas / exportar revisoes.csv	Métricas operacionais; revisões para novo treino
python uan.py limpar --dias 180 / copia	Prazo de conservação; cópia de segurança
python uan.py medir-latencia ficheiro.csv	Mede o tempo de processamento (H2)

Nota. O modelo treinado no Google Colab deve ser guardado no formato da biblioteca Transformers, com o ficheiro colab_guardar_modelo.py, e acompanhado do ficheiro ficha_modelo.json, que a página Sobre o modelo apresenta.

F.4 Verificação dos requisitos

A Tabela F.2 liga cada requisito da Tabela 3.3 aos testes automáticos que o verificam; cada teste conta no requisito principal, e o do fluxo completo cobre também RF2 a RF6. Os 121 testes passam na versão final.

Tabela F.2 – Requisitos e testes automáticos

Req.	Testes	O que verificam (exemplos)
RF1	30	Detecção do tipo de fonte; robots.txt; páginas com conta excluídas; YouTube e RSS
RF2–RF3	4	Importação com proveniência; máscaras; pseudónimo dependente do segredo
RF4	5	Migração de bases antigas; prazo de conservação; cópia de segurança
RF5	7	Carregamento do modelo; gravação por sublotes; API protegida por chave
RF6	5	Prioridade 1 − P(Normal); decisão e anulação na fila
RF7–RF8	2	Fluxo completo (importar, classificar, rever, métricas, exportar); κ
RF9	11	Palavras-passe, bloqueio, papéis, CSRF, fim da sessão
RF10	6	Revisão cega; amostra de controlo reprodutível; dois analistas
RF11	10	Alertas só de decisões humanas; tendência normalizada; e-mail sem texto nem autor
RF12	11	18 províncias; topónimos ambíguos; taxa com mínimo de casos; séries
RF13–RF14	3	Relatório com tendências; fluxo alerta–mapa–relatório; Sobre o modelo
RF15	4	Modo de demonstração; dados fictícios reprodutíveis; troca de modo
RF16	6	Recolha periódica; fontes inactivas; quota; chave nunca exposta
RF17	10	Código de uso único; pedido ao supervisor; reposição local
Outros	7	Configuração sem segredos à vista; aspecto; visita guiada